

ARCHON AGENTIC OS 2026 — LISTA COMPLETA DE FUNCIONES

Catálogo de sistema y módulos, resumen de arquitectura y matriz de funciones

Estuvo: 11 de noviembre de 2026 | Versión: v 0. 5.1 («Archon Hardened») | Sprache: Deutsch

Catálogo de sistema y módulos, resumen de arquitectura y matriz de funciones

© Michael Keller

Índice

1. Estado de versión y resumen de release (v0.5.1) 3
2. Vistas del sistema y estudios especiales (UI Views) 3
3. Ecosistema FinOps y de ahorro de tokens (minimización de costes) 8
4. Núcleo, planificación y arquitectura de demonios (pilar 1) 11
5. Multi-Agenten-Prozessmodell, Jerarquía& Synthese (Pillar 2) 12
6. MCP- Treiber, Externo Servicios& Multimodale Herramienta (Pillar 3) 14
7. Gedächtnis, Datenbank-Hygiene& Obsidian 2 nd Brain (Pillar 4) 15
8. Seguridad, Zero-Trust Governance& System-Diagnose (Pillar 6) 17
9. Selbst-Evolution, Marktplätze& Auto-Dokumentation (Pillar 7) 18
10. Matriz de referencia: plugins Evey/Hermes controlables 19
11. Arquitectura empresarial y de resiliencia 21
12. Arquitectura de autonomía, sandbox y gobernanza 22
13. Núcleo de rendimiento, escalado de throughput y eficiencia de tokens 24
14. Arquitectura moderna de memoria y RAG 25
15. Fiable Ausführung& Determinismus (Durable Execution) 27
16. Seguridad, privacidad y guardarraíles empresariales 28
17. Autooptimización, evaluación e inteligencia de enjambre 29
18. Pilar 3: economía y ERP (alfa) y suite de mandantes 30
19. Arquitectura-, Security-& Deployment-Features (v 0. 5.0- v 0. 5.1) 31
20. Glosario alfabético e índice de términos 32

© Michael Keller

1. Estado de versión y resumen de release (v0.5.1)

Versión	Nombre en clave	Hitos esenciales de arquitectura y funciones
v0.5.1	Archon Hardened	Modulare FastAPI- Router (main.py- 88%), 25 crítico + 68 alta Security-Befunde resuelto, Docker- Admin-Proxy Clase A, RBAC- Benutzerverwaltung (PBKDF2), 2- Fases Sistema actualización (? local_only = true), AnythingLLM Proxy-Integration, portabler 1- Click-Installer.
v0.5.0	Economía y ERP (alfa)	Completo Pilar 3 (CRM/PocketBase-Sync, Artikel/Leistungen, Vorgänge ANG/AB, Rechnungswesen con DATEV& GiroCode, Corporate-Mandanten), Research Lab v 2& 55 Boardroom-Frameworks.
v0.3.x	Sentinel / Foundation	7- Pilar OS-Kernel, 70 Spezialisten-Kader, 34 + Evey- Plugin, FinOps 3- Tier-Routing, Ephemeral Code-Sandboxen, Replay Debugging, PII-Scrubber, Semantic Caché& FTS5 Hybrid Search.

2. Vistas del sistema y estudios especiales (UI Views)

1. Vista: Mission Control (cabina de monitorización y puesto de mando)

Problema: Sin central Echtzeit-Cockpit fehlen el Resumen sobre activo Agentes, Token-Durchsatz, Días costar y bloqueado Freigaben.

Mecánica: Bündelt 5 vitale KPI- Kacheln (Flottenlast, Throughput TPM, Kostenwächter, Stabilität, Approval Gate), la 5- Spalten-Board-Projektion, la Active Process Inspection Bar (3- Slot-Footer para Heartbeat, Tool-Concurrency y Context Saturation), el 15- Minuten-Token-Aktivitätsband (SVG-Sparkline) y el Live-Audit-Stream.

Beneficio: *Entrega una verzögerungsfreie 360 °- Überwachung del total Empresa sistema en un einzigen Bildschirm.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

2. Vista: operaciones – tablero Kanban y motor de tareas

Problema: Tareas en reinen Chat-Verläufen gehen bajo y se pueden ni tras Estado aún tras Verantwortlichkeiten dirigir.

Mecánica: 5 Lebenszyklus-Spalten (To-Do, En Bearbeitung, Review& QA, Bloqueado, Cerrado) directo en kanban. db (Single Source of Truth). Apoya konfigurierbare WIP-Limits por Columna, Prioritätsfilter (P0-P3), Agenten-Zuweisung, Zeiterfassung y 1- Klick- Obsidian- Verknüpfung. Integrado el 4- Augen Qualitäts-Gate: Ante Verschieben una Tarea en ' done ' verifica un Peer-Reviewer (Katharina Völk para QM/Compliance o Robert) el Trabajar resultado en Vollständigkeit, Substanz y Handlungsfähigkeit (1-100% Score). En ' changes_requested ' greift una Estado Bloquear; un Human-in-the-Loop Override (force = True) übersteuert si ello necesario.

Beneficio: *Estructurado todos operativen Proyectos transparente e impide Systemüberlastung mediante Work-in-Progress-Schranken.* Impide unfertige Arbeitsstände en el ' done '- Estado mediante zwingendes Vier-Augen-Review.

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

3. Vista: Operations- Interaktives 2 Es decir Organigrama& Berichtslinien

Problema: Flache Listas de Agentes mostrar ninguna Weisungsbefugnisse o Eskalationspfade en bloqueado Proceso.

Mecánica: Visualisiert 56 Knoten y 55 Berichtslinien como interaktiven 2 D-Graphen (Apex- > CEO Robert- > Fach-Leads- > Especialista). Apoya Drag& Drop al Umhängen de Vorgesetzten, Raster-Ausrichtung, Team-

Karten-Ansicht y permanente Speicherung en config/org_hierarchy.json.

Beneficio: *Definido vinculante Eskalations- y Delegationsketten, denen el Sistema en Blockaden automático folgt.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

4. Vista: Operations- Interno Agenten-Kommunikation (Funkverkehr)

Problema: Wenn Especialista untereinander Teilaufgaben entregado, überflutet dies o bien el Nutzer-Chat o permanece unsichtbar.

Mecánica: Dedizierte Abhörzentrale con Canal lista (# general, # tech-dev, # legal, # marketing) y chronologischem Nachrichten-Feed aller Inter-Agenten-Absprachen de kanban. db.

Beneficio: *Macht la Zusammenarbeit el Agenten-Flotte trazable, sin el primäre Nutzer-Postfach cargar.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

5. Vista: Eingang& Triage (3- Columnas HITL- Gatekeeper& Postfach)

Problema: Unkontrollierte Schreibaktionen de Agentes (por ejemplo E-Mail-Versand) as í como verstreute Eingänge de Mail y Telegram bergen Seguridad riesgos.

Mecánica: Dreispaltige Triage-Zentrale: Columna 1 para gelb markierte Human-in-the-Loop-Freigaben (Freigeben/Ablehnen), Columna 2 para IMAP/SMTP-E-Mail-Synchronisation con Auto-Triage& Delegation, Columna 3 para el gespiegelten Live- Telegram- Stream (@ Beatman _ bot).

Beneficio: *Garantiza, dass ninguna externo Schreiboperation sin ausdrückliche Freigabe del Betreibers ausgeführt será.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

6. Vista: Agenten-Kader& Flottenmanagement (8-Reiter-Cockpit)
Problema: Especialista necesitar individual Modelos, System-Prompts, Herramienta y Trabajar instrucción en un central Ort.
Mechanik: Gestiona 70 Especialista Perfil con Rápido filtrar (Activo, Favoriten, Todos, 7 Domänen), Hot-Swap para Provider& Modelo as í como 8 Fach-Reitern: Übersicht (360 °- Dossier& Telegram- Rufname), Direkt-Chat, Fähigkeiten (Skills), Operations (Task-Historie), SOUL (System-Prompt-Editor), Personalakte (SOPs), Talent-Marktplatz y Skill-Marktplatz.
Usar: Central Personalabteilung a la segundos rápido Kalibrierung y Extensión del total Agenten-Stamms.
Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

7. Vista: Master Chat (Dual-Mode Workspace& Multi-Session-Sidebar)

Problema: Al directo Trabajar con Agentes fehlte una enfocado Vollbild-Umgebung con rápido Wechsel entre 1:1- Dialog, Gruppenchat y Missions-Auftrag.

Mecánica: Ofrece el Dual-Mode-Switch (' Directo ' para inmediato Respuesta vs. ' Mission ' para estructurado Task-Anlage), Multi-File-Upload (hasta 5 Archivos), Browser-Screen-Capture (Kamera-Button), Spracheingabe (Diktat), Reasoning-Budget-Wähler (0 hasta 16 k Tokens), KI- Prompt-Optimizer y derechos Session-Historie (Agentes vs. Gruppe). Beinhaltet la Telegram Voice-Pipeline: Eingehende Sprachnachrichten (.ogg/Opus) de unterwegs serán v í a Whisper/Gemini transkribiert, anhand de Rufnamen (/ robert,/ anwalt etc.) en el Fachagenten geroutet y Responder v í a edge-tts (de-DE-ConradNeural) como natürliche Sprachmemos directo en Telegram zurückgesendet.

Beneficio: *Vereint Hochgeschwindigkeits-Dialog, multimodale Entrada y Missions-Steuerung en una durchgängigen Arbeitsfläche.* Permite completo mobile Sprachbedienung y bidirektionalen Audio-Austausch sobre Telegram.

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

8. Vista: AI Mastermind& Boardroom (55 Methodik-Frameworks)

Problema: Complejo strategische Decisiones requerir estructurado Management-Methoden y kontroverse Perspektiven en lugar de Einzelmeinungen.

Mechanik: Simulado mehrstufige Gremiensitzungen (Chairman + 3 reale Fachagenten-Slots + Red-Team-Challenger) anhand de 34 auswählbaren Frameworks en 7 Kategorien (35 Base) (por ejemplo CLEAR, Design Sprint, Double Diamond, Lean Startup, First Principles, Game Theory, Blue Ocean, Pre-Mortem, Six Sigma).

Usar: Erzwingt methodische Strenge, deckt blinde Flecken mediante el Red-Team en y entrega entscheidungsreife Board-Memos.

Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

9. Vista: Showroom (Projekt-Explorer, Artefakt-Galerie& Python- Sandbox)

Problema: Genera Informes, HTML- Prototypen, Kalkulationen y Script gehen en largo Konversationen verloren.

Mecánica: Katalogisiert todos Trabajar resultados tras Crear, Fecha y Tipo. Beinhaltet el Workspace Vault Reader con Live-Rendering para Markdown/HTML/JSON as í como una aislado Python- Sandbox a la se Code-Ausführung. Ampliado um el interaktiven Showroom Live-Runner: Permite la directo Ausführung de Python- y Code-Dateien en el Browser con 12 s Timeout, aislado Scratch-Verzeichnis y ausklappbarem Terminal-Drawer (STDOUT, STDERR, Exit-Code y Millisekunden-Laufzeit).

Beneficio: *Sirve como Abnahme- y Präsentationshalle para todos fertigen Deliverables ante al Clientes- o Produktionseinsatz.* Code-Artefakte y Script se pueden sin Konsolenwechsel directo en el Showroom verificar y probar.

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

10. Vista: Central biblioteca& 2 nd Brain (RAG, Auto- OCR& Obsidian- Vault)

Problema: Fachbücher, DIN-Normen y Bebauungspläne como PDF pudo de Agentes bisher no sin manual Kopieren mediante busca serán.

Mechanik: Vereint 3 Sub-Tabs y 4 Core Hubs (00 _ HR _ Agentes, 02 _ Saber biblioteca, Registro/, 00 _ Notebook _ Synthesen): 1. AnythingLLM RAG- Index (Port 3001), 2. Dokumenten-Erfasser con Drag& Drop, Auto- OCR (Docling) y KI- Themenklassifikation, 3. Directo Obsidian- Dateibaum& Markdown-Viewer incl. Vault- Umschalter.

Usar: Verwandelt PDF- Gutachten totalmente autom á tico en durchsuchbares Markdown- y Vektor-Wissen para todos 70 Agentes.

Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

11. Vista: Workflow-Engine (n8n Automation Mesh en Port 5678)

Problema: Wiederkehrende Interfaz procesos (Cron-Jobs, Webhooks, Datenbank-Abgleiche) verbrauchen unnötig Tokens, wenn ella sobre LLMs ejecutarse.

Mecánica: Betten el visuellen n8n- Workflow-Editor directo un y conecta lo sobre el Skill n8n- automation-mesh (FastMCP) con al CEO- Agentes Robert. Activado 0- Token-Routinen: 1. Morning-Briefing (werktags 07:30 Uhr con Obsidian- Ablage y Telegram- Zustellung), 2. Weekly Maintenance (sonntags 23:00 Uhr con SQLite-

Respaldo& Health-Audit), 3. RSS& News Watchdog (stündlicher Scan), plus 5 activo Funktions-Webhooks para Web-Extraktion, Messaging, Dokumenten-Rendering, Feed-Suche y CRM- Sync.

Beneficio: *Combinado deterministische 0- Token-Hintergrundprozesse con kognitiven Agentes Decisiones en Schlüsselstellen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

12. Vista: pasarela LLM (panel del enrutador IA OmniRoute)

Problema: La feste Bindung en un einzigen Cloud-Anbieter dirige en Rate-Limits o Ausfällen al inmediato Systemstillstand.

Mecánica: Central Proxy-Dashboard (Port 20128/ 8000) con Multi-Provider- Vault, Echtzeit-Latenzmessung (ms), HTTP- Fehlermonitor (429/500), automático Circuit-Breaker y 4- stufiger Fallback-Kaskade (GLM- 4.7 Flash- > Gemini 2.5 Flash- > Claude 3.5 Sonnet- > local Llama 3.3 70 B).

Beneficio: *Sichert 99,9% Verfügbarkeit aller kognitiven Procesos en minimalen API- Costar.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

13. Vista: Token Guard (Guardian& Token Analytics en 3 Sub-Views)

Problema: Fehlende Transparenz sobre ello/ encima, welcher Agente, cuál Modelo o cuál Einzelsitzung la meisten Tokens y Costar verursacht.

Mecánica: Ofrece Zeitfilter (24 h, 7 es decir, 30 es decir, Total), Inaktivitäts-Timer y 3 Sub-Views: 1. Übersicht& Tages-Trend-Chart con Profil-/Modell-Tabellen y Schutz-Schranken-Formular, 2. Einzel-Session Verbrauchs-Inspektor (Input, Output, Cache-Read Tokens sortierbar), 3. Ressourcen& Task-Drosselung (Schieberegler 1-16 Tasks).

Beneficio: *Pleno Costar control hasta en la einzelne Session-ID herab incl. inmediato Presupuesto- y Parallelitäts-Begrenzung.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

14. Vista: Extensión& Módulo Central (34 Evey- Spezial-Plugins)

Problema: Seguridad-, Memoria- y Análisis función ließen se bisher no modular por Fachgebiet a- o abschalten.

Mecánica: Steuert 34 spezialisierte Hermes/Evey-Plugins sobre 8 Fach-Reiter: Seguridad& Wächter (4), Performance& Caché (2), Monitoring& Analytics (3), Agenten-Intelligenz (6), Planificación& Tasks (2), Brücken& Interfaz (4), Gedächtnis& Saber (3), Herramienta& Execution (3) plus Finanzen/ Calidad/ Mantenimiento. Beinhaltet el estandarizado Plugin sistema& Runtime-Hooks: Modulare Ordnerstruktur (plugin/ < plugin_id >/ plugin.json), 4 Lifecycle-Hooks (on_load, on_enable, on_disable, on_unload) y 2 Tool-Interzeptoren (before_tool_execute, after_tool_execute) con vorinstallierten Iniciar Plugin (Sistema Metrics, Security Auditoría Hook, Cost Guard).

Beneficio: *Permite el preciso A- y Abschalten einzelner Systemfähigkeiten en el laufenden Empresa con un clic.* Permite aislado Runtime-Erweiterungen y global Tool-Interzeption sin Eingriff en el Kernel-Code.

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

15. Vista: Research Lab (Deep Search& Evidenz-Triangulation)

Problema: Simple Suchanfragen entregar ungeprüfte Einzeltreffer sin Quellenabgleich o Vertrauensbewertung.

Mecánica: Mehrstufiges Forschungs-Cockpit con wählbarer Suchtiefe, Quellen-Monitor, Evidenz-Score, Live-

Synthese-Protokoll a la Triangulation widersprüchlicher Aussagen y 1- Klick-Export en el Obsidian- Vault. Beinhaltet la Autonome Tiefenrecherche& Reflexionsschleife v 2 (Re-Search Loop): Zerlegung complejo Recherchen en 3-5 Teilfragen, autonome Lückenanalyse, hasta a 3 iterative Nachfolge-Suchläufe, Multi-Provider Fallback (SearXNG/ Jina Reader) y SSRF-Schutz.

Beneficio: *Genera belastbare, zitierfähige Mercado-, Derecho- y Technik-Dossiers.* Cierra Wissenslücken selbstständig mediante rekursive Folgerecherchen en widersprüchlichen o unvollständigen Fuentes.

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

16. Vista: telemetría y registros (flujo de auditoría en vivo de 3 fuentes)

Problema: En Error en Containern o Agenten-Prompts tuvo que bisher mühsam en el Terminal sobre Docker-Comando buscado serán.

Mecánica: Bündelt 3 Registro Fuentes en tiempo real: Physische Docker- Container-Logs (stdout/stderr el 11 Container), kognitive Agentes Registros y el kryptografischen Audit-Trail. Con Level-Filter (DEBUG, INFO, WARN, ERROR), Auto-Scroll-Lock y Export.

Beneficio: *Unbestechlicher Flugschreiber para segundos rápida Fehlerdiagnose y Compliance-Nachweise.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

17. Spezial-Studio: Archon Prompt Studio (832 Plantilla& Fabric SOP)

Problema: Unpräzise formulierte Tareas liderar a Halluzinationen, falso Ausgabeformaten y teuren Korrekturschleifen.

Mechanik: Integrado Baukasten con 824 Enterprise-Vorlagen en 16 Fachkategorien, sobre 255 Fabric- SOP-Modelo y el 5- Felder-Formel (1. Rol, 2. Contexto, 3. Tarea, 4. Format, 5. Constraints/Negativ-Regeln) as í como KI- Prompt-Optimizer.

Usar: Zwingt cada Delegation en una glasklare Struktur y überträgt ella con un clic en Chat o Kanban-Aufgabe.

Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

18. Spezial-Studio: Visual CSS Live Studio& In-Place Transform Gizmo (Antiguo + S)

Problema: Design-Anpassungen requiere bisher el Buscar en CSS- Archivos y ständiges Neuladen del Browsers.

Mecánica: Schwebendes Echtzeit-Design-Studio (Antiguo + S) con Fadenkreuz- DOM- Inspektor, interaktivem Transform-Gizmo (Position ziehen, 4 Ecken/Kanten escalar, Eckenrundung ziehen), Theme-Profil-Manager y directo CSS- Export tras custom_studio. css.

Beneficio: *Permite pixelgenaues Live-Styling el total Benutzeroberfläche en el laufenden Empresa sin Seiten-Reload.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

19. Spezial-Studio: Design Sistema Lab, AppShell Architekt& 15- Komponenten-Studio

Problema: Abweichende Header-Höhen, Abstände o Kontraste entre Hell- y Dunkelmodus stören la visuelle Ruhe.

Mecánica: Beinhaltet el interaktiven AppShell-Architekten (56 px Header-Flucht, Sidebar-Breite, Viewport-Padding con Live-Miniatursimulation) as í como el 15- Komponenten-Design-Studio (os-workspace hasta os-badge) con Dual-Theme-Engine (Light/Dark).

Beneficio: *Garantiert un einheitliches, blendfreies B 2 B- SaaS- Erscheinungsbild sobre todos 20 Vistas hinweg.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución

activa de acciones LLM dentro del módulo).

20. Spezial-Ansichten: System Control Center (11 Fachreiter, Live-Dock)& Global Omnibox (Strg + K)
Problema: Ajuste fueron verstreut; la Navigation entre 20 Vistas y 70 Agentes requiere mucho Mausklicks.
Mechanik: El System Control Center bündelt 7 Administrations-Reiter (Hermes Core incl.. YAML- Editor, Container& Servicios, Provider& Gateway, Metodología, Plugin, Kommunikation, Design) y se puede por ' Live-Dock ' derecho andocken. La Omnibox (Strg + K) navigiert por Tastatur de inmediato a cada Tab (#), Agentes (@) o Comando. Integrado el 1- Klick Actualización sistema& Continuous Deployment: Automático GitHub- Sync con Pre-Update Snapshots aller SQLite- Base de datos (WAL) en data/snapshots/ ante cada Git-Pull, 1- Klick Rollback y minimalen Git-Stat-Prüfungen contra Mount-Timeouts.
Usar: Maximale Bediengeschwindigkeit para Administratoren y Power-User. Permite gefahrlose Software-Updates con automático Datenbank-Rollback en el Fehlerfall.
Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

3. Ecosistema FinOps y de ahorro de tokens (minimización de costes)

21. 3- Tier Automático Kosten-Routing-Caps (LOW/ MEDIUM/ HIGH)

Problema: Wenn simple Routineaufgaben en teuren Spitzenmodellen (como Claude Sonnet o GPT- 4 o) ejecutarse, explodieren la Días costar.

Mecánica: Konfigurierbare Preis-Obergrenzen por 1 Million Tokens en el System Control Center: LOW (máx.. $ 0.10/ 1 M- > erzwingt Free-Tier/Flash-Lite), MEDIUM (máx.. $ 1.00/ 1 M- > Haiku/Gemini Flash), HIGH (No Cap- > beste Reasoning-Modelle para complejo Arquitectura).

Beneficio: *Senkt la laufenden API- Resultado en el Alltag um hasta a 85%, sin en schwierigen Tareas en Calidad einzubüßen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

22. FreeLLM- API Docker- Proxy& ' auto/best-free ' Routing (Port 3002)

Problema: Gratuito Kontingente verschiedener Proveedor son grave manual supervisar y cambiar frecuente.

Mecánica: Un dedizierter Docker- Container (freellmapi en Port 3002) bündelt kostenfreie LLM- Endpunkte. El Routing-Profil ' auto/best-free ' elige automático el stärkste disponible Null-Euro-Modell.

Beneficio: *Permite el Dauerbetrieb de Tras motivo- y Triage-Agenten a exakt $ 0.00 API- Costar.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

23. Stufenlose Reasoning-Budget-Steuerung en el Master Chat& Router (0 hasta 16 k Tokens)

Problema: Reasoning-Modelle (Thinking-Mode) verbrauchen a menudo tausende unsichtbare Denk-Tokens para triviale Preguntar.

Mecánica: 6- stufiger Regler (De: 0 Tok, Minimal: ~ 1 k, Bajo: ~ 2 k, Mittel: ~ 4 k, Alto: ~ 8 k, Maximal: ~ 16 k) en el Chat-Footer y en agent_router. py.

Beneficio: *Schaltet teure Denk-Schleifen en simple Tareas completo desde y reserviert profundo Reasoning para echte Komplexfälle.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

24. Evey- Caché& Cache-TTL-Steuerung (24 h Semantischer& Exakter Respuesta Caché)

Problema: Wiederkehrende identische o muy ähnliche Sistema consulta dirige cada Mal demasiado nuevos, de pago API- Calls.

Mecánica: El Plugin evey-cache guarda Modelo responder con konfigurierbarer Lebensdauer (Estándar: 24 Horas TTL) y asigna en el Session-Inspektor la eingesparten Cache-Read-Tokens separat de.

Beneficio: *Beantwortet repetido Consulta en 0 Millisekunden a 0 Token-Kosten.*

Coste y contrapartida (Trade-off): Es la Cache-TTL demasiado alto (> 72 h), entrega el Sistema en dinámico Themen obsoleto Responder.

¿Cuándo desactivar? y umbrales: Apagar en Echtzeit-Abfragen (Live-Kurse, Servidor estado). Std-TTL: 24 h.

25. Max-Context& Max-History Hard-Clipper en el Guardian (32 k/ 20 Turns)

Problema: Endlos wachsende Chat-Sitzungen enviar en cada nuevos Pregunta la total Historie erneut con y treiben la Input-Tokens exponentiell tras oben.

Mecánica: En el Guardian einstellbare Hardschranken para el maximale Contexto ventana (por ejemplo 32.000 Tokens) y la maximale Anzahl übermittelter Chat-Nachrichten (por ejemplo letzte 20 Turns).

Beneficio: *Kapselt la maximal posible Input-Kosten por Turn verlässlich tras oben desde.*

Coste y contrapartida (Trade-off): Schneidet Mensaje por encima de de 32 k Tokens o 20 Turns hart desde, por lo cual muy früher Contexto wegfällt.

¿Cuándo desactivar? y umbrales: Para profundo Dokumenten-Analysen en 64 k- 128 k en el Hermes Core anheben.

26. Dinámico Token-Clipper para Low-Context-Modelle (backend/token_clipper.py)

Problema: Kompakte o local Modelos (8k/16k) brechen desde, wenn gran Herramienta Resultado el Contexto ventana sprengen.

Mecánica: Bewahrt zwingend el System-Prompt (Index 0) y la letzte Usuario instrucción, kürzt überlange Einzelblöcke intelligent y elimina ältere Entre pasos.

Beneficio: *Permite el estable Einsatz extrem günstiger Pequeño modelos también en umfangreichen Tareas.*

Coste y contrapartida (Trade-off): Kürzt überlange Herramienta Resultado en el Mitte heraus ([...SNIP...]), por lo cual einzelne Code-Zeilen en el Rohtext fehlen pueden.

¿Cuándo desactivar? y umbrales: Kurzzeitig desactivar, wenn completo Roh-Logs ungekürzt necesita serán.

27. Sliding Window Memory Compression (Konsolidierter Decisión contexto)

Problema: Al simple Abschneiden alter Mensaje gehen frühere Projektbeschlüsse verloren.

Mecánica: Verdichtet ältere Gesprächsrunden a una kompakten Zusammenfassung e injiziert esta como Bloque [KONSOLIDIERTER GESPRÄCHS- & ENTSCHEIDUNGSKONTEXT] en Position 1.

Beneficio: *Ahorra hasta a 70% historische Konversations-Tokens en pleno Erhalt aller getroffenen Decisiones.*

Coste y contrapartida (Trade-off): El Komprimierungs-Schritt cuesta einmalig ~ 800 Tokens y glättet wörtliche Formulierungen früher Alrededor de.

¿Cuándo desactivar? y umbrales: En Bedarf sobre protect_last_n (Std: 20) en el Hermes Core feinjustieren.

28. LRU-K Page Swapping para Subagenten- RAM (backend/context_swapper.py)

Problema: Paralelo Subagenten halten riesige Mengen en Rohdaten simultáneo en el activo Prompt-Speicher.

Mecánica: Lagert no más akut necesita Contexto Desde desde 80% Auslastung tras al Least-Recently-Used-Prinzip en SQLite de y lädt ella solo si ello necesario (Re-Hydration) zurück.

Beneficio: *Hält la Prompts schlank e impide unnötige Token-Gebühren para inactivo Hintergrundwissen.*

Coste y contrapartida (Trade-off): El Externalizar y Nachladen de Agentes- RAM en Disk genera ~ 10-25 ms I/O-Latenz al Kontextwechsel.

¿Cuándo desactivar? y umbrales: Desde 80% RAM- Auslastung activo lassen, um OOM-Abstürze impedir.

29. JEV Router- 0- Token Deterministische Intent-Vorfilterung (jev_router.py)

Problema: Cada simple Sistema instrucción sobre un grande Sprachmodell clasificar, verschwendet Tokens y

Tiempo.

Mecánica: Clasificado eingehende Entrada ante al LLM- Aufruf por deterministischem JSON Execution Vector y Keyword-Heuristik.

Beneficio: *Dirige claro Sistema comando directo en la Zielroutine weiter, sin un einziges LLM- Token a verbrauchen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

30. ASD- STE100 Simplified Technical English Prompter (.agents/skills/asd-ste100-prompter)

Problema: Weitschweifige Prosatexte en System-Prompts y Agentes Instrucción blähen cada einzelnen API- Call unnötig en.

Mecánica: Transformiert Instruktionen tras al Luftfahrt-Standard ASD- STE100 (una Significado por Palabra, activo Verben, breve Sätze, null Füllwörter).

Beneficio: *Reducido la Token-Länge de System-Prompts um aprox.. 30-40% y senkt simultáneo la Fehlerrate en Tool-Calls.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

31. Anti- AI- Slop& Output-Komprimierung (.agents/skills/anti-ai-slop)

Problema: Sprachmodelle generar standardmäßig largo Höflichkeitsfloskeln, Introducción y redundante Zusammenfassungen (teure Output-Tokens).

Mecánica: Unterbindet KI- Floskeln, vacío Phrasen y künstliches Aufblähen directo en el System-Prompt y depurado Resultado.

Beneficio: *Ahorra hasta a 25% el besonders teuren Output-Tokens y entrega de inmediato verwertbare Fachtexte.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

32. Pre-Flight Costar Estimar& Presupuesto Previsión (backend/cost_estimator.py)

Problema: Ante al Start grande Tareas fue no absehbar, lo que el Lauf costar será.

Mecánica: Calculado vorab sobre POST/ api/router/estimate-cost la espera Input-/Output-Tokens as í como el Dollar-Betrag anhand el actualmente Modell-Preisliste y gleicht lo con al Task-Budget desde.

Beneficio: *Advierte ante teuren Läufen, aún antes de que el solo Cent ausgegeben será.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

33. Dinámico Task-Budget con 80%- Spar-Downgrade& 100%- Stopp

Problema: Un einzelner complejo Task pudo unbemerkt el total Días presupuesto verzehren.

Mecánica: Supervisado la kumulierten Costar por Tarea (por ejemplo Limit $ 0.25): Schaltet en 80% automático en un günstiges Spar-Modell herunter y pausiert el Task en 100% con Telegram- Freigabeanfrage.

Beneficio: *Impide Kostenausreißer en mehrstufigen autonomen Recherchen.*

Coste y contrapartida (Trade-off): En Erreichen de 80% del Task-Budgets será en un günstigeres Spar-Modell heruntergeschaltet; en 100% erfolgt el Hard-Stop.

¿Cuándo desactivar? y umbrales: Task-Budget (Std: 0,50 $) para gran Architektur-Läufe en 2,00 $ anheben.

34. Loop-Killer& Max-Steps-Begrenzung (15 Pasos/ Jaccard > 90%)

Problema: Wenn un Agente en un fehlerhaften Tool-Aufruf en una Endlosschleife gerät, verbrennt él en el Sekundentakt Guthaben.

Mecánica: Verifica cada Paso en exakte Reintento (> = 3) o semantische Kreisbezüge (> 90% Ähnlichkeit) y kappt

Tareas spätestens tras al konfigurierbaren Max-Steps-Limit (Estándar: 15 Pasos).

Beneficio: *Protege el Cuenta fiable ante unbemerkten Endlosschleifen sobre Nacht.*

Coste y contrapartida (Trade-off): A scharfe Grenzwerte (Máx. Identisch = 2 o Jaccard < 0.80) detener legitime iterative Tareas como schrittweises Test-Fixing o Paginierung a früh.

¿Cuándo desactivar? y umbrales: Kurzzeitig apagar, wenn un Agente bewusst mucho gleichförmige Schleifen-Schritte (por ejemplo Massen-Migration de 50 Archivos) despachar debe. | Umbral valores: Máx. Identisch: 2 = stoppt Retries | > 5 = teure Schleifen (Std: 3). Jaccard: < 0.80 = Fehlalarme | > 0.96 = detecta Schleifen spät (Std: 0.90). Máx. Pasos: Std 15.

4. Núcleo, planificación y arquitectura de demonios (pilar 1)

35. Hermes Master Orchestrator (núcleo Hermes)
Problema: Unkoordinierte Einzelagenten trabajar gegeneinander o verlieren el Gesamtziel de el Augen.
Mechanik: Central Prozess-Leitstelle a la Encargo análisis, Rollenauswahl, Überwachung y Ergebnis-Abnahme.
Usar: Sichert strategische Kohärenz sobre todos 70 Especialista.
Precio& Schattenseite (Trade-off): Más activo Hintergrund-Dienste y alta Reasoning (' high ') aumentar la Grundlast y Token-Kosten.
Cuándo apagar?& Umbral valores: Sobre la 14 Sektionen en el Tab ' HERMES CORE ' granular steuerbar.

36. Tickless Kernel Demonio& Asyncio Event-Loop (Port 8420/ 8501)

Problema: Ständiges Polling en el Sekundentakt verschwendet CPU- Ressourcen y Systemenergie.

Mecánica: Calculado el exakten Momento del nächsten fälligen Tasks (' Sleep-until-next-due ') y versetzt el Kernel hasta dahin en el Ruhezustand.

Beneficio: *Minimale Systemlast en el Leerlauf en verzögerungsfreier Aufwach-Reaktion.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

37. Planificador de preempción por prioridad (cola P0–P3)

Problema: Dringende Usuario preguntar en el Direkt-Chat tuvo que esperar, wenn Hintergrund-Jobs todos Slots acreditado.

Mecánica: Priorizado Cola: P3- Tareas (Direkt-Chat/ Emergencia) überholen laufende P1/P2-Routinejobs de inmediato.

Beneficio: *Garantiert rápida Respuesta tiempo en el Dialog a pesar de hoher Hintergrundlast.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

38. Frei escalable Concurrency-Drosselung (backend/concurrency_throttle.py)

Problema: A mucho simultáneo Agentes liderar a HTTP- 429- Rate-Limits y 99% CPU- Spitzen.

Mecánica: Reguliert activo Worker sobre una Asyncio-Semaphore (einstellbar por Slider de 1 hasta 16 paralelo Tasks en el Guardian y Control Center).

Beneficio: *Permite gedrosselten Protección empresa en Laptops ebenso como Hochlastbetrieb en Workstations.*

Coste y contrapartida (Trade-off): Knappe Stagnations-Limits (< 30 Sek.) brechen lento Deep-Reasoning-Modelle (por ejemplo o3/R1) fälschlich en medio del Denkprozess desde; más Worker aumentar RAM- y API- Spitzenlast.

¿Cuándo desactivar? y umbrales: Apagar en extrem langlaufenden Einzel-Analysen o local LLM- Läufen en lento Hardware. | Umbral valores: Máx. Worker: 1-2 = Rückstau | > 8 = RAM- Spitzen& HTTP- 429 (Std: 4). Stagnation: < 30 s = bricht Pensar desde | > 180 s = späte Heilung (Std: 45 s).

39. Autonomer 30- Sekunden-Watchdog& Crash-Recovery (watchdog_daemon.py)

Problema: Abgestürzte o eingefrorene Tasks blieben permanente en el Estado in_progress hängen.

Mecánica: Verifica todos 30 Segundos todos laufenden Procesos, bricht Zombie-Tasks tras Timeout (120s) desde y überführt verwaiste Tareas en la automático Crash-Recovery.

Beneficio: *Mantiene todas las ranuras de workers libres de residuos.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

40. Deadlock-& Stagnations-Supervisor (backend/deadlock_supervisor.py)

Problema: Gegenseitige Dependencia entre zwei Agentes pueden a un stillen Einfrieren liderar.

Mecánica: Detecta zirkuläre Wartezustände y Tasks sin Avance (> 45 s) y löst la Blockade autonom con exponentiellem Backoff en.

Beneficio: *Impide Pipeline-Stillstände en complejo Gruppenarbeiten.*

Coste y contrapartida (Trade-off): Un a knappes Stagnations-Limit (< 30 s) bricht lento Deep-Reasoning-Modelle (o3/R1) en medio del Denkprozess desde.

¿Cuándo desactivar? y umbrales: En Nutzung de Reasoning-Modellen Stagnations-Limit en 90- 120 s aumentar (Std: 45 s).

41. Flotten-Selbstheilung& Container-Auto-Restart (backend/fleet_self_healing.py)

Problema: Cae una el 11 Docker- Container de, tuvo que él manual nuevo iniciado serán.

Mecánica: Supervisado todos Core-Container sobre el abgesicherten docker-socket-proxy y dirige en Ausfällen (> 60 s) autonom un Neustart incl. Auditoría Entrada mediante.

Beneficio: *Sichert el unbeaufsichtigten 24/7-Betrieb el total Docker- Landschaft.*

Coste y contrapartida (Trade-off): Un permanente defekter Container puede mediante Auto-Restart en una Neustart-Schleife geraten.

¿Cuándo desactivar? y umbrales: Mientras/ durante manual Container-Wartungsarbeiten kurzzeitig desactivar.

42. Proaktiver Morgen-Standup& Weckdienst (backend/autonomous_standup.py)

Problema: Mañana fehlte una kompakte Übersicht sobre nächtliche Läufe, Costar y anstehende Decisiones.

Mecánica: Genera diario um 08:00 Uhr un konsolidierten Estado informe en el Obsidian- Vault (01_PROJEKTE/Daily_Briefings/) y pusht lo en Panel y Telegram.

Beneficio: *Inicia cada Arbeitstag con una fertigen Decisión plantilla.*

Coste y contrapartida (Trade-off): Cada automático Morgen-Briefing verbraucht ~ 1.500-3.000 Tokens al eingestellten Momento.

¿Cuándo desactivar? y umbrales: Apagar, wenn ningún diario Morgen-Report gewünscht es (Std: 08:00 Uhr).

5. Multi-Agenten-Prozessmodell, Jerarquía& Synthese (Pillar 2)

43. 70 perfiles de agente declarativos y expedientes Markdown
Problema: Generische KI- Assistenten tener ningún Rollenbewusstsein y ninguna definido Calidad estándar.
Mechanik: Cada el 70 Especialista es en agent_profiles. json as í como una eigenen Personalakte (00_HR_Agenten/) con System-Prompt, Modellroute, Werkzeug-Scope y SOPs verankert.
Usar: Schafft verlässliche virtuelle Fachkräfte para Estrategia, Derecho, Bau, Finanzen, Marketing y IT.
Coste y contrapartida (Trade-off): como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

44. Robert Delegation, Fan-in-Synchronisation& Lisa Marker-Kontrakt (SYNTHESE-BEREIT)

Problema: En paralelo Teilaufgaben gingen Teilergebnisse verloren o se resumie unvollständig resumido.

Mecánica: Robert zerlegt Großprojekte; un Prozess-Lock (_MC_DATA_LOCK) espera en el Abschluss aller Teilaufgaben (Fan-in). Lisa aggregiert la Informes bajo Verificación del Pflicht-Markers SYNTHESE-BEREIT; Robert erteilt en Fila 1 la formale FREIGABE.

Beneficio: *Mehrstufige Aseguramiento de calidad tras al Vorbild una echten Empresa liderazgo.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

45. Estandarizado Agent-to-Agent Handoff-Desk (backend/handoff_desk.py)

Problema: Stille Contexto pérdida en el Übergabe de un Especialista en el nächsten.

Mecánica: Genera formale Übergabeprotokolle con Deliverables, abierto Annahmen y SHA- 256- Prüfsumme, la del Empfänger-Agenten quittiert serán deben.

Beneficio: *Interfaces a prueba de auditoría entre todos los departamentos.*

Coste y contrapartida (Trade-off): Strikte SLA- Verificación weisen muy breve, pero correcto Faktenantworten zurück, wenn min_content_length demasiado alto (> 300) es.

¿Cuándo desactivar? y umbrales: Estándar: 100 caracteres de longitud mínima, 60 min de respuesta.

46. Zweistufiger DAG-Scheduler para paralelo Projekt-Ausführung (backend/dag_scheduler.py)

Problema: Sequentielle Abarbeitung mucho Teilaufgaben dura en Großprojekten a largo.

Mecánica: Calculado el gerichteten azyklischen Graphen (DAG): Dirige unabhängige Recherchen (Nivel 1) paralelo de e inicia despu é s/ tras ello automático la Synthese (Nivel 2).

Beneficio: *Verkürzt la Durchlaufzeit complejo Análisis um un Vielfaches.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

47. Bucle de autocorrección y reflexión de ejecución de herramientas

Problema: Flüchtige Syntax- o Parámetro error en Herramienta Llamar dirige al inmediato Abbruch.

Mecánica: Fängt Herramienta Error desde, reflexionado la Error aviso y korrigiert la Aufrufparameter autonom en hasta a 3 Versuchen.

Beneficio: *Deutlich höhere Robustheit en Archivo-, Base de datos- y Web-Operationen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

48. Unterbrechbare Langzeit-Workflows con SQLite State-Snapshotting

Problema: Espera un Task stundenlang en una Nutzer-Freigabe, acreditado él unnötig Memoria o verliert su Estado en un Neustart.

Mecánica: Friert el exakten Ausführungszustand en el Tabla workflow_checkpoints un y nimmt la Arbeit tras Freigabe nahtlos wieder en.

Beneficio: *Permite mehrtägige Geschäftsprozesse sobre Neustarts hinweg.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

49. Dual-Agent Konsens-Gate& Adversarial Critic Review (backend/consensus_gate.py)

Problema: Un einzelner Agente bemerkt eigene Denkfehler o Halluzinationen en crítico Tareas a menudo no.

Mecánica: Erzwingt en P3- Tasks y crítico Eingriffen un formales Gegenlesen mediante un unabhängigen Revisor-Agenten (Red-Team/Critic). En el Kanban-Board como automatizado 4- Augen Qualitäts-Gate verdrahtet (Katharina Völk/ Robert Review con 1-100% Score y Status-Lock en Revisionsbedarf).

Beneficio: *Principio de cuatro ojos para todo resultado crítico.*

Coste y contrapartida (Trade-off): Verdreifacht (3x) el Token-Verbrauch y aumentado la Antwortzeit um + 6 hasta + 20 Sek.; Einstimmigkeit birgt Deadlock-Gefahr.

¿Cuándo desactivar? y umbrales: Activar solo desde prioridad P3/P4 y elegir mayoría de 2/3.

6. MCP- Treiber, Externo Servicios& Multimodale Herramienta (Pillar 3)

50. Archon CRM& PocketBase- Ökosystem (Ports 3005, 8090, 8092)

Problema: Kundenkontakte, E-Mail-Historien y Medien-Assets lagen separado de el KI- Agentes.

Mecánica: Dediziertes CRM- Frontend (Port 3005) con PocketBase- Backend (Port 8090) y Media-Server (Port 8092), pleno angebunden sobre scripts/archon_crm_mcp.py.

Beneficio: *Agentes pueden Kontakte recuperar, nachrecherchieren, evaluar (Lead-Scoring) y Korrespondenz asignar.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

51. Emparejamiento auto de correo e importador de archivo LinkedIn

Problema: Tausende Kontakte de LinkedIn-Exporten y E-Mail-Postfächern tuvo que manual abgeglichen serán.

Mecánica: Sincronizado Postfächer (--fetch-mails), ordnet Mails automático bestehenden CRM- Kontakten a e importado completo LinkedIn-Connections-CSVs incl. Deduplizierung.

Beneficio: *Baut en Minutos una completo, angereicherte Beziehungsdatenbank en.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

52. Robert Tool-Permission Manager (backend/tool_permission_manager.py)

Problema: Agentes deben en fehlenden Python-/Node-Paketen no hilflos cancelar, pueden pero también nada ungefragt instalar.

Mecánica: Robert plantea un formellen Installationsantrag (pending_permission) con Comando y Begründung; solo tras tu 1- Klick-Freigabe será el Paquete instala.

Beneficio: *Kontrollierte Erweiterbarkeit en pleno Protección del Host-Systems.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

53. Malla webhook dirigida por eventos (backend/event_mesh.py)

Problema: Externo Ereignisse de GitHub, Formulario o Drittsystemen pudo ninguna Agentes Acción auslösen.

Mecánica: Universeller Webhook-Empfänger, el externo JSON- Payloads validado y directo en ausführbare Kanban-Tasks umwandelt.

Beneficio: *Conecta Archon OS en tiempo real con el restlichen IT- Landschaft.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

54. Central Multi-Channel Notification Hub (backend/notification_hub.py)

Problema: Importante Aviso gingen en el UI bajo, mientras/ durante unwichtige Avisos en al Handy störten.

Mecánica: Routet Avisos strikt tras Schweregrad: INFO- > UI- Toast, WARNING- > Panel Registro, CRITICAL- > inmediato Telegram- Push.

Beneficio: *Alertas precisas sin fatiga de notificaciones.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

55. Multi-Modale Vision-& Screen-Capture-Pipeline (backend/vision_pipeline.py)

Problema: Visuelle Problemas o Tablas en Bildern tuvo que mühsam beschrieben serán.

Mecánica: Directo Bildschirmaufnahme en el Browser (Kamera-Button en el Chat) as í como automático OCR- y Strukturanalyse para subido Bilder (. png,. jpg,. webp).

Beneficio: *Los agentes ven exactamente lo que ves en pantalla.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

56. Apollo Voice Engine- Edge- TTS& Whisper Diktat (apollo_voice_engine.py)

Problema: Largo Texte en el Smartphone o Desktop einzutippen cuesta Tiempo; Informes quisiera se se unterwegs anhören.

Mecánica: Bidirektionale Sprachpipeline: Mikrofon-Diktat (Speech-to-Text) directo en el Chat-Eingabefeld y natürliche Sprachausgabe (Text-to-Speech) para Briefings. Completo Telegram- Voice-Integration (POST/ api/telegram/voice-relay y POST/ api/voice/synthesize) para mobile Audio-Memos v í a edge-tts (de-DE-ConradNeural).

Beneficio: *Verwandelt Archon OS en un sprachgesteuerten Executive Assistant.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

57. Radar de noticias Oracle y agente de ejecución SEO

Problema: Marktveränderungen y SEO- Schwachstellen eigener Webseiten se verificae solo sporadisch verificado.

Mecánica: Oracle News Radar scannt continuo Fachquellen en Projektrelevanz; el SEO Agente verifica Desde en Meta-Tags, Struktur y Keyword-Dichte.

Beneficio: *Continuo Mercado- y Sichtbarkeitsoptimierung en segundo plano.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

7. Gedächtnis, Datenbank-Hygiene& Obsidian 2 nd Brain (Pillar 4)

58. Capa central de memoria SQLite WAL (5 tablas estándar)

Problema: Simultáneo Lese- y Schreibzugriffe mehrerer Agentes dirige en simple Archivos a Konflikten.

Mecánica: Transaktionale SQLite- Base de datos (data/agentic_memory.db) en el Write-Ahead-Logging-Modus (WAL) con el 5 Kerntabellen tasks, conversations, learnings, kv_store y user_profile.

Beneficio: *Accesos paralelos sin bloqueos con máxima seguridad de datos.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

59. Proceso seguro Kanban-Sidecar con atomarem Dateiaustausch (backend/kanban_sidecar.py)

Problema: Metadaten como WIP-Limits o Tags pudo en paralelo Schreibvorgängen korrumpieren.

Mecánica: Protege config/kanban_meta.json sobre un prozessweiten Mutex y atomare Write-Replace-Operationen.

Beneficio: *Impide Datos pérdida en hochfrequenten Board-Aktualisierungen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

60. Docker- RAG- Bridge a AnythingLLM (5.068 indexierte Dokumente en Port 3001)

Problema: El en el Docker- Vektorspeicher vorhandene Saber fue en normal Chat-Anfragen a menudo no automático herangezogen.

Mecánica: backend/rag_bridge.py conecta el Agentenkern directo con al AnythingLLM- Workspace ARCHON y entrega relevante Textpassagen como Grounded Context.

Beneficio: *Fundierte Responder en Basis tu echten Unternehmensdokumente en lugar de general Schätzungen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

61. Disposición de carpetas de proyecto en 3 niveles en la bóveda Obsidian

Problema: Wenn Agentes Archivos generar, surge sin feste Regular rápido Unordnung en el Vault.

Mecánica: Legt para cada Proyecto automático la 3- Stufen-Struktur en: 01 _ Entre informes, 02 _ Medien y 03 _ Endprodukte.

Beneficio: *Saubere Trennung entre Rohentwürfen y abgenommenen Endergebnissen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

62. Obsidian Vault Indexer& Automático Map of Content (backend/vault_hygiene.py)

Problema: Nueva Proyecto informes blieben en el Obsidian- Graph a menudo unverlinkt (' Orphan Notes ').

Mecánica: Scannt el Vault, spürt verwaiste Notizen en y actualizado totalmente autom á tico la central _MOC_Projekt_Index.md con Wikilinks.

Beneficio: *Hält el Wissensgraphen en Obsidian en todo momento completo vernetzt.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

63. Autonomes Fact-Harvesting& 85%- Ähnlichkeits-Deduplizierung (backend/post_task_pipeline.py)

Problema: Importante Erkenntnisse de cerrado Tareas gingen bajo o se guardae mehrfach doppelt guardado.

Mecánica: Extrahiert tras Task-Abschluss automático nueva Fakten para learnings y user_profile e impide Dubletten desde 85% Textähnlichkeit.

Beneficio: *El Sistema será con cada despachado Tarea klüger, sin el Memoria zuzumüllen.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

64. Automático Online- DB- Respaldo con 7- Tage-Rotation (backend/db_backup_manager.py)

Problema: Sin regular Base de datos respaldo droht en Hardwaredefekten el Pérdida aller Tasks y Perfil.

Mecánica: Dirige en el laufenden Empresa PRAGMA wal_checkpoint (TRUNCATE) de y guarda comprimido. db. gz-Archive en. hermes/backups/db/.

Beneficio: *Respaldo íntegro sin un segundo de inactividad.*

Coste y contrapartida (Trade-off): Diario Pleno Respaldo acreditar seg ú n Aufbewahrungsdauer ~ 50-500 MB Disco duro memoria.

¿Cuándo desactivar? y umbrales: Estándar: 7 días de retención (db_backup_keep_days).

65. Autonomer SQLite Vacuum& Fragmentierungs-Optimizer (backend/db_optimizer.py)

Problema: Eliminado Datensätze y frecuente Actualización blähen SQLite- Archivos sobre Meses unnötig en.

Mecánica: Dirige sobre POST/ api/system/optimize-db en todos Base de datos PRAGMA optimize y VACUUM de y calculado el aprobado Speicherplatz.

Beneficio: *Mantiene los tiempos de consulta permanentemente en milisegundos.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

66. Atomares Pre-Write-Snapshotting& 1- Klick-Rollback (backend/snapshot_manager.py)

Problema: Wenn un Agente una Archivo fehlerhaft überschreibt, fue la Wiederherstellung del Vorzustands aufwendig.

Mecánica: Sichert ante cada Schreibzugriff automático el Original en. hermes/snapshots/ y plantea ello con un clic o API de inmediato wieder her. Adicional como Pre-Update Snapshots aller SQLite- Base de datos ante GitHub- Pulls y Container-Updates en data/snapshots/ integrado.

Beneficio: *Completo Sicherheitsnetz en todos Archivo- y Code-Änderungen.*

Coste y contrapartida (Trade-off): Cada Pre-Write-Snapshot cuesta ~ 5-15 ms Disk-I/O ante al Überschreiben una Archivo.

¿Cuándo desactivar? y umbrales: Búfer circular limitado por defecto a 50 snapshots.

67. Git-kompatible Live-Diff-Vorschau (backend/diff_engine.py)

Problema: Ante una Freigabe quisiera se exakt sehen, cuál Fila se cambiar, en lugar de la entero Archivo nuevo a lesen.

Mecánica: Genera un farbigen Zeilenvergleich (Rot = elimina, Grün = nuevo) entre Existencias y Agentes Borrador.

Beneficio: *Segundos rápida Verificación de Code- y Dokumentenänderungen en el HITL- Gate.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

8. Seguridad, Zero-Trust Governance& System-Diagnose (Pillar 6)

68. Kryptografisch verkettetes SHA- 256 Auditoría Registro (backend/audit_log.py)

Problema: Simple Text-Logs se pueden nachträglich verändern o eliminar.

Mecánica: Cada Evento será con al SHA- 256- Hash del Vorgängereintrags verkettet (Blockchain-Prinzip) y es sobre GET/ api/audit/verify en Manipulation prüfbar.

Beneficio: *Inalterable Acreditación aller Sistema- y Freigabeaktionen.*

Coste y contrapartida (Trade-off): Minimaler Schreib-Overhead (~ 2 ms por Entrada); la kryptografische Kette crece sobre Meses en.

¿Cuándo desactivar? y umbrales: Para inalterable Governance permanente eingeschaltet lassen.

69. Local Security Guard- 25 Prompt-Injection-& Jailbreak-Signaturen

Problema: Bösartige E-Mails o Webseiten pueden versteckte Comando contener (' Ignore previous instructions... ').

Mecánica: Scannt cada externo Texteingang anhand de 25 Ataque modelo, antes de que él en el Contexto de un Agentes gelangt.

Beneficio: *Rechaza prompt injections indirectas en la frontera del sistema.*

Coste y contrapartida (Trade-off): Muy strenge Heuristiken pueden en IT- Security-Texten o Pen-Testing-Prompts Fehlalarme (False Positives) auslösen.

¿Cuándo desactivar? y umbrales: Solo relajar brevemente para pruebas red-team autorizadas.

70. Secret-Masking& Red-Teaming Output Guard (backend/secret_masker.py)

Problema: API- Clave o Passwörter podría versehentlich en Registros, Informe o Chat-Ausgaben auftauchen.

Mecánica: Filtert ausgehende Texte en tiempo real en Clave Modelo (sk-..., Bearer, Passwörter) y ersetzt ella mediante [GESCHÜTZTER_KEY].

Beneficio: *Impide el versehentliche Offenlegen vertraulicher Zugangsdaten.*

Coste y contrapartida (Trade-off): Aggressive Regex-Maskierung puede en raro Fällen harmlose Base 64- o Hash-Strings en Code-Ausgaben schwärzen.

¿Cuándo desactivar? y umbrales: En el Produktivbetrieb al Protección de API- Keys permanente activo lassen.

71. Proxy Docker socket asegurado (puerto 2375 interno)

Problema: Directo Acceso en/ var/run/docker.sock hay Containern uneingeschränkte Root-Rechte sobre el Host-System.

Mecánica: Schaltet un restriktiven Proxy-Container dazwischen, el solo explícito permite Estado- y Neustart-Befehle durchlässt.

Beneficio: *Protege el SO anfitrión según el principio zero-trust.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

72. A/B-Modell-Benchmarker& Empirischer Performance-Scorer (backend/model_benchmarker.py)

Problema: Nueva Sprachmodelle aparecer semanal; su Eignung para eigene Empresa tareas permanece a menudo unklar.

Mecánica: Prueba zwei Modelos paralelo con identischen Tareas y compara Antwortzeit, Token-Kosten y Resultado calidad.

Beneficio: *Base de datos objetiva para la elección de modelo en el equipo.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

73. Systemweiter 360 °- Health-Score& Diagnose-Engine (backend/system_diagnostics.py)

Problema: Einzelne Métrica mostrar a menudo no de un vistazo, como gesund el Total sistema realmente es.

Mecánica: Calculado de Docker- Flottenstatus (35%), Concurrency-Queue (20%), Audit-Integrität (20%), Deadlock-Freiheit (15%) y RAG- Erreichbarkeit (10%) un Gesamtscore de 0-100% incl.. Handlungsempfehlungen.

Beneficio: *Inmediato Gesamtdiagnose del Empresa sistema sobre GET/ api/system/health-score.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

9. Selbst-Evolution, Marktplätze& Auto-Dokumentation (Pillar 7)

74. Autonome Skill-Synthese con Personalakten-Rückkopplung (backend/skill_synthesizer.py)

Problema: Erfolgreiche mehrstufige Lösungswege tuvo que bisher manual como neuer Skill programmiert serán.

Mecánica: Detecta wiederkehrende erfolgreiche Tool-Ketten, genera automático un SKILL. md-Entwurf, trägt lo en la Personalakte del Agentes un y legt lo a la Freigabe ante.

Beneficio: *El Sistema ampliado su Fähigkeiten en el Empresa selbstständig.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

75. Dinámico Talent-& Skill-Marktplatz (skill_markt. js& AgentSkillsHub)

Problema: Nueva Roles o Flujo de trabajo para nueva Geschäftsfelder desde cero nuevo a schreiben, es zeitintensiv.

Mecánica: Durchsuchbarer Catálogo al 1- Klick-Import y- Export completo Agentes Perfil as í como externo Skills (incl.. agentskillshub. dev Integration).

Beneficio: *Escala la flota de agentes en segundos ante nuevos proyectos.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

76. Completo Frontend-Backend-Synchronisation (238 Fetches/ 581 Pfade/ 29 Modale)

Problema: En grande Web-Anwendungen liderar verwaiste Buttons o unverbundene Modale a menudo a stillen Error.

Mecánica: Automatizado Prüf-Pipeline garantiza, dass todos 238 Frontend- API- Llamar y 29 Modale exakt con el 368 Backend-Routen verdrahtet son.

Beneficio: *Garantiert 0 tote Links y 100% bedienbare Steuerelemente en todos Vistas.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

77. Autonomer Master-Dossier-& Handbuch-Generator (backend/system_dossier_generator.py)

Problema: Arquitectura Documentación veralten meist ya poco Días tras ihrer Erstellung.

Mecánica: Genera pulsando un bot ó n (POST/ api/system/generate-dossier) el actual System-Architektur-Dossier simultan en el Proyecto carpeta y en el Obsidian- Vault (00_DOKUMENTATION/).

Beneficio: *Hält la Sistema documentación sin manual Pflegeaufwand permanente al es decir í a.*

Coste y contrapartida (Trade-off): Como vista central permanente e infraestructura del sistema integrado en el panel (necesidad base insignificante de RAM/CPU; solo se generan costes de tokens durante la ejecución activa de acciones LLM dentro del módulo).

10. Matriz de referencia: plugins Evey/Hermes controlables

N.º e ID de plugin	Categoría especializada	Mecánica central y función en el sistema operativo
78. evey-cost-guard	Seguridad y guardianes	Echtzeit-Kostenüberwachung y harte Budget-Abschaltung por Día y Task.
79. evey-session-guard	Seguridad y guardianes	Supervisado Sitzungslaufzeiten, Token-Obergrenzen e impide Zombie-Sessions.
80. evey-email-guard	Seguridad y guardianes	Scannt eingehende E-Mails ante el Triage en Phishing y Prompt-Injections.
81. evey-watchdog	Seguridad y guardianes	Verifica en el 30 s-Takt activo Procesos e inicia bloqueado Worker automático nuevo.
82. evey-cache	Rendimiento y caché	24 h-Antwort-Cache a la inmediato, kostenfreien Beantwortung repetido Consulta.
83. disk-cleanup	Rendimiento y mantenimiento	Depurado temporal Artefakte, obsoleto Registros y hay Disco duro memoria frei.
84. evey-telemetry	Monitorización y analítica	Erfasst Token-Ströme, Latencia y Modelo Llamar para Mission Control y Guardian.

85. evey-status	Monitorización y analítica	Continuo Health-Ping en todos 11 Docker- Container y Gateways.
86. evey-delegation-score	Monitorización y analítica	Evaluado la Erfolgs- y Qualitätsquote de Aufgabenübergaben entre Agentes.
87. evey-autonomy	Inteligencia de agentes	Controla el Autonomiegrad en mehrstufigen Hintergrund-Entscheidungen.
88. evey-council	Inteligencia de agentes	Mehrheits- y Konsensbildung entre más Especialista (Mastermind-Kopplung).
89. evey-reflect	Inteligencia de agentes	Selbstreflexions-Schleife a la eigenständigen Fehlerkorrektur ante Ergebnisabgabe.
90. evey-learner	Inteligencia de agentes	Extrahiert permanente Erkenntnisse de despachado Tareas para la learnings-Tabelle.
91. evey-identity	Inteligencia de agentes	Sichert la strikte Einhaltung de SOUL. md, Tonalität y Rollen-Leitplanken.
92. evey-habits	Inteligencia de agentes	Gestiona wiederkehrende Routinen como el diario 08:00-Uhr-Standup-Briefing.
93. evey-proactive	Inteligencia de agentes	Permite Agentes, en erkannten Engpässen selbstständig Handlungsvorschläge a machen.
94. evey-goals	Planificación y tareas	Vinculado operative Einzelaufgaben en el Kanban con übergeordneten Empresa objetivo.
95. evey-scheduler	Planificación y tareas	Tiempo- y prioritätsgesteuerte Einplanung de Hintergrund-Aufträgen.
96. evey-bridge	Puentes e interfaces	Interno Datendrehscheibe entre FastAPI- Monolith, Hermes- Demonio y Sidecars.
97. evey-mqtt	Puentes e interfaces	Leichtgewichtiges Mensaje registro para IoT- y Echtzeit-Statussignale.
98. evey-moltbook	Puentes e interfaces	Sincronizado estructurado Arbeitsbücher y Synthese-Notizen.
99. evey-telegram-ux	Puentes e interfaces	Steuert Rufnamen-Routing (/ robert,/ anwalt) e interaktive Freigabe-Buttons en Telegram.
100. evey-github	Puentes e interfaces	Conexión para Repository-Operationen, Commit-Analysen e Issue-Tracking.
101. evey-research	Herramientas e investigación	Tiefensuche-Treiber para Web-Scraping y Quellen-Extraktion en el Research Lab.
102. evey-news	Herramientas e investigación	Hintergrund-Scanner para Branchen-Feeds y Markt-Neuigkeiten (Oracle News Radar).
103. evey-digest	Herramientas e investigación	Comprimido umfangreiche Dokumentensammlungen en kompakte Management-Summaries.
104. evey-sandbox	Herramientas y	Aislado Ausführungsumgebung para genera Python- y

	ejecución	Analyse-Code en el Showroom.
105. evey-rag	Memoria y conocimiento	Vektor-Retrieval-Treiber a la Conexión de AnythingLLM y local Saber archivo.
106. evey-memory-adaptive	Memoria y conocimiento	Dinámico Gewichtung de Kurzzeit- y Langzeitgedächtnis seg ú n Kontextdruck.
107. evey-memory-consolidate	Memoria y conocimiento	Nachtlauf a la Zusammenführung y Deduplizierung verwandter Gedächtniseinträge.
108. evey-wallet	Finanzas y presupuestos	Gestiona API- Guthaben, Kontingente y costar referido Transaktions-Limits.
109. evey-validate	Calidad y ejecución	Verifica Resultado en Esquema-Konformität, Pflicht-Marker (SYNTHESE-BEREIT) y Formatvorgaben.
110. evey-verification	Calidad y ejecución	Faktencheck y Contra verificación crítico Aussagen ante el Endfreigabe.
111. evey-delegate-model	Calidad y ejecución	Elige en Teilaufgaben automático el costar- y leistungsoptimale Zielmodell.

11. Arquitectura empresarial y de resiliencia

78. Replay& Time-Travel Debugging (backend/time_travel_debugger.py)

Problema: En complejo Agentes Flujo de trabajo con mucho Tool-Calls es la nachträgliche Fehlerdiagnose en el Textlog unübersichtlich y el Verzweigen de Ausführungssträngen unmöglich.

Mecánica: Guarda cada Teilschritt con Ein-/Ausgaben, Snapshots y Tokenverbrauch en ' execution_traces '. Permite interaktives Replay (GET/ api/traces/ { task_id }), State-Forking desde Paso N (POST/ api/traces/ { task_id }/ fork) y 1-Klick-Rollback modifizierter Archivos.

Beneficio: Rápida Causa análisis y risikofreie Was-wäre-wenn-Experimente con alternativa Prompts o Modelo sin Neustart el total Pipeline.

Coste y contrapartida (Trade-off): Aumentado Disk-I/O um ~ 5-15 ms por Datei-Edit y acreditado seg ú n Snapshot-Limit ~ 50-250 MB adicional Speicherplatz en el Disco duro.

¿Cuándo desactivar? y umbrales: Apagar en Sistemas con extrem knappem Disk-Speicher o en massenhaften Datei-Generierungen (por ejemplo Build-Artefakte). | Umbral valores: Máx. Snapshots: < 10 = breve Historie | > 200 = höherer Disk-Verbrauch (Std: 50). Máx. Trace-Steps: Std 100.

79. Multi-Modell Eval- Matrix& A/B-Benchmarker (backend/model_benchmarker.py)

Problema: Modell-Zuweisungen en Agentes basarse a falta de empirischer Comparar valores a menudo en subjektiven Annahmen.

Mecánica: Envía denselben Prompt simultan en zwei configurado LLMs (POST/ api/router/benchmark), mide Latencia, Token-Verbrauch y Antwortlänge y guarda la Historie persistent en ' model_benchmarks ' (GET/ api/router/benchmark/history).

Beneficio: Objektive, datengestützte Modellauswahl cada Agentes rol (por ejemplo DeepSeek V 3 para Schnelligkeit/Kosten vs. Claude 3.7 para complejo Arquitectura).

Coste y contrapartida (Trade-off): N modelos candidatos cuestan N veces los tokens API por corrida.

¿Cuándo desactivar? y umbrales: Cuándo apagar? Solo selectivo para Modelo comparar iniciar, no en el Dauerbetrieb.

80. Tri-Agent Konsens-Gate& Schiedsgericht (backend/consensus_gate.py)

Problema: Crítico Eingriffe (Code-Refactorings, Migración) bergen en Einzelentscheidungen el Riesgo de Halluzinationen o Sicherheitslücken.

Mecánica: Beruft un dreiköpfiges Comité (Sistema Architect, Security Officer, QA Lead) un (POST/ api/consensus/council-vote). Cada Revisor votiert unabhängig; Freigabe requiere 2/3-Mehrheit. Todos Beschlüsse se archivae en ' consensus_decisions ' archivado (GET/ api/consensus/history).

Beneficio: Verlässliche Risikominimierung y Eliminierung de Single-Point-of-Failure-Halluzinationen en sensiblen Sistema cambio.

Coste y contrapartida (Trade-off): Verdreifacht (3x) el Token-Verbrauch y aumentado la Antwortzeit um + 6 hasta + 20 Sek. En Einstimmigkeits-Zwang droht Entscheidungs-Stillstand (Deadlock).

¿Cuándo desactivar? y umbrales: Apagar (o solo desde Priorität 4 = Crítico activar), wenn Geschwindigkeit y bajo API-Costar Vorrang tener. | Umbral valores: Desde Priorität: Prio 2 = casi cada Task cuesta 3 x Tokens | Prio 4 = solo crítico Tasks (Std: Prio 3). Mehrheit: 2/3-Mehrheit empfohlen.

81. Autonome Task-Selbstheilung con Git-Rollback (backend/task_self_healer.py)

Problema: Syntaxfehler o fehlerhafte Code-Imports bloquear Tasks de inmediato y requerir manual Eingreifen del Usuario.

Mecánica: Aislado el Stacktrace, dirige en Laufzeitfehlern un Git-Rollback modifizierter Archivos mediante y übergibt al Agentes un estructurado Korrektur-Prompt (POST/ api/healing/attempt). Hasta a 3 autonome Reparaturversuche; Log-Abruf v í a GET/ api/healing/logs.

Beneficio: Maximale Resilienz en Code- y Skript-Ausführungen con automático Selbstreparatur ante el Eskalation ins HITL- Board.

Coste y contrapartida (Trade-off): Cada Selbstheilungsversuch cuesta 1 adicional LLM- Call (+ 3 hasta + 12 Sek. Latencia& Token-Kosten). Un automático Git-Rollback verwirft en Fehlschlag también útil Compartir consecuencia.

¿Cuándo desactivar? y umbrales: Git-Rollback apagar, wenn unfertige Code-Entwürfe a la manual Weiterarbeit en el Trabajar directorio estar permanecer deben. | Umbral valores: Máx. Reparaturversuche: 1 = hay de inmediato en | > 5 = teure Reparatur-Kaskade (Std: 3).

82. Event-Mesh& Posteingangs-Verzeichnis-Watcher (backend/event_mesh.py)

Problema: Tareas tuvo que bisher manual sobre el Panel angestoßen o sobre zeitgesteuertes IMAP- Polling abgefragt serán.

Mecánica: Central Inbound-Event-Bus para externo Webhooks (POST/ api/events/inbound/ { channel }) y automático Verzeichnis-Watcher (POST/ api/events/scan-directory), el nueva Archivos en ' data/inbox/ ' directo en Kanban-Triage-Tasks überführt.

Beneficio: Vollautomatische Event- y Belegerfassung de externo Sistemas (GitHub, n8n, Stripe, local Dateiscanner) sin Benutzerinteraktion.

Coste y contrapartida (Trade-off): Muy breve Scan-Intervalle (< 3 Sek.) generar continuo Dateisystem-Polls; el diario Morgen-Standup verbraucht ~ 1.500-3.000 Tokens por Lauf.

¿Cuándo desactivar? y umbrales: Apagar, wenn el local Inbox-Ordner no activo genutzt será o ningún morgendlicher Briefing-Bericht gewünscht es. | Umbral valores: Scan-Intervall: 1- 2 s = unnötige Disk-Polls | > 30 s = verzögerte Datei-Erkennung (Std: 5 s). Standup-Zeit: Std 08:00 Uhr.

12. Arquitectura de autonomía, sandbox y gobernanza

83. Zonas de pruebas de código efímeras (backend/ephemeral_sandbox.py)

Problema: Ausführung de Agenten-Code birgt el Riesgo de Systemabstürzen, Endlosschleifen o unbeabsichtigten Archivo cambio en al Host.

Mecánica: Dirige Code en kurzlebigen, aislado Docker- Micro-Containern con harter Ressourcen-Begrenzung (512 MB RAM, 1 CPU, 30 s Timeout, ningún Netz) de (POST/ api/sandbox/execute). La Sandbox se eliminae tras Abschluss rückstandslos eliminado.

Beneficio: Absolute Seguridad y Systemstabilität en el automatizado Code-Ausführung y- Erprobung.

Coste y contrapartida (Trade-off): Container-Kaltstart cuesta ~ 300-800 ms Zusatzlatenz por Tool-Call. Es el Red desactivado, schlagen pip install o externo API- Recuperar en el Script de inmediato fehl.

¿Cuándo desactivar? y umbrales: Apagar (o Red activar), wenn vertrauenswürdige local Script directo Host-Zugriff o rápida Paketinstallationen necesitar. | Umbral valores: RAM- Limit: < 256 MB = OOM-Kill en Pandas/NumPy | > 2048 MB = Host- RAM- Riesgo (Std: 512 MB). Timeout: < 10 s = bricht Builds desde (Std: 30 s).

84. Nächtliche Gedächtnis-Konsolidierung (backend/memory_consolidator.py)

Problema: Stetig anwachsende Traces, Heartbeats y obsoleto Dialogdaten ralentizar Base de datos consulta en el Dauerbetrieb.

Mecánica: Prunt en Ruhephasen (Estándar 03:00 Uhr) obsoleto Traces y unkritische Registros anhand konfigurierbarer Retention-Fristen (settings.json). Completo steuerbar sobre la Hermes Core Ajuste (Uhrzeit, Retention-Tage, Pruning-Tiefe, manual Run-Button).

Beneficio: Permanente schlanke Base de datos, reducido Latencia y automático System-Hygiene sin manual Mantenimiento esfuerzo.

Coste y contrapartida (Trade-off): Mientras/ durante del Konsolidierungslaufs (~ 10-30 Sek.) surge breve CPU-/Disk-Last; una a bajo Pruning-Schwelle (< 0.88) puede verwandte, pero eigenständige Fakten resumir.

¿Cuándo desactivar? y umbrales: Apagar, wenn íntegro Roh-Traces para un forensisches Auditoría permanente ungefiltert erhalten permanecer deben. | Umbral valores: Aufbewahrung: < 7 Días = Pérdida importante Audit-Spuren | > 60 Días = gran SQLite- DB (Std: 14 Días). Pruning-Schwelle: 0.95 = konservativ | 0.88 = aggressiv (Std: 0.92).

85. Visueller Web-Agent con Screenshot-Audit (backend/visual_web_agent.py)

Problema: Tareas en complejo Webportalen sin API (SPAs, Formulario, interaktive Panel) pueden con Text-Scrapern no bedient serán.

Mecánica: Steuert un echten Headless-Chromium-Browser (POST/ api/browser/browse-and-capture), erfasst Screenshots para cada Klick- y Entrada paso en. hermes/visual_traces/ { task_id }/ y extrahiert estructurado Datos.

Beneficio: Íntegro visuelle Nachvollziehbarkeit y automatizado Interaktion con moderno Webanwendungen sin API-Zugang.

Coste y contrapartida (Trade-off): Headless-Chromium necesita por activo Audit-Lauf ~ 300 MB RAM y ~ 3-5 Sek. Renderzeit.

¿Cuándo desactivar? y umbrales: Cuándo apagar? En reinem Backend-Betrieb sin UI- Verificación.

86. Virtueller War-Room& Pre-Mortem Stresstest (backend/war_room_simulator.py)

Problema: Unvorhergesehene Seguridad-, Akzeptanz- o Compliance-Risiken serán en Produkteinführungen a menudo solo tras al Rollout bemerkt.

Mecánica: Simulado drei gegnerische Parteien (Crítico Großkunde, Offensiver Pentester, Strenger Compliance-Auditor) ante el Freigabe (POST/ api/simulation/war-room). Creado una aggregierte Riesgo- Matrix (LOW hasta CRITICAL) con vinculante Auflagen.

Beneficio: Proaktives Aufdecken de Schwachstellen y Vermeidung kostspieliger Fehlentscheidungen ante al Livegang.

Coste y contrapartida (Trade-off): Cuesta ~ 1.500-3.000 adicional Tokens y + 4 hasta + 10 Sek. Wartezeit ante al en realidad Task. En Bloque Umbral MEDIUM surgir frecuente Fehlalarme.

¿Cuándo desactivar? y umbrales: Auto-Pre-Mortem en el normal Entwicklungsalltag apagar y solo para produktionskritische Eingriffe (HIGH/CRITICAL) usar. | Umbral valores: Bloque Umbral: MEDIUM = bloqueado a menudo vorsorglich | CRITICAL = stoppt solo katastrophale Riesgos (Std: HIGH).

87. SLA-& Übergabe-Verträge entre Agentes (backend/sla_contract_enforcer.py)

Problema: Lose Delegationen en Multi-Agenten-Hierarchien liderar a menudo a unvollständigen Zuarbeiten, la en el menschlichen Operator escalado serán.

Mecánica: Cierra en interno Delegationen digitale Verträge con Obligación campo, Mindestlänge y Akzeptanzkriterien desde (POST/ api/contracts/create). Validado Entrega autonom (POST/ api/contracts/validate) y asigna mangelhafte Resultados automático a la Nachbesserung desde.

Beneficio: Strikte Einhaltung de Calidad estándar en el Agentes Equipo y Vermeidung unfertiger Entre nivel en el HITL-Board.

Coste y contrapartida (Trade-off): Será la Mindestlänge demasiado alto angesetzt (> 300 Zeichen), se rechazae preciso

Kurzantworten rechazado y resolver teure Nacharbeits-Schleifen de.

¿Cuándo desactivar? y umbrales: Auto-Reject apagar, wenn Subagenten también knappe Estado- o Ja/Nein-Antworten zurückgeben pueden. | Umbral valores: Mín.. Länge: < 30 = lässt Platzhalter mediante | > 300 = rechaza knappe Faktenantworten desde (Std: 100 Zeichen). Máx. Turnaround: Std 60 Mín..

88. Central Autonomie-& Schwellenwert-Steuerung (backend/autonomy_settings.py)

Problema: Feste Umbral valores en el Programmcode impedir una rápida Anpassung de Seguridad-, Sandbox- y Resilienz-Regeln en el laufenden Empresa.

Mecánica: Bündelt todos 10 Autonomie-Gruppen (Concurrency, Loop-Killer, Selbstheilung, Docker- Sandbox, Time-Travel-Snapshots, Konsens-Gate, War-Room, SLA- Verträge, Inbox/Standup y Flotten-Hygiene) en settings.json y sincronizado ella sobre GET/POST/ api/settings/autonomy-modules con al System Control Center.

Beneficio: Cada Protección- y Autonomie-Modul se puede a la Laufzeit con un clic un- o apagar y exakt en el gewünschte Riesgo- y Ressourcenprofil feinjustieren.

Coste y contrapartida (Trade-off): Un defekter Container puede mediante Auto-Restart en una Crash-Loop geraten; el visuelle Browser-Audit inicia Chromium (+ 300 MB RAM, + 4 Sek. Dauer).

¿Cuándo desactivar? y umbrales: Auto-Restart mientras/ durante manual Container-Wartung apagar; Browser-Audit en reinem Backend-Betrieb desactivar. | Umbral valores: DB- Respaldo Días: < 3 Días = knappe Historie | > 30 Días = ~ 500 MB + Respaldo Memoria (Std: 7 Días).

13. Núcleo de rendimiento, escalado de throughput y eficiencia de tokens

89. Semantisches Prompt-& Response-Caching (backend/semantic_cache.py)

Problema: Wiederkehrende o fácil umformulierte Agentes Solicitud verursachen unnötige LLM- API- Costar y segundos largo Esperar tiempo.

Mecánica: Calculado para cada Prompt un SHA- 256- Hash as í como un L 2- normalisierten Wort-/3-Gramm-Vektor en SQLite y entrega en una Cosine-Ähnlichkeit > = 0.95 de inmediato el guardado Response-Treffer.

Beneficio: Respuesta tiempo bajo 10 Millisekunden y 100% Token-Ersparnis en semantisch identischen Solicitud.

Coste y contrapartida (Trade-off): Es la Cosine-Schwelle demasiado bajo (< 0.92), übersieht el Caché feine Bedeutungsunterschiede (por ejemplo ' eliminar Prueba- DB ' vs. ' eliminar Prod- DB ') y entrega falso o obsoleto Responder.

¿Cuándo desactivar? y umbrales: Apagar en Tareas con Echtzeit-Daten (Börsenkurse, Live-Logs, Sistema estado) o wenn cada Respuesta frisch genera serán debe. | Umbral valores: Cosine-Schwelle: < 0.92 = falso Responder de Caché! | > 0.98 = apenas Treffer (Std: 0.95). TTL: Std 24 h. Máx. Einträge: Std 500.

90. Paralelo Map-Reduce Sub-Tasking/ Fan-Out& Fan-In (backend/map_reduce_executor.py)

Problema: Sequenzielle Abarbeitung mucho Einzeldokumente o Teilfragen conduce a linearem Zeitwachstum y largo Esperar tiempo.

Mecánica: Comparte Listen-Aufträge automático en hasta a N paralelo Asyncio-Worker (Semaphore-gesteuert) en y dirige la Teilergebnisse en el Reduce-Schritt zusammen.

Beneficio: Vervielfacht el Throughput en Dokumenten-, Recherche- y Code-Batch-Analysen sin Überlastung el Event-Loop.

Coste y contrapartida (Trade-off): Genera N-fache simultáneo API- Carga (Peligro de HTTP- 429 Rate-Limits al Provider) y ~ 20-35% Token-Overhead mediante la a continuación Reduce-Synthese.

¿Cuándo desactivar? y umbrales: Apagar en strikten API- Rate-Limits o wenn la Teilaufgaben eng voneinander abhängen y sequenziell aufeinander aufbauen deben. | Umbral valores: Máx. Worker: > 8 = Rate-Limit-Gefahr (Std: 4). Chunk-Timeout: Std 30 s. Desde Elementen: Std 3.

91. Speculative Fast-Routing& Latenz-Hedging (backend/speculative_hedger.py)

Problema: Einzelne lento Cloud-Requests (Tail-Latency-Spikes) bloquear la total Agenten-Ausführung.

Mecánica: Inicia tras Flujo de hedge_delay_seconds (por ejemplo 2. 5 s) automático un paralelo Ersatz-Call en un

rápido Fallback-Modell y asume el primero eintreffende Resultado.

Beneficio: Eliminiert Hänger mediante lento API- Endpunkte y stabilisiert la Respuesta tiempo en el 99. Perzentil.

Coste y contrapartida (Trade-off): Wenn el Primärmodell breve tras al Hedge-Start doch aún responde, serán ambos Requests abgerechnet (hasta a 2 x Token-Kosten en lento Prompts).

¿Cuándo desactivar? y umbrales: Apagar en knappem API- Presupuesto o wenn lento Reasoning-Modelle genutzt serán, la regulär > 10 Sek. Denkzeit necesitar. | Umbral valores: Hedge-Verzögerung: < 1. 5 s = casi siempre doppelte API- Costar! | > 8 s = apenas Latencia Protección (Std: 2. 5 s).

92. Dinámico Context-Compaction& Hierarchisches Summarizing (backend/context_compactor.py)

Problema: Largo Agentes Sesión blähen el Contexto ventana en, ralentizar el Prompt-Prefill y aumentar la Costar por Turn drastisch.

Mecánica: Extrahiert desde un einstellbaren Token-Schwellenwert todos harten Fakten (Objetivos, Dateipfade, Decisiones, Error) en un kompakten [HIERARCHICAL_MEMORY_STATE]- Bloque y behält solo la jüngsten Alrededor de en el Volltext.

Beneficio: Ahorra 65-80% Kontext-Tokens en largo Sessions sin Pérdida importante Proyecto datos.

Coste y contrapartida (Trade-off): El Komprimierungslauf cuesta einmalig ~ 1.000 Tokens; exakte Code-Zeilen o pequeño Detailwerte de weit zurückliegenden Mensaje pueden en el Zusammenfassung verloren gehen.

¿Cuándo desactivar? y umbrales: Apagar, wenn el Agente wortwörtlich en muy frühe Mensaje derselben Sesión zurückgreifen debe. | Umbral valores: Token-Schwelle: < 3000 = vergisst Details a früh | > 24000 = alta Prompt-Kosten (Std: 6000). Letzte Turns behalten: Std 4.

93. SQLite WAL Connection-Pool& Async Write-Batching (backend/async_write_batcher.py)

Problema: Hunderte einzelne SQLite- INSERTs en paralelo Agenten-Läufen generar Disk-I/O-Spitzen y ' database is locked '- Konflikte.

Mecánica: Sammelt Telemetrie- y Audit-Ereignisse en un Thread-sicheren RAM- Ringpuffer y schreibt ella gebündelt v í a executemany () en el WAL- Modus.

Beneficio: Reducido Festplatten-Schreibzugriffe um alrededor de 80% y hält la Haupt-Event-Loop frei de Blockaden.

Coste y contrapartida (Trade-off): En el Caso de un harten Stromausfalls o kill- 9 ante al nächsten Flush-Intervall gehen la en el RAM gepufferten Einträge el letzten 1-5 Segundos verloren.

¿Cuándo desactivar? y umbrales: Apagar, wenn cada einzelne Registro Entrada de inmediato y sin Sekundenverzögerung synchron en el Disco duro estar debe. | Umbral valores: Batch-Größe: < 5 = mucho Disk-Writes | > 100 = más Pérdida en Crash (Std: 25). Flush-Intervall: Std 2. 0 s.

14. Arquitectura moderna de memoria y RAG

94. Hybrid-Search con BM25 FTS5& Reciprocal Rank Fusion (backend/hybrid_search_engine.py)

Problema: Reine Vektorsuche encuentra semantisch ähnliche Texte, scheitert sin embargo a menudo en exakten Fehlercodes, Función nombre o Seriennummern.

Mecánica: Combinado SQLite FTS5 Volltext-Ranking (BM25) y Cosine-Vektor-Ähnlichkeit sobre Reciprocal Rank Fusion (RRF).

Beneficio: Vereint exakte Keyword-Treffer y semantisches Verständnis en una einzigen, hochpräzisen Trefferliste.

Coste y contrapartida (Trade-off): Doppelte Index-Abfrage aumentado la Such-Latenz um ~ 15-40 ms; un a alta Top-K (> 10) füllt el Agenten-Prompt con tausenden Zusatz-Tokens.

¿Cuándo desactivar? y umbrales: Casi nunca apagar- como máximo Top-K en 3-5 reducir, wenn Token-Kosten por Solicitud minimizado serán deben. | Umbral valores: RRF- Konstante K: Std 60. BM25- Gewicht: 0.0 = solo Vektor | 0.5 = Balance | 1.0 = solo Stichwort (Std: 0.50). Top-K: Std 5.

95. Local Knowledge-Graph/ Tripel-Speicher (backend/knowledge_graph_store.py)

Problema: Flache Text-Chunks erfassen ninguna estructurado Dependencia (quién gestiona cuál Sistema o cuál

Componente usa cuál Servicio).

Mecánica: Extrahiert y guarda Subjekt-Prädikat-Objekt-Tripel con Konfidenzscore en SQLite y permite mehrstufige Graph-Traversierungen (Multi-Hop).

Beneficio: Agentes detectar Sistema- y Organisationszusammenhänge sobre mehrere Nivel hinweg.

Coste y contrapartida (Trade-off): Automático Tripel-Extraktion cuesta al Guardar ~ 500 Zusatz-Tokens. Desde > 2 Traversal-Hops explodiert la Anzahl el Nachbarknoten exponentiell.

¿Cuándo desactivar? y umbrales: Auto-Extraktion apagar en reinem Kurzzeit-Chat sin langfristigen Wissensaufbau; Hops en maximal 2 limitar. | Umbral valores: Máx. Hops: 1 = directo Nachbarn | 2 = optimal | > = 3 = Knoten-Explosion! (Std: 2). Mín.. Konfidenz: Std 0.70.

96. Agentic Corrective RAG/ CRAG (backend/corrective_rag.py)

Problema: Clásico RAG reicht irrelevante Suchtreffer ungeprüft en el Sprachmodell weiter y provoziert mediante ello Fehlantworten.

Mecánica: Evaluado cada recuperado Dokument-Chunk contra un Relevanz-Schwellenwert (0.45) y dirige en schwachen Treffern automático un Query-Rewrite con Synonym-Expansion mediante.

Beneficio: Filtert Wissensrauschen ante el Antwortgenerierung heraus y aumentado la Trefferqualität en unklaren Preguntar.

Coste y contrapartida (Trade-off): Cada Query-Umformulierung cuesta 1 adicional LLM- Call (+ 1,5 hasta + 4 Sek. Latencia). Es la Relevanz-Schwelle demasiado alto (> 0.70), dreht CRAG unnötige Extrarunden.

¿Cuándo desactivar? y umbrales: Apagar, wenn la Saber base de datos pequeño y sauber gepflegt es o rápida Respuesta tiempo bajo 2 Segundos gefordert son. | Umbral valores: Relevanz-Schwelle: < 0.30 = lässt schwache Fuentes mediante | > 0.70 = endlose Such-Schleifen (Std: 0.45). Máx. Rewrites: Std 2.

97. 2- Nivel Core-Memory tras MemGPT/Letta-Vorbild (backend/core_memory_manager.py)

Problema: Importante Nutzerpräferenzen y Proyecto objetivos gehen verloren, en cuanto ella de al kurzlebigen Chat-Fenster herausfallen.

Mecánica: Verankert editierbare Pinned-Working-Memory-Blöcke (< CORE _ WORKING _ MEMORY >) permanente en el System-Prompt, separado del grande Archivo Memoria.

Beneficio: Garantiert un permanentes, del Agentes incluso pflegbares Kerngedächtnis sobre beliebig mucho Sesión hinweg.

Coste y contrapartida (Trade-off): Cada angepinnte Bloque acreditado en absolut cada LLM- Aufruf permanente Prompt-Tokens (10 Blöcke × 800 Zeichen ≈ 2.000 Tokens Grundlast por Mensaje).

¿Cuándo desactivar? y umbrales: Apagar o Block-Anzahl en 3-5 reducir, wenn pequeño Modelos con engem Contexto ventana o knappe Token-Budgets genutzt serán. | Umbral valores: Máx. Blöcke: > 15 = hoher Token-Grundverbrauch (Std: 10). Máx. Zeichen/Block: < 300 = schneidet Regular desde | > 1500 = verstopft Prompt (Std: 800).

98. Automático Citation-& Quellen-Pinning (backend/citation_pinner.py)

Problema: Sin directo Fuentes remitir es para el Usuario no überprüfbar, de cuál Dokument una Faktenaussage del Agentes stammt.

Mecánica: Ordnet Sätze el Respuesta por Token-Overlap el recuperado Quell-Dokumenten a, fügt Inline-Belege ([Quelle: ID]) un y verifica la Mindest-Belegquote.

Beneficio: Macht cada Aussage inalterable trazable y deckt unbelegte Behauptungen de inmediato en.

Coste y contrapartida (Trade-off): Aumentado el Output-Token-Verbrauch um ~ 10-15%; una demasiado alta Mindest-Abdeckung (> 80%) dirige en kreativen o zusammenfassenden Preguntar a Fehlwarnungen.

¿Cuándo desactivar? y umbrales: Apagar en freiem Brainstorming, Code-Generierung o lockerem Alltags-Chat sin Dokumentenbezug. | Umbral valores: Mín.. Abdeckung: < 30% = unbelegte Aussagen | > 85% = Fehlwarnungen en Zusammenfassungen (Std: 60%).

15. Fiable Ausführung& Determinismus (Durable Execution)

99. Structured Outputs& JSON- Esquema-Garantie (backend/structured_output_enforcer.py)

Problema: Sprachmodelle entregar a veces ungültiges JSON (Markdown-Rahmen, fehlende Klammern o falso Datentypen), por lo cual nachgelagerte Code-Pipelines abstürzen.

Mecánica: Repariert Syntaxfehler en el Roh-String automático y erzwingt todos Obligación campo y Datentypen del entregado Ziel-Schemas.

Beneficio: Garantiert 100% maschinenlesbare, typensichere JSON- Payloads entre Agentes y Backend-Schnittstellen.

Coste y contrapartida (Trade-off): Cada Auto-Reparatur-Schleife cuesta + 1 hasta + 3 Sek. Latencia y adicional Tokens. Strikte Esquema-Validierung rechaza Responder también por harmloser Zusatzfelder desde.

¿Cuándo desactivar? y umbrales: Strikte Validierung apagar, wenn API- Endpunkte o Script también con flexiblen o parcial JSON- Campo eludir pueden. | Umbral valores: Esquema-Prüfung: Strikt vs. Tolerant (Std: Strikt). Máx. Reparaturen: 1-2 = repariert 98% aller Tippfehler | > 3 = verschwendet Tokens (Std: 2).

100. Durable Execution Checkpointing/ Pause& Resume (backend/durable_checkpoint_manager.py)

Problema: Bricht un 10- schrittiger Recherche- o Build-Auftrag en Paso 8 mediante un Neustart desde, tuvo que bisher todos 7 Vorarbeiten teuer repetido serán.

Mecánica: Sichert tras cada cerrado Paso el completo Variable- y Avance estado transaktional en SQLite.

Beneficio: Unterbrochene Langläufer setzen exakt en el letzten válido Checkpoint wieder en, sin Arbeit o Tokens doppelt a verbrauchen.

Coste y contrapartida (Trade-off): Checkpointing en cada einzelnen Paso (N = 1) genera spürbare SQLite-Schreiblast. Auto-Resume al Booten puede obsoleto Tasks del Vortag ungewollt wieder anfeuern.

¿Cuándo desactivar? y umbrales: Auto-Resume apagar, wenn unterbrochene Tareas tras un Neustart solo manual verificado y aprobado serán deben. | Umbral valores: Todos N Pasos: 1 = absolut absturzsicher, más Disk-I/O | 3-5 = schont SSD (Std: 1). Aufbewahrung: Std 14 Días.

101. Idempotency-Keys& Tool-Call-Deduplizierung (backend/idempotency_guard.py)

Problema: En Netzwerk-Retries o Agenten-Schleifen existe la Peligro, dass dieselbe E-Mail, Factura o Webhook-Aktion mehrfach ausgelöst será.

Mecánica: Vergibt para cada mutierenden Tool-Call un SHA- 256- Idempotency-Key en el SQLite- Ledger y bloqueado identische Consecuencia llamar dentro de el TTL.

Beneficio: Impide doppelte Außenwirkungen fiable tras al Vorbild moderno Zahlungs-Gateways (Stripe-Prinzip).

Coste y contrapartida (Trade-off): Wenn el Usuario exakt denselben Comando dentro de el Sperrfrist (Estándar 24 h) absichtlich un zweites Mal ejecutar quiere, bloqueado el Guard.

¿Cuándo desactivar? y umbrales: TTL-Stunden en 1 h senken o kurzzeitig apagar, wenn identische Acción en el Testbetrieb mehrfach hintereinander ausgeführt serán deben. | Umbral valores: TTL (Stunden): < 1 h = breve Duplikatschutz | > 48 h = bloqueado gewollte Reintento (Std: 24 h).

102. Dry-Run/ Shadow-Mode para Agenten-Aufträge (backend/dry_run_simulator.py)

Problema: Nueva o complejo Agenten-Aufträge quisiera se ante el scharfen Ausführung a menudo solo sin Riesgo en echten Produktionsdaten probar.

Mecánica: Fängt en el Shadow-Mode todos schreibenden Archivo-, Base de datos- y API- Comando desde y registrado stattdessen un detaillierten Mutations-Vorschauplan.

Beneficio: Permite gefahrlose Trockenübungen y Riesgo Auditoría ante el definitivo Freigabe.

Coste y contrapartida (Trade-off): SOLANGE ACTIVO, serán NINGUNA ECHTEN ARCHIVOS GESCHRIEBEN Y NINGUNA ECHTEN APIS AUSGEFÜHRT! Vergisst se el Interruptor, wirkt el Sistema tras außen hin ' tot '.

¿Cuándo desactivar? y umbrales: En el normal Produktivbetrieb zwingend AUSGESCHALTET lassen! Solo selectivo para Trockenübungen (Dry-Runs) y Seguridad Auditoría activar. | Umbral valores: Hauptschalter standardmäßig DE (false). Solo para aislado Testläufe activar.

103. Dead-Letter-Queue (DLQ) con Auto-Replay-Manager (backend/dead_letter_queue.py)

Problema: Fehlgeschlagene Webhooks o asynchrone Hintergrund-Jobs gehen en kurzzeitigen Drittanbieter-Ausfällen sin Auffangbecken spurlos verloren.

Mecánica: Guarda cada gescheiterten Trabajo samt Original-Payload y Error motivo en el DLQ-Tabelle y repetido lo con exponentiellem Backoff.

Beneficio: Ningún Encargo se trata verloren; fehlgeschlagene Tasks se pueden en todo momento einzeln o gesammelt erneut abspielen.

Coste y contrapartida (Trade-off): En permanente fehlerhaften Aufträgen (por ejemplo ungültiger API- Key) verbrauchen la Wiederholungsversuche unnötig Ressourcen; zeitversetzte Replays pueden Acción verspätet auslösen.

¿Cuándo desactivar? y umbrales: Auto-Replay apagar, wenn fehlgeschlagene Aufträge exclusivamente manual gesichtet y einzeln aprobado serán deben. | Umbral valores: Máx. Retries: 1 = bricht en breve Fallo desde | > 5 = staut tote Jobs en (Std: 3). Backoff-Basis: Std 10 s (10 s- > 20 s- > 40 s).

16. Seguridad, privacidad y guardarraíles empresariales

104. Bidirektionaler PII-Scrubber& Re-Hydration (backend/pii_scrubber.py)

Problema: Serán E-Mails, Telefonnummern o IBANs en el Klartext en externo Cloud-LLMs übertragen, drohen DSGVO- Verstöße y ungewollter Datenabfluss.

Mecánica: Ersetzt sensible Personendaten ante al API- Aufruf local mediante Platzhalter ([EMAIL_1], [IBAN_1]) y tauscht esta en el eintreffenden Respuesta wieder contra la echten Valores de.

Beneficio: Cloud-Modelle sehen niemals echte Personendaten, mientras/ durante el Usuario en situ sin embargo completo Dokumente y Responder erhält.

Coste y contrapartida (Trade-off): Wenn el LLM el Platzhalter en el Antworttext fácil abwandelt, propone la Rückübersetzung (Rehydrierung) fehl. Adem á s puede Regex-Maskierung a veces Code-Strings verfälschen.

¿Cuándo desactivar? y umbrales: Apagar, wenn exclusivamente local Modelos (Ollama) genutzt serán o el LLM zwingend la echten E-Mail-Domains/Namen analizar debe. | Umbral valores: Granulare Interruptor para E-Mails, Telefonnummern, IBANs y automático Rehydrierung (todos standardmäßig activo).

105. Egress-Firewall& Domain-Allowlisting para Agentes (backend/egress_firewall.py)

Problema: Sobre versteckte Prompt-Injections en Webseiten podría Agentes angewiesen serán, interno Datos por HTTP- Request en fremde Angreifer-Server enviar.

Mecánica: Verifica cada ausgehende Ziel-URL contra la configurado Domain-Allowlist y bloqueado unautorisierte Hosts as í como rohe IPv 4- Adressen.

Beneficio: Unterbindet Daten-Exfiltration en Red nivel incluso en manipulierten Entrada.

Coste y contrapartida (Trade-off): Solange allowlist_only activo es, será cada nueva Webseite, API o Documentación, la no explícito en el Domain-Liste está, en Web-Recherchen hart bloqueado.

¿Cuándo desactivar? y umbrales: Apagar (o necesita Domains ergänzen), wenn el Research-Agent frei en el abierto Web recherchieren debe. | Umbral valores: Permite Domains: Kommagetrennte Whitelist. Roh- IP- Blockade protege ante directo IP- Exfiltrationen.

106. Granulare Agentes- RBAC& Datei-Scope-Jails (backend/agent_rbac_jail.py)

Problema: Wenn cada Sub-Agent pleno Schreibzugriff en el total Proyecto directorio besitzt, puede un Frontend-Agent versehentlich Backend-Kernel-Dateien o. env-Schlüssel überschreiben.

Mecánica: Bindet cada Agentes rol en una feste Herramienta lista y un permite Verzeichnis-Jail (por ejemplo static/ para Frontend-Agenten).

Beneficio: Setzt el Prinzip minimaler Derechos (Least Privilege) para cada einzelnen Proceso en el Empresa sistema mediante.

Coste y contrapartida (Trade-off): Impide, dass un Administrator-Agent legitim Configuración archivos fuera de del Proyecto carpeta espera o. env-Vorlagen directo überprüft.

¿Cuándo desactivar? y umbrales: Solo para dedizierte Systemwartungs-Aufgaben kurzzeitig lockern; el. env-Schutz debería en el Normal empresa siempre activo permanecer. | Umbral valores: Interruptor para Path-Jail,. env-Sperre y Systemordner-Sperre (/ etc,/ root,/ proc).

107. Deterministischer Output-Linter& Policy-Checker (backend/output_policy_linter.py)

Problema: Sprachmodelle verfallen gelegentlich a pesar de System-Prompt en künstliche KI- Floskeln o generar riskante Shell- Snippets.

Mecánica: Scannt el genera Text en tiempo real mittels regulärer Ausdrücke, elimina Sycophancy-Opener/AI-Slop y entschärft destruktive Comando.

Beneficio: Sichert sprachliche Präzision y technische Seguridad sin adicional LLM- Prüfaufruf.

Coste y contrapartida (Trade-off): El Destruktiv-Filter puede también harmlose Aufräum-Skripte o gewollte Base de datos Migración bloquear, wenn en ello Comando como DROP o rm- rf vorkommen.

¿Cuándo desactivar? y umbrales: Destruktiv-Blocker kurzzeitig apagar, wenn selectivo Server-Aufräumskripte o SQL- Reset-Migrationen creado serán. | Umbral valores: Interruptor para KI- Floskeln eliminar, Destruktive Comando bloquear y Auto-Bereinigung.

108. A prueba de manipulación Execution Receipts/ SHA- 256- Quittungen (backend/execution_receipt_ledger.py)

Problema: Para Compliance-Audits (EU AI Act/ ISO 42001) reichen simple Text-Logs no de, da ella nachträglich verändert serán pueden.

Mecánica: Verkettet cada Task-Abrechnung (Modelo, Tokens, USD-Kosten, ausgeführte Herramienta) con al SHA-256- Hash del Vorgängereintrags en una Blockchain-ähnlichen Kette.

Beneficio: Cada nachträgliche Manipulation en Costar- o Decisión registro cae en el Integritätsprüfung de inmediato en.

Coste y contrapartida (Trade-off): Verursacht minimalen Rechen- y Speicher-Overhead (~ 2 ms y ~ 2 KB SQLite-Memoria por Task); la Hash-Kette crece sobre Meses continuo en.

¿Cuándo desactivar? y umbrales: Puede en el Produktivbetrieb permanente activado permanecer; solo en extrem speicherlimitierten Kleinstsystemen apagar. | Umbral valores: Hash-Verkettung (SHA-256) + detaillierte Kosten-Aufschlüsselung por Lauf.

17. Autooptimización, evaluación e inteligencia de enjambre

109. Automático Prompt-Optimizer tras DSPy/TextGrad-Prinzip (backend/prompt_optimizer.py)

Problema: Estático System-Prompts repetir dieselben Error siempre wieder, solange ningún Persona manual nachbessert.

Mecánica: Wertet reale Error Registros una Rol de, detecta systematische Schwächen y genera selectivo Guardrail-Zusatzregeln para el System-Prompt.

Beneficio: Agentes aprender continuo de gescheiterten Läufen y härten su Instruktionen selbstständig.

Coste y contrapartida (Trade-off): Es Auto-Apply activo, puede una fehlerhaft abgeleitete Regla el Verhalten del Agentes permanente verzerren (Prompt-Drift) y el System-Prompt aufblähen.

¿Cuándo desactivar? y umbrales: Auto-Apply en el Produktivbetrieb ausgeschaltet lassen, con ello vorgeschlagene Prompt-Patches solo tras menschlicher Verificación asumido serán. | Umbral valores: Desde Error: 1 = überreagiert en Einzelfehler | > 8 = aprende muy träge (Std: 3). Máx. Regular: > 10 = bläht System-Prompt en (Std: 5).

110. Gold-Standard Regression-Test-Suite/ Eval-Runner (backend/eval_regression_runner.py)

Problema: Una vermeintlich pequeño Cambio en el System-Prompt o Modelo puede bestehende Seguridad- o Formatregeln unbemerkt empeorar.

Mecánica: Dirige ante el Übernahme neuer Ajuste automatizado Gold-Standard-Testfälle de y verifica Bestehensquote as í como verbotene Modelo.

Beneficio: Impide Qualitäts-Regressionen en el Produktivbetrieb mediante un objektives Quality-Gate.

Coste y contrapartida (Trade-off): Cada completo Eval-Durchlauf feuert todos depositado Test-Prompts contra la

LLM- API (cuesta seg ú n Testumfang ~ 5.000-25.000 Tokens y 15-60 Sek. Laufzeit).

¿Cuándo desactivar? y umbrales: Deploy-Blockade apagar, wenn rápida experimentelle Prompt-Tests sin Wartezeit realizado serán. | Umbral valores: Mín.. Pass-Rate: < 75% = lässt Verschlechterungen mediante | 100% = bloqueado ya en pequeño Abweichungen (Std: 90%).

111. Multi-Armed Bandit Modell-Router (backend/bandit_model_router.py)

Problema: Feste Modell-Zuweisungen reaccionar no sobre ello, wenn un Cloud-Provider plötzlich lento será o aumentado Fehlerraten muestra.

Mecánica: Bepunktet cada Modelo laufend tras realer Erfolgsquote (60%) y Geschwindigkeit (40%) y elige dinámico el besten Kandidaten.

Beneficio: Maximiert Respuesta calidad y Tempo automático anhand echter Laufzeit-Telemetrie.

Coste y contrapartida (Trade-off): Mediante la Explorationsrate (Epsilon, por ejemplo 0.15 = 15%) prueba el Router absichtlich siempre wieder alternativa Modelos de, la en el Einzelfall lento su pueden.

¿Cuándo desactivar? y umbrales: Apagar (o Epsilon en 0.00 setzen), wenn para cada Lauf un 100% festes, vorhersagbares Modelo erzwungen serán debe. | Umbral valores: Epsilon: 0.00 = usa stur el beste Modelo | > 0.30 = probiert demasiado a menudo schwächere Modelos (Std: 0.15). Erfolgs-/Latenz-Gewicht: Std 0.60/ 0.40.

112. Dinámico Ephemeral-Team-Spawning (backend/ephemeral_team_spawner.py)

Problema: Un einzelner Generalisten-Agent es en grande Querschnittsaufgaben (Arquitectura + UI + Security + QA) rápido überfordert.

Mecánica: Rekrutiert passend al Missions-Briefing una temporal Spezialisten-Task-Force y löst ella tras despachado Mission wieder en.

Beneficio: Bündelt Spezialwissen bedarfsgerecht sin permanente Ressourcen-Overhead.

Coste y contrapartida (Trade-off): Un 4- köpfiges Ad-hoc-Team vervielfacht el Token-Verbrauch (3 x hasta 5 x) y necesita adicional Koordinations-Overhead entre el Teammitgliedern.

¿Cuándo desactivar? y umbrales: Apagar en simple Einzelaufgaben o knappem Token-Budget; Máx.. Teamgröße en el Alltag en 3-4 limitar. | Umbral valores: Máx. Teamgröße: 2-4 = ideal | > 5 = hoher Kommunikations-Overhead& 5 x Token-Verbrauch (Std: 4).

113. Live-Ressourcen-Protector& Host-Backpressure (backend/resource_backpressure.py)

Problema: Paralelo Container, Browser-Audits y local Procesos pueden en Lastspitzen el Host- RAM o la CPU überlasten (OOM-Kill).

Mecánica: Supervisado CPU-, RAM- y Disk-Metriken en tiempo real y drosselt bajo priorizado Hintergrund-Tasks desde 85% Auslastung automático.

Beneficio: Protege el Servidor fiable ante Abstürzen mediante Überlastung y hält crítico Kernprozesse en todo momento reaktionsfähig.

Coste y contrapartida (Trade-off): Son la Umbral valores demasiado bajo eingestellt (CPU < 70% o RAM < 70%), serán Hintergrund-Aufgaben ya en normal breve Lastspitzen ständig ausgebremst.

¿Cuándo desactivar? y umbrales: No completo apagar- stattdessen en starker Hardware la CPU-/RAM-Schwellen en 90% anheben. | Umbral valores: Máx. CPU/RAM: < 70% = drosselt en normal Arbeit | > 92% = OOM-Gefahr (Std: 85%). Mín.. freie Disk: Std 2.0 GB.

18. Pilar 3: economía y ERP (alfa) y suite de mandantes

Módulo / vista	Alcance funcional y características técnicas (v0.5.1)
Direcciones y CRM + sincronización PocketBase	Central Kontakt-, Debitoren- (10000 +) y Kreditorenstamm (70000 +), 360 °- Kontakt-Drawer, Multi-Channel-Timeline, Kalender/Wiedervorlagen as í como LinkedIn-& Medien-Sync sobre PocketBase (Ports 3005/8090/8092).

Módulo / vista	Alcance funcional y características técnicas (v0.5.1)
Artículos y servicios (ART)	Stammdatenkatalog desde ART- 1001 para Servicio prestación, Stundensätze, Pauschalen, SaaS- Abonnements as í como physische Producto con Lagerbestandsführung.
Operaciones y contratos	Durchgängige Belegkette Oferta (ANG-YYYY-NNNN) → Encargo (AB-YYYY-NNNN) incl.. gewichteter Deal-Pipeline, Umsatz-Forecast y Vertrags-Fristenradar (30/14/7-Tage-Alarme).
Contabilidad y DATEV	Ausgangs- y Eingangsbelege tras § 14 UStG, GiroCode-Zahlungs- QR, Finanz-Analytics, automático Mahnwesen (Dunning Engine) y EXTF/CSV-Export para DATEV.
Aislamiento corporativo y por mandante	Mehrere eigene Unternehmungen (company_id) con physisch separado SQLite- Base de datos en el WAL- Modus, eigenen Nummernkreisen, Briefbögen y Vorlagen-Editor.

19. Arquitectura-, Security-& Deployment-Features (v 0. 5.0- v 0. 5.1)

Función / subsistema	Implementación y beneficio operativo (v0.5.1)
Arquitectura modular de enrutadores	Auslagerung en dedizierte FastAPI- Router bajo archon/routers/ (main.py de 16.254 en 1.875 Fila reducido,- 88%) y central Configuración capa archon/core/config.py.
Endurecimiento de seguridad (Archon Hardened)	Schließung de 25 crítico y 68 alta Audit-Befunden; Starlette Threadpool-Entlastung, gehärtete UI- DOM- Pfade y Klasse-A Docker- Admin-Proxy para hermes_updater.
Gestión de usuarios RBAC (17.10)	Granulare Roles (admin, operator, viewer) sobre backend/auth_service.py con 100.000 Alrededor de PBKDF2-HMAC-SHA256 Passwort-Hashing y Single-User/Multi-User-Modus.
Actualización del sistema en 2 fases (17.11)	Inmediato Mostrar local Version/HEAD v í a? local_only = true (~ 0,25 s) plus asynchroner GitHub- Abgleich, Pre-Update SQLite Online-Snapshots y 1- Klick-Rollback.
Proxy AnythingLLM y stack Chroma	Nahtlose Einbettung de AnythingLLM en la Central biblioteca sobre/ anythingllm-proxy incl../ assets/ * Fast-Path y local ChromaDB Vektor-Index.
Instalador portable en 1 clic	Multiplataforma Erstinstallation sobre setup. bat, setup. ps 1 y install.sh con docker-compose.yml,. env. example, INSTALL _ AGENTE. md y 9- sprachiger GitHub- Doku.
Puerta de calidad de cuatro ojos y zona de pruebas de código	Automático Zweitprüfung en el Kanban ante Ticket-Abschluss as í como interaktive Code-Sandbox en el Showroom (4.4.1) a la Live-Vorschau genera Artefakte.

20. Glosario alfabético e índice de términos

Alphabetisches Término directorio aller Kernmodule, Arquitectura componente y Features (v0.5.1) con exakten Seitenzahlen.

Función / término	Descripción breve	Página(s)
Anti-AI-Slop y STE100	Stil- y Wortfilter a la Vermeidung unnötiger Floskeln y Einsparung de Output-Tokens.	—
Archon Hardened (v0.5.1)	Seguridad- y Stabilitäts-Release con modularer Router-Struktur y cerrado Audit-Befunden.	p. 3, 31
Arquitectura del enrutador (archon/routers)	Modulare Backend-Aufteilung en schlanke FastAPI- Router (- 88% Dateigröße en main.py).	—
Bot Screen (navegador web)	Visueller Ausführungsmonitor para Browser-Interaktionen v í a Playwright.	—
Búsqueda híbrida (FTS5 + RRF)	Kombination de BM25- Volltextsuche y Vektorsuche por Reciprocal Rank Fusion.	—
Caché semántica	24 h-Zwischenspeicherung inhaltlich ähnlicher Prompts a la Token-Einsparung.	—
Cadena documental ERP (ANG -> AB -> RE)	Vinculado Vertriebs- y Buchhaltungsdokumente incl.. Pipeline-Forecast y Mahnwesen.	—
Capacidad corporativa y multiempresa	Physische Datenbank-Trennung mehrerer Gesellschaften por company_id.	—
ChromaDB	Local Vektordatenbank para semantisches Dokumenten-Retrieval en Pilar 2.	p. 31
Claves de idempotencia y dry-run	Protección ante doppelter Tool-Ausführung as í como Simulationsmodus sin Schreibzugriff.	—
Cola de mensajes fallidos (DLQ)	Error cola con automático Reintento dirección para gescheiterte Jobs.	—
Compactación de contexto y LRU-K	Speicherauslagerung y Komprimierung largo Chat-Kontexte en Erreichen del RAM- Limits.	—
Consolidación del ciclo de sueño	Nächtliche Deduplizierung y Langzeit-Verdichtung del Agenten-Gedächtnisses.	—
Contratos SLA (aplicación de contratos)	Formale Übergabe- y Qualitätszusicherungen entre spezialisierten Agentes.	—
Cortafuegos de salida	Ausgehende Red- y Domain-Kontrolle para Agenten-Toolaufrufe.	—
Decision Engine (55 marcos)	Estrategia módulo para estructurado Boardroom-Debatten sobre 9 Methodik-Kategorien.	—
Depurador de PII y rehidratación	Bidirektionale Anonymisierung sensibler Personendaten ante externo LLM- Calls.	—
Ejecución duradera y viaje en el tiempo	Unterbrechbare Langläufe con SQLite- Checkpoints y schrittweisem Execution-Replay.	—
Enrutador de modelos Bandit	Adaptiver Router (Multi-Armed Bandit) a la dinámico Modellwahl tras Trefferquote y Costar.	—
Enrutador JEV (intención 0 tokens)	Deterministischer Vorfilter sin KI- Costar para eindeutige Kurzbefehle.	—

Función / término	Descripción breve	Página(s)
Enrutamiento de costes de 3 niveles	Automático Modellauswahl en LOW/ MEDIUM/ HIGH tras Aufgabenkomplexität y Presupuesto.	—
Estimador de costes pre-vuelo	Vorabberechnung espera Token-Kosten incl.. Task-Budget-Stopp en Überschreitung.	—
Exportación DATEV y GiroCode	EXTF/CSV-Schnittstelle para Buchhaltungsdaten y EPC-Zahlungs- QR en Factura.	—
Grafo de conocimiento	Local Tripel-Speicher para estructurado Entitätsbeziehungen junto a Vektordaten.	—
Hermes Master Orchestrator	Central Kern-Engine para Zielzerlegung, Delegation y Synthese en el Demonio en Port 8420.	p. 11
Malla de eventos y disparadores webhook	Evento controlado Verarbeitung eingehender Webhooks y Carpeta cambio.	—
MCP (Model Context Protocol)	Estandarizado Treiberarchitektur a la se Herramienta conexión.	p. 6, 14
Optimizador DSPy / TextGrad	Automático Verbesserung de System-Prompts anhand realer Evaluations-Metriken.	—
Planificador DAG	Zweistufige Ausführungsplanung abhängiger Teilaufgaben con paralelo Fan-Out/ Fan-In.	—
Plugins de Evey / Hermes	Modulare Sistema Extensión para Memoria, Delegation, Verifikation e Interfaz.	—
Pool de conexiones SQLite WAL	Schreibsicherer Multi-Thread-Datenbankzugriff sobre Write-Ahead Logging.	—
Pre-mortem y puerta de consenso	Simulado Fehler-Stresstest y Mehrfach-Agenten-Abstimmung ante crítico Freigaben.	—
Proxy de AnythingLLM	Local Einbettung de AnythingLLM + ChromaDB sobre/ anythingllm-proxy en el Central biblioteca.	—
Puerta de aprobación (HITL)	Menschlicher Prüfschritt ante externo E-Mails, Buchungen o crítico Archivo acceso.	—
Puerta de calidad de cuatro ojos	Unabhängige Verificación cerrado Kanban-Aufgaben mediante un Revisor-Agenten.	p. 31
Puerta de enlace IA OmniRoute	Multi-Provider-Gateway incl.. Free-Tier-Routing, Latency-Hedging y Eval-Arena.	—
RAG correctivo (CRAG)	Selbstprüfende Saber consulta con Relevanzbewertung ante Antwortgenerierung.	—
RBAC PBKDF2 / Argon2id	Roles- y Passwort-Absicherung en el System Control Center (Tab 17.10).	—
Registro de auditoría (cadena hash SHA-256)	Inalterable Protokollkette aller Sistema- y Agentes acción.	—
Research Lab	Mehrstufige Web- y Quellenrecherche con Evidenz-Triangulation.	p. 3, 6, 20
Supervisor de watchdog y deadlock	30- Sekunden-Überwachung hängender Tasks, Container y automático Selbstheilung.	—
System Control Center (11 pestañas)	Central Administrationskonsole incl.. Benutzer/RBAC y 2- Fases Sistema actualización.	p. 8, 24

Función / término	Descripción breve	Página(s)
Token Guard y exterminador de bucles	Echtzeit-Schutz contra Endlosschleifen (Jaccard-Prüfung) y Token-Überschreitungen.	—
Zona de pruebas de código efímera	Flüchtige, aislado Container-Laufzeit para se Python- y Skriptcode.	—