

ARCHON AGENTIC OS 2026 — Volledige FEATURELISTE

Systeem- & Module-Catalogus, Architectuuroverzicht en Functiematrix

Stand: 11. November 2026 | Versie: v0.5.1 („Archon Hardened“) | Taal: Duits

Systeem- & Module-Catalogus, Architectuuroverzicht en Functiematrix

© Michael Keller

Inhoudsopgave

1. Versionsstand & Release-Übersicht (v0.5.1) 3
2. System-Ansichten & Spezial-Studios (UI Views) 3
3. Token-Spar- & FinOps-Ökosystem (Kostenminimierung) 8
4. Kernel, Scheduling & Daemon-Architektur (Pillar 1) 11
5. Multi-Agenten-Prozessmodell, Hierarchie & Synthese (Pillar 2) 12
6. MCP-Treiber, Externe Dienste & Multimodale Werkzeuge (Pillar 3) 14
7. Gedächtnis, Datenbank-Hygiene & Obsidian 2nd Brain (Pillar 4) 15
8. Sicherheit, Zero-Trust Governance & System-Diagnose (Pillar 6) 17
9. Selbst-Evolution, Marktplätze & Auto-Dokumentation (Pillar 7) 19
10. Referenz-Matrix: Steuerbare Evey/Hermes-Plugins 19
11. Enterprise- & Resilienz-Architektur 21
12. Autonomie-, Sandbox- & Governance-Architektur 23
13. Performance-Core, Durchsatz-Skalierung & Token-Effizienz 24
14. Moderne Gedächtnis- & RAG-Architektur 25
15. Zuverlässige Ausführung & Determinismus (Durable Execution) 27
16. Sicherheit, Datenschutz & Enterprise-Guardrails 28
17. Selbst-Optimierung, Evaluation & Schwarm-Intelligenz 29
18. Säule 3: Wirtschaft & ERP (alpha) & Mandanten-Suite 31
19. Architektur-, Security- & Deployment-Features (v0.5.0 – v0.5.1) 31
20. Alphabetisches Glossar & Stichwortverzeichnis 32

© Michael Keller

1. Versionsstand & Releaseoverzicht (v0.5.1)

Versie	Codename	Wesentliche Architectuur- & Feature-Mijlpalen
v0.5.1	Archon Hardened	Modulare BijnaAPI-Router (main.py -88%), 25 kritische + 68 hoge Security-Befunde behoben, Docker-Admin-Proxy Klasse A, RBAC-Benutzerverwaltung (PBKDF2), 2-Fasen Systemupdate (?local_only=true), AnythingLLM Proxy-Integratie, portabler 1-Click-Installer.
v0.5.0	Wirtschaft & ERP (alpha)	Volledige Pijler 3 (CRM/PocketBase-Sync, Artikel/Diensten, Vorgänge ANG/VANAF, Rechnungswesen met DATEV & GiroCode, Corporate-Cliënten), Research Lab v2 & 55 Boardroom-Frameworks.
v0.3.x	Sentinel / Foundation	7-Pijlern OS-Kernel, 70 Specialisten-Kader, 34+ Evey-Plugins, FinOps 3-Tier-Routing, Ephemeral Code-Sandboxen, Replay Debugging, PII-Scrubber, Semantic Cache & FTS5 Hybrid Search.

2. Systeem-Ansichten & Spezial-Studios (UI Views)

1. Ansicht: Mission Control (Monitoring-Cockpit & Meldkamer)

Problem: Zonder zentrales Realtime-Cockpit fehlen de Overzicht over aktive Agenten, Token-Doorvoer, Tageskosten en blockierte Goedkeuringn.

Mechanik: Bundelt 5 vitale KPI-Kacheln (Flottenlast, Doorvoer TPM, Kostenwächter, Stabiliteit, Approval Gate), de 5-Kolommen-Board-Projektion, de Active Process Inspection Bar (3-Slot-Footer voor Heartbeat, Tool-Concurrency en Context Saturation), het 15-Minuten-Token-Aktivitätsband (SVG-Sparkline) en de Live-Audit-Stream.

Nut: *Levert een verzögerungsfreie 360°-Bewaking van de gesamten Besturingssysteems op een einzigen Scherm.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

2. Ansicht: Operations – Kanban Board & Task-Engine

Problem: Taken in reinen Chat-Verläufen gaan onder en lassen zich nog na Status nog na Verantwoordelijkheiden besturen.

Mechanik: 5 Levenscyclus-Kolommen (To-Do, In Bearbeitung, Review & QA, Blockiert, Afgesloten) direkt op kanban.db (Single Source of Truth). Ondersteunt konfigurierbare WIP-Limits pro Kolom, Prioritätsfilter (P0–P3), Agenten-Zuweisung, Zeiterfassung en 1-Klik-Obsidian-Verknüpfung. Integreert het 4-Augen Qualitäts-Gate: Voor Verschieben een Taak op 'done' controleert een Peer-Reviewer (Katharina Völk voor QM/Compliance of Robert) het Arbeitsergebnis op Vollständigkeit, Substanz en Handlungsfähigkeit (1–100% Score). Bij 'changes_requested' greift een Status-Sperre; een Human-in-the-Loop Override (force=True) übersteuert bij Bedarf.

Nut: *Gestructureerd alle operationele Projecten transparant en voorkomt Systemüberlastung via Work-in-Progress-Schranken.* Voorkomt unfertige Arbeitsstände in de 'done'-Status via zwingendes Vier-Augen-Review.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

3. Ansicht: Operations – Interaktives 2D-Organogram & Berichtslinien

Problem: Flache Listen van Agenten tonen geen Weisungsbefugnisse of Eskalationspfade bij blockierten Prozessen.

Mechanik: Visualiseert 56 Knoten en 55 Berichtslinien als interaktiven 2D-Graphen (Apex -> CEO Robert -> Fach-Leads -> Specialisten). Ondersteunt Drag & Drop voor de Umhängen van Vorgesetzten, Raster-Ausrichtung, Team-Karten-Ansicht en dauerhafte Speicherung in config/org_hierarchy.json.

Nut: *Definieert verbindliche Eskalations- en Delegationsketten, denen het Systeem bij Blockaden automatisch folgt.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

4. Ansicht: Operations – Interne Agenten-Communicatie (Funkverkehr)

Problem: Als Specialisten untereinander Teilaufgaben übergeben, überflutet dies ofwel de Nutzer-Chat of blijft unsichtbar.

Mechanik: Dedizierte Abhörzentrale met Kanalliste (#allgemein, #tech-dev, #legal, #marketing) en chronologischem Nachrichten-Feed alle Inter-Agenten-Absprachen uit kanban.db.

Nut: *Maakt de Samenwerking de Agenten-Vloot nachvollziehbar, zonder het primäre Nutzer-Postfach te belasten.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

5. Ansicht: Eingang & Triage (3-Kolommen HITL-Gatekeeper & Postfach)

Problem: Unkontrollierte Schreibaktionen van Agenten (z. B. E-Mail-Verzending) evenals verstreute Eingänge uit Mail en Telegram bergen Sicherheitsrisiken.

Mechanik: Dreispaltige Triage-Centrale: Kolom 1 voor gelb markierte Human-in-the-Loop-Goedkeuringn (Goedkeuren/Ablehnen), Kolom 2 voor IMAP/SMTP-E-Mail-Synchronisation met Auto-Triage & Delegation, Kolom 3 voor de gespiegelten Live-Telegram-Stream (@Beatman_bot).

Nut: *Borgt, dass geen externe Schreiboperation zonder ausdrückliche Goedkeuring van de Betreibers ausgeführt wordt.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

6. Ansicht: Agentenkader & Flottenmanagement (8-Reiter-Cockpit)
Problem: Specialisten nodig hebben individuelle Modellen, Systeem-Prompts, Werkzeuge en Arbeitsanweisungen op een zentralen Ort.
Mechanik: Beheert 70 Specialisten-Profile met Schnellfiltern (Aktiv, Favoriten, Alle, 7 Domänen), Hot-Swap voor Provider & Model evenals 8 Fach-Reitern: Übersicht (360°-Dossier & Telegram-Rufname), Direkt-Chat, Fähigkeiten (Skills), Operations (Task-Historie), SOUL (Systeem-Prompt-Editor), Personalakte (SOPs), Talent-Marktplatz en Skill-Marktplatz.
Nut: Centrale Personalabteilung voor de sekundenschnellen Kalibrierung en Uitbreiding van de gesamten Agenten-Stamms.
Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

7. Ansicht: Masterchat (Dual-Mode Workspace & Multi-Session-Sidebar)

Problem: Bij de direkten Werken met Agenten fehlte een fokussierte Vollbild-Umgebung met schnellem Wechsel tussen 1:1-Dialog, Gruppenchat en Missions-Opdracht.

Mechanik: Biedt de Dual-Mode-Switch ('Direkt' voor onmiddellijke Antwoord vs. 'Missie' voor gestructureerde Task-Anlage), Multi-File-Upload (tot 5 Bestanden), Browser-Screen-Capture (Kamera-Button), Spracheingabe (Diktat), Reasoning-Budget-Wähler (0 tot 16k Tokens), KI-Prompt-Optimizer en rechten Session-Historie (Agenten vs. Gruppe). Omvat de Telegram Voice-Pipeline: Eingehende Sprachnachrichten (.ogg/Opus) van unterwegs worden via Whisper/Gemini transkribiert, anhand van Rufnamen (/robert, /anwalt etc.) op de Fachagenten geroutet en Antwoorden via edge-tts (de-DE-ConradNeural) als natürliche Sprachmemos direkt

op Telegram zurückgesendet.

Nut: *Vereint Hochgeschwindigkeits-Dialog, multimodale Invoer en Missions-Besturing in een doorlopenden Arbeitsfläche.* Maakt mogelijk Volledige mobile Sprachbedienung en bidirektionalen Audio-Austausch over Telegram.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

8. Ansicht: AI Mastermind & Boardroom (55 Methodiek-Frameworks)

Problem: Komplexe strategische Beslissingen vereisen gestructureerde Management-Methoden en kontroverse Perspektiven in plaats van Einzelmeinungen.

Mechanik: Simuliert mehrstufige Gremiensitzungen (Chairman + 3 reale Fachagenten-Slots + Red-Team-Challenger) anhand van 34 auswählbaren Frameworks in 7 Kategorien (35 Base) (z. B. CLEAR, Design Sprint, Double Diamond, Lean Startup, First Principles, Game Theory, Blue Ocean, Pre-Mortem, Six Sigma).

Nut: Erzwingt methodische Strenge, deckt blinde Flecken via het Red-Team op en levert entscheidungsreife Board-Memos.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

9. Ansicht: Showroom (Project-Explorer, Artefakt-Galerie & Python-Sandbox)

Problem: Generierte Rapporten, HTML-Prototypen, Kalkulationen en Skripte gaan in langen Konversationen verloren.

Mechanik: Katalogisiert alle Arbeitsergebnisse na Ersteller, Datum en Typ. Omvat de Workspace Vault Reader met Live-Rendering voor Markdown/HTML/JSON evenals een isolierte Python-Sandbox voor de sicheren Code-Ausführung. Breidt uit om de interaktiven Showroom Live-Runner: Maakt mogelijk de directe Ausführung van Python- en Code-Bestanden in de Browser met 12s Timeout, isoliertem Scratch-Overzicht en ausklappbarem Terminal-Drawer (STDOUT, STDERR, Exit-Code en Millisekunden-Looptijd).

Nut: *Dient als Abnahme- en Präsentationshalle voor alle fertigen Deliverables voor de Klanten- of Produktionseinsatz.* Code-Artefakte en Skripte lassen zich zonder Konsolenwechsel direkt in de Showroom verifiëren en testen.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

10. Ansicht: Centrale bibliotheek & 2nd Brain (RAG, Auto-OCR & Obsidian-Vault)

Problem: Fachbücher, DIN-Normen en Bebauungspläne als PDF konnten van Agenten bisher niet zonder manuelles Kopieren durchsucht worden.

Mechanik: Vereint 3 Sub-Tabs en 4 Core Hubs (00_HR_Agenten, 02_Wissensbibliothek, Protokolle/, 00_Notebook_Synthesen): 1. AnythingLLM RAG-Index (Port 3001), 2. Dokumenten-Erfasser met Drag & Drop, Auto-OCR (Docling) en KI-Themenklassifikation, 3. Direkter Obsidian-Dateibaum & Markdown-Viewer inclusief Vault-Umschalter.

Nut: Verwandelt PDF-Expertrapport vollautomatisch in durchsuchbares Markdown- en Vektor-Kennis voor alle 70 Agenten.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

11. Ansicht: Workflow-Engine (n8n Automation Mesh op Port 5678)

Problem: Terugkerende Koppelingenprozesse (Cron-Jobs, Webhooks, Database-Abgleiche) verbrauchen onnodig Tokens, als zij over LLMs lopen.

Mechanik: Betten de visuellen n8n-Workflow-Editor direkt een en verbindt ihn over de Skill n8n-automation-

mesh (BijnaMCP) met de CEO-Agenten Robert. Aktivierte 0-Token-Routinen: 1. Morning-Briefing (werktags 07:30 Uhr met Obsidian-Archief en Telegram-Zustellung), 2. Weekly Maintenance (sonntags 23:00 Uhr met SQLite-Back-up & Health-Audit), 3. RSS & News Watchdog (stündlicher Scan), plus 5 aktive Funktions-Webhooks voor Web-Extraktion, Messaging, Dokumenten-Rendering, Feed-Zoekopdracht en CRM-Sync.

Nut: *Kombiniert deterministische 0-Token-Achtergrondprozesse met kognitiven Agenten-Beslissingen op Schlüsselstellen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

12. Ansicht: LLM Gateway (OmniRoute AI Router Dashboard)

Problem: De feste Bindung op een einzigen Cloud-Anbieter voert bij Tarief-Limits of Ausfällen voor de sofortigen Systemstillstand.

Mechanik: Zentrales Proxy-Dashboard (Port 20128 / 8000) met Multi-Provider-Vault, Realtime-Latenzmessung (ms), HTTP-Fehlermonitor (429/500), automatischem Circuit-Breaker en 4-stufiger Fallback-Kaskade (GLM-4.7 Flash -> Gemini 2.5 Flash -> Claude 3.5 Sonnet -> lokales Llama 3.3 70B).

Nut: *Borgt 99,9 % Beschikbaarheid alle kognitiven Prozesse bij minimalen API-Kosten.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

13. Ansicht: Token Guard (Guardian & Token Analytics in 3 Sub-Views)

Problem: Fehlende Transparantie daarover, welke Agent, welk Model of welke Einzelsitzung de meisten Tokens en Kosten verursacht.

Mechanik: Biedt Zeitfilter (24h, 7d, 30d, Gesamt), Inaktivitäts-Timer en 3 Sub-Views: 1. Übersicht & Tages-Trend-Chart met Profil-/Model-Tabellen en Bescherming-Schranken-Formular, 2. Einzel-Session Verbrauchs-Inspektor (Input, Output, Cache-Read Tokens sortierbar), 3. Ressourcen & Task-Drosselung (Schieberegler 1–16 Tasks).

Nut: *Volle Kostenkontrolle tot op de einzelne Session-ID herab inclusief sofortiger Budget- en Parallelitäts-Begrenzung.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

14. Ansicht: Erweiterungen & Module-Centrale (34 Evey-Spezial-Plugins)

Problem: Sicherheits-, Opslag- en Analysefunktionen ließen zich bisher niet modulair pro Fachgebiet te- of abschalten.

Mechanik: Bestuurt 34 spezialisierte Hermes/Evey-Plugins over 8 Fach-Reiter: Veiligheid & Wächter (4), Performance & Cache (2), Monitoring & Analytics (3), Agenten-Intelligenz (6), Planning & Tasks (2), Brücken & Koppelingen (4), Geheugen & Kennis (3), Tools & Execution (3) plus Financiën/Qualität/Wartung. Omvat het standardisierte Pluginsystem & Runtime-Hooks: Modulare Mappenstructuur (plugins/<plugin_id>/plugin.json), 4 Lifecycle-Hooks (on_load, on_enable, on_disable, on_unload) en 2 Tool-Interzeptoren (before_tool_execute, after_tool_execute) met vorinstallierten Starter-Plugins (Systeem Metrics, Security Audit Hook, Cost Guard).

Nut: *Staat toe het präzise Te- en Abschalten einzelner Systemfähigkeiten in de laufenden Betrieb per Mausklick.* Maakt mogelijk isolierte Runtime-Erweiterungen en globale Tool-Interzeption zonder Ingreep in de Kernel-Code.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

15. Ansicht: Research Lab (Deep Search & Evidenz-Triangulation)

Problem: Eenvoudige Suchanfragen leveren ungeprüfte Einzeltreffer zonder Quellenabgleich of

VertrauensBeoordeling.

Mechanik: Mehrstufiges Forschungs-Cockpit met wählbarer Suchtiefe, Quellen-Monitor, Evidenz-Score, Live-Synthese-Verslag voor de Triangulation widersprüchlicher Aussagen en 1-Klik-Export in de Obsidian-Vault. Omvat de Autonome Tiefenrecherche & Reflexionsschleife v2 (Re-Search Loop): Zerlegung komplexer Recherchen in 3–5 Teilfragen, autonome Lückenanalyse, tot te 3 iterative Nachfolge-Suchläufe, Multi-Provider Fallback (SearXNG / Jina Reader) en SSRF-Bescherming.

Nut: *Erzeugt belastbare, zitierfähige Markt-, Rechts- en Technik-Dossiers.* Sluit Wissenslücken selbstständig via rekursive Folgerecherchen bij widersprüchlichen of unVolledigen Quellen.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

16. Ansicht: Telemetrie & Logs (3-Quellen Live-Audit Stream)

Problem: Bij Fouten in Containern of Agenten-Prompts musste bisher mühsam in de Terminal over Docker-Befehle gesucht worden.

Mechanik: Bundelt 3 Log-Quellen in Realtime: Physische Docker-Container-Logs (stdout/stderr de 11 Container), kognitive Agenten-Logs en de kryptografischen Audittrail. Met Level-Filter (DEBUG, INFO, WARN, ERROR), Auto-Scroll-Lock en Export.

Nut: *Unbestechlicher Flugschreiber voor sekundenschnelle Fehlerdiagnose en Compliance-Nachweise.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

17. Spezial-Studio: Archon Prompt Studio (832 Sjablonen & Fabric SOP)

Problem: Unpräzise formulierte Taken voeren te Halluzinationen, falschen Ausgabeformaten en teuren Korrekturschleifen.

Mechanik: Integrierter Baukasten met 824 Enterprise-Sjablonen in 16 Fachkategorien, over 255 Fabric-SOP-Mustern en de 5-Felder-Formel (1. Rol, 2. Context, 3. Taak, 4. Format, 5. Constraints/Negativ-Regeln) evenals KI-Prompt-Optimizer.

Nut: Zwingt iedere Delegation in een glasklare Structuur en überträgt zij per Klik in Chat of Kanban-Taak.

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

18. Spezial-Studio: Visual CSS Live Studio & In-Place Transform Gizmo (Oud + S)

Problem: Design-Anpassungen erforderten bisher het Zoeken in CSS-Bestanden en ständiges Neuladen van de Browsers.

Mechanik: Schwebendes Realtime-Design-Studio (Oud + S) met Fadenkreuz-DOM-Inspektor, interaktivem Transform-Gizmo (Position ziehen, 4 Ecken/Kanten schalen, Eckenrundung ziehen), Theme-Profil-Manager en direktem CSS-Export na custom_studio.css.

Nut: *Maakt mogelijk pixelgenaues Live-Styling de gesamten Gebruikersinterface in de laufenden Betrieb zonder Pagina's-Reload.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

19. Spezial-Studio: Design Systeem Lab, AppShell Architekt & 15-Komponenten-Studio

Problem: Abweichende Header-Höhen, Abstände of Kontraste tussen Licht- en Dunkelmodus stören de visuelle Ruhe.

Mechanik: Omvat de interaktiven AppShell-Architekten (56px Header-Flucht, Sidebar-Breite, Viewport-Padding met Live-Miniatursimulation) evenals het 15-Komponenten-Design-Studio (os-workspace tot os-badge) met Dual-Theme-Engine (Light/Dark).

Nut: *Garandeert een einheitliches, blendfreies B2B-SaaS-Erscheinungsbild over alle 20 Ansichten hinweg.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

20. Spezial-Ansichten: System Control Center (11 Fachreiter, Live-Dock) & Globale Omnibox (Strg + K)
Problem: Einstellungen waren verstreut; de Navigation tussen 20 Ansichten en 70 Agenten erforderte viele Mausklicks.
Mechanik: Het System Control Center Bundelt 7 Administrations-Reiter (Hermes Core incl. YAML-Editor, Container & Dienste, Provider & Gateway, Methodiken, Plugins, Communicatie, Design) en lässt zich per 'Live-Dock' rechts andocken. De Omnibox (Strg + K) navigiert per Toetsenbord direct te jedem Tab (#), Agenten (@) of Befehl.
Integreert het 1-Klik Updatesystem & Continuous Deployment: Automatischer GitHub-Sync met Pre-Update Snapshots alle SQLite-Databases (WAL) in data/snapshots/ voor jedem Git-Pull, 1-Klik Rollback en minimalen Git-Stat-Controles tegen Mount-Timeouts.
Nut: Maximale Bediengeschwindigkeit voor Administratoren en Power-User. Maakt mogelijk gefahrlose Software-Updates met automatischem Database-Rollback in de Fehlerfall.
Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

3. Token-Spar- & FinOps-Ecosysteem (Kostenminimierung)

21. 3-Tier Automatische Kosten-Routing-Caps (LOW / MEDIUM / HIGH)

Problem: Als eenvoudige Routineaufgaben op teuren Spitzenmodellen (hoe Claude Sonnet of GPT-4o) lopen, explodieren de Tageskosten.

Mechanik: Konfigurierbare Prijs-Obergrenzen pro 1 Million Tokens in de System Control Center: LOW (max. $0.10/1M -> erzwingt Free-Tier/Flash-Lite), MEDIUM (max. $1.00/1M -> Haiku/Gemini Flash), HIGH (No Cap -> beste Reasoning-Modellen voor komplexe Architectuur).

Nut: *Verlaagt de laufenden API-Ausgaben in de Alltag om tot te 85 %, zonder bij schwierigen Taken op Qualität einzubüßen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

22. FreeLLM-API Docker-Proxy & 'auto/best-free' Routing (Port 3002)

Problem: Kostenlose Kontingente verschiedener Anbieter zijn zwaar manuell te bewaken en wechseln häufig.

Mechanik: Een dedizierter Docker-Container (freellmapi op Port 3002) Bundelt kostenfreie LLM-Endpunkte. Het Routing-Profil 'auto/best-free' kiest automatisch het stärkste verfügbare Null-Euro-Model.

Nut: *Maakt mogelijk de Dauerbetrieb van Achtergrond- en Triage-Agenten te exact $0.00 API-Kosten.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

23. Stufenlose Reasoning-Budget-Besturing in de Masterchat & Router (0 tot 16k Tokens)

Problem: Reasoning-Modellen (Thinking-Mode) verbrauchen vaak tausende unsichtbare Denk-Tokens voor triviale Vragen.

Mechanik: 6-stufiger Regler (Uit: 0 Tok, Minimaal: ~1k, Laag: ~2k, Mittel: ~4k, Hoog: ~8k, Maximaal: ~16k) in de Chat-Footer en in agent_router.py.

Nut: *Schaltet teure Denk-Schleifen bij eenvoudigen Taken komplett vanaf en reserviert tiefes Reasoning voor echte Komplexfälle.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

24. Evey-Cache & Cache-TTL-Besturing (24h Semantischer & Exakter Antwoord-Cache)

Problem: Terugkerende identische of sehr ähnliche Systemabfragen führten ieder Mal te nieuwe, kostenpflichtigen API-Calls.

Mechanik: Het Plugin evey-cache slaat op Modellantworten met konfigurierbarer Lebensdauer (Standard: 24 Stunden TTL) en weist in de Session-Inspektor de eingesparten Cache-Read-Tokens separat uit.

Nut: *Beantwoordt wiederholte Abfragen in 0 Millisekunden te 0 Token-Kosten.*

Prijs & Schattenseite (Trade-off): Is de Cache-TTL te hoog (> 72h), levert het Systeem bij dynamischen Thema's veraltete Antwoorden.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij Realtime-Abfragen (Live-Kurse, Serverstatus). Std-TTL: 24h.

25. Max-Context & Max-History Hard-Clipper in de Guardian (32k / 20 Turns)

Problem: Endlos wachsende Chat-Sitzungen verzenden bij iedere nieuwe Vraag de gesamte Historie opnieuw met en treiben de Input-Tokens exponentiell na oben.

Mechanik: In de Guardian einstellbare Hardschranken voor het maximale Kontextfenster (z. B. 32.000 Tokens) en de maximale Anzahl übermittelter Chat-Nachrichten (z. B. letzte 20 Turns).

Nut: *Kapselt de maximaal möglichen Input-Kosten pro Turn verlässlich na oben vanaf.*

Prijs & Schattenseite (Trade-off): Schneidet Nachrichten oberhalb van 32k Tokens of 20 Turns hart vanaf, wodurch sehr früher Context wegfällt.

Wanneer ausschalten? & Drempelwaarden: Voor tiefe Dokumenten-Analyses op 64k–128k in de Hermes Core anheben.

26. Dynamischer Token-Clipper voor Low-Context-Modellen (backend/token_clipper.py)

Problem: Kompakte of lokale Modellen (8k/16k) brechen vanaf, als große Tool-Ausgaben het Kontextfenster sprengen.

Mechanik: Bewahrt dwingend de Systeem-Prompt (Index 0) en de letzte Benutzeranweisung, kürzt überlange Einzelblöcke intelligent en entfernt ältere Zwischenschritte.

Nut: *Staat toe de stabilen Einsatz extrem günstiger Kleinmodelle ook bij umfangreichen Taken.*

Prijs & Schattenseite (Trade-off): Kürzt überlange Tool-Ausgaben in de Mitte heraus ([...SNIP...]), wodurch einzelne Code-Zeilen in de Rohtext fehlen kunnen.

Wanneer ausschalten? & Drempelwaarden: Kurzzeitig deaktivieren, als komplette Roh-Logs ungekürzt heeft nodig worden.

27. Sliding Window Memory Compression (Konsolidierter Entscheidungskontext)

Problem: Bij de eenvoudigen Abschneiden alter Nachrichten gaan frühere Projektbeschlüsse verloren.

Mechanik: Verdichtet ältere Gesprächsrunden te een kompakten Samenvatting en injiziert deze als Block [KONSOLIDIERTER GESPRÄCHS- & ENTSCHEIDUNGSKONTEXT] op Position 1.

Nut: *Bespaart tot te 70 % historische Konversations-Tokens bij vollem Erhalt alle getroffenen Beslissingen.*

Prijs & Schattenseite (Trade-off): De Komprimierungs-Stap kost einmalig ~800 Tokens en glättet wörtliche Formulierungen früher Runden.

Wanneer ausschalten? & Drempelwaarden: Bij Bedarf over protect_last_n (Std: 20) in de Hermes Core feinjustieren.

28. LRU-K Page Swapping voor Subagenten-RAM (backend/context_swapper.py)

Problem: Parallele Subagenten houden riesige Mengen op Rohdaten tegelijkertijd in de aktiven Prompt-Opslag.

Mechanik: Slaat op niet mehr akut benötigte Context-Pagina's vanaf 80 % Bezetting na de Least-Recently-Used-Principe in SQLite uit en laadt zij alleen bij Bedarf (Re-Hydration) zurück.

Nut: *Houdt de Prompts schlank en voorkomt unnötige Token-Gebühren voor inaktives Achtergrondwissen.*

Prijs & Schattenseite (Trade-off): Het Auslagern en Nachladen van Agenten-RAM op Disk erzeugt ~10–25 ms I/O-Latentie bij de Kontextwechsel.

Wanneer ausschalten? & Drempelwaarden: Vanaf 80 % RAM-Bezetting aktiv lassen, om OOM-Abstürze te voorkomen.

29. JEV Router — 0-Token Deterministische Intent-Vorfilterung (jev_router.py)

Problem: Iedere eenvoudige Systemanweisung over een großes Sprachmodell te classificeren, verschwendet Tokens en Zeit.

Mechanik: Classificeert eingehende Eingaben voor de LLM-Aufruf per deterministischem JSON Execution Vector en Keyword-Heuristik.

Nut: *Leidt klare Systembefehle direkt op de Zielroutine weiter, zonder een einziges LLM-Token te verbrauchen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

30. ASD-STE100 Simplified Technical English Prompter (.agents/skills/asd-ste100-prompter)

Problem: Weitschweifige Prosatexte in Systeem-Prompts en Agenten-Anweisungen blähen iedere einzelnen API-Call onnodig op.

Mechanik: Transformiert Instruktionen na de Luftfahrt-Standard ASD-STE100 (een Bedeutung pro Wort, aktive Verben, korte Sätze, null Füllwörter).

Nut: *Reduceert de Token-Länge van Systeem-Prompts om ca. 30–40 % en verlaagt tegelijkertijd de Fehlerrate bij Tool-Calls.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

31. Anti-AI-Slop & Output-Komprimierung (.agents/skills/anti-ai-slop)

Problem: Sprachmodelle erzeugen standardmäßig lange Höflichkeitsfloskeln, Einleitungen en redundante Samenvattingen (teure Output-Tokens).

Mechanik: Unterbindet KI-Floskeln, leere Phrasen en künstliches Aufblähen direkt in de Systeem-Prompt en bereinigt Ausgaben.

Nut: *Bespaart tot te 25 % de besonders teuren Output-Tokens en levert direct verwertbare Fachtexte.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

32. Pre-Flight Kosten-Schätzer & Budget-Voorspelling (backend/cost_estimator.py)

Problem: Voor de Start großer Taken wat niet absehbar, wat de Lauf kosten wordt.

Mechanik: Berekent vooraf over POST /api/router/estimate-cost de erwarteten Input-/Output-Tokens evenals de Dollar-Betrag anhand de aktuellen Model-Preisliste en gleicht ihn met de Task-Budget vanaf.

Nut: *Waarschuwt voor teuren Läufen, nog bevor de erste Cent ausgegeben wordt.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

33. Dynamisches Task-Budget met 80%-Spar-Downgrade & 100%-Stop

Problem: Een einzelner komplexer Task kon unbemerkt het gesamte Tagesbudget verzehren.

Mechanik: Bewaakt de kumulierten Kosten pro Taak (z. B. Limit $0.25): Schaltet bij 80 % automatisch op een günstiges Spar-Model herunter en gepauzeerd de Task bij 100 % met Telegram-Goedkeuringanfrage.

Nut: *Voorkomt Kostenausreißer bij mehrstufigen autonomen Recherchen.*

Prijs & Schattenseite (Trade-off): Bij Erreichen van 80 % van de Task-Budgetten wordt op een günstigeres Spar-Model heruntergeschaltet; bij 100 % erfolgt de Hard-Stop.

Wanneer ausschalten? & Drempelwaarden: Task-Budget (Std: 0,50 $) voor große Architectuur-Läufe op 2,00 $ anheben.

34. Loop-Killer & Max-Steps-Begrenzung (15 Stappen / Jaccard > 90%)

Problem: Als een Agent bij een fehlerhaften Tool-Aufruf in een Endlosschleife gerät, verbrennt hij in de Sekundentakt Guthaben.

Mechanik: Controleert iedere Stap op exakte Wiederholungen (>= 3) of semantische Kreisbezüge (> 90 % Ähnlichkeit) en kappt Taken spätestens na de konfigurierbaren Max-Steps-Limit (Standard: 15 Stappen).

Nut: *Beschermt het Konto betrouwbaar voor unbemerkten Endlosschleifen over Nacht.*

Prijs & Schattenseite (Trade-off): Te scharfe Grenzwerte (Max Identisch = 2 of Jaccard < 0.80) stoppen legitime iterative Taken hoe schrittweises Test-Fixing of Paginierung te früh.

Wanneer ausschalten? & Drempelwaarden: Kurzzeitig ausschalten, als een Agent bewusst viele gleichförmige Schleifen-Stappen (z. B. Massen-Migration van 50 Bestanden) abarbeiten moet. | Drempelwaarden: Max Identisch: 2 = stopt Retries | > 5 = teure Schleifen (Std: 3). Jaccard: < 0.80 = Fehlalarme | > 0.96 = herkent Schleifen spät (Std: 0.90). Max Stappen: Std 15.

4. Kernel, Scheduling & Daemon-Architectuur (Pillar 1)

35. Hermes Master Orchestrator (Hermes-Core)
Problem: Unkoordinierte Einzelagenten werken gegeneinander of verliezen het Gesamtziel uit de Augen.
Mechanik: Centrale Prozess-Leitstelle voor de Auftragsanalyse, Rollenauswahl, Bewaking en Resultaat-Abnahme.
Nut: Borgt strategische Kohärenz over alle 70 Specialisten.
Prijs & Schattenseite (Trade-off): Mehr aktive Achtergrond-Dienste en hohes Reasoning ('high') verhogen de Grundlast en Token-Kosten.
Wanneer ausschalten? & Drempelwaarden: Over de 14 Sektionen in de Tab 'HERMES CORE' granular steuerbar.

36. Tickless Kernel Daemon & Asyncio Event-Loop (Port 8420 / 8501)

Problem: Ständiges Polling in de Sekundentakt verschwendet CPU-Ressourcen en Systemenergie.

Mechanik: Berekent de exakten Zeitpunkt van de nächsten fälligen Tasks ('Sleep-until-next-due') en versetzt de Kernel tot dahin in de Ruhezustand.

Nut: *Minimale Systemlast in de Leerlauf bij verzögerungsfreier Aufwach-Reactie.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

37. Prioritäts-Preemption Scheduler (P0–P3 Warteschlange)

Problem: Urgente Benutzerfragen in de Direkt-Chat mussten warten, als Achtergrond-Jobs alle Slots belegten.

Mechanik: Priorisierte Warteschlange: P3-Taken (Direkt-Chat / Notfall) überholen laufende P1/P2-Routinejobs direct.

Nut: *Garandeert schnelle Antwortzeiten in de Dialog ondanks hoher Achtergrondlast.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

38. Frei skalierbare Concurrency-Drosselung (backend/concurrency_throttle.py)

Problem: Te viele gleichzeitige Agenten voeren te HTTP-429-Tarief-Limits en 99 % CPU-Spitzen.

Mechanik: Reguliert aktive Worker over een Asyncio-Semaphore (einstellbar per Slider van 1 tot 16 parallelen Tasks

in de Guardian en Control Center).

Nut: *Staat toe gedrosselten Schutzbetrieb op Laptops eveneens hoe Hochlastbetrieb op Workstations.*

Prijs & Schattenseite (Trade-off): Knappe Stagnations-Limits (< 30 Sek.) brechen langsame Deep-Reasoning-Modellen (z. B. o3/R1) fälschlich mitten in de Denkprozess vanaf; mehr Worker verhogen RAM- en API-Spitzenlast.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij extrem langlaufenden Einzel-Analyses of lokalen LLM-Läufen op langsamer Hardware. | Drempelwaarden: Max Worker: 1–2 = Rückstau | > 8 = RAM-Spitzen & HTTP-429 (Std: 4). Stagnation: < 30s = bricht Denker vanaf | > 180s = späte Heilung (Std: 45s).

39. Autonomer 30-Sekunden-Watchdog & Crash-Recovery (watchdog_daemon.py)

Problem: Abgestürzte of eingefrorene Tasks blieben dauerhaft in de Status in_progress hangen.

Mechanik: Controleert alle 30 Sekunden sämtliche laufenden Prozesse, bricht Zombie-Tasks na Timeout (120s) vanaf en überführt verwaiste Taken in de automatische Crash-Recovery.

Nut: *Houdt alle Worker-Slots frei van Karteileichen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

40. Deadlock- & Stagnations-Supervisor (backend/deadlock_supervisor.py)

Problem: Gegenseitige Abhängigkeiten tussen zwei Agenten kunnen te een stillen Einfrieren voeren.

Mechanik: Herkent zirkuläre Wartezustände en Tasks zonder Voortgang (> 45s) en lost op de Blockade autonom met exponentiellem Backoff op.

Nut: *Voorkomt Pipeline-Stillstände bij komplexen Gruppenarbeiten.*

Prijs & Schattenseite (Trade-off): Een te knappes Stagnations-Limit (< 30s) bricht langsame Deep-Reasoning-Modellen (o3/R1) mitten in de Denkprozess vanaf.

Wanneer ausschalten? & Drempelwaarden: Bij Gebruik van Reasoning-Modellen Stagnations-Limit op 90–120s verhogen (Std: 45s).

41. Flotten-Selbstheilung & Container-Auto-Restart (backend/fleet_self_healing.py)

Problem: Fällt een de 11 Docker-Container uit, musste hij manuell nieuw gestartet worden.

Mechanik: Bewaakt alle Core-Container over de abgeborgten docker-socket-proxy en voert bij Ausfällen (> 60s) autonom een Neustart inclusief Audit-Eintrag via.

Nut: *Borgt de unbeaufsichtigten 24/7-Betrieb de gesamten Docker-Landschaft.*

Prijs & Schattenseite (Trade-off): Een dauerhaft defekter Container kan via Auto-Restart in een Neustart-Schleife geraten.

Wanneer ausschalten? & Drempelwaarden: Tijdens manueller Container-Wartungsarbeiten kurzzeitig deaktivieren.

42. Proaktiver Morgen-Standup & Weckdienst (backend/autonomous_standup.py)

Problem: Morgens fehlte een kompakte Übersicht over nächtliche Läufe, Kosten en anstehende Beslissingen.

Mechanik: Generiert dagelijks om 08:00 Uhr een konsolidierten Statusbericht in de Obsidian-Vault (01_PROJEKTE/Daily_Briefings/) en pusht ihn op Dashboard en Telegram.

Nut: *Start iedere Arbeitstag met een fertigen Beslisdocument.*

Prijs & Schattenseite (Trade-off): Ieder automatische Morgen-Briefing verbraucht ~1.500–3.000 Tokens voor de eingestellten Zeitpunkt.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als geen täglicher Morgen-Report gewünscht is (Std: 08:00 Uhr).

5. Multi-Agenten-Procesmodel, Hiërarchie & Synthese (Pillar 2)

43. 70 Deklarative Agenten-Profile & Markdown-Personalakten

Problem: Generische KI-Assistenten hebben geen Rollenbewusstsein en geen definierten Qualitätsstandards.
Mechanik: Iedere de 70 Specialisten is in agent_profiles.json evenals een eigenen Personalakte (00_HR_Agenten/) met Systeem-Prompt, Modellroute, Werkzeug-Scope en SOPs verankert.
Nut: Schafft verlässliche virtuelle Fachkräfte voor Strategie, Recht, Bau, Financiën, Marketing en IT.
Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

44. Robert Delegation, Fan-in-Synchronisation & Lisa Marker-Kontrakt (SYNTHESE-Beschikbaar)

Problem: Bij parallelen Teilaufgaben gingen Teilergebnisse verloren of werden onvolledig samengevat.

Mechanik: Robert zerlegt Großprojekte; een Prozess-Lock (_MC_DATA_LOCK) wartet op de Abschluss alle Teilaufgaben (Fan-in). Lisa aggregiert de Rapporten onder Controle van de Pflicht-Markers SYNTHESE-Beschikbaar; Robert erteilt in Rij 1 de formale Goedkeuring.

Nut: *Mehrstufige Qualitätssicherung na de Vorbild een echten Unternehmensführung.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

45. Standardisierter Agent-to-Agent Handoff-Desk (backend/handoff_desk.py)

Problem: Stille Kontextverluste bij de Übergabe van een Specialisten op de nächsten.

Mechanik: Erzeugt formale Übergabeprotokolle met Deliverables, offenen Aannames en SHA-256-Prüfsumme, de van de Empfänger-Agenten quittiert worden moeten.

Nut: *Revisionssichere Koppelingen tussen alle Abteilungen.*

Prijs & Schattenseite (Trade-off): Strikte SLA-Controles weisen sehr korte, maar korrekte Faktenantworten zurück, als min_content_length te hoog (> 300) is.

Wanneer ausschalten? & Drempelwaarden: Standard: 100 Zeichen Mindestlänge, 60 Min. Turnaround.

46. Zweistufiger DAG-Scheduler voor parallele Project-Ausführung (backend/dag_scheduler.py)

Problem: Sequentielle Abarbeitung vieler Teilaufgaben dauert bij Großprojekten te lange.

Mechanik: Berekent de gerichteten azyklischen Graphen (DAG): Voert unabhängige Recherchen (Niveau 1) parallel uit en start daarna automatisch de Synthese (Niveau 2).

Nut: *Verkürzt de Doorlooptijd komplexer Analyses om een Vielfaches.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

47. Self-Correction & Tool Execution Reflection Loop

Problem: Flüchtige Syntax- of Parameterfehler bij Tool-Aufrufen führten voor de sofortigen Abbruch.

Mechanik: Fängt Tool-Fout vanaf, reflecteert de Foutmelding en korrigiert de Aufrufparameter autonom in tot te 3 Versuchen.

Nut: *Deutlich hogere Robustheit bij Bestand-, Database- en Web-Operationen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

48. Unterbrechbare Langzeit-Workflows met SQLite State-Snapshotting

Problem: Wartet een Task stundenlang op een Nutzer-Goedkeuring, aangetoond hij onnodig Opslag of verliest zijn Zustand bij een Neustart.

Mechanik: Friert de exakten Ausführungszustand in de Tabel workflow_checkpoints een en neemt de Werk na Goedkeuring nahtlos opnieuw op.

Nut: *Maakt mogelijk mehrtägige Bedrijfsprocese over Neustarts hinweg.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

49. Dual-Agent Consensus-Gate & Adversarial Critic Review (backend/consensus_gate.py)

Problem: Een einzelner Agent bemerkt eigene Denkfehler of Halluzinationen bij kritischen Taken vaak niet.

Mechanik: Erzwingt bij P3-Tasks en kritischen Eingriffen een formales Gegenlesen via een unabhängigen Revisor-Agenten (Red-Team/Critic). In de Kanban-Board als automatisiertes 4-Augen Qualitäts-Gate verdrahtet (Katharina Völk / Robert Review met 1–100% Score en Status-Lock bij Revisionsbedarf).

Nut: *Vierogenprincipe voor alle geschäftskritischen Resultaten.*

Prijs & Schattenseite (Trade-off): Verdreifacht (3x) de Token-Verbruik en verhoogt de Antwortzeit om +6 tot +20 Sek.; Einstimmigkeit birgt Deadlock-Gefahr.

Wanneer ausschalten? & Drempelwaarden: Erst vanaf Prioriteit P3/P4 aktivieren en 2/3-Meerderheid kiezen.

6. MCP-Drivers, Externe Diensten & Multimodale Tools (Pillar 3)

50. Archon CRM & PocketBase-Ecosysteem (Ports 3005, 8090, 8092)

Problem: Kundenkontakte, E-Mail-Historien en Medien-Assets lagen getrennt van de KI-Agenten.

Mechanik: Dediziertes CRM-Frontend (Port 3005) met PocketBase-Backend (Port 8090) en Media-Server (Port 8092), vol angebunden over scripts/archon_crm_mcp.py.

Nut: *Agenten kunnen Kontakte abrufen, nachrecherchieren, beoordelen (Lead-Scoring) en Korrespondenz zuordnen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

51. Automatisches E-Mail-Matching & LinkedIn-Archiv-Importer

Problem: Tausende Kontakte uit LinkedIn-Exporten en E-Mail-Postfächern mussten manuell abgeglichen worden.

Mechanik: Synchroniseert Postfächer (--fetch-mails), ordnet Mails automatisch bestehenden CRM-Kontakten te en importeert komplette LinkedIn-Connections-CSVs inclusief Deduplizierung.

Nut: *Baut in Minuten een Volledige, angereicherte Beziehungsdatenbank op.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

52. Robert Tool-Permission Manager (backend/tool_permission_manager.py)

Problem: Agenten moeten bij fehlenden Python-/Node-Paketen niet hilflos abbrechen, mogen maar ook nichts ungefragt installeren.

Mechanik: Robert stelt een formellen Installationsantrag (pending_permission) met Befehl en Begründung; erst na deiner 1-Klik-Goedkeuring wordt het Paket installeert.

Nut: *Kontrollierte Erweiterbarkeit bij vollem Bescherming van de Host-Systems.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

53. Event-Driven Webhook-Mesh (backend/event_mesh.py)

Problem: Externe Gebeurtenissen uit GitHub, Formularen of Drittsystemen konnten geen Agenten-Acties auslösen.

Mechanik: Universeller Webhook-Empfänger, de externe JSON-Payloads valideert en direkt in ausführbare Kanban-Tasks umwandelt.

Nut: *Verbindt Archon OS in Realtime met de restlichen IT-Landschaft.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

54. Zentraler Multi-Channel Notification Hub (backend/notification_hub.py)

Problem: Belangrijke Warnungen gingen in de UI onder, tijdens unwichtige Meldingen op de Handy störten.

Mechanik: Routet Meldingen strikt na Schweregrad: INFO -> UI-Toast, WARNING -> Dashboard-Log, CRITICAL -> sofortiger Telegram-Push.

Nut: *Zielgenaue Alarmierung zonder Benachrichtigungs-Müdigkeit.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

55. Multi-Modale Visie- & Screen-Capture-Pipeline (backend/vision_pipeline.py)

Problem: Visuelle Probleme of Tabellen in Bildern mussten mühsam beschrieben worden.

Mechanik: Directe Bildschirmaufnahme in de Browser (Kamera-Button in de Chat) evenals automatische OCR- en Strukturanalyse voor hochgeladene Bilder (.png, .jpg, .webp).

Nut: *Agenten sehen precies het, wat jij op de Scherm siehst.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

56. Apollo Voice Engine — Edge-TTS & Whisper Diktat (apollo_voice_engine.py)

Problem: Lange Texte op de Smartphone of Desktop einzutippen kost Zeit; Rapporten wil graag man zich unterwegs anhören.

Mechanik: Bidirektionale Sprachpipeline: Mikrofon-Diktat (Speech-to-Text) direkt in de Chat-Invoerveld en natürliche Sprachausgabe (Text-to-Speech) voor Briefings. Volledige Telegram-Voice-Integratie (POST /api/telegram/voice-relay en POST /api/voice/synthesize) voor mobile Audio-Memos via edge-tts (de-DE-ConradNeural).

Nut: *Verwandelt Archon OS in een sprachgesteuerten Executive Assistant.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

57. Oracle News Radar & SEO Execution Agent

Problem: Marktveränderungen en SEO-Schwachstellen eigener Webseiten werden alleen sporadisch gecontroleerd.

Mechanik: Oracle News Radar scannt kontinuierlich Fachquellen op Projektrelevanz; de SEO Agent controleert Pagina's op Meta-Tags, Structuur en Keyword-Dichte.

Nut: *Kontinuierliche Markt- en Sichtbarkeitsoptimierung in de Achtergrond.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

7. Geheugen, Database-Hygiene & Obsidian 2nd Brain (Pillar 4)

58. Zentraler SQLite WAL-Memory-Layer (5 Standardtabellen)

Problem: Gleichzeitige Lese- en SchreibToegange mehrerer Agenten führten bij eenvoudigen Bestanden te Konflikten.

Mechanik: Transaktionale SQLite-Database (data/agentic_memory.db) in de Write-Ahead-Logging-Modus (WAL)

met de 5 Kerntabellen tasks, conversations, learnings, kv_store en user_profile.

Nut: *Blockadefreie ParallelToegange met höchster Datensicherheit.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

59. Prozesssicheres Kanban-Sidecar met atomarem Dateiaustausch (backend/kanban_sidecar.py)

Problem: Metadaten hoe WIP-Limits of Tags konnten bij parallelen Schreibvorgängen korrumpieren.

Mechanik: Beschermt config/kanban_meta.json over een prozessweiten Mutex en atomare Write-Replace-Operationen.

Nut: *Voorkomt Gegevensverlies bij hochfrequenten Board-Aktualisierungen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

60. Docker-RAG-Bridge te AnythingLLM (5.068 indexierte Documenten op Port 3001)

Problem: Het in de Docker-Vektorspeicher vorhandene Kennis werd bij normalen Chat-Anfragen vaak niet automatisch herangezogen.

Mechanik: backend/rag_bridge.py verbindt de Agentenkern direkt met de AnythingLLM-Workspace ARCHON en levert relevante Textpassagen als Grounded Context.

Nut: *Fundierte Antwoorden op Basis deiner echten Unternehmensdokumente in plaats van allgemeiner Schätzungen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

61. Drietraps Projektordner-Disposition in de Obsidian-Vault

Problem: Als Agenten Bestanden erzeugen, entsteht zonder feste Regeln snel Unordnung in de Vault.

Mechanik: Legt voor ieder Project automatisch de 3-Niveaus-Structuur op: 01_Zwischenberichte, 02_Medien en 03_Endprodukte.

Nut: *Saubere Trennung tussen Rohentwürfen en abgenommenen Endergebnissen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

62. Obsidian Vault Indexer & Automatische Map of Content (backend/vault_hygiene.py)

Problem: Nieuwe Projektberichte blieben in de Obsidian-Graph vaak unverlinkt ('Orphan Notes').

Mechanik: Scannt de Vault, spürt verwaiste Notizen op en werkt bij vollautomatisch de centrale _MOC_Projekt_Index.md met Wikilinks.

Nut: *Houdt de Wissensgraphen in Obsidian jederzeit volledig verbonden.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

63. Autonomes Fact-Harvesting & 85%-Ähnlichkeits-Deduplizierung (backend/post_task_pipeline.py)

Problem: Belangrijke Erkenntnisse uit abgeschlossenen Taken gingen onder of werden mehrfach doppelt gespeichert.

Mechanik: Extrahiert na Task-Abschluss automatisch nieuwe Feiten voor learnings en user_profile en voorkomt Dubletten vanaf 85 % Textähnlichkeit.

Nut: *Het Systeem wordt met iedere erledigten Taak klüger, zonder de Opslag zuzumüllen.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard

integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

64. Automatisches Online-DB-Back-up met 7-Tage-Rotation (backend/db_backup_manager.py)

Problem: Zonder regelmäßige Datenbanksicherungen droht bij Hardwaredefekten de Verlies alle Tasks en Profile.

Mechanik: Voert in de laufenden Betrieb PRAGMA wal_checkpoint(TRUNCATE) uit en slaat op komprimierte .db.gz-Archive in .hermes/backups/db/.

Nut: *Sluitende Gegevensback-up zonder een Sekunde Uitvaltijd.*

Prijs & Schattenseite (Trade-off): Tägliche Vol-Backups aantonen je na Aufbewahrungsdauer ~50–500 MB Festplattenspeicher.

Wanneer ausschalten? & Drempelwaarden: Standard: 7 Tage Aufbewahrung (db_backup_keep_days).

65. Autonomer SQLite Vacuum & Fragmentierungs-Optimizer (backend/db_optimizer.py)

Problem: Gelöschte Datensätze en häufige Updates blähen SQLite-Bestanden over Monate onnodig op.

Mechanik: Voert over POST /api/systeem/optimize-db op alle Databases PRAGMA optimize en VACUUM uit en berekent de freigegebenen Speicherplatz.

Nut: *Houdt Abfragezeiten dauerhaft in de Millisekundenbereich.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

66. Atomares Pre-Write-Snapshotting & 1-Klik-Rollback (backend/snapshot_manager.py)

Problem: Als een Agent een Bestand fehlerhaft überschreibt, wat de Herstel van de Vorzustands aufwendig.

Mechanik: Borgt voor jedem SchreibToegang automatisch het Origineel in .hermes/snapshots/ en stelt het per Klik of API direct opnieuw her. Aanvullend als Pre-Update Snapshots alle SQLite-Databases voor GitHub-Pulls en Container-Updates in data/snapshots/ integreert.

Nut: *Volledig Sicherheitsnetz bij alle Bestand- en Code-Wijzigingen.*

Prijs & Schattenseite (Trade-off): Iedere Pre-Write-Snapshot kost ~5–15 ms Disk-I/O voor de Überschreiben een Bestand.

Wanneer ausschalten? & Drempelwaarden: Ringpuffer standardmäßig op 50 Snapshots begrenzt.

67. Git-kompatible Live-Diff-Vooruitblik (backend/diff_engine.py)

Problem: Voor een Goedkeuring wil graag man exact sehen, welke Zeilen zich wijzigen, in plaats van de ganze Bestand nieuw te lesen.

Mechanik: Erzeugt een farbigen Zeilenvergleich (Rot = entfernt, Grün = nieuw) tussen Bestand en Agenten-Entwurf.

Nut: *Sekundenschnelle Controle van Code- en Dokumentenänderungen in de HITL-Gate.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

8. Veiligheid, Zero-Trust Governance & Systeem-Diagnose (Pillar 6)

68. Kryptografisch verkettetes SHA-256 Audit-Log (backend/audit_log.py)

Problem: Eenvoudige Text-Logs lassen zich achteraf verändern of verwijderen.

Mechanik: Ieder Gebeurtenis wordt met de SHA-256-Hash van de Vorgängereintrags verkettet (Blockchain-Principe) en is over GET /api/audit/verify op Manipulation prüfbar.

Nut: *Revisionssicherer Bewijs alle Systeem- en Goedkeuringaktionen.*

Prijs & Schattenseite (Trade-off): Minimaler Schreib-Overhead (~2 ms pro Eintrag); de kryptografische Kette wächst over Monate op.

Wanneer ausschalten? & Drempelwaarden: Voor revisionssichere Governance dauerhaft eingeschaltet lassen.

69. Local Security Guard — 25 Prompt-Injection- & Jailbreak-Signaturen

Problem: Bösartige E-Mails of Webseiten kunnen verborgen Befehle bevatten ('Ignore previous instructions...').

Mechanik: Scannt iedere externen Texteingang anhand van 25 Angriffsmustern, bevor hij in de Context een Agenten gelangt.

Nut: *Wehrt indirecte Prompt-Injections op de Systemgrenze vanaf.*

Prijs & Schattenseite (Trade-off): Sehr strenge Heuristiken kunnen bij IT-Security-Texten of Pen-Testing-Prompts Fehlalarme (False Positives) auslösen.

Wanneer ausschalten? & Drempelwaarden: Alleen voor autorisierte Red-teaming-Tests kurzzeitig lockern.

70. Secret-Masking & Red-teaming Output Guard (backend/secret_masker.py)

Problem: API-Schlüssel of Passwörter könnten versehentlich in Logs, Rapporteren of Chat-Ausgaben auftauchen.

Mechanik: Filtert ausgehende Texte in Realtime op Schlüssel-Muster (sk-..., Bearer, Passwörter) en ersetzt zij via [GESCHÜTZTER_KEY].

Nut: *Voorkomt het versehentliche Offenlegen vertraulicher Zugangsdaten.*

Prijs & Schattenseite (Trade-off): Aggressive Regex-Maskierung kan in seltenen Fällen harmlose Base64- of Hash-Strings in Code-Ausgaben schwärzen.

Wanneer ausschalten? & Drempelwaarden: In de Produktivbetrieb voor de Bescherming van API-Keys dauerhaft aktiv lassen.

71. Abgeborgter Docker-Socket-Proxy (Port 2375 intern)

Problem: Direkter Toegang op /var/run/docker.sock geeft Containern uneingeschränkte Root-Rechten over het Host-Systeem.

Mechanik: Schaltet een restriktiven Proxy-Container dazwischen, de alleen explizit erlaubte Status- en Neustart-Befehle durchlässt.

Nut: *Beschermt het Host-Besturingssysteem na de Zero-Trust-Principe.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

72. A/B-Model-Benchmarker & Empirischer Performance-Scorer (backend/model_benchmarker.py)

Problem: Nieuwe Sprachmodelle erscheinen wöchentlich; ihre Eignung voor eigene Unternehmensaufgaben blijft vaak unklar.

Mechanik: Test zwei Modellen parallel met identischen Taken en vergelijkt Antwortzeit, Token-Kosten en Ergebnisqualität.

Nut: *Objektive Datenbasis voor de Modellwahl in de Agentenkader.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

73. Systemweiter 360°-Health-Score & Diagnose-Engine (backend/system_diagnostics.py)

Problem: Einzelne Metrieken tonen vaak niet in één oogopslag, hoe gesund het Gesamtsystem echt is.

Mechanik: Berekent uit Docker-Flottenstatus (35%), Concurrency-Queue (20%), Audit-Integrität (20%), Deadlock-Freiheit (15%) en RAG-Erreichbarkeit (10%) een Gesamtscore van 0–100 % incl. Handlungsempfehlungen.

Nut: *Onmiddellijke Gesamtdiagnose van de Besturingssysteems over GET /api/systeem/health-score.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

9. Selbst-Evolution, Marktplätze & Auto-Documentatie (Pillar 7)

74. Autonome Skill-Synthese met Personalakten-Rückkopplung (backend/skill_synthesizer.py)

Problem: Succesvolle mehrstufige Lösungswege mussten bisher manuell als nieuwe Skill programmiert worden.

Mechanik: Herkent terugkerende succesvolle Tool-Ketten, generiert automatisch een SKILL.md-Entwurf, trägt ihn in de Personalakte van de Agenten een en legt ihn voor de Goedkeuring voor.

Nut: *Het Systeem breidt uit zijn Fähigkeiten in de Betrieb selbstständig.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

75. Dynamischer Talent- & Skill-Marktplatz (skill_markt.js & AgentSkillsHub)

Problem: Nieuwe Rollen of Workflows voor nieuwe Geschäftsfelder van Grund op nieuw te schreiben, is zeitintensiv.

Mechanik: Durchsuchbarer Catalogus voor de 1-Klik-Import en -Export kompletter Agenten-Profile evenals externer Skills (incl. agentskillshub.dev Integratie).

Nut: *Schaalt de Agenten-Vloot bij nieuwe Projekten in Sekunden.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

76. Volledige Frontend-Backend-Synchronisation (238 Fetches / 581 Pfade / 29 Modale)

Problem: In großen Web-Toepassingen voeren verwaiste Buttons of unverbundene Modale vaak te stillen Fouten.

Mechanik: Automatisierte Prüf-Pipeline borgt, dass alle 238 Frontend-API-Aufrufe en 29 Modale exact met de 368 Backend-Routen verdrahtet zijn.

Nut: *Garandeert 0 tote Links en 100 % bedienbare Steuerelemente in alle Ansichten.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

77. Autonomer Master-Dossier- & Handboek-Generator (backend/system_dossier_generator.py)

Problem: Architectuur-Dokumentationen veralten meist al wenige Tage na ihrer Creatie.

Mechanik: Generiert op Knopfdruck (POST /api/systeem/generate-dossier) het aktuelle Systeem-Architectuur-Dossier simultan in de Projektordner en in de Obsidian-Vault (00_DOKUMENTATION/).

Nut: *Houdt de Systemdokumentation zonder manuellen Pflegeaufwand dauerhaft op de neuesten Stand.*

Prijs & Schattenseite (Trade-off): Als permanente Kern-Ansicht bzw. Systeem-Infrastruktur in de Dashboard integreert (vernachlässigbarer RAM-/CPU-Grundbedarf; Token-Kosten entstehen alleen bij aktiver Ausführung van LLM-Acties innerhalb van de Moduls).

10. Referentie-Matrix: Steuerbare Evey/Hermes-Plugins

Nr. & Plugin-ID	Fach-Kategorie	Kernmechanik & Functie in de Besturingssysteem
78. evey-cost-guard	Veiligheid & Wächter	Realtime-Kostenüberwachung en harte Budget-Abschaltung pro Tag en Task.
79. evey-session-guard	Veiligheid & Wächter	Bewaakt Sitzungslaufzeiten, Token-Obergrenzen en voorkomt Zombie-Sessions.
80. evey-email-guard	Veiligheid & Wächter	Scannt eingehende E-Mails voor de Triage op Phishing en

		Prompt-Injections.
81. evey-watchdog	Veiligheid & Wächter	Controleert in de 30s-Takt aktive Prozesse en start blockierte Worker automatisch nieuw.
82. evey-cache	Performance & Cache	24h-Antwoord-Cache voor de sofortigen, kostenfreien Beantwortung wiederholter Abfragen.
83. disk-cleanup	Performance & Wartung	Bereinigt temporäre Artefakte, veraltete Logs en geeft Festplattenspeicher frei.
84. evey-telemetry	Monitoring & Analytics	Erfasst Token-Ströme, Latenzen en Model-Aufrufe voor Mission Control en Guardian.
85. evey-status	Monitoring & Analytics	Continu Health-Ping op alle 11 Docker-Container en Gateways.
86. evey-delegation-score	Monitoring & Analytics	Beoordeelt de Erfolgs- en Qualitätsquote van Aufgabenübergaben tussen Agenten.
87. evey-autonomy	Agenten-Intelligenz	Bestuurt de Autonomiegrad bij mehrstufigen Achtergrond-Beslissingen.
88. evey-council	Agenten-Intelligenz	Mehrheits- en Konsensbildung tussen mehreren Specialisten (Mastermind-Kopplung).
89. evey-reflect	Agenten-Intelligenz	Selbstreflexions-Schleife voor de eigenständigen Fehlerkorrektur voor Ergebnisabgabe.
90. evey-learner	Agenten-Intelligenz	Extrahiert dauerhafte Erkenntnisse uit erledigten Taken voor de learnings-Tabel.
91. evey-identity	Agenten-Intelligenz	Borgt de strikte Einhaltung van SOUL.md, Tonalität en Rollen-Vangrails.
92. evey-habits	Agenten-Intelligenz	Beheert terugkerende Routinen hoe het tägliche 08:00-Uhr-Standup-Briefing.
93. evey-proactive	Agenten-Intelligenz	Staat toe Agenten, bij erkannten Engpässen selbstständig Handlungsvorschläge te maken.
94. evey-goals	Planning & Tasks	Verknüpft operationele Einzelaufgaben in de Kanban met übergeordneten Unternehmenszielen.
95. evey-scheduler	Planning & Tasks	Zeit- en prioritätsgesteuerte Einplanung van Achtergrond-Aufträgen.
96. evey-bridge	Brücken & Koppelingen	Interne Datendrehscheibe tussen BijnaAPI-Monolith, Hermes-Daemon en Sidecars.
97. evey-mqtt	Brücken & Koppelingen	Leichtgewichtiges Nachrichtenprotokoll voor IoT- en Realtime-Statussignale.
98. evey-moltbook	Brücken & Koppelingen	Synchroniseert gestructureerde Arbeitsbücher en Synthese-Notizen.
99. evey-telegram-ux	Brücken & Koppelingen	Bestuurt Rufnamen-Routing (/robert, /anwalt) en interaktive Goedkeuring-Buttons in Telegram.

© Michael Keller

100. evey-github	Brücken & Koppelingen	Anbindung voor Repository-Operationen, Commit-Analyses en Issue-Tracking.
101. evey-research	Tools & Research	Tiefensuche-Treiber voor Web-Scraping en Quellen-Extraktion in de Research Lab.
102. evey-news	Tools & Research	Achtergrond-Scanner voor Branchen-Feeds en Markt-Neuigkeiten (Oracle News Radar).
103. evey-digest	Tools & Research	Komprimiert umfangreiche Dokumentensammlungen in kompakte Management-Summaries.
104. evey-sandbox	Tools & Execution	Isolierte Ausführungsumgebung voor generierten Python- en Analyse-Code in de Showroom.
105. evey-rag	Geheugen & Kennis	Vektor-Retrieval-Treiber voor de Anbindung van AnythingLLM en lokalen Wissensarchiven.
106. evey-memory-adaptive	Geheugen & Kennis	Dynamische Gewichtung van Kurzzeit- en Langetermijngeheugen je na Kontextdruck.
107. evey-memory-consolidate	Geheugen & Kennis	Nachtlauf voor de Zusammenführung en Deduplizierung verwandter Geheugeneinträge.
108. evey-wallet	Financiën & Budgetten	Beheert API-Guthaben, Kontingente en kostenbezogene Transaktions-Limits.
109. evey-validate	Qualität & Ausführung	Controleert Ausgaben op Schema-Konformität, Pflicht-Marker (SYNTHESE-Beschikbaar) en Formatvorgaben.
110. evey-verification	Qualität & Ausführung	Faktencheck en Gegenprüfung kritiek Aussagen voor de EndGoedkeuring.
111. evey-delegate-model	Qualität & Ausführung	Kiest bij Teilaufgaben automatisch het kosten- en leistungsoptimale Zielmodell.

11. Enterprise- & Veerkracht-Architectuur

78. Replay & Time-Travel Debugging (backend/time_travel_debugger.py)

Problem: Bij komplexen Agenten-Workflows met vielen Tool-Calls is de nachträgliche Fehlerdiagnose in de Textlog unübersichtlich en het Verzweigen van Ausführungssträngen unmöglich.

Mechanik: Slaat op iedere Teilschritt met Een-/Ausgaben, Snapshots en Tokenverbruik in 'execution_traces'. Maakt mogelijk interaktives Replay (GET /api/traces/{task_id}), State-Forking vanaf Stap N (POST /api/traces/{task_id}/fork) en 1-Klik-Rollback modifizierter Bestanden.

Nut: Schnelle Ursachenanalyse en risikofreie Wat-wäre-als-Experimente met alternativen Prompts of Modellen zonder Neustart de gesamten Pipeline.

Prijs & Schattenseite (Trade-off): Verhoogt Disk-I/O om ~5–15 ms pro Bestand-Edit en aangetoond je na Snapshot-Limit ~50–250 MB zusätzlichen Speicherplatz op de Festplatte.

Wanneer ausschalten? & Drempelwaarden: Ausschalten op Systemen met extrem knappem Disk-Opslag of bij massenhaften Bestand-Generierungen (z. B. Build-Artefakte). | Drempelwaarden: Max Snapshots: < 10 = korte Historie | > 200 = höherer Disk-Verbruik (Std: 50). Max Trace-Steps: Std 100.

79. Multi-Model Eval-Matrix & A/B-Benchmarker (backend/model_benchmarker.py)

Problem: Model-Zuweisungen op Agenten basieren mangels empirischer Vergleichswerte vaak op subjektiven

Aannames.

Mechanik: Verzendt denselben Prompt simultan op zwei konfigurierte LLMs (POST /api/router/benchmark), meet Latentie, Token-Verbruik en Antwortlänge en slaat op de Historie persistent in 'model_benchmarks' (GET /api/router/benchmark/history).

Nut: Objektive, datengestützte Modellauswahl je Agentenrolle (z. B. DeepSeek V3 voor Schnelligkeit/Kosten vs. Claude 3.7 voor komplexe Architekturen).

Prijs & Schattenseite (Trade-off): N Kandidaten-Modellen kosten N-fache API-Tokens pro Testlauf.

Wanneer ausschalten? & Drempelwaarden: Wanneer ausschalten? Alleen gezielt voor Modellvergleiche starten, niet in de Dauerbetrieb.

80. Tri-Agent Consensus-Gate & Schiedsgericht (backend/consensus_gate.py)

Problem: Kritische Eingriffe (Code-Refactorings, Migrationen) bergen bij Einzelentscheidungen het Risico van Halluzinationen of Sicherheitslücken.

Mechanik: Beruft een dreiköpfiges Orgaan (Systeem Architect, Security Officer, QA Lead) een (POST /api/consensus/council-vote). Iedere Revisor votiert unabhängig; Goedkeuring vereist 2/3-Meerderheid. Alle Beschlüsse worden in 'consensus_decisions' archiviert (GET /api/consensus/history).

Nut: Verlässliche Risikominimierung en Eliminierung van Single-Point-of-Failure-Halluzinationen bij sensiblen Systemänderungen.

Prijs & Schattenseite (Trade-off): Verdreifacht (3x) de Token-Verbruik en verhoogt de Antwortzeit om +6 tot +20 Sek. Bij Einstimmigkeits-Zwang droht Entscheidungs-Stillstand (Deadlock).

Wanneer ausschalten? & Drempelwaarden: Ausschalten (of erst vanaf Prioriteit 4 = Kritiek aktivieren), als Geschwindigkeit en lage API-Kosten Vorrang hebben. | Drempelwaarden: Vanaf Prioriteit: Prio 2 = bijna iedere Task kost 3x Tokens | Prio 4 = alleen kritische Tasks (Std: Prio 3). Meerderheid: 2/3-Meerderheid aanbevolen.

81. Autonome Task-Selbstheilung met Git-Rollback (backend/task_self_healer.py)

Problem: Syntaxfehler of fehlerhafte Code-Imports blockieren Tasks direct en vereisen manuelles Eingreifen van de Nutzers.

Mechanik: Isoliert de Stacktrace, voert bij Laufzeitfehlern een Git-Rollback modifizierter Bestanden via en übergibt de Agenten een strukturierten Korrektur-Prompt (POST /api/healing/attempt). Tot te 3 autonome Reparaturversuche; Log-Abruf via GET /api/healing/logs.

Nut: Maximale Veerkracht bij Code- en Skript-Ausführungen met automatischer Selbstreparatur voor de Escalatie in de HITL-Board.

Prijs & Schattenseite (Trade-off): Iedere Selbstheilungsversuch kost 1 zusätzlichen LLM-Call (+3 tot +12 Sek. Latentie & Token-Kosten). Een automatisches Git-Rollback verwirft bij Mislukking ook nützliche Teilerfolge.

Wanneer ausschalten? & Drempelwaarden: Git-Rollback ausschalten, als unfertige Code-Entwürfe voor de manuellen Weiterarbeit in de Arbeitsverzeichnis staan blijven moeten. | Drempelwaarden: Max Reparaturversuche: 1 = geeft direct op | > 5 = teure Reparatur-Kaskade (Std: 3).

82. Event-Mesh & Posteingangs-Overzicht-Watcher (backend/event_mesh.py)

Problem: Taken mussten bisher manuell over het Dashboard angestoßen of over zeitgesteuertes IMAP-Polling abgefragt worden.

Mechanik: Zentraler Inbound-Event-Bus voor externe Webhooks (POST /api/events/inbound/{channel}) en automatischer Overzicht-Watcher (POST /api/events/scan-directory), de nieuwe Bestanden in 'data/inbox/' direkt in Kanban-Triage-Tasks überführt.

Nut: Vollautomatische Event- en Belegerfassung uit externen Systemen (GitHub, n8n, Stripe, lokale Dateiscanner) zonder Benutzerinteraktion.

Prijs & Schattenseite (Trade-off): Sehr korte Scan-Intervalle (< 3 Sek.) erzeugen kontinuierliche Dateisystem-Polls; het tägliche Morgen-Standup verbraucht ~1.500–3.000 Tokens pro Lauf.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als de lokale Inbox-Map niet aktiv gebruikt wordt of geen morgendlicher Briefing-Rapport gewünscht is. | Drempelwaarden: Scan-Intervall: 1–2s = unnötige Disk-Polls | > 30s = verzögerte Bestand-Erkennung (Std: 5s). Standup-Zeit: Std 08:00 Uhr.

12. Autonomie-, Sandbox- & Governance-Architectuur

83. Flüchtige Code-Sandboxen (backend/ephemeral_sandbox.py)

Problem: Ausführung van Agenten-Code birgt het Risico van Systemabstürzen, Endlosschleifen of unbeabsichtigten Dateiänderungen op de Host.

Mechanik: Voert Code in kurzlebigen, isolierten Docker-Micro-Containern met harter Ressourcen-Begrenzung (512 MB RAM, 1 CPU, 30s Timeout, geen Netz) uit (POST /api/sandbox/execute). De Sandbox wordt na Abschluss rückstandslos gelöscht.

Nut: Absolute Veiligheid en Systemstabilität bij de automatisierten Code-Ausführung en -Beproeving.

Prijs & Schattenseite (Trade-off): Container-Kaltstart kost ~300–800 ms Zusatzlatenz pro Tool-Call. Is het Netwerk deaktiviert, schlagen pip install of externe API-Abrufe in de Skript direct fehl.

Wanneer ausschalten? & Drempelwaarden: Ausschalten (of Netwerk aktivieren), als vertrauenswürdige lokale Skripte direkten Host-Toegang of schnelle Paketinstallationen nodig hebben. | Drempelwaarden: RAM-Limit: < 256 MB = OOM-Kill bij Pandas/NumPy | > 2048 MB = Host-RAM-Risico (Std: 512 MB). Timeout: < 10s = bricht Builds vanaf (Std: 30s).

84. Nächtliche Geheugen-Konsolidierung (backend/memory_consolidator.py)

Problem: Stetig anwachsende Traces, Heartbeats en veraltete Dialogdaten verlangsamen Datenbankabfragen in de Dauerbetrieb.

Mechanik: Prunt in Ruhephasen (Standard 03:00 Uhr) veraltete Traces en unkritische Logs anhand konfigurierbarer Retention-Termijnen (settings.json). Volledig steuerbar over de Hermes Core Einstellungen (Uhrzeit, Retention-Tage, Pruning-Tiefe, manueller Run-Button).

Nut: Dauerhaft schlanke Databases, reduzierte Latenzen en automatische Systeem-Hygiene zonder manuellen Wartungsaufwand.

Prijs & Schattenseite (Trade-off): Tijdens van de Konsolidierungslaufs (~10–30 Sek.) entsteht korte CPU-/Disk-Last; een te lage Pruning-Drempel (< 0.88) kan verwandte, maar eigenständige Feiten zusammenfassen.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als sluitende Roh-Traces voor een forensisches Audit dauerhaft ungefiltert ontvangen blijven moeten. | Drempelwaarden: Aufbewahrung: < 7 Tage = Verlies wichtiger Audit-Spuren | > 60 Tage = große SQLite-DB (Std: 14 Tage). Pruning-Drempel: 0.95 = konservativ | 0.88 = aggressiv (Std: 0.92).

85. Visueller Web-Agent met Screenshot-Audit (backend/visual_web_agent.py)

Problem: Taken op komplexen Webportalen zonder API (SPAs, Formulare, interaktive Dashboards) kunnen met Text-Scrapern niet bedient worden.

Mechanik: Bestuurt een echten Headless-Chromium-Browser (POST /api/browser/browse-and-capture), erfasst Screenshots voor iedere Klik- en Eingabeschritt in .hermes/visual_traces/{task_id}/ en extrahiert gestructureerde Daten.

Nut: Sluitende visuelle Traceerbaarheid en automatisierte Interaktion met modernen Webanwendungen zonder API-Zugang.

Prijs & Schattenseite (Trade-off): Headless-Chromium heeft nodig pro aktivem Audit-Lauf ~300 MB RAM en ~3–5 Sek. Renderzeit.

Wanneer ausschalten? & Drempelwaarden: Wanneer ausschalten? Bij reinem Backend-Betrieb zonder UI-Controles.

86. Virtueller Wat-Room & Pre-Mortem Stresstest (backend/war_room_simulator.py)

Problem: Unvorhergesehene Sicherheits-, Akzeptanz- of Compliance-Risico's worden bij Produkteinführungen vaak erst na de Rollout bemerkt.

Mechanik: Simuliert drei gegnerische Parteien (Kritiek Großkunde, Offensiver Pentester, Strenger Compliance-Auditor) voor de Goedkeuring (POST /api/simulation/wat-room). Creëert een aggregierte Risico-Matrix (LOW tot CRITICAL) met verbindlichen Auflagen.

Nut: Proaktives Aufdecken van Schwachstellen en Vermeidung kostspieliger Fehlentscheidungen voor de Livegang.

Prijs & Schattenseite (Trade-off): Kost ~1.500–3.000 zusätzliche Tokens en +4 tot +10 Sek. Wachttijd voor de eigentlichen Task. Bij Block-Drempel MEDIUM entstehen häufiger Fehlalarme.

Wanneer ausschalten? & Drempelwaarden: Auto-Pre-Mortem in de normalen Entwicklungsalltag ausschalten en

alleen voor produktionskritische Eingriffe (HIGH/CRITICAL) nut. | Drempelwaarden: Block-Drempel: MEDIUM = blockiert vaak vorsorglich | CRITICAL = stopt alleen katastrophale Risico's (Std: HIGH).

87. SLA- & Übergabe-Verträge tussen Agenten (backend/sla_contract_enforcer.py)

Problem: Lose Delegationen in Multi-Agenten-Hierarchien voeren vaak te unVolledigen Zuarbeiten, de op de menschlichen Operator eskaliert worden.

Mechanik: Sluit bij internen Delegationen digitale Verträge met Pflichtfeldern, Mindestlänge en Akzeptanzkriterien vanaf (POST /api/contracts/create). Valideert Lieferungen autonom (POST /api/contracts/validate) en weist mangelhafte Resultaten automatisch voor de Herstel vanaf.

Nut: Strikte Einhaltung van Qualitätsstandards in de Agenten-Team en Vermeidung unfertiger Zwischenstufen in de HITL-Board.

Prijs & Schattenseite (Trade-off): Wordt de Mindestlänge te hoog angesetzt (> 300 Zeichen), worden präzise Kurzantworten afgewezen en oplossen teure Nacharbeits-Schleifen uit.

Wanneer ausschalten? & Drempelwaarden: Auto-Reject ausschalten, als Subagenten ook knappe Status- of Ja/Nein-Antwoorden zurückgeben mogen. | Drempelwaarden: Min. Länge: < 30 = lässt Platzhalter via | > 300 = lehnt knappe Faktenantworten vanaf (Std: 100 Zeichen). Max Turnaround: Std 60 Min.

88. Centrale Autonomie- & Drempelwaarde-Besturing (backend/autonomy_settings.py)

Problem: Feste Drempelwaarden in de Programmcode voorkomen een schnelle Anpassung van Sicherheits-, Sandbox- en Veerkracht-Regeln in de laufenden Betrieb.

Mechanik: Bundelt alle 10 Autonomie-Gruppen (Concurrency, Loop-Killer, Selbstheilung, Docker-Sandbox, Time-Travel-Snapshots, Consensus-Gate, Wat-Room, SLA-Verträge, Inbox/Standup en Flotten-Hygiene) in settings.json en synchroniseert zij over GET/POST /api/settings/autonomy-modules met de System Control Center.

Nut: Ieder Bescherming- en Autonomie-Module lässt zich voor de Looptijd per Klik een- of ausschalten en exact op het gewünschte Risico- en Ressourcenprofil feinjustieren.

Prijs & Schattenseite (Trade-off): Een defekter Container kan via Auto-Restart in een Crash-Loop geraten; de visuelle Browser-Audit start Chromium (+300 MB RAM, +4 Sek. Dauer).

Wanneer ausschalten? & Drempelwaarden: Auto-Restart tijdens manueller Container-Wartung ausschalten; Browser-Audit bij reinem Backend-Betrieb deaktivieren. | Drempelwaarden: DB-Back-up-Tage: < 3 Tage = knappe Historie | > 30 Tage = ~500 MB+ Back-up-Opslag (Std: 7 Tage).

13. Performance-Core, Doorvoer-Schaling & Token-Effizienz

89. Semantisches Prompt- & Response-Caching (backend/semantic_cache.py)

Problem: Terugkerende of licht umformulierte Agenten-Anfragen verursachen unnötige LLM-API-Kosten en sekundenlange Wartezeiten.

Mechanik: Berekent voor iedere Prompt een SHA-256-Hash evenals een L2-normalisierten Wort-/3-Gramm-Vektor in SQLite en levert bij een Cosine-Ähnlichkeit >= 0.95 direct de gespeicherten Response-Treffer.

Nut: Antwortzeiten onder 10 Millisekunden en 100 % Token-Ersparnis bij semantisch identischen Anfragen.

Prijs & Schattenseite (Trade-off): Is de Cosine-Drempel te laag (< 0.92), übersieht de Cache feine Bedeutungsunterschiede (z. B. 'lösche Test-DB' vs. 'lösche Prod-DB') en levert falsche of veraltete Antwoorden.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij Taken met Realtime-Daten (Börsenkurse, Live-Logs, Systemstatus) of als iedere Antwoord frisch generiert worden moet. | Drempelwaarden: Cosine-Drempel: < 0.92 = falsche Antwoorden uit Cache! | > 0.98 = nauwelijks Treffer (Std: 0.95). TTL: Std 24h. Max Einträge: Std 500.

90. Paralleles Map-Reduce Sub-Tasking / Fan-Out & Fan-In (backend/map_reduce_executor.py)

Problem: Sequenzielle Abarbeitung vieler Einzeldokumente of Teilfragen leidt tot linearem Zeitwachstum en langen Wartezeiten.

Mechanik: Teilt Listen-Opdrachten automatisch op tot te N parallele Asyncio-Worker (Semaphore-gesteuert) op en voert de Teilergebnisse in de Reduce-Stap zusammen.

Nut: Vervielfacht de Doorvoer bij Dokumenten-, Research- en Code-Batch-Analyses zonder Overbelasting de Event-Loop.

Prijs & Schattenseite (Trade-off): Erzeugt N-fache gleichzeitige API-Last (Gefahr van HTTP-429 Tarief-Limits bij de Provider) en ~20–35 % Token-Overhead via de anschließende Reduce-Synthese.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij strikten API-Tarief-Limits of als de Teilaufgaben eng voneinander abhängen en sequenziell aufeinander opbouwen moeten. | Drempelwaarden: Max Worker: > 8 = Tarief-Limit-Gefahr (Std: 4). Chunk-Timeout: Std 30s. Vanaf Elementen: Std 3.

91. Speculative Bijna-Routing & Latentie-Hedging (backend/speculative_hedger.py)

Problem: Einzelne langsame Cloud-Requests (Tail-Latency-Spikes) blockieren de gesamte Agenten-Ausführung.

Mechanik: Start na Ablauf van hedge_delay_seconds (z. B. 2.5s) automatisch een parallelen Ersatz-Call op een schnellen Fallback-Model en übernimmt het eerst eintreffende Resultaat.

Nut: Eliminiert Hänger via langsame API-Endpunkte en stabilisiert de Antwortzeiten in de 99. Perzentil.

Prijs & Schattenseite (Trade-off): Als het Primärmodell kort na de Hedge-Start doch nog antwoordt, worden beide Requests afgerekend (tot te 2x Token-Kosten bij langsamen Prompts).

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij knappem API-Budget of als langsame Reasoning-Modellen gebruikt worden, de regulär > 10 Sek. Denkzeit nodig hebben. | Drempelwaarden: Hedge-Verzögerung: < 1.5s = bijna altijd doppelte API-Kosten! | > 8s = nauwelijks Latentie-Bescherming (Std: 2.5s).

92. Dynamisches Context-Compaction & Hierarchisches Summarizing (backend/context_compactor.py)

Problem: Lange Agenten-Sitzungen blähen het Kontextfenster op, verlangsamen de Prompt-Prefill en verhogen de Kosten pro Turn drastisch.

Mechanik: Extrahiert vanaf een einstellbaren Token-Drempelwaarde alle harten Feiten (Doelen, Dateipfade, Beslissingen, Fout) in een kompakten [HIERARCHICAL_MEMORY_STATE]-Block en behoudt alleen de jüngsten Runden in de Volltext.

Nut: Bespaart 65–80 % Context-Tokens bij langen Sessions zonder Verlies wichtiger Projektdaten.

Prijs & Schattenseite (Trade-off): De Komprimierungslauf kost einmalig ~1.000 Tokens; exakte Code-Zeilen of kleine Detailwerte uit weit zurückliegenden Nachrichten kunnen in de Samenvatting verloren gaan.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als de Agent wortwörtlich op sehr frühe Nachrichten derselben Vergadering zurückgreifen moet. | Drempelwaarden: Token-Drempel: < 3000 = vergisst Details te früh | > 24000 = hoge Prompt-Kosten (Std: 6000). Letzte Turns behouden: Std 4.

93. SQLite WAL Connection-Pool & Async Write-Batching (backend/async_write_batcher.py)

Problem: Hunderte einzelne SQLite-INSERTs bij parallelen Agenten-Läufen erzeugen Disk-I/O-Spitzen en 'database is locked'-Conflicten.

Mechanik: Sammelt Telemetrie- en Audit-Gebeurtenissen in een Thread-sicheren RAM-Ringpuffer en schreibt zij geBundelt via executemany() in de WAL-Modus.

Nut: Reduceert Festplatten-SchreibToegange om ongeveer 80 % en houdt de Haupt-Event-Loop frei van Blockaden.

Prijs & Schattenseite (Trade-off): In de Falle een harten Stromausfalls of kill -9 voor de nächsten Flush-Intervall gaan de in de RAM gepufferten Einträge de letzten 1–5 Sekunden verloren.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als iedere einzelne Log-Eintrag direct en zonder Sekundenverzögerung synchron op de Festplatte liggen moet. | Drempelwaarden: Batch-Größe: < 5 = viele Disk-Writes | > 100 = mehr Verlies bij Crash (Std: 25). Flush-Intervall: Std 2.0s.

14. Moderne Geheugen- & RAG-Architectuur

94. Hybrid-Search met BM25 FTS5 & Reciprocal Rank Fusion (backend/hybrid_search_engine.py)

Problem: Reine Vektorsuche vindt semantisch ähnliche Texte, scheitert echter vaak op exakten Fehlercodes, Funktionsnamen of Seriennummern.

Mechanik: Kombiniert SQLite FTS5 Volltext-Ranking (BM25) en Cosine-Vektor-Ähnlichkeit over Reciprocal Rank

Fusion (RRF).

Nut: Vereint exakte Keyword-Treffer en semantisches Begrip in een einzigen, hochpräzisen Trefferliste.

Prijs & Schattenseite (Trade-off): Doppelte Index-Abfrage verhoogt de Such-Latentie om ~15–40 ms; een te hohes Top-K (> 10) füllt de Agenten-Prompt met tausenden Zusatz-Tokens.

Wanneer ausschalten? & Drempelwaarden: Bijna nooit ausschalten — hoogstens Top-K op 3–5 verminderen, als Token-Kosten pro Anfrage minimaliseert worden moeten. | Drempelwaarden: RRF-Konstante K: Std 60. BM25-Gewicht: 0.0 = alleen Vektor | 0.5 = Balance | 1.0 = alleen Trefwoord (Std: 0.50). Top-K: Std 5.

95. Lokaler Knowledge-Graph / Tripel-Opslag (backend/knowledge_graph_store.py)

Problem: Flache Text-Chunks erfassen geen strukturierten Abhängigkeiten (wie beheert welk Systeem of welke Component gebruikt welke Dienst).

Mechanik: Extrahiert en slaat op Subjekt-Prädikat-Objekt-Tripel met Konfidenzscore in SQLite en maakt mogelijk mehrstufige Graph-Traversierungen (Multi-Hop).

Nut: Agenten herkennen Systeem- en Organisationszusammenhänge over mehrere Ebenen hinweg.

Prijs & Schattenseite (Trade-off): Automatische Tripel-Extraktion kost bij de Opslaan ~500 Zusatz-Tokens. Vanaf > 2 Traversal-Hops explodiert de Anzahl de Nachbarknoten exponentiell.

Wanneer ausschalten? & Drempelwaarden: Auto-Extraktion ausschalten bij reinem Kurzzeit-Chat zonder langfristigen Wissensaufbau; Hops op maximaal 2 begrenzen. | Drempelwaarden: Max Hops: 1 = directe Nachbarn | 2 = optimal | >= 3 = Knoten-Explosion! (Std: 2). Min. Konfidenz: Std 0.70.

96. Agentic Corrective RAG / CRAG (backend/corrective_rag.py)

Problem: Klassisches RAG reicht irrelevante Suchtreffer ungeprüft op het Sprachmodell weiter en provoziert daardoor Fehlantworten.

Mechanik: Beoordeelt iedere abgerufenen Document-Chunk tegen een Relevanz-Drempelwaarde (0.45) en voert bij schwachen Treffern automatisch een Query-Rewrite met Synonym-Expansion via.

Nut: Filtert Wissensrauschen voor de Antwortgenerierung heraus en verhoogt de Trefferqualität bij unklaren Vragen.

Prijs & Schattenseite (Trade-off): Iedere Query-Umformulierung kost 1 zusätzlichen LLM-Call (+1,5 tot +4 Sek. Latentie). Is de Relevanz-Drempel te hoog (> 0.70), dreht CRAG unnötige Extrarunden.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als de Kennisbank klein en sauber gepflegt is of schnelle Antwortzeiten onder 2 Sekunden gefordert zijn. | Drempelwaarden: Relevanz-Drempel: < 0.30 = lässt zwakke Quellen via | > 0.70 = endlose Such-Schleifen (Std: 0.45). Max Rewrites: Std 2.

97. 2-Niveaus Core-Memory na MemGPT/Letta-Vorbild (backend/core_memory_manager.py)

Problem: Belangrijke Nutzerpräferenzen en Projektziele gaan verloren, zodra zij uit de kurzlebigen Chat-Venster herausfallen.

Mechanik: Verankert editierbare Pinned-Working-Memory-Blöcke (<CORE_WORKING_MEMORY>) dauerhaft in de Systeem-Prompt, getrennt van de großen Archiv-Opslag.

Nut: Garandeert een permanentes, van de Agenten selbst pflegbares KernGeheugen over beliebig viele Sitzungen hinweg.

Prijs & Schattenseite (Trade-off): Iedere angepinnte Block aangetoond bij absolut jedem LLM-Aufruf dauerhaft Prompt-Tokens (10 Blöcke × 800 Zeichen ≈ 2.000 Tokens Grundlast pro Nachricht).

Wanneer ausschalten? & Drempelwaarden: Ausschalten of Block-Anzahl op 3–5 verminderen, als kleine Modellen met engem Kontextfenster of knappe Token-Budgetten gebruikt worden. | Drempelwaarden: Max Blöcke: > 15 = hoher Token-Grundverbrauch (Std: 10). Max Zeichen/Block: < 300 = schneidet Regeln vanaf | > 1500 = verstopft Prompt (Std: 800).

98. Automatisches Citation- & Quellen-Pinning (backend/citation_pinner.py)

Problem: Zonder directe Quellenverweise is voor de Nutzer niet überprüfbar, uit welchem Document een Faktenaussage van de Agenten stammt.

Mechanik: Ordnet Sätze de Antwoord per Token-Overlap de abgerufenen Quell-Dokumenten te, fügt Inline-Belege

([Quelle: ID]) een en controleert de Mindest-Belegquote.

Nut: Maakt iedere Verklaring revisionssicher nachvollziehbar en deckt unbelegte Behauptungen direct op.

Prijs & Schattenseite (Trade-off): Verhoogt de Output-Token-Verbruik om ~10–15 %; een te hoge Mindest-Abdeckung (> 80 %) voert bij kreativen of zusammenfassenden Vragen te Fehlwarnungen.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij freiem Brainstorming, Code-Generierung of lockerem Alltags-Chat zonder Dokumentenbezug. | Drempelwaarden: Min. Abdeckung: < 30% = unbelegte Aussagen | > 85% = Fehlwarnungen bij Samenvattingen (Std: 60%).

15. Betrouwbare Uitvoering & Determinisme (Durable Execution)

99. Structured Outputs & JSON-Schema-Garantie (backend/structured_output_enforcer.py)

Problem: Sprachmodelle leveren soms ungültiges JSON (Markdown-Rahmen, fehlende Klammern of falsche Datentypen), wodurch nachgelagerte Code-Pipelines abstürzen.

Mechanik: Repariert Syntaxfehler in de Roh-String automatisch en erzwingt alle Pflichtfelder en Datentypen van de übergebenen Doel-Schemas.

Nut: Garandeert 100 % maschinenlesbare, typensichere JSON-Payloads tussen Agenten en Backend-Koppelingen.

Prijs & Schattenseite (Trade-off): Iedere Auto-Reparatur-Schleife kost +1 tot +3 Sek. Latentie en zusätzliche Tokens. Strikte Schema-Validatie lehnt Antwoorden ook vanwege harmloser Zusatzfelder vanaf.

Wanneer ausschalten? & Drempelwaarden: Strikte Validatie ausschalten, als API-Endpunkte of Skripte ook met flexiblen of teilweisen JSON-Feldern umgehen kunnen. | Drempelwaarden: Schema-Controle: Strikt vs. Tolerant (Std: Strikt). Max Reparaturen: 1–2 = repariert 98 % alle Tippfehler | > 3 = verschwendet Tokens (Std: 2).

100. Durable Execution Checkpointing / Pause & Resume (backend/durable_checkpoint_manager.py)

Problem: Bricht een 10-schrittiger Research- of Build-Opdracht bij Stap 8 via een Neustart vanaf, mussten bisher alle 7 Vorarbeiten teuer wiederholt worden.

Mechanik: Borgt na jedem abgeschlossenen Stap de kompletten Variablen- en Fortschrittszustand transaktional in SQLite.

Nut: Unterbrochene Langläufer zetten exact op de letzten gültigen Checkpoint opnieuw op, zonder Werk of Tokens doppelt te verbrauchen.

Prijs & Schattenseite (Trade-off): Checkpointing bij jedem einzelnen Stap (N = 1) erzeugt spürbare SQLite-Schreiblast. Auto-Resume bij de Booten kan veraltete Tasks van de Vortag ungewollt opnieuw anfeuern.

Wanneer ausschalten? & Drempelwaarden: Auto-Resume ausschalten, als unterbrochene Taken na een Neustart erst manuell gecontroleerd en freigegeben worden moeten. | Drempelwaarden: Alle N Stappen: 1 = absolut absturzsicher, mehr Disk-I/O | 3–5 = schont SSD (Std: 1). Aufbewahrung: Std 14 Tage.

101. Idempotency-Keys & Tool-Call-Deduplizierung (backend/idempotency_guard.py)

Problem: Bij Netwerk-Retries of Agenten-Schleifen bestaat de Gefahr, dass dieselbe E-Mail, Factuur of Webhook-Actie mehrfach ausgelöst wordt.

Mechanik: Vergibt voor iedere mutierenden Tool-Call een SHA-256-Idempotency-Key in de SQLite-Ledger en blockiert identische Folgeaufrufe innerhalb de TTL.

Nut: Voorkomt doppelte Außenwirkungen betrouwbaar na de Vorbild moderner Zahlungs-Gateways (Stripe-Principe).

Prijs & Schattenseite (Trade-off): Als de Nutzer exact denselben Befehl innerhalb de Sperrfrist (Standard 24 h) absichtlich een zweites Mal ausführen wil, blockiert de Guard.

Wanneer ausschalten? & Drempelwaarden: TTL-Stunden op 1 h verlagen of kurzzeitig ausschalten, als identische Acties in de Testbetrieb mehrfach hintereinander ausgeführt worden moeten. | Drempelwaarden: TTL (Stunden): < 1h = kurzer Duplikatschutz | > 48h = blockiert gewollte Wiederholungen (Std: 24h).

102. Dry-Run / Shadow-Mode voor Agenten-Opdrachten (backend/dry_run_simulator.py)

Problem: Nieuwe of komplexe Agenten-Opdrachten wil graag man voor de scharfen Ausführung vaak erst zonder

Risico op echten Produktionsdaten testen.

Mechanik: Fängt in de Shadow-Mode alle schreibenden Bestand-, Database- en API-Befehle vanaf en notuleert in plaats daarvan een detaillierten Mutations-Vorschauplan.

Nut: Maakt mogelijk gefahrlose Trockenübungen en Risico-Audits voor de endgültigen Goedkeuring.

Prijs & Schattenseite (Trade-off): SOLANGE AKTIV, WORDEN GEEN ECHTEN BESTANDEN GESCHRIEBEN EN GEEN ECHTEN APIS AUSGEFÜHRT! Vergisst man de Schalter, werkt het Systeem na außen hin 'tot'.

Wanneer ausschalten? & Drempelwaarden: In de normalen Produktivbetrieb dwingend AUSGESCHALTET lassen! Alleen gezielt voor Trockenübungen (Dry-Runs) en Sicherheits-Audits einschalten. | Drempelwaarden: Hauptschalter standardmäßig UIT (false). Alleen voor isolierte Testläufe aktivieren.

103. Dead-Letter-Queue (DLQ) met Auto-Replay-Manager (backend/dead_letter_queue.py)

Problem: Fehlgeschlagene Webhooks of asynchrone Achtergrond-Jobs gaan bij kurzzeitigen Drittanbieter-Ausfällen zonder Auffangbecken spurlos verloren.

Mechanik: Slaat op iedere gescheiterten Job samt Origineel-Payload en Fehlergrund in de DLQ-Tabel en wiederholt ihn met exponentiellem Backoff.

Nut: Geen Opdracht gaat verloren; fehlgeschlagene Tasks lassen zich jederzeit einzeln of gesammelt opnieuw abspielen.

Prijs & Schattenseite (Trade-off): Bij dauerhaft fehlerhaften Aufträgen (z. B. ungültiger API-Key) verbrauchen de Wiederholungsversuche onnodig Ressourcen; zeitversetzte Replays kunnen Acties verspätet auslösen.

Wanneer ausschalten? & Drempelwaarden: Auto-Replay ausschalten, als fehlgeschlagene Opdrachten uitsluitend manuell gesichtet en einzeln freigegeben worden moeten. | Drempelwaarden: Max Retries: 1 = bricht bij kurzem Ausfall vanaf | > 5 = staut tote Jobs op (Std: 3). Backoff-Basis: Std 10s (10s -> 20s -> 40s).

16. Veiligheid, Gegevensbescherming & Enterprise-Vangrails

104. Bidirektionaler PII-Scrubber & Re-Hydration (backend/pii_scrubber.py)

Problem: Worden E-Mails, Telefonnummern of IBANs in de Klartext op externe Cloud-LLMs übertragen, drohen DSGVO-Verstöße en ungewollter Datenabfluss.

Mechanik: Ersetzt gevoelige Personendaten voor de API-Aufruf lokaal via Platzhalter ([EMAIL_1], [IBAN_1]) en tauscht deze in de eintreffenden Antwoord opnieuw tegen de echten Werte uit.

Nut: Cloud-Modellen sehen niemals echte Personendaten, tijdens de Nutzer voor Ort toch Volledige Documenten en Antwoorden ontvangt.

Prijs & Schattenseite (Trade-off): Als het LLM de Platzhalter in de Antworttext licht abwandelt, stelt de Rückübersetzung (Rehydrierung) fehl. Bovendien kan Regex-Maskierung soms Code-Strings verfälschen.

Wanneer ausschalten? & Drempelwaarden: Ausschalten, als uitsluitend lokale Modellen (Ollama) gebruikt worden of het LLM dwingend de echten E-Mail-Domains/Namen analyseren moet. | Drempelwaarden: Granulare Schalter voor E-Mails, Telefonnummern, IBANs en automatische Rehydrierung (alle standardmäßig aktiv).

105. Egress-Firewall & Domain-Allowlisting voor Agenten (backend/egress_firewall.py)

Problem: Over verborgen Prompt-Injections in Webseiten könnten Agenten angewiesen worden, interne Daten per HTTP-Request op fremde Angreifer-Server te verzenden.

Mechanik: Controleert iedere ausgehende Doel-URL tegen de konfigurierte Domain-Allowlist en blockiert unautorisierte Hosts evenals rohe IPv4-Adressen.

Nut: Unterbindet Daten-Exfiltration op Netzwerkebene selbst bij manipulierten Eingaben.

Prijs & Schattenseite (Trade-off): Solange allowlist_only aktiv is, wordt iedere nieuwe Webseite, API of Documentatie, de niet explizit in de Domain-Liste staat, bij Web-Recherchen hart blockiert.

Wanneer ausschalten? & Drempelwaarden: Ausschalten (of benötigte Domains ergänzen), als de Research-Agent frei in de offenen Web recherchieren moet. | Drempelwaarden: Erlaubte Domains: Kommagetrennte Whitelist. Roh-IP-Blockade beschermt voor direkten IP-Exfiltrationen.

106. Granulare Agenten-RBAC & Bestand-Scope-Jails (backend/agent_rbac_jail.py)

Problem: Als iedere Sub-Agent vollen SchreibToegang op het gesamte Projektverzeichnis besitzt, kan een Frontend-Agent versehentlich Backend-Kernel-Bestanden of .env-Schlüssel überschreiben.

Mechanik: Bindet iedere Agentenrolle op een feste Werkzeugliste en een erlaubtes Overzicht-Jail (z. B. static/ voor Frontend-Agenten).

Nut: Zet het Principe minimaler Rechten (Least Privilege) voor iedere einzelnen Prozess in de Besturingssysteem via.

Prijs & Schattenseite (Trade-off): Voorkomt, dass een Beheerder-Agent legitim Konfigurationsdateien außerhalb van de Projektordners wartet of .env-Sjablonen direkt gecontroleerd.

Wanneer ausschalten? & Drempelwaarden: Alleen voor dedizierte Systemwartungs-Taken kurzzeitig lockern; de .env-Bescherming zou moeten in de Normalbetrieb altijd aktiv blijven. | Drempelwaarden: Schalter voor Path-Jail, .env-Sperre en Systemordner-Sperre (/etc, /root, /proc).

107. Deterministischer Output-Linter & Beleid-Checker (backend/output_policy_linter.py)

Problem: Sprachmodelle verfallen gelegentlich ondanks Systeem-Prompt in künstliche KI-Floskeln of generieren riskante Shell-Snippets.

Mechanik: Scannt de generierten Text in Realtime mittels regulärer Ausdrücke, entfernt Sycophancy-Opener/AI-Slop en entschärft destruktive Befehle.

Nut: Borgt sprachliche Präzision en technische Veiligheid zonder zusätzlichen LLM-Prüfaufruf.

Prijs & Schattenseite (Trade-off): De Destruktiv-Filter kan ook harmlose Aufräum-Skripte of gewollte Database-Migrationen blockieren, als darin Befehle hoe DROP of rm -rf vorkommen.

Wanneer ausschalten? & Drempelwaarden: Destruktiv-Blocker kurzzeitig ausschalten, als gezielt Server-Aufräumskripte of SQL-Reset-Migrationen creëert worden. | Drempelwaarden: Schalter voor KI-Floskeln entfernen, Destruktive Befehle blockieren en Auto-Bereinigung.

108. Manipulationssichere Execution Receipts / SHA-256-Quittungen (backend/execution_receipt_ledger.py)

Problem: Voor Compliance-Audits (EU AI Act / ISO 42001) reichen eenvoudige Text-Logs niet uit, da zij achteraf verändert worden kunnen.

Mechanik: Verkettet iedere Task-Afrekening (Model, Tokens, USD-Kosten, ausgeführte Tools) met de SHA-256-Hash van de Vorgängereintrags in een Blockchain-ähnlichen Kette.

Nut: Iedere nachträgliche Manipulation op Kosten- of Entscheidungsprotokollen fällt bij de Integritätsprüfung direct op.

Prijs & Schattenseite (Trade-off): Verursacht minimalen Rechen- en Opslag-Overhead (~2 ms en ~2 KB SQLite-Opslag pro Task); de Hash-Kette wächst over Monate kontinuierlich op.

Wanneer ausschalten? & Drempelwaarden: Kan in de Produktivbetrieb dauerhaft aktiviert blijven; alleen op extrem speicherlimitierten Kleinstsystemen ausschalten. | Drempelwaarden: Hash-Verkettung (SHA-256) + detaillierte Kosten-Aufschlüsselung pro Lauf.

17. Selbst-Optimalisatie, Evaluation & Schwarm-Intelligenz

109. Automatischer Prompt-Optimizer na DSPy/TextGrad-Principe (backend/prompt_optimizer.py)

Problem: Statische Systeem-Prompts wiederholen dieselben Fout altijd opnieuw, solange geen Mens manuell nachbessert.

Mechanik: Wertet reale Fout-Logs een Rol uit, herkent systematische Zwakten en generiert gezielte Guardrail-Zusatzregeln voor de Systeem-Prompt.

Nut: Agenten leren kontinuierlich uit gescheiterten Läufen en härten ihre Instruktionen selbstständig.

Prijs & Schattenseite (Trade-off): Is Auto-Apply aktiv, kan een fehlerhaft abgeleitete Regel het Verhalten van de Agenten dauerhaft verzerren (Prompt-Drift) en de Systeem-Prompt aufblähen.

Wanneer ausschalten? & Drempelwaarden: Auto-Apply in de Produktivbetrieb ausgeschaltet lassen, zodat vorgeschlagene Prompt-Patches erst na menschlicher Controle übernommen worden. | Drempelwaarden: Vanaf Fouten: 1 = überreagiert op Einzelfehler | > 8 = leert sehr träge (Std: 3). Max Regeln: > 10 = bläht Systeem-Prompt

op (Std: 5).

110. Gold-Standard Regression-Test-Suite / Eval-Runner (backend/eval_regression_runner.py)

Problem: Een vermeintlich kleine Wijziging op de Systeem-Prompt of Model kan bestehende Sicherheits- of Formatregeln unbemerkt verschlechtern.

Mechanik: Voert voor de Übernahme nieuwe Einstellungen automatisierte Gold-Standard-Testfälle uit en controleert Bestehensquote evenals verbotene Muster.

Nut: Voorkomt Qualitäts-Regressionen in de Produktivbetrieb via een objektives Quality-Gate.

Prijs & Schattenseite (Trade-off): Iedere komplette Eval-Durchlauf feuert alle hinterlegten Test-Prompts tegen de LLM-API (kost je na Testumfang ~5.000–25.000 Tokens en 15–60 Sek. Looptijd).

Wanneer ausschalten? & Drempelwaarden: Deploy-Blockade ausschalten, als schnelle experimentelle Prompt-Tests zonder Wachttijd durchgeführt worden. | Drempelwaarden: Min. Pass-Tarief: < 75% = lässt Verschlechterungen via | 100% = blockiert al bij kleinsten Abweichungen (Std: 90%).

111. Multi-Armed Bandit Model-Router (backend/bandit_model_router.py)

Problem: Feste Model-Zuweisungen reageren niet darauf, als een Cloud-Provider plötzlich langsamer wordt of erhöhte Fehlerraten toont.

Mechanik: Bepunktet ieder Model lopend na realer Erfolgsquote (60 %) en Geschwindigkeit (40 %) en kiest dynamisch de besten Kandidaten.

Nut: Maximaliseert Antwortqualität en Tempo automatisch anhand echter Looptijd-Telemetrie.

Prijs & Schattenseite (Trade-off): Via de Explorationsrate (Epsilon, z. B. 0.15 = 15 %) test de Router absichtlich altijd opnieuw alternative Modellen uit, de in de Einzelfall langsamer zijn kunnen.

Wanneer ausschalten? & Drempelwaarden: Ausschalten (of Epsilon op 0.00 zetten), als voor iedere Lauf een 100 % festes, vorhersagbares Model erzwungen worden moet. | Drempelwaarden: Epsilon: 0.00 = gebruikt stur het beste Model | > 0.30 = probiert te vaak schwächere Modellen (Std: 0.15). Erfolgs-/Latentie-Gewicht: Std 0.60 / 0.40.

112. Dynamisches Ephemeral-Team-Spawning (backend/ephemeral_team_spawner.py)

Problem: Een einzelner Generalisten-Agent is bij großen Querschnittsaufgaben (Architectuur + UI + Security + QA) snel überfordert.

Mechanik: Rekrutiert passend voor de Missions-Briefing een temporäre Specialisten-Task-Force en lost op zij na erledigter Missie opnieuw op.

Nut: Bundelt Spezialwissen bedarfsgerecht zonder dauerhaften Ressourcen-Overhead.

Prijs & Schattenseite (Trade-off): Een 4-köpfiges Ad-hoc-Team vervielfacht de Token-Verbruik (3x tot 5x) en heeft nodig zusätzlichen Koordinations-Overhead tussen de Teammitgliedern.

Wanneer ausschalten? & Drempelwaarden: Ausschalten bij eenvoudigen Einzelaufgaben of knappem Token-Budget; Max. Teamgröße in de Alltag op 3–4 begrenzen. | Drempelwaarden: Max Teamgröße: 2–4 = ideal | > 5 = hoher Kommunikations-Overhead & 5x Token-Verbruik (Std: 4).

113. Live-Ressourcen-Protector & Host-Backpressure (backend/resource_backpressure.py)

Problem: Parallele Container, Browser-Audits en lokale Prozesse kunnen bij Lastspitzen de Host-RAM of de CPU überlasten (OOM-Kill).

Mechanik: Bewaakt CPU-, RAM- en Disk-Metrieken in Realtime en drosselt laag priorisierte Achtergrond-Tasks vanaf 85 % Bezetting automatisch.

Nut: Beschermt de Server betrouwbaar voor Abstürzen via Overbelasting en houdt kritische Kernprozesse jederzeit reaktionsfähig.

Prijs & Schattenseite (Trade-off): Zijn de Drempelwaarden te laag eingestellt (CPU < 70 % of RAM < 70 %), worden Achtergrond-Taken al bij normalen kurzen Lastspitzen ständig ausgebremst.

Wanneer ausschalten? & Drempelwaarden: Niet komplett ausschalten — in plaats daarvan bij starker Hardware de CPU-/RAM-Schwellen op 90 % anheben. | Drempelwaarden: Max CPU/RAM: < 70% = drosselt bij normaler Werk | > 92% = OOM-Gefahr (Std: 85%). Min. freie Disk: Std 2.0 GB.

18. Pijler 3: Wirtschaft & ERP (alpha) & Cliënten-Suite

Module / View	Funktionsumfang & Technische Merkmale (v0.5.1)
Adressen & CRM + PocketBase-Sync	Zentraler Kontakt-, Debiteuren- (10000+) en Kreditorenstamm (70000+), 360°-Kontakt-Drawer, Multi-Channel-Timeline, Kalender/Wiedervorlagen evenals LinkedIn- & Medien-Sync over PocketBase (Ports 3005/8090/8092).
Artikelen & diensten (ART)	Stammdatenkatalog vanaf ART-1001 voor Dienstleistungen, Stundensätze, Pauschalen, SaaS-Abonnements evenals physische Produkte met Voorraadbeheer.
Vorgänge & Verträge	Doorlopende Belegkette Offerte (ANG-YYYY-NNNN) → Opdracht (VANAF-YYYY-NNNN) incl. gewichteter Deal-Pipeline, Omzet-Forecast en Vertrags-Fristenradar (30/14/7-Tage-Alarmen).
Rechnungswesen & DATEV	Ausgangs- en Eingangsbelege na § 14 UStG, GiroCode-Zahlungs-QR, Finanz-Analytics, automatisches Aanmaningsprocedure (Dunning Engine) en EXTF/CSV-Export voor DATEV.
Corporate & Cliënten-Isolation	Mehrere eigene Unternehmungen (company_id) met physisch getrennten SQLite-Databases in de WAL-Modus, eigenen Nummernkreisen, Briefbögen en Sjablonen-Editor.

19. Architectuur-, Security- & Deployment-Features (v0.5.0 – v0.5.1)

Feature / Subsystem	Implementatie & Betriebsnutzen (v0.5.1)
Modulare Router-Architectuur	Auslagerung in dedizierte BijnaAPI-Router onder archon/routers/ (main.py van 16.254 op 1.875 Zeilen reduceert, -88 %) en centrale Konfigurationsschicht archon/core/config.py.
Security Hardening (Archon Hardened)	Schließung van 25 kritischen en 68 hoge Audit-Befunden; Starlette Threadpool-Entlastung, gehärtete UI-DOM-Pfade en Klasse-A Docker-Admin-Proxy voor hermes_updater.
RBAC-Benutzerverwaltung (17.10)	Granulare Rollen (admin, operator, viewer) over backend/auth_service.py met 100.000 Runden PBKDF2-HMAC-SHA256 Passwort-Hashing en Single-User/Multi-User-Modus.
2-Fasen Systemupdate (17.11)	Onmiddellijke Anzeige lokaler Versie/HEAD via ?local_only=true (~0,25 s) plus asynchroner GitHub-Abgleich, Pre-Update SQLite Online-Snapshots en 1-Klik-Rollback.
AnythingLLM Proxy & Chroma Stack	Nahtlose Einbettung van AnythingLLM in de Centrale bibliotheek over /anythingllm-proxy incl. /assets/* Bijna-Path en lokalem ChromaDB Vektor-Index.
Portabler 1-Click-Installer	Plattformübergreifende Erstinstallation over setup.bat, setup.ps1 en install.sh met docker-compose.yml, .env.example, INSTALL_AGENT.md en 9-sprachiger GitHub-Doku.
4-Augen Qualitäts-Gate & Code-Sandbox	Automatische Zweitprüfung in de Kanban voor Ticket-Abschluss evenals interaktive Code-Sandbox in de Showroom (4.4.1) voor de Live-Vooruitblik erzeugter Artefakte.

20. Alphabetisches Woordenlijst & Stichwortverzeichnis

Alphabetisches Begriffsverzeichnis alle Kernmodule, Architekturkomponenten en Features (v0.5.1) met exakten Seitenzahlen.

Feature / Begrip	Kurzbeschreibung	Pagina(n)
3-Tier Kosten-Routing	Automatische Modellauswahl in LOW / MEDIUM / HIGH na Aufgabenkomplexität en Budget.	S. 3, 8
4-Augen Qualitäts-Gate	Unabhängige Controle abgeschlossener Kanban-Taken via een Revisor-Agenten.	S. 3, 14, 31
Anti-AI-Slop & STE100	Stil- en Wortfilter voor de Vermeidung unnötiger Floskeln en Einsparung van Output-Tokens.	S. 8, 10
AnythingLLM Proxy	Lokale Einbettung van AnythingLLM + ChromaDB over /anythingllm-proxy in de Centrale bibliotheek.	S. 3, 31
Approval Gate (HITL)	Menschlicher Controlestap voor externen E-Mails, Buchungen of kritischen DateiToegangen.	S. 4, 17, 22, 28
Archon Hardened (v0.5.1)	Sicherheits- en Stabilitäts-Release met modularer Router-Structuur en geschlossenen Audit-Befunden.	S. 3, 31
Audit-Log (SHA-256 Hashkette)	Revisionssichere Protokollkette alle Systeem- en Agentenaktionen.	S. 13, 17, 28, 29
Bandit Model-Router	Adaptiver Router (Multi-Armed Bandit) voor de dynamischen Modellwahl na Trefferquote en Kosten.	S. 29, 30
Bot Screen (Web-Navigator)	Visueller Ausführungsmonitor voor Browser-Interaktionen via Playwright.	S. 14, 23
ChromaDB	Lokale Vektordatenbank voor semantisches Dokumenten-Retrieval in Pijler 2.	S. 25, 31
Context-Compaction & LRU-K	Speicherauslagerung en Komprimierung langer Chat-Kontexte bij Erreichen van de RAM-Limits.	S. 8, 9, 24, 25
Corporate & Cliëntenfähigkeit	Physische Database-Trennung mehrerer Gesellschaften per company_id.	S. 3, 31
Corrective RAG (CRAG)	Selbstprüfende Wissensabfrage met RelevanzBeoordeling voor Antwortgenerierung.	S. 25, 26
DAG-Scheduler	Zweistufige Ausführungsplanung abhängiger Teilaufgaben met parallelem Fan-Out / Fan-In.	S. 12, 13, 24
DATEV-Export & GiroCode	EXTF/CSV-Koppeling voor Buchhaltungsdaten en EPC-Zahlungs-QR op Facturen.	S. 3, 31
Dead-Letter-Queue (DLQ)	Fehlerwarteschlange met automatischer Wiederholungssteuerung voor gescheiterte Jobs.	S. 27, 28
Decision Engine (55 Frameworks)	Strategiemodul voor gestructureerde Boardroom-Debatten over 9 Methodiek-Kategorien.	S. 3, 5, 20
DSPy / TextGrad Optimizer	Automatische Verbetering van Systeem-Prompts anhand realer Evaluations-Metrieken.	S. 29
Durable Execution & Time-Travel	Unterbrechbare Langläufe met SQLite-Checkpoints en schrittweisem Execution-Replay.	S. 3, 21, 27, 28
Egress-Firewall	Ausgehende Netwerk- en Domain-Controle voor Agenten-Toolaufrufe.	S. 28

Feature / Begrip	Kurzbeschreibung	Pagina(n)
Ephemeral Code-Sandbox	Flüchtige, isolierte Container-Looptijd voor sicheren Python- en Skriptcode.	S. 3, 23, 31
ERP-Belegkette (ANG -> VANAF -> RE)	Verknüpfte Vertriebs- en Buchhaltungsdokumente incl. Pipeline-Forecast en Aanmaningsprocedure.	S. 22, 24, 25, 31
Event-Mesh & Webhook-Trigger	Ereignisgesteuerte Verarbeitung eingehender Webhooks en Ordneränderungen.	S. 14, 21, 22
Evey / Hermes Plugins	Modulare Systeem-Erweiterungen voor Opslag, Delegation, Verifikation en Koppelingen.	S. 3, 19, 20, 21
Hermes Master Orchestrator	Centrale Kern-Engine voor Zielzerlegung, Delegation en Synthese in de Daemon op Port 8420.	S. 9, 11, 12, 19
Hybrid-Search (FTS5 + RRF)	Kombination uit BM25-Volltextsuche en Vektorsuche per Reciprocal Rank Fusion.	S. 25
Idempotency-Keys & Dry-Run	Bescherming voor doppelter Tool-Ausführung evenals Simulationsmodus zonder SchreibToegang.	S. 27, 28
JEV Router (0-Token Intent)	Deterministischer Vorfilter zonder KI-Kosten voor eindeutige Kurzbefehle.	S. 8, 10
Knowledge-Graph	Lokaler Tripel-Opslag voor gestructureerde Entitätsbeziehungen naast Vektordaten.	S. 25, 26
MCP (Model Context Protocol)	Standardisierte Treiberarchitektur voor de sicheren Werkzeuganbindung.	S. 6, 14
OmniRoute AI Gateway	Multi-Provider-Gateway incl. Free-Tier-Routing, Latency-Hedging en Eval-Arena.	S. 3, 6, 21
PBKDF2 / Argon2id RBAC	Rollen- en Passwort-Absicherung in de System Control Center (Tab 17.10).	S. 3, 28, 29, 31
PII-Scrubber & Re-Hydration	Bidirektionale Anonymisierung sensibler Personendaten voor externen LLM-Calls.	S. 3, 28
Pre-Flight Kostenschätzer	Vorabberechnung erwarteter Token-Kosten incl. Task-Budget-Stop bij Überschreitung.	S. 8, 10, 11
Pre-Mortem & Consensus-Gate	Simulierter Fout-Stresstest en Mehrfach-Agenten-Afstemming voor kritischen Goedkeuringn.	S. 5, 21, 23, 24
Research Lab	Mehrstufige Web- en Quellenrecherche met Evidenz-Triangulation.	S. 3, 7, 21
Router-Architectuur (archon/routers)	Modulare Backend-Aufteilung in schlanke BijnaAPI-Router (-88 % Dateigröße in main.py).	S. 3, 31
Semantic Caching	24h-Zwischenspeicherung inhaltlich ähnlicher Prompts voor de Token-Einsparung.	S. 8, 9, 24, 26
SLA-Verträge (Contract Enforcement)	Formale Übergabe- en Qualitätszusicherungen tussen spezialisierten Agenten.	S. 13, 23, 24
Sleep-Cycle Konsolidierung	Nächtliche Deduplizierung en Langzeit-Verdichtung van de Agenten-Geheugenses.	S. 15, 23
SQLite WAL Connection-Pool	Schreibsicherer Multi-Thread-DatenbankToegang over Write-Ahead Logging.	S. 15, 20, 21, 24
System Control Center (11 Tabs)	Centrale Administrationskonsole incl. Gebruiker/RBAC en 2-Fasen Systemupdate.	S. 3, 8, 11, 31

Feature / Begrip	Kurzbeschreibung	Pagina(n)
Token Guard & Loop-Killer	Realtime-Bescherming tegen Endlosschleifen (Jaccard-Controle) en Token-Überschreitungen.	S. 3, 6, 8, 11
Watchdog & Deadlock-Supervisor	30-Sekunden-Bewaking hängender Tasks, Container en automatischer Selbstheilung.	S. 6, 11, 12, 21