

ARCHON AGENTIC OS 2026

Offizielles System-Handbuch, Modul-Referenz & Praxisführer

Stand: 11. November 2026 | Version: v0.5.1 („Archon Hardened“) | Benutzer- & Firmenhandbuch (DE)

Praxisnahes Benutzer- und Firmenhandbuch für den täglichen Betrieb mit Archon Agentic OS. Umfassende Entwickler-, Architektur- und Framework-Kataloge stehen als separate PDF-Begleitdokumente bereit.

© Michael Keller

Inhalt

Vorwort: Was ist Archon OS und wie arbeitet man damit? 6
Die vier System-Säulen von Archon OS im Überblick: 6
Wie liest man dieses Handbuch? 6
Die philosophische Frage: Ist das wirklich ein „OS“? 7
Wo Archon über ein klassisches OS hinausgeht: 7
Wie man das System präzise nennen kann: 7
Fazit: 7
Das interaktive In-App-Hilfesystem: Der (?)-Kontext-Guide in jeder Ansicht 8
Installationshinweise 9
0.1 Systemvoraussetzungen 9
0.2 Interaktive 1-Click-Installation (Windows: setup.bat / setup.ps1) 9
0.3 Agenten-Installation, täglicher Betrieb & Sicherheit 9
0.4 Installation unter Linux & macOS (install.sh) 9
1. Operations – Operative Projektsteuerung & Funk 11
1.1 Mission Control 11
1.2 Kanban 13
1.2.1 4-Augen Qualitäts-Gate & Revisor-Freigabe (Auto-Validation) 13
1.3 Organisation 14
1.4 n8n Automatisierung 15
1.5 Kommunikation 17
2. Posteingang & Ereignis-Stream 18
2.1 Übersicht 18
2.2 Webhooks 19
2.3 Intern 20
2.4 E-Mail 21
2.5 Messenger 22
2.6 Freigaben 23
3. Agenten-Kader 24
3.1 Übersicht 25
3.2 Chat 27
3.3 Operation 28
3.4 Bot Screen (Desktop & Web-Navigator) 29
3.5 Fähigkeiten & Autonomie-Engines 31
3.6 Soul 32
3.7 Personalakte 33
3.8 Marktplatz 34
3.9 Der vollständige Flotten-Kader: Alle 70 Spezialisten nach Fachdomänen 35
Domäne: 1. Strategie, Führung & Lebensplanung (10 Spezialisten) 35
Domäne: 2. Handel, Beschaffung & E-Commerce (7 Spezialisten) 35

Domäne: 3. Recht, Steuern & Compliance (11 Spezialisten) 36
Domäne: 4. Immobilien & Objektentwicklung (7 Spezialisten) 36
Domäne: 5. Kreation, Medien & Content (8 Spezialisten) 37
Domäne: 5b. Synthese, Integration & Ergebnissicherung (2 Spezialistinnen) 37
Domäne: 6. Tech, Software & Data (8 Spezialisten) 37
Domäne: 7. Vertrieb, CRM & Growth (11 Spezialisten) 38
Domäne: 8. Medizin, Chemie, Wissenschaft & Ingenieurwesen (6 Spezialisten) 38
4. Showroom 39
4.1 Explorer 40
4.2 Berichte 40
4.3 Medien 41
4.4 Endprodukte 41
5. Internet-Watchdog 42
5.1 Radar 42
5.2 Korb 42
5.3 Quellen 43
5.4 Optionen 43
6. Research Lab 44
6.1 Labor 45
6.2 Dossiers 46
6.3 Quellen 46
7. Zentralbibliothek 47
7.1 RAG Index 47
7.2 Erfasser 48
7.3 Obsidian 49
8. Decision Engine 50
8.1 Übersicht 52
8.2 Debatte 52
8.3 Live 53
9. Adressen & CRM (Säule 3: Wirtschaft & ERP) 54
9.1 Kontakte (Haupttabelle & CRM-Adressstamm) 54
9.2 Kundenstamm (Debitoren 10000+) 55
9.3 Lieferantenstamm (Kreditoren 70000+) 55
9.4 Alle Nachrichten (Multi-Channel Timeline) 56
9.5 Kalender & Wiedervorlagen 56
9.6 Bericht (CRM-Missionskontrolle & KPI-Analyse) 57
9.7 Datensatzansicht & Kontakt-Drawer (Enterprise ERP-Standard & 360°-Akte) 58
10. Artikel & Leistungen (Säule 3: Wirtschaft & ERP) 59
10.1 Gesamtkatalog (Alle Artikel & Leistungen) 59
10.2 Zeit / Service & Pauschalen 59

10.3 SaaS & Abonnements 60
10.4 Produkte & Hardware (inkl. Lagerbestand) 60
10.5 Artikel-Drawer & Enterprise ERP Stammdaten-Inspektor 61
11. Vorgänge & Verträge (Säule 3: Wirtschaft & ERP) 62
11.1 Angebote (ANG) & Aufträge (AB) 62
11.2 Deal-Pipeline & Gewichteter Umsatz-Forecast 62
11.3 Vertrags- & Fristenradar 63
12. Rechnungswesen (Säule 3: Wirtschaft & ERP) 64
12.1 Belege 64
12.2 Analytics 64
12.3 Verträge 65
12.4 Mahnwesen 65
13. Corporate & Mandant (Säule 3: Wirtschaft & ERP) 66
13.1 Stammdaten 66
13.2 Formulare & Vorlagen 66
14. Approval-Policies 67
14.1 Finanzen 67
14.2 E-Mail 67
14.3 System & IT 68
15. Token Guard 69
15.1 Übersicht 70
15.2 Sessions 71
15.3 Drosselung 71
16. Telemetrie & Logs 72
16.1 Container 73
16.2 Agenten 73
16.3 Audit 74
17. System Control Center 75
17.1 Hermes Core 76
17.2 Autonomie & Module (36 Subsysteme) 76
17.2.1 Replay & Time-Travel Debugging (Execution Trace Player & State-Forker) 77
17.2.2 Multi-Modell Head-to-Head Benchmark & Eval-Matrix (OmniRoute Arena) 78
17.2.3 Dual- & Tri-Agent Konsens-Gate & Schiedsgericht (Debate / Voting Protocol) 78
17.2.4 Autonome Task-Selbstheilung mit Git- & Snapshot-Rollback 78
17.2.5 Event-Mesh & Webhook-Trigger-Brücke (Inbound Automation & Directory Watcher) 79
17.2.6 Flüchtige Code-Sandboxen (Ephemeral Micro-Containers & Runner) 79
17.2.7 Nächtliche Gedächtnis-Konsolidierung & Sleep-Cycle Wartung 79
17.2.8 Headless-Browser & Visueller Web-Agent (Playwright Screenshot-Audit) 80
17.2.9 Virtueller Pre-Mortem Stresstest (War-Room-Simulation) 80
17.2.10 SLA- & Übergabe-Verträge zwischen Agenten (Contract Enforcement) 80

17.3 Container & Dienste 81
17.4 Provider & Gateway 81
17.5 API-Keys & Access 83
17.6 Methodiken 84
17.7 Plugins 84
17.8 Kommunikation 85
17.9 Design 86
17.10 Benutzer & Rollen 86
17.11 Systemupdate 86
18. Spezial-Feature: Archon Prompt Studio (832 Vorlagen & Fabric SOP) 87
19. Spezial-Feature: Visual CSS Live Studio & In-Place Inspector 88
Anhang I: 5 Praxis-Use-Cases 89
I.1 Use Case 1: Telegram-Direktansprache über persönliche Rufnamen (/anwalt, /robert) 89
I.2 Use Case 2: Eingehende Partner-E-Mail: Triage, Antwortentwurf & Human-in-the-Loop Freigabe 90
I.3 Use Case 3: Wissensaufbau: 80-seitiges PDF-Gutachten per Auto-OCR in Zentralbibliothek & RAG 91
I.4 Use Case 4: Strategische Projektentwicklung: Delegation durch Robert (CEO), Research Lab & Kanban 92
I.5 Use Case 5: Vollautonome Hintergrundüberwachung, OmniRoute-Failover & Notfall-Eskalation 93
Anhang II: IT-Sicherheit, Verschlüsselung & DSGVO im Überblick 94
II.1 DSGVO-Konformität & Lokales Privacy-Routing 94
II.2 Verschlüsselung (In Transit & At Rest) 94
II.3 Revisionssicherheit (GoBD), Prompt-Schutz & Freigaben 94
II.4 Weiterführende Sicherheits- & Betriebsdokumentation 94
Anhang III: Alphabetisches Glossar & Stichwortverzeichnis 95

Vorwort:

Was ist Archon OS und wie arbeitet man damit?

Ein Leitfaden für die autonome Wertschöpfung in vernetzten Organisationen

Wer sich mit Archon OS beschäftigt, blickt nicht auf eine simple Chat-Oberfläche oder ein isoliertes Programmier-Tool. Archon OS ist ein vollwertiges kognitives Betriebssystem für das moderne Unternehmen. Es verbindet 70 spezialisierte Fachagenten, autonome Hintergrunddienste (Daemons), deterministische Workflow-Pipelines und strenge Sicherheits-Gatekeeper zu einer integrierten Arbeitsumgebung. Das erklärte Ziel: Wiederkehrende Grundaufgaben des operativen Alltags vollkommen selbstständig abzuwickeln, während strategische Großaufträge transparent gesteuert, aufgeteilt und überwacht werden.

Die vier System-Säulen von Archon OS im Überblick:

1. **Operative Steuerung (Säule 1 – Cockpit, Projekte & Flotte):** Steuert die tägliche Ausführung über das Dashboard (Mission Control), Operations (Projekt-Zentrale, Master Chat, 5-Spalten-Kanban, Organigramm, n8n-Automatisierung und Kommunikation), den Eingang (Triage für E-Mail, Webhooks, Messenger und HITL-Freigaben), den Agenten-Kader (70 spezialisierte Rollenprofile) sowie den Showroom für abnahmebereite Artefakte.
2. **Kognition & Wissen (Säule 2 – Recherche, Gedächtnis & AI-Boardroom):** Bündelt Informationsbeschaffung, Langzeitgedächtnis und strategische Analyse: Der Internet-Watchdog überwacht Web-Quellen und Feeds, das Research Lab erstellt quellenbelegte Tiefenanalysen, die Zentralbibliothek verbindet AnythingLLM-Vektorsuche mit Auto-OCR-Erfasser und dem lokalen Obsidian Vault (Markdown auf eigener Festplatte), und der AI-Boardroom führt Multi-Modell-Debatten anhand von 55 Lösungs-Frameworks.
3. **Wirtschaft & ERP [alpha] (Säule 3 – CRM, Aufträge, Finanzen & Mandant): Bildet die durchgängige kaufmännische Wertschöpfungskette ab – von Adressen & CRM (Debitoren, Kreditoren, 360°-Kundenakte) über Artikel & Leistungen sowie Vorgänge & Verträge (Angebote, Deal-Pipeline, DocuSeal-E-Signatur) bis zum Rechnungswesen (Beleg-OCR, Analytics, 3-stufiges BGB-Mahnwesen mit Freigabepflicht) und Corporate & Mandant.**
4. **Infrastruktur & Governance (Säule 4 – Sicherheit, Budget & Leitstand):** Sichert Betrieb, Kosten und Compliance über Approval-Policies (dreistufige Freigabe-Schwellenwerte), Token Guard (Raten- und Budgetwächter), Telemetrie & Logs (Container-, Agenten- und SHA-256-verkettetes Audit-Log), das System Control Center (Hermes Core, OmniRoute-Provider-Routing, In-App-Updater) sowie die Spezial-Studios (Prompt Studio und Visual CSS Live Studio).

Externe Zugangskanäle (Schnittstellen statt eigener Säule): Telegram-Bot, E-Mail-Gateway, Webhooks und MCP-Clients dienen als angebundene Ein- und Ausgabekanäle zur Operativen Steuerung (Eingang & Operations), bilden aber keine eigene System-Säule. Sämtliche Kernfunktionen stehen vollständig und eigenständig direkt im Web-Cockpit zur Verfügung.

Wie liest man dieses Handbuch?

Jedes der 19 Hauptkapitel widmet sich einem Fachmodul aus den vier System-Säulen oder einem der beiden Spezial-Studios (Kernkonzept, Steuerelemente, Workflow, Praxistipp und Muster-Prompt). Im Anhang finden sich fünf Praxis-Use-Cases (Anhang I), eine kompakte Firmen-Übersicht zu IT-Sicherheit, Verschlüsselung und DSGVO (Anhang II) sowie das alphabetische Glossar mit exakten Seitenzahlen (Anhang III). Alle technischen Detailsysteme und die 55 Strategie-Methodiken sind in die beiden schlanken Begleitdokumente ARCHON_OS_FEATURELISTE_2026.pdf und ARCHON_OS_BOARDROOM_FRAMEWORKS_2026.pdf ausgelagert.

Die philosophische Frage: Ist das wirklich ein „OS“?

Vom einfachen Coding-Assistenten zum kybernetischen Unternehmens-Betriebssystem

Die Zweifel sind verständlich, wenn man bei dem Begriff „OS“ primär an Windows, macOS oder Linux denkt – also an Systeme, die Festplattenblöcke verwalten, Peripheriegeräte per USB ansteuern und reine CPU-Threads takten.

Gleichzeitig greift die ursprüngliche Bezeichnung „Agent OS for Agentic Coding“ inzwischen viel zu kurz. Das System schreibt zwar auch Code (über das Research Lab oder Prompts), aber der funktionale Schwerpunkt hat sich längst verschoben: Sie steuern damit ein virtuelles Unternehmen inklusive Rollenverteilung, Organigramm, Dokumentenerfassung, Mail-Triage und Kommunikationskanälen.

Klassisches OS (z. B. Linux)	Archon OS (Ist-Zustand)	Einordnung
Prozessmanagement & Scheduler (CPU-Zeit zuweisen, Statuszyklen, Task-Killing)	Daemon & Watchdog (Port 8420): Task-Queue, Status (pending -> in_progress -> completed), Watchdog terminiert hängende Prozesse.	OS-Prinzip
Hardware-Abstraktion & Treiber (HAL übersetzt Befehle, Treiber steuern Hardware)	OmniRoute & MCP-Server: OmniRoute abstrahiert LLM-Rechenkerne (OpenAI, Anthropic, Google). MCP-Server fungieren als Treiber für Tools, Mail & Web.	OS-Prinzip
Speicher-Hierarchie & Paging (L1/L2 Cache, RAM vs. Swap/Disk)	Transiente RAM-Prompts vs. Persistent Storage: Kontextfenster-Kurzzeitgedächtnis, ausgelagert in SQLite (kanban.db), ChromaDB & Obsidian Vault.	OS-Prinzip
IPC & Security (Inter-Process-Comms, Ringschutz, User-Rechte)	Telegram/Kanban-Funkverkehr, Guardian Token Guard, HITL-Gatekeeper: Inter-Agenten-Nachrichten und kryptografisch geschützte Freigaben.	OS-Prinzip

Wo Archon über ein klassisches OS hinausgeht:

Ein traditionelles Betriebssystem hat keine Ahnung vom geschäftlichen Sinn der Software, die darauf ausgeführt wird. Archon implementiert dagegen eine tiefe organisatorische Semantik:

- Personalakten & Rollenverteilung: Agenten sind keine namenlosen Threads, sondern Spezialisten mit definierten Zuständigkeiten (Recht, Steuern, Vertrieb, CEO).
- Entscheidungshierarchien: Robert fungiert als Executive Decision Architect, der Aufgaben zerlegt, delegiert und überwacht.
- Workflow-Orchestrierung: Aufgaben wandern von der Mail-Inbox über die Guardian-Freigabe ins Kanban-Board.

Wie man das System präzise nennen kann:

1. Agentic Enterprise OS (AEOS): Ein Betriebssystem nicht für einen einzelnen Programmierer, sondern für die operative Steuerung eines autonomen digitalen Unternehmens.
2. Autonomous Operations System (AOS): Betont die Abwicklung von Geschäftsprozessen, Hintergrund-Daemons und Multi-Agenten-Koordination.
3. gentic Enterprise OS (AEOS): Ein Betriebssystem nicht für einen einzelnen Programmierer, sondern für die operative Steuerung eines autonomen digitalen Unternehmens.
4. Autonomous Operations System (AOS): Betont die Abwicklung von Geschäftsprozessen, Hintergrund-Daemons und Multi-Agenten-Koordination.
5. Executive Cybernetic System: In Anlehnung an Stafford Beers Viable System Model (Kybernetik zur Unternehmensführung über vernetzte Steuerkreise).

Fazit:

Der Begriff OS ist technisch völlig legitim, weil Prozessverwaltung, Hardware-Abstraktion (Modell-Routing), IPC und Speicherhierarchie real als Kernel-Dienste laufen. Der Zusatz sollte jedoch nicht mehr „Coding“, sondern „Enterprise“ oder „Operations“ lauten.

Das interaktive In-App-Hilfesystem: Der (?)-Kontext-Guide in jeder Ansicht

Eingebettete Live-Dokumentation direkt im Arbeitsfluss – Alle Funktionen, Steuerelemente & Workflows mit einem Klick auf das Fragezeichen

Kernkonzept: Keine Trennung zwischen Betriebssystem und Handbuch

Archon OS verfolgt ein radikales Usability-Prinzip: Niemand soll gezwungen sein, während der operativen Arbeit im System ein separates 80-seitiges PDF- oder Word-Handbuch auf einem zweiten Monitor durchsuchen zu müssen. Aus diesem Grund ist das gesamte Systemwissen dieses Handbuchs direkt als interaktiver Kontext-Guide in jede einzelne Benutzeroberfläche eingewoben.

Der (?)-Button in der Kopfzeile jeder Ansicht:

Direkt in der Kopfzeile jeder Ansicht – unmittelbar rechts neben dem jeweiligen Titel (z. B. Mission Control [?], Operations [?], Eingang & Triage [?], Agenten-Kader [?], Zentralbibliothek [?] oder OmniRoute [?]) – befindet sich ein dezenter, runder Hilfe-Button mit einem Fragezeichen (Lucide-Icon `help-circle`).

Ein Klick auf diesen Button öffnet sofort ein modales Hilfefenster (Context Help Guide) mit vier strukturierten Kernbereichen:

Zweck & architektonische Einordnung: Wozu dient dieses Modul im Gesamtsystem und welche Hintergrund-Dienste und Daemons sind daran gekoppelt?
Steuerelemente & Kacheln im Detail: Detaillierte Erklärung jeder einzelnen KPI-Kachel, jedes Filters, Schalters und Aktions-Buttons direkt vor deinen Augen.
Operativer Praxis-Workflow (1-2-3): Präzise Schritt-für-Schritt-Anleitung, wie typische Arbeitsaufträge in dieser Ansicht fehlerfrei ausgeführt werden.
[Tipp] Leitplanken & Praxistipps: Wichtige Best Practices, Budget-Warnungen, No-Go-Fehler und Absicherungen gegen Fehlausführungen.

> **[Tipp] Schnellanleitung für den Arbeitsalltag: Der (?)-Button als interaktiver Copilot**
> Wann immer du oder ein Teammitglied vor einer Kachel, einem komplexen Schwellenwert-Schalter im System Control Center oder einem blockierten Status im Kanban steht: Ein Klick auf das [?] neben der Überschrift öffnet sofort die exakte Dokumentation für genau diesen Bereich. Alle dort hinterlegten Hilfetexte werden synchron mit diesem Handbuch gepflegt – so bleibt das Wissen immer aktuell und griffbereit.

Ergänzende Schnellzugriffe & Tastatur-Kürzel:

Strg + K (Globale Omnibox): Öffnet die zentrale Befehlszeile, um blitzschnell per Tastatur zwischen allen Ansichten, Agenten-Profilen und Einstellungen zu springen.
Alt + S (Visual CSS Live Studio): Aktiviert den In-Place-Inspector, um Farben, Kontraste oder Element-Abstände direkt zur Laufzeit im Browser anzupassen.
Telegram-Kurzbefehle (/anwalt, /robert): Ermöglicht direkte mobile Fachdelegationen und Statusabfragen direkt vom Smartphone aus.

© Michael Keller

Installationshinweise

Archon OS lässt sich auf jedem modernen Rechner (Windows 10/11, macOS, Linux) mit minimalem Einrichtungsaufwand in Betrieb nehmen:

0.1 Systemvoraussetzungen

- Docker Desktop / Engine: Unter Windows 10/11 mit aktiviertem WSL2-Backend (docker.com/products/docker-desktop); unter macOS Docker Desktop; unter Linux Docker Engine + Compose v2.
- Betriebssysteme: Windows 10/11 (64-Bit), macOS (Intel / Apple Silicon) sowie Ubuntu, Debian oder Fedora Linux.

Hardware-Empfehlung: 8 GB RAM Minimum (16 GB empfohlen; 32 GB bei lokalem LLM-Betrieb) und 15–40 GB freier Festplattenspeicher.
Software-Basis: Für den geführten 1-Klick-Installer genügt Docker. Für manuelle CLI- oder Agenten-Installationen sind zusätzlich Git und Python 3.11+ empfehlenswert.
KI-Provider: Mindestens ein API-Key (empfohlen: OpenRouter für alle Top-Modelle über einen Key, alternativ OpenAI/Anthropic/Gemini) ODER eine lokale KI-Instanz (Ollama / LM Studio für DSGVO Zero-Egress).

0.2 Interaktive 1-Click-Installation (Windows: setup.bat / setup.ps1)

- Doppelklick auf setup.bat im Projektordner (startet setup.ps1 mit dem interaktiven Einrichtungsassistenten).
- Der Assistent prüft Docker, erfragt die wichtigsten Parameter (Enter übernimmt Standardwerte) und richtet das System vollautomatisch ein:
  - Zielpfad & Obsidian Vault: Übernimmt einen vorhandenen Obsidian-Ordner oder legt automatisch ./obsidian_vault an (portabel über ARCHON_OBSIDIAN_DIR in .env).
  - Sprache, Stack-Größe & KI-Anbindung: Fragt gewünschte Systemsprache (de/en), Container-Umfang (Core ~2 GB RAM, Standard mit n8n oder Full RAG), Cloud-API-Keys sowie lokale Ollama-/LM-Studio-Nutzung ab.
  - Netzwerk-Freigabe & Start: Konfiguriert ARCHON_BIND_IP (Standard 127.0.0.1 lokal; optional 0.0.0.0 für LAN/WLAN), legt das Docker-Netzwerk archon-os-dev_agents_net an, baut den Stack und synchronisiert alle 70 SOUL-Profile.
  - Healthcheck & Browser: Wartet auf http://127.0.0.1:8501/health (HTTP 200) und öffnet das Dashboard automatisch im Standard-Browser.

0.3 Agenten-Installation, täglicher Betrieb & Sicherheit

- 1-Prompt Installation per KI-Agent (INSTALL_AGENT.md): Antigravity, Claude Code, Codex oder Cursor führen damit vorab ein verpflichtendes 6-Punkte-Interview durch (Pfad, Sprache/Lokalisierung, Stack, API-Keys & Lokale KI, LAN/Auth, Telegram) und prüfen den Start.
- Täglicher Betrieb (Windows): start.bat liest ARCHON_STACK_PROFILE aus .env und startet nur den konfigurierten Stack; stop.bat fährt alle Container geordnet herunter.

LAN-Freigabe & Auth: Für Zugriffe im Heimnetzwerk ARCHON_BIND_IP=0.0.0.0 in .env setzen und vorab Multi-User-Auth (auth.enabled=true) in den Einstellungen aktivieren.
Portabler Obsidian Vault: Der Wissenspfad ist über ARCHON_OBSIDIAN_DIR in .env frei konfigurierbar (Standard: ./obsidian_vault).
Wartung & Backup: Tägliches automatisches SQLite-Backup (03:00 Uhr) sowie 1-Klick-Updates unter System Control Center → System-Update.

0.4 Installation unter Linux & macOS (install.sh)

git clone https://github.com/michaelbeatman/Agentic-Archon-Os.git && cd Agentic-Archon-Os && chmod +x install.sh && ./install.sh

Interaktiver Assistent (./install.sh): Prüft Docker/Compose v2, erkennt automatisch laufendes Ollama, erfragt Obsidian-Pfad, Sprache, Stack (Core/Standard/RAG), API-Keys sowie LAN-Binding und öffnet das Dashboard.
Unbeaufsichtigte Installation (./install.sh --yes): Übernimmt direkt Standardwerte aus .env.example (Core-Stack auf 127.0.0.1:8501) für Skripte und Headless-Server.
Automatisierter Server-Rollout: Für Produktiv- oder Homeserver steht im Ordner ansible/ ein vollständiges Playbook (site.yml) zur idempotenten Ersteinrichtung bereit.

1. Operations – Operative Projektsteuerung & Funk

Kanban Board, Organisation/Ablaufdiagramm & Interne Agenten-Kommunikation

Kernkonzept & Architektur:

Operations ist das operative Zentrum von Archon OS. Hier laufen die zentralen Arbeitsbereiche der täglichen Steuerung zusammen: Die Projekt-Zentrale, das Cockpit (Mission Control), das 5-Spalten-Kanban-Board, das Organigramm für Berichtslinien, die n8n-Automatisierung sowie der interne Funkverkehr für die Abstimmung zwischen den Agenten.

1.1 Mission Control

Echtzeit-Telemetrie, Flottenlast, Kostenkontrolle & HITL-Freigabemonitor



Kernkonzept & Architektur:

Mission Control fungiert als oberster Beobachtungs- und Überwachungsleitstand des gesamten Agentic OS. Wichtig: Diese Ansicht ist primär für das Monitoring und den schnellen Überblick ausgelegt – neue Aufgaben werden im Operations-Kanban angelegt oder via Telegram beauftragt. Das Cockpit führt alle vitalen Systemparameter zusammen und spiegelt das operative Arbeitsaufkommen in einer kompakten Projektionsansicht.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

5 vitale KPI-Kacheln (Kopfzeile):

- Flottenlast: Zeigt die Anzahl gleichzeitig arbeitender Agenten im Verhältnis zum Gesamt-Kader (z. B. 0 / 56 aktiv).
- Durchsatz (TPM): Überwacht die erzeugten Tokens pro Minute gegenüber dem definierten Schwellenwert (z. B. 2M TPM Limit).
- Kostenwächter: Kumulierte Tageskosten in USD mit farblicher Warnanzeige bei Annäherung an das Tageslimit ($5.00).
- Stabilität: Erfolgsquote aller Tool- und Modellausführungen (100% nominal bedeutet fehlerfreie Ausführung).
- Approval Gate: Zähler für blockierte Aktionen, die auf deine manuelle Human-in-the-Loop-Freigabe warten.

Workflow & Approval Board (5 Spalten & HITL-Freigabe):

Spiegelt den operativen Lebenszyklus der Aufgaben in fünf dynamischen Spalten wider (To-Do, In Bearbeitung, Review & QA, Blockiert, Abgeschlossen). Aufgaben in der Review-Spalte blockieren automatisch systemkritische Tool-Aktionen (z. B. Schreibzugriffe auf Produktivdateien, Mailversand oder API-Löschungen), bis du sie im Cockpit manuell prüfst und freigibst.

Active Process Inspection Bar (3-Slot-Maschinenraum im Footer):

Der untere Balken liefert eine lückenlose Diagnose der internen Systemvitalität in drei synchronisierten Modulen:

- **Slot A – Process Heartbeat & Watchdog:** Überwacht den asynchronen Hintergrund-Daemon (Port 8420). Ein pulsierender Indikator bestätigt den nominalen Zustand. Bei Leerlauf schaltet der Kernel in den energiesparenden 'Tickless Sleep'. Der Watchdog-Timer (120 s Timeout) fängt hängende Prozesse automatisch ab und startet Worker bei Bedarf neu.
- **Slot B – Tool Concurrency Slots:** Zeigt die Auslastung paralleler Werkzeuge in Echtzeit (z. B. web_search [0/5], code_gen [0/2], obsidian [1/3]). Die integrierte Hashmap-Sperre verhindert API-Rate-Limits und blockiert kollidierende Schreibzugriffe.
- **Slot C – Context Saturation & Speicherdruck:** Misst die Belegung des aktiven LLM-Kontextfensters (z. B. deepseek-v4-flash: 18k / 128k Tokens belegt, 110k Puffer). Erreicht die Sättigung 80%, greift automatisch die LRU-K Eviction-Policy, um Kontextüberläufe zu verhindern.

Rolling Token-Aktivitäts-Band (15-Minuten-Sparkline):

Ein hochauflösendes Live-SVG-Flussband visualisiert den Durchsatz der letzten 15 Minuten. Die Anzeige weist den gleitenden Durchschnitt (Ø Tok/min) sowie Lastspitzen (Peak Tok/min) aus. Unerwartete Ausschläge deuten auf Rekursionsschleifen oder umfangreiche Code-Analysen hin und können sofort gestoppt werden.

Aktiver Agenten-Kader & Aktive Aufgaben (Rechte Flanke):

- Kader-Statusliste: Schnellsicht auf die 51 vorkonfigurierten Profile inklusive Bereitschaftszustand (Standby / Aktiv / Blockiert) und hinterlegtem Modell-Alias.
- Aktive Aufgaben: Zeigt laufende Worker-Prozesse inklusive Startzeitpunkt, ausführendem Agenten und aktuellem Einzelschritt.

Direktes Artefakt-Vorschau-Modal:

Ein Klick auf eine fertige Aufgabe in der Spalte 'Abgeschlossen' öffnet ohne Seitenwechsel das Artefakt-Modal. Das generierte Ergebnis (z. B. Markdown-Berichte in /opt/data/obsidian/Projects/...) kann sofort im Volltext gelesen, geprüft und kopiert werden.

Live-Audit & Telemetrie-Stream:

Der rechte Syslog-Feed dokumentiert alle Ereignisse sekundengenau im Monospace-Klartext: Tool-Invocations, Promptfoo-Sicherheitsprüfungen, HITL-Freigabestopps und Prozessübergaben bleiben revisionssicher nachvollziehbar.

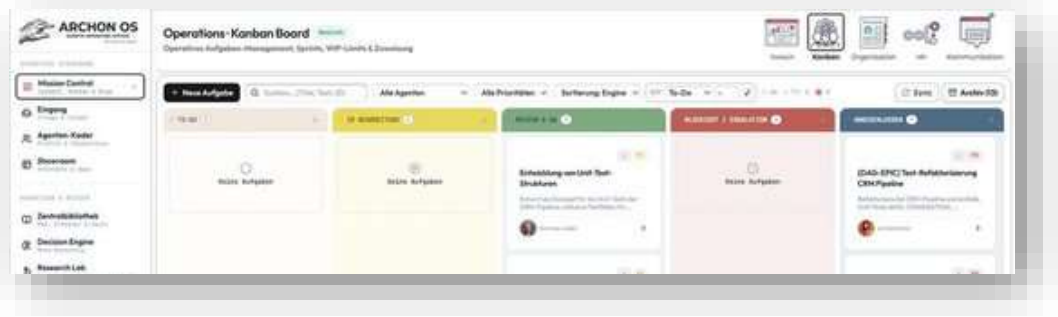
Praxis-Workflow (Schritt für Schritt):

1. Kontrolliere zu Arbeitsbeginn die KPI-Kacheln auf Auffälligkeiten (Kostenstand und Approval Gate).
2. Steht der Zähler bei 'Approval Gate' auf > 0, wechsle in die Review-Spalte oder den Eingang, um die anstehende Schreibaktion zu prüfen.
3. Beobachte im Live-Audit, welche Agenten autonom arbeiten und ob alle Worker nominal reagieren.

[Tipp] Praxistipp & Leitplanke: Nutze Mission Control für den schnellen Überblick während des Betriebs. Für Eingriffe in Aufgaben, Priorisierungen oder Detailanalysen wechsle immer direkt in das Operations-Kanban.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Gib mir eine Zusammenfassung des aktuellen System-Status laut Mission Control: Wie viele Agenten sind aktiv und gibt es blockierte Freigaben?"

1.2 Kanban



Jede geschäftliche Aufgabe wird im Board als strukturierte Karte geführt, einem Fachagenten zugewiesen und durchläuft die Spalten To-Do, In Bearbeitung, Review & QA, Blockiert und Abgeschlossen. WIP-Limits (Work-in-Progress) verhindern Token-Spitzen und Überlastung.

- **Die 5 Lebenszyklus-Spalten:**
  To-Do (Warteschlange), In Bearbeitung (aktive Ausführung), Review & QA (Prüfung), Blockiert (Eskalation), Abgeschlossen (Erledigt).
- **WIP-Limit Konfiguration:** Begrenze in der Toolbar die maximale Kartenzahl pro Spalte (z. B. max. 3 Tasks gleichzeitig in Bearbeitung).
- **Toolbar mit Filtern & Archiv:** Volltextsuche, Filter nach verantwortlichem Agenten, Filter nach Priorität (P0 bis P3) sowie Klick-Archivierung erledigter Aufgaben.

Arbeitsablauf:

1. Erstelle eine neue Karte für eine Rolle oder empfange eine via Telegram delegierte Aufgabe.
2. Beobachte, wie der Agent die Karte autonom bearbeitet und bei Fertigstellung nach 'Review & QA' schiebt.
3. Öffne die Karte, prüfe das Ergebnis (oder nutze 'In Obsidian öffnen') und ziehe sie auf 'Abgeschlossen'.

Praxistipp: Sollte ein Task auf 'Blockiert' springen, prüfe im Task-Detail die Ursache – oft fehlt ein Parameter oder ein API-Key.

1.2.1 4-Augen Qualitäts-Gate & Revisor-Freigabe (Auto-Validation)

Das Kanban Qualitäts-Gate (backend/operations_api.py) sichert Arbeitsergebnisse ab, bevor eine Aufgabe auf 'done' verschoben werden kann:

- Unabhängiger Prüfer: Katharina Völk (QM/Compliance) oder Robert prüft das Ergebnis automatisch auf Vollständigkeit, Substanz und Handlungsfähigkeit.

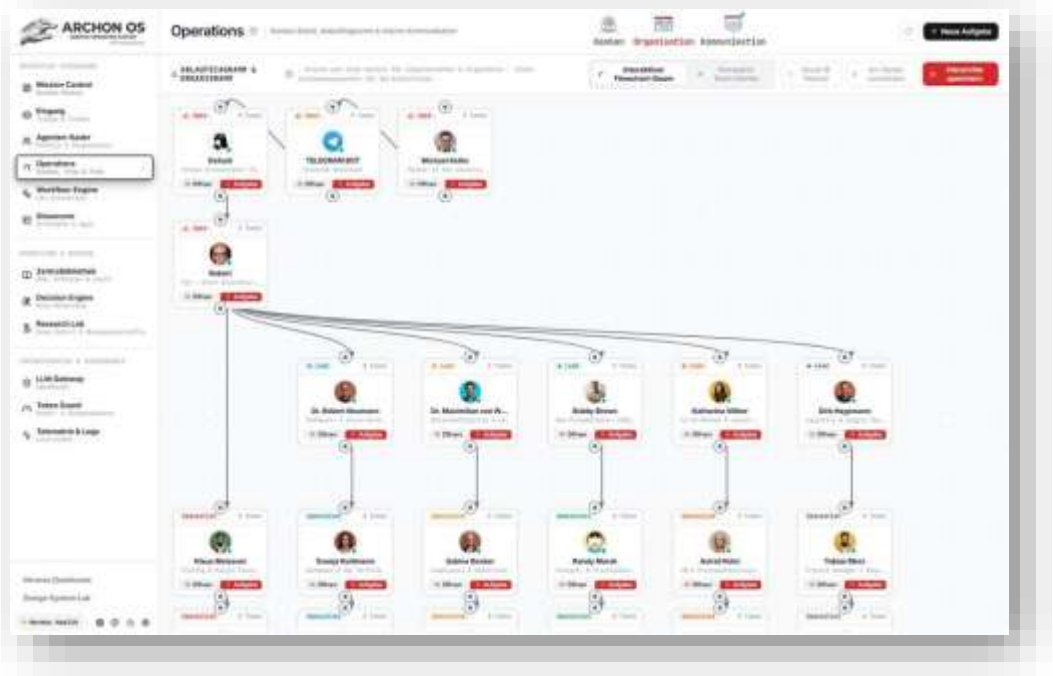
- Bewertungsschema: Der Reviewer vergibt einen Qualitäts-Score (1–100%) sowie das Prädikat 'approved' oder 'changes_requested'.

- Status-Sperre: Bei Mängeln verbleibt der Task in 'review' mit dem Warn-Badge '[Achtung] 4-Augen: Nachbesserung'. Das Verschieben nach 'done' wird serverseitig abgewiesen, bis Mängel behoben sind oder der Operator eine manuelle Freigabe (Human-in-the-Loop Override) erteilt.

Deal-Pipeline & Vertriebs-Integration (t-5b159d): Neben klassischen Projektaufgaben unterstützt das Kanban-Board eine B2B-Vertriebspipeline mit den Phasen Lead, Qualified, Proposal, Negotiation, Closed Won und Closed Lost inklusive gewichteter Umsatzprognose (Forecast).

Vertiefender Leitfaden: Siehe die Spezifikation zu Massenoperationen im Board in Markdown-Systemdokumentation (docs/system/KANBAN_BULK_ACTIONS_GUIDE.md).

1.3 Organisation



Visualisiert die Aufbau- und Ablaufstruktur deines Unternehmens als interaktiven 2D-Graphen. Die Verbindungslinien definieren echte Weisungs- und Berichtswege für autonome Eskalationen: von der Apex-Ebene über Robert (CEO) bis zu den Fach-Leads und Spezialisten.

- **Apex & CEO-Ebene: Gründer-Profil (micha) und Telegram Gateway ganz oben; Robert als zentraler Executive Decision Architect darunter.**
- **Lead- & Spezialisten-Kacheln:** Abteilungsleiter für Tech, Recht, Marketing etc. mit ihren jeweils unterstellten Fach-Agenten.
- **Interaktive Werkzeuge:** Modus-Umschaltung (Flowchart vs. Team-Karten), dynamisches Ziehen neuer Verbindungslinien, 'Hierarchie speichern' und 'Am Raster ausrichten'.

Arbeitsablauf:

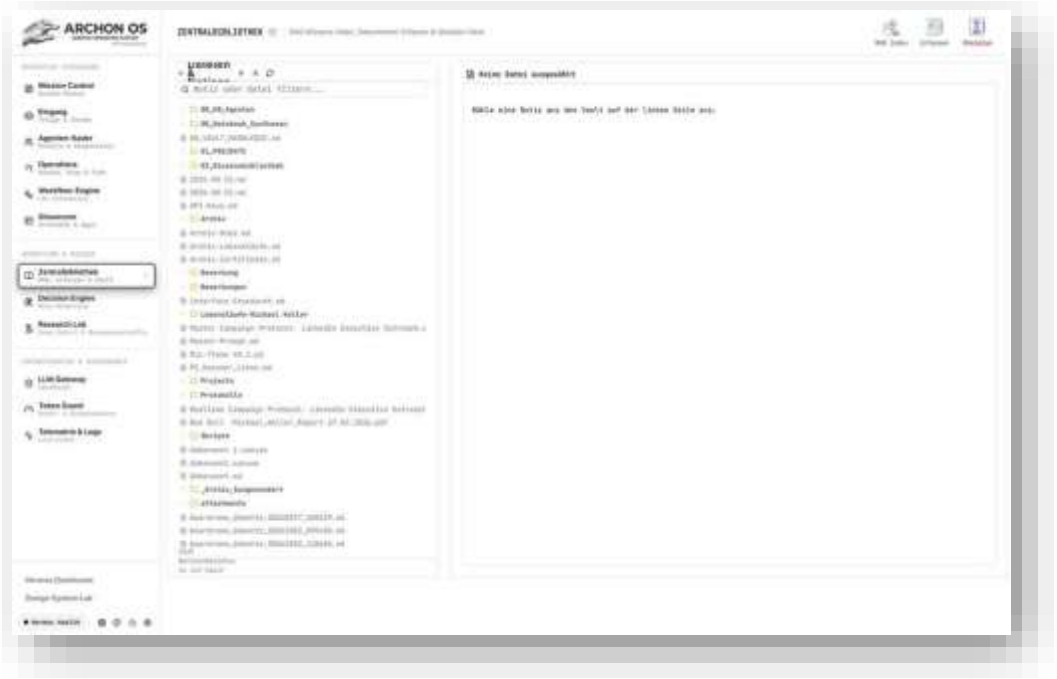
1. Klicke auf eine Agenten-Kachel, um Rollenprofil, Modell und aktuelle Auslastung einzusehen.
2. Ziehe Verbindungspunkte neu, um Fachrollen einer anderen Führungskraft zuzuordnen.
3. Klicke auf 'Hierarchie speichern', um die neuen Eskalationspfade aktiv zu schalten.

[Tipp] Praxistipp & Leitplanke: Nutze die Hierarchie, um Eskalationspfade abzusichern. Wenn ein Spezialist bei einer Aufgabe blockiert ist, eskaliert das System immer automatisch an den im Organigramm verknüpften Supervisor.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Zeige mir alle Agenten, die aktuell Robert als direktem Supervisor unterstellt sind, und prüfe deren Modell-Zuweisung."

1.4 n8n Automatisierung

Eingebettete Low-Code Automatisierung, Event-Trigger & Cron-Jobs



Kernkonzept & Architektur:

Die Workflow-Engine bindet die Open-Source Automatisierungsplattform n8n (Offizielle Website: https://n8n.io | Repository: https://github.com/n8n-io/n8n) als lokales Docker-Mesh nahtlos in Archon OS ein. Auf Port 5678 betrieben, schließt n8n die Lücke zwischen generativer KI und deterministischer Unternehmens-IT: Während LLMs über Heuristiken entscheiden, führt n8n wiederkehrende Schnittstellenprozesse (z. B. CRM-Sync, Webhook-Dispatching, PDF-Verarbeitung) absolut fehlerfrei und regelbasiert aus.

CEO-Autonomie & MCP-Steuerung (n8n-automation-mesh):

Der leitende CEO-Agent sowie berechtigte Operatoren sind dank des integrierten Skills 'n8n-automation-mesh' in der Lage, n8n direkt aus dem Chat oder per Telegram-Funkbefehl vollständig zu steuern. Über standardisierte FastMCP-Webhook-Tools kann der Agent:

- Bestehende Workflow-Ketten aktivieren, pausieren oder auf Abruf triggern,
- Ausführungsmetriken und Fehlerprotokolle in Echtzeit abfragen,
- Neue Integrationsszenarien anhand von JSON-Vorlagen dynamisch provisionieren,
- Asynchrone Benachrichtigungen an das Operations-Kanban oder mobile Endgeräte senden.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

- Vollwertige n8n Canvas-Oberfläche: Direkt im Archon-Frame eingebetteter Node-Editor mit über 400 fertigen API-Konnektoren (Slack, Google Workspace, PostgreSQL, GitHub u. v. m.).
- Archon FastMCP Node-Bridge: Dedizierte HTTP- und Webhook-Knoten, über die Workflows Ereignisse direkt an den Hermes-Kernel oder spezialisierte Fachagenten übergeben.
- Webhook- & Event-Eingänge: Lauscht im Hintergrund auf externe Trigger aus E-Mail-Servern, Lead-Formularen oder Webhooks und überführt sie in strukturierte System-Tasks.
- Execution History & Debugger: Lückenlose Historie jedes Einzellaufs mit Ein- und Ausgabedaten zur sekundenschnellen Fehleranalyse.

Tabelle 1.1: Technische Eckdaten der n8n Workflow-Engine

Architektur-Parameter	Konfiguration & Endpunkte	Operativer Nutzen
Deployment	Docker Container (agent-os-n8n)	Isolierte Ausführungsumgebung ohne Abhängigkeiten auf dem Host.
Port & Web-UI	Port 5678 (http://localhost:5678)	Voller Zugriff auf den visuellen Canvas-Editor im Browser.
MCP-Integration	Skill: n8n-automation-mesh	Ermöglicht dem CEO-Agenten die autonome Ausführung per FastMCP.
Webhook-Eingang	http://localhost:5678/webhook/...	Reaktiver Empfang externer Signale (z. B. CRM-Leads, GitHub-Hooks).

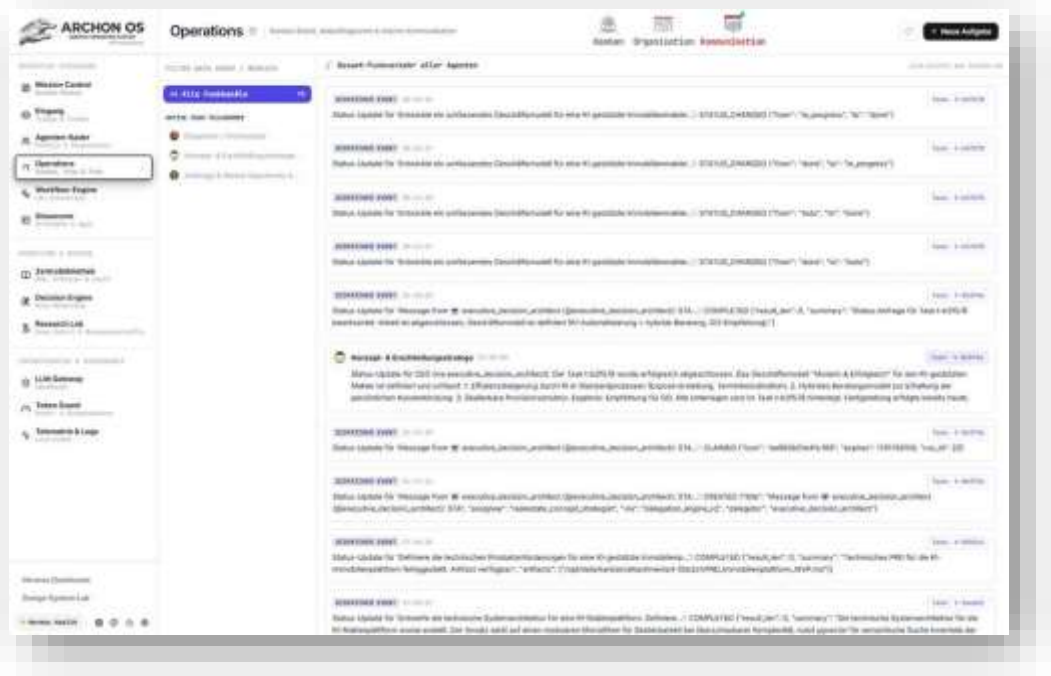
Praxis-Workflow (Schritt für Schritt):

1. Erstelle einen neuen Workflow und platziere einen Trigger-Knoten (z. B. 'Schedule' für tägliche Ausführung).
2. Verknüpfe den Trigger mit einem 'Archon Agent Node' und wähle die gewünschte Rolle (z. B. Marktanalyst).
3. Leite das Ergebnis an einen Benachrichtigungs-Knoten (z. B. Telegram Push) oder das Operations-Kanban weiter.
4. Aktiviere den Workflow per Kippschalter – er läuft ab sofort vollautonom im Docker-Netzwerk.

[Tipp] Praxistipp & Leitplanke: Nutze n8n für alle deterministischen Routineabläufe (Daten abholen, filtern, transformieren). Schalte Agenten nur an den Stellen dazwischen, an denen echte kognitive Bewertung oder Textverständnis erforderlich ist.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Welche n8n-Workflows sind aktuell aktiv und wann lief der letzte automatische Hintergrund-Job?"

1.5 Kommunikation



Der interne Kommunikationskanal dient als Abhörzentrale für den automatischen Datenaustausch zwischen den Agenten. Hier siehst du im Klartext, wie Teilaufträge zwischen Abteilungen übergeben werden, ohne dass dein persönlicher Chat überflutet wird.

- **Kanalliste (Linke Spalte):**
  Strukturiert nach Agenten, Teams und Domänen (z. B. #allgemein, #tech-dev, #legal, #marketing).
- **Nachrichten-Feed (Rechte Spalte):**
  Chronologischer Stream aller Inter-Agenten-Nachrichten und Status-Meldungen direkt aus kanban.db.

Arbeitsablauf:

1. Wähle links einen Kanal aus, um den Funkverkehr einer bestimmten Fachgruppe zu isolieren.
2. Verfolge, wie Robert einem Spezialisten Kontext bereitstellt oder wie zwei Agenten Ergebnisse abgleichen.

Praxistipp: Nutze die interne Kommunikation zur Fehlersuche, wenn bei komplexen Mehretappen-Aufgaben Unklarheiten zwischen Agenten entstehen.

Praxis-Workflow (Schritt für Schritt):

1. Kontrolliere im Kanban-Board offene Tasks und weise neue Aufgaben gezielt zu.
2. Prüfe im Organigramm, ob alle Spezialisten der richtigen Führungskraft zugeordnet sind.
3. Wirf einen Blick in die interne Kommunikation, um autonome Absprachen zwischen Agenten zu verfolgen.

[Tipp] Praxistipp & Leitplanke: Halte die Spalte 'In Bearbeitung' durch strikte WIP-Limits schlank. Verknüpfe neue Fachrollen immer mit einem klaren Supervisor im Organigramm.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Erstelle eine P1-Aufgabe im Kanban für Dr. Maximilian von W. zur Prüfung von Lizenzklauseln und weise Robert als Supervisor zu."

2. Posteingang & Ereignis-Stream

2.1 Übersicht

3-Spalten-Zentrale: Human-in-the-Loop Freigaben, E-Mail-Postfach & Telegram-Stream



Kernkonzept & Architektur:

Die Eingang & Triage Ansicht ist das operative Nadelöhr für alle eingehenden Signale von außen sowie für kritische Aktionen von innen. Das System trennt hier streng zwischen harmlosen Lese-Operationen und folgenreichen Schreib-Operationen (z. B. E-Mail-Versand, Code-Deployment oder Datenbank-Änderungen). Diese Ansicht garantiert, dass kein Agent eigenmächtig kritische Handlungen vollzieht, ohne deine ausdrückliche Bestätigung erhalten zu haben.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Spalte 1: Human-in-the-Loop Freigaben (HITL):
Hier landen alle blockierten Tool-Aufrufe mit gelber Warnmarkierung. Du siehst exakt: Welcher Agent will welche Aktion mit welchen Parametern ausführen? Mit 'Freigeben' wird die Aktion physisch ausgeführt, mit 'Ablehnen' verworfen.

Spalte 2: E-Mail Postfach & Auto-Triage:
Synchronisiert ein- und ausgehende geschäftliche E-Mails via IMAP/SMTP. Neue Mails werden automatisch auf Dringlichkeit gescannt und können direkt per Klick an einen zuständigen Fach-Agenten zur Beantwortung übergeben werden.

Spalte 3: Telegram Stream (Live-Chat):
Spiegelt den gesamten Live-Dialog zwischen dir und dem Telegram-Bot (@Beatman_bot). Hier siehst du Befehle wie /robert oder /anwalt und die Antworten der Agenten in Echtzeit synchronisiert.

Mail-Sync & Status-Controls (Header): Button 'Sync': Löst den sofortigen Mail-Abruf aus. Anzeige des Triage-Status (Nominal / Wartend).

Praxis-Workflow (Schritt für Schritt):

1. Prüfe Spalte 1 auf anstehende Freigabekarten. Lies den vorgeschlagenen Befehl oder Textentwurf durch.
2. Klicke auf 'Freigeben', wenn der Entwurf passt, oder 'Ablehnen' mit einer Korrektur-Notiz.
3. Sichte in Spalte 2 neue Mails. Klicke auf 'Delegieren', um die Mail z. B. Katharina Völker (Marketing/Sales) zuzuweisen.
4. Verfolge in Spalte 3 den Chatverlauf von deinem Smartphone.

[Tipp] Praxistipp & Leitplanke: Behalte die HITL-Spalte im Blick: Wenn ein Agent auf deine Freigabe wartet, pausiert sein Task im Kanban-Board. Durch zügige Freigaben hältst du den operativen Workflow flüssig.

Vertiefender Leitfaden: Zur Absicherung aller Eingänge gegen schädliche Manipulationen siehe Anhang II (IT-Sicherheit & DSGVO) sowie docs/security/DUAL_LLM_PROMPT_INJECTION_GUARD_GUIDE.md.

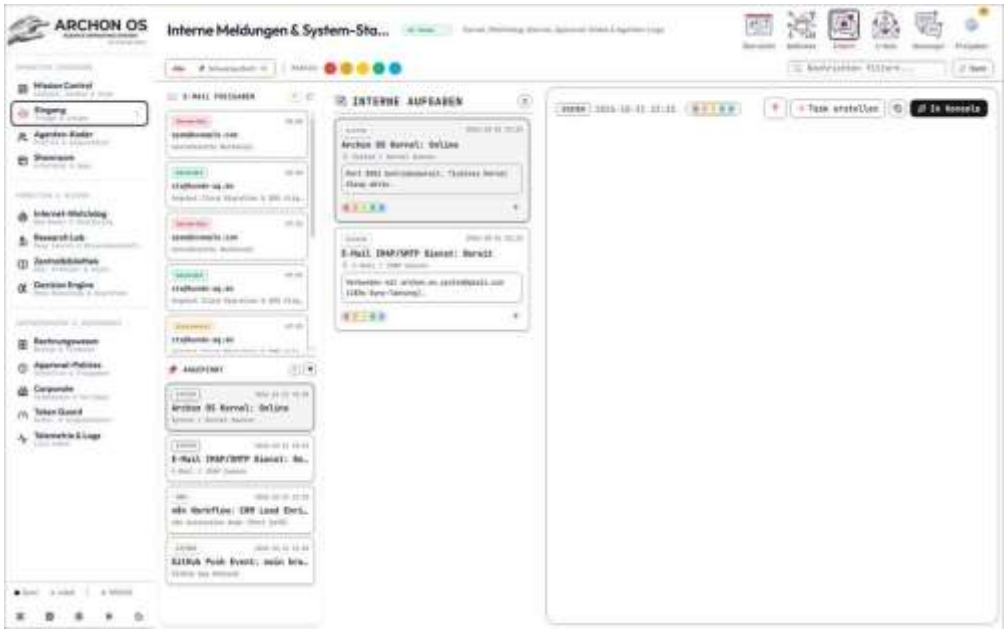
2.2 Webhooks



Die Webhook-Ansicht empfängt und protokolliert Echtzeit-Events externer Systeme (GitHub, Stripe, Typeform, Monitoring-Alarme oder eigene Web-Crawler).

HMAC-SHA256 Signaturprüfung (t-803095): Eingehende Payloads werden kryptografisch auf Authentizität und Replay-Schutz geprüft.
Automatische Triage: Validierte Ereignisse werden regelbasiert in strukturierte Aufgaben für den zuständigen Fachagenten umgewandelt.
Ereignis-Filter & Payload-Inspektor: Jeder Webhook-Eingang zeigt Zeitstempel, Quellsystem (z. B. n8n, GitHub, Stripe oder DocuSeal) und den rohen JSON-Payload zur schnellen Diagnose.
Signatur- & Replay-Prüfung: Eingehende Anfragen werden gegen hinterlegte Webhook-Secrets validiert; fehlgeschlagene Zustellungen lassen sich direkt erneut anstoßen.
Praxistipp: Nutze den Webhook-Reiter zur Kontrolle, ob externe Automationen (wie DocuSeal-Vertragsabschlüsse oder n8n-Trigger) sauber im Kernel angekommen sind.

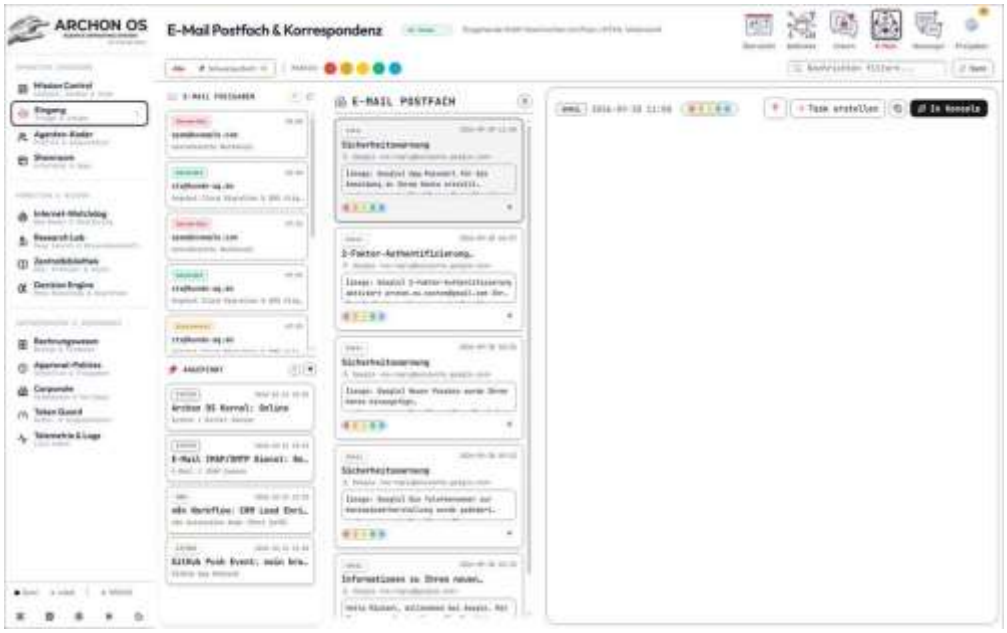
2.3 Intern



Bündelt systeminterne Ereignisse, Eskalationen aus Hintergrundprozessen und Statusmeldungen des Daemon-Kernels.

Watchdog-Meldungen bei ungewöhnlichen Laufzeiten, Deadlocks oder Speicherschwellen.
Rückmeldungen autonomer Nachtläufe (Memory Consolidation, Backup-Verifikation, Fristen-Scanner).
Inter-Agenten-Übergaben: Dokumentiert systeminterne Benachrichtigungen, Delegationen von Robert an Fachagenten sowie Abschlussmeldungen laufender Hintergrund-Daemons.
Status- & Fehlerfilter: Nach Schweregrad (Info, Warnung, Eskalation) filterbar, um blockierte Fan-in-Synthesen oder Watchdog-Eingriffe sofort zu erkennen.
Praxistipp: Bei unerwarteten Task-Verzögerungen liefert dieser Tab den kürzesten Überblick über interne Rückfragen zwischen einzelnen Rollen.

2.4 E-Mail



Zwei-Wege-E-Mail-Synchronisation mit automatischer Kontakt- und Vorgangszuordnung (Auto-Enrichment).

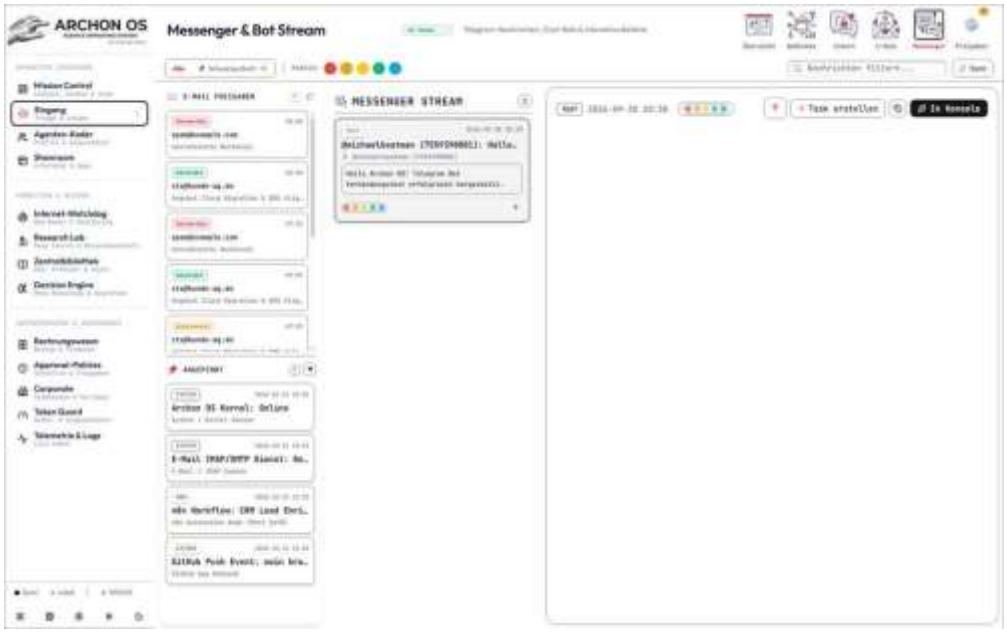
Direkter MAPI-Abgleich mit lokal geöffnetem Microsoft Outlook sowie Unterstützung für IMAP/SMTP-Konten. Automatische Extraktion von Absenderdaten, Signaturen und Anhängen zur Ablage im Kontakt-Dossier. Vorbereitung von Antwort-Entwürfen durch Kommunikations-Agenten mit anschließender Vorlage zur Freigabe.

Automatische Zuordnung & CRM-Verknüpfung: Eingehende Mails werden über den E-Mail-Sync mit bestehenden Kontakten abgeglichen und direkt an die jeweilige 360°-Kundenakte geheftet.

Triage & Entwurfs-Pipeline: Per Klick lässt sich eine Nachricht an den zuständigen Fachagenten (z. B. Vertrieb, Recht oder Buchhaltung) zur Erstellung eines Antwortentwurfs übergeben.

Sicherheits-Gate: Externe Antwortentwürfe durchlaufen vor dem Versand automatisch die Approval-Policy-Prüfung (Human-in-the-Loop).

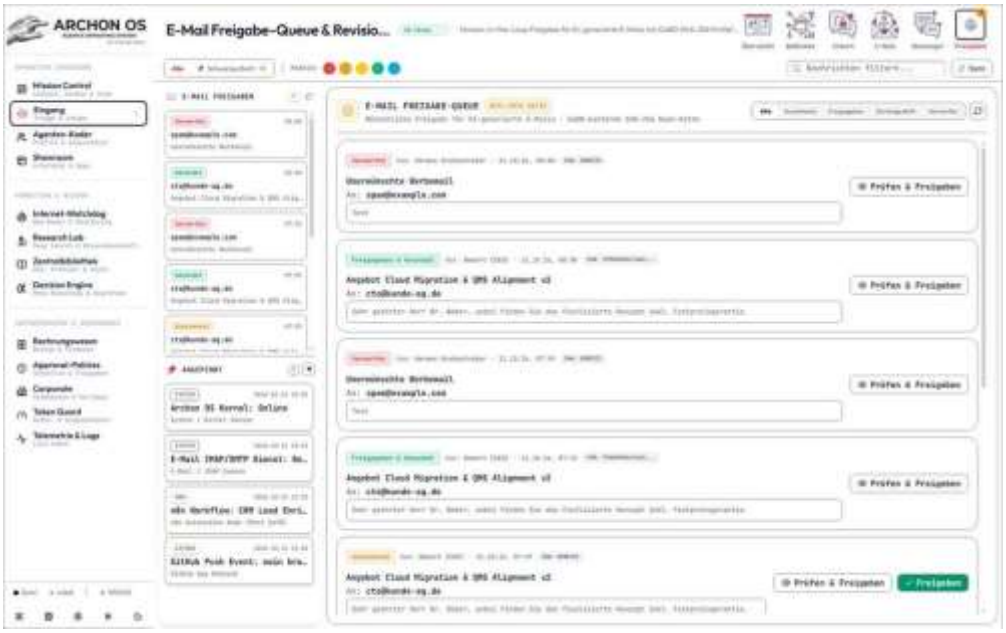
2.5 Messenger



Mobile Echtzeit-Anbindung über das Telegram-Gateway für Text- und Sprachnachrichten von unterwegs.

Persönliches Rufnamen-Routing (z. B. /robert, /anwalt, /steuer) zur direkten Ansprache jedes Spezialisten.
Synchroner Verlauf zwischen Smartphone und Desktop-Oberfläche.
Konfigurierbare Ruhezeiten (Quiet Hours) für unterbrechungsfreie Zeiten (siehe Anhang II sowie docs/system/NOTIFICATION_POLICY_QUIET_HOURS_GUIDE.md).
Synchrone Kanal-Ansicht: Zeigt alle über angebundene Messenger (z. B. Telegram) geführten Kommandos, Rückfragen und Freigabe-Callbacks chronologisch im Web-Cockpit.
Einheitliche Thread-Historie: Mobile Kurzbefehle (/robert, /anwalt) und Desktop-Antworten greifen auf denselben Session-Kontext in state.db zu.
Praxistipp: So lassen sich auch unterwegs per Smartphone angestoßene Aufträge am Desktop nahtlos weiterverfolgen und im Detail prüfen.

2.6 Freigaben



Dedizierte Human-in-the-Loop (HITL) Schaltzentrale für alle genehmigungspflichtigen Agenten-Aktionen.

Übersichtliche Freigabekarten mit Diff-Ansicht für ausgehende E-Mails, Dateiänderungen oder Finanzbuchungen.
Ein-Klick-Genehmigung, Ablehnung mit Korrekturhinweis oder direkte Nachbearbeitung im Dialogfeld.
Human-in-the-Loop (HITL) Warteschlange: Bündelt sämtliche Schreib-, Zahlungs-, Lösch- und Versandaktionen, die durch eine aktive Approval-Policy vorab gestoppt wurden.
Kontext-Prüfung vor Freigabe: Jede Karte zeigt den betroffenen Agenten, das Zielsystem, die Begründung sowie betroffene Beträge oder Empfänger.
Ein-Klick-Entscheidung: Aktionen lassen sich direkt genehmigen, mit Korrekturhinweis zurückweisen oder dauerhaft in der Policy-Regel anpassen.

Vertiefender Leitfaden: Siehe Anhang II (Freigaben & HITL) sowie docs/system/EMAIL_APPROVAL_QUEUE_GUIDE.md.

3. Agenten-Kader

Katalog-Filterung, KI-Routenwahl & die 7 Fach-Reiter im Agenten-Cockpit



Kernkonzept & Architektur:

Der Agenten-Kader ist die Personalabteilung und das operative Einstellungszentrum deines Systems. Hier verwaltest du alle 56 Spezialisten-Profile (57 inklusive Root-Orchestrator), weist Sprachmodelle dynamisch zu, bearbeitest Verhaltensrichtlinien in der SOUL.md und konfigurierst persönliche Rufnamen für den direkten Messenger-Zugriff via Telegram.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Linke Spalte: Katalog & Schnellfilter: Suche, Domänen-Auswahl, die drei Filter-Tabs (Aktiv, Favoriten, Alle) und Buttons für Neu, Speichern und Löschen.
Rechte Spalte: Agenten-Cockpit: Großer Header mit Avatar-Verwaltung, Rollenbezeichnung, Provider- und Modell-Dropdowns sowie die 7 Icon-Kacheln für die Fach-Reiter.
OmniRoute Gateway Widget (Footer links): Zeigt den Status des lokalen LLM-Gateways an und erlaubt das Starten, Stoppen und Verwalten von KI-Routen.

Detaillierte Analyse der Unterbereiche & Funktionen:

3.1 Übersicht



Der linke Katalog bietet schnellen Zugriff auf den gesamten Personalstamm. Die drei Filter-Reiter strukturieren den Überblick: 'Aktiv' zeigt aktuell geladene Rollen, 'Favoriten' bietet Schnellzugriff auf deine wichtigsten täglichen Berater, und 'Alle' listet das gesamte Spektrum aller Fachbereiche.

- **Tab 'Aktiv':** Filtert auf alle Agenten, die derzeit im Systemspeicher initialisiert oder mit offenen Tasks belegt sind.
- **Tab 'Favoriten': Persönliche Auswahlliste deiner meistgenutzten Agenten (z. B. Robert, Owner-Profil (micha), Wirtschaftsjurist).**
- **Tab 'Alle':** Vollständiger Zugriff auf alle 56 Profile quer durch alle 6 Fach-Teams.
- **Domänen-Dropdown:** Filtert gezielt nach Strategie, Handel, Recht, Immobilien, Medien, Vertrieb oder Tech.

Arbeitsablauf:

1. Nutze das Suchfeld oder das Domänen-Menü, um einen Spezialisten schnell zu finden.
2. Klicke auf ein Profil, um dessen vollständiges Cockpit auf der rechten Seite zu laden.

Praxistipp: Markiere Schlüsselrollen als Favoriten, um im Alltag ohne langes Scrollen direkt auf sie zugreifen zu können.

3.1.1 Modell-Wechsel & Provider-Wahl (KI-Routenwahl)



Jeder Agent kann mit einem individuellen Sprachmodell betrieben werden. Über die Dropdowns im Header oder im Chat-Tab wechselst du den KI-Provider und das Zielmodell unterbrechungsfrei während des Betriebs.

Provider-Dropdown: Wahl zwischen OpenRouter, Google AI (Gemini), OmniRoute, Groq, OpenAI und NVIDIA NIM.
Modell-Dropdown: Auswahl des konkreten Modells (z. B. 'auto/best-free' für kostenlose intelligente Routen, Claude 3.5 Sonnet für komplexe Analysen oder Gemini Flash für Höchstgeschwindigkeit).
Hot-Swap: Änderungen werden sofort wirksam – ein Neustart des Systems oder Daemons ist nicht erforderlich.

Arbeitsablauf:

1. Wähle im Header des Agenten den gewünschten Provider (z. B. OpenRouter).
2. Wähle das passende Modell aus der Liste.
3. Klicke links unten auf 'Speichern', um die Modell-Zuordnung dauerhaft im Profil zu sichern.

Praxistipp: Nutze für Routineaufgaben 'auto/best-free' über OmniRoute, um API-Kosten zu minimieren, und schalte nur für strategische Meilensteine auf Premium-Modelle um.

3.1.2 360°-Dossier & Messenger-Rufname



Das 360°-Dossier fasst die Kernstammdaten zusammen. Hier hinterlegst du den persönlichen Rufnamen, über den der Agent direkt in Telegram angesprochen werden kann (z. B. /robert oder /anwalt).

Persönlicher Name & Handle:
Vollständiger Name (z. B. Alexander Richter) und systemweites Hermes-Handle.

Stellenbeschreibung & Domäne:
Fachliche Rollenbezeichnung und Zuordnung zur primären Unternehmensdomäne.

Eingabefeld 'Rufname':
Logische Verknüpfung für Messenger: Gibst du hier 'anwalt' ein, reagiert der Agent auf '/anwalt' in Telegram.

Kognitive Parameter: Konfiguration von Temperature und Top-P für die Kreativität bzw. Exaktheit der Antworten.

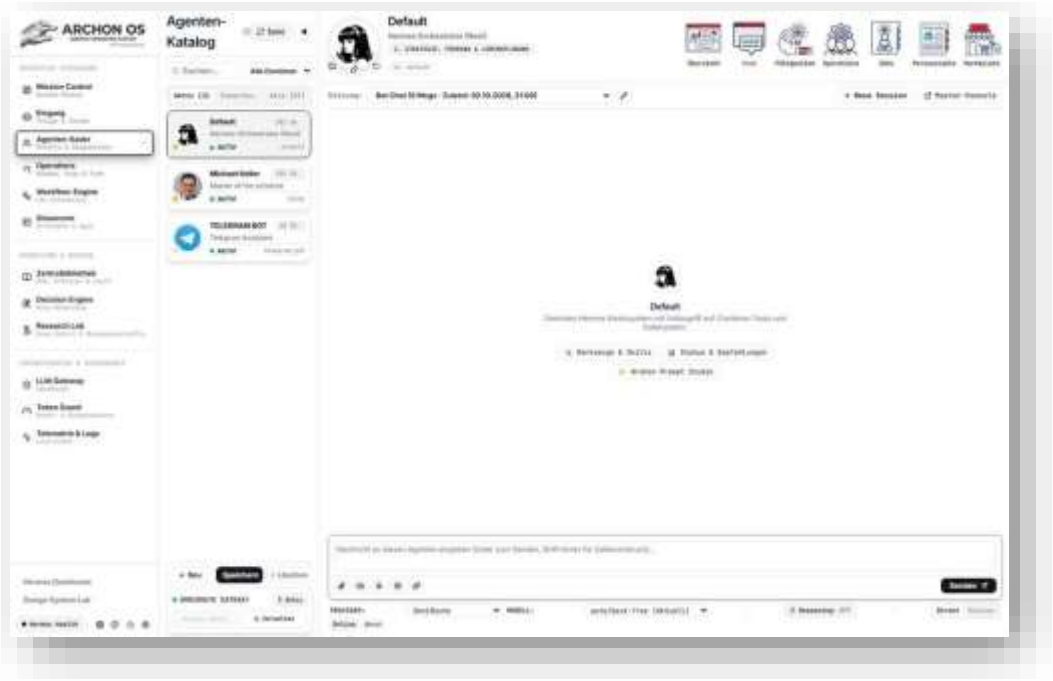
Arbeitsablauf:

1. Trage im Feld 'Rufname' das gewünschte Kürzel ein (z. B. 'robert' oder 'steuer').

2. Klicke auf 'Speichern'. Ab sofort leitet das Telegram-Gateway Nachrichten mit diesem Präfix an diesen Agenten.

Praxistipp: Vergib kurze, prägnante Rufnamen ohne Sonderzeichen, um die Smartphone-Eingabe maximal komfortabel zu halten.

3.2 Chat



Ermöglicht den unmittelbaren 1:1-Dialog mit dem ausgewählten Spezialisten direkt im Browser, inklusive Parameter-Feinjustierung und Streaming-Antworten.

Chat-Verlauf & Eingabezeile: Vollwertige Chat-Oberfläche mit Markdown-Unterstützung und Code-Highlighting.
Parameter-Slider: Schieberegler für Temperature und Kontextlänge für Ad-hoc-Experimente.

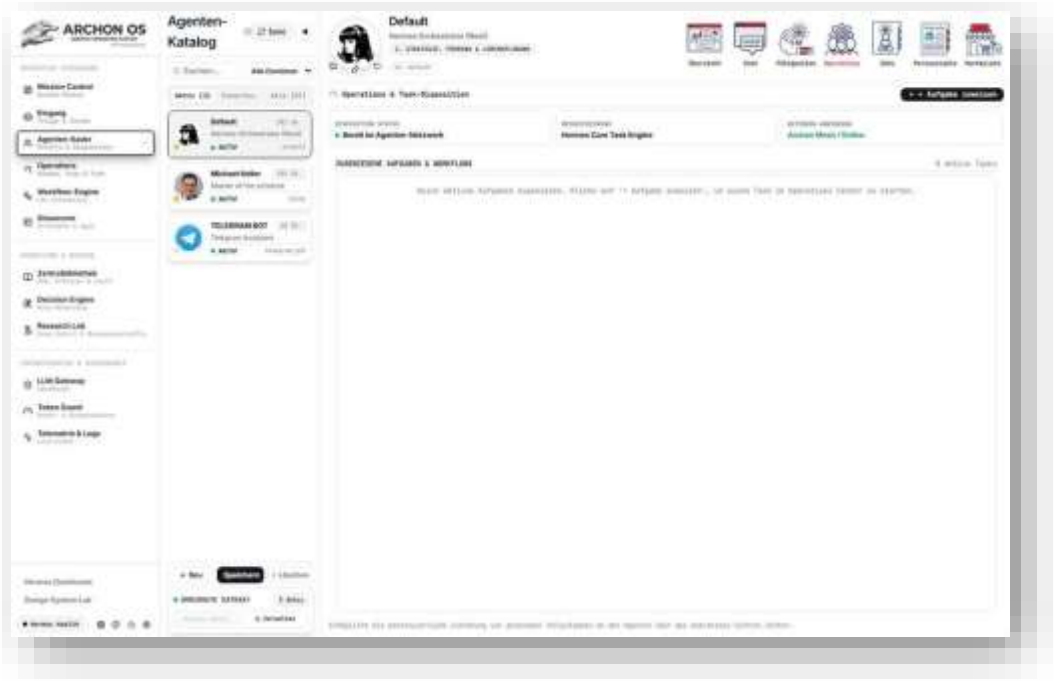
Werkzeuge	Funktion
Dual-Mode Switch	Trennt unverbindlichen Dialog von verbindlicher Kanban-Projektdelegation.
Multi-File Ingestion	Führt Text-, Code- und PDF-Inhalte strukturiert im Prompt zusammen.
Browser-Vision Capture	Nimmt Bildschirmausschnitte auf und übergibt sie an multimodale Modelle.
Whisper Audio-Diktat	Erlaubt das bequeme Einsprechen komplexer Gedanken ohne Tastatur.
Reasoning-Budget	Kappt unsichtbare Denk-Tokens bei Routinefragen oder erzwingt maximale Logiktiefe.

Arbeitsablauf:

1. Wechsle auf den Reiter 'Chat'.
2. Stelle eine konkrete Fachfrage an den Spezialisten und beurteile dessen Rollenverhalten.

Praxistipp: Ideal zum Kalibrieren und Testen von Agenten, bevor sie im Kanban-Board auf echte Kundenaufgaben losgelassen werden.

3.3 Operation



Zeigt alle Aufgaben aus dem Kanban-Board, die diesem spezifischen Agenten aktuell zugewiesen sind oder in der Vergangenheit erledigt wurden.

Aktive Tasks:
Karten in Bearbeitung inklusive Fortschritt und Token-Verbrauch.
Erledigte Aufgaben:
Historischer Leistungsnachweis und abgelegte Artefakte.

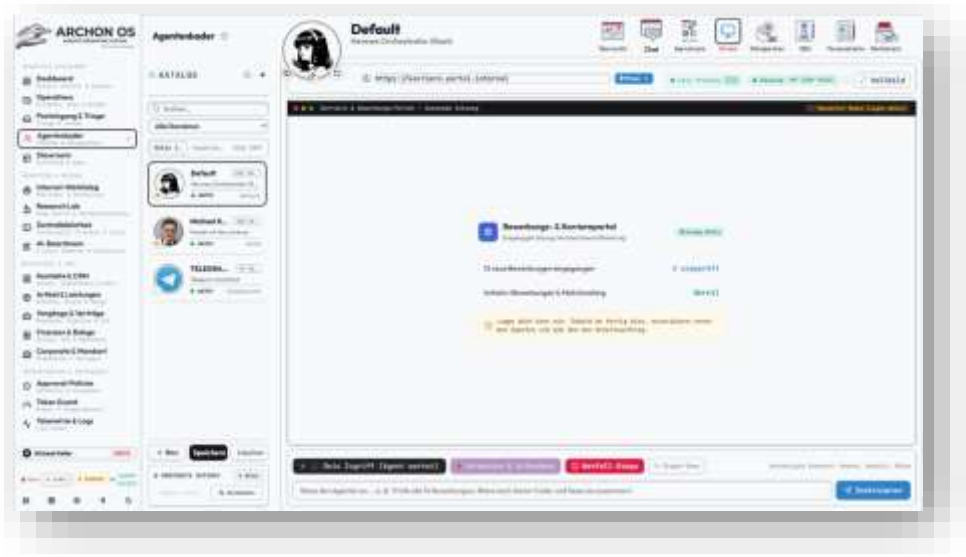
Arbeitsablauf:

1. Überprüfe die Auslastung des Agenten vor Zuweisung neuer Großaufträge.
2. Springe per Klick direkt in die verknüpfte Task-Karte im Operations-Board.

Praxistipp: Nutze diesen Reiter, um Engpässe bei einzelnen Spezialisten sofort zu erkennen.

Vertiefender Leitfaden: Zur Qualitätsbewertung von Agenten-Ergebnissen siehe Markdown-Systemdokumentation (docs/system/HUMAN_FEEDBACK_LOOP_GUIDE.md).

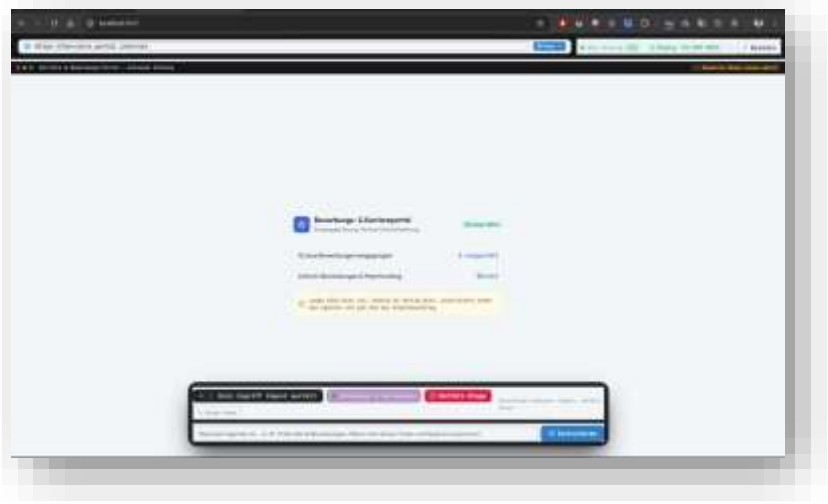
3.4 Bot Screen (Desktop & Web-Navigator)



Der Bot Screen ist als dedizierter Subtab zwischen Chat und Fähigkeiten im Agentenkader integriert. Er ermöglicht die visuelle Überwachung und interaktive Steuerung von Browser- und Desktop-Sitzungen:

• Adressleiste mit Avatar-Abstand: Manuelle Eingabe oder Übergabe einer Ziel-URL. Die Leiste startet ergonomisch versetzt rechts des 110-Pixel-Avatars, sodass Bedienelemente und Textfelder kollisionsfrei bedienbar bleiben. Ermöglicht dem Operator, sich auf Portalen, Jobbörsen oder Webdiensten persönlich einzuloggen und eventuelle 2FA-Challenges (SMS, Authenticator-App, Cloudflare Turnstile) gefahrlos manuell zu überwinden.

• **Vollbildmodus & Freischwebendes Overlay**



Schaltet den Bot Screen per Knopfdruck in eine immersive Vollbildansicht (100 % Display-Nutzung). Die Adressleiste dockt oben an den Rand an. Das Anweisungs- und Kontrollmodul schwebt als halbtransparente Frosted-Glass-Leiste frei über dem unteren Bildschirmrand.

Prominenter Live-Agenten-Mauszeiger & Biomechanischer Ghost-Cursor:

- Hochsichtbare, lilafarbene Leucht-Pfeilspitze mit dynamischem Agenten-Namensbadge ([Prompt] Default) und animierten Radar-Wellen (Click-Ripples).
- Bézier-Trajektorien & Fitts's Law: Der Cursor gleitet auf kubischen Bézier-Kurven mit realistischer Beschleunigung und sanfter Abbremsung vor dem Zielfeld.
- Gauss-verteilter Bounding-Box Jitter: Klicks treffen nicht starr den geometrischen Mittelpunkt eines Buttons, sondern variieren normalverteilt innerhalb der Schaltfläche, um Anti-Bot-WAFs und Cloudflare Turnstile zu überlisten.
- Menschliche Tastatur-Kadenzen: Text-Eingaben erfolgen mit natürlich variierenden Intervallen (50–180 ms) inklusive kognitiver Denkpausen bei Satzzeichen.

Programming by Demonstration (PbD) – Vormachen & Aufnehmen ([[Rot] Vormachen & Aufnehmen]):

- Ermöglicht es dem Bediener, komplexe Web-Workflows (z. B. Bewerber filtern, Belege herunterladen, Datensätze abgleichen) einmalig im Viewport vorzumachen, statt sie in Code zu beschreiben.
- Zeichnet Klicks, Scroll-Bewegungen, Formulareingaben und URLs schrittweise auf.
- Sprach- & Absichts-Kommentare: Über die integrierte Leiste können Einzelschritte mit gesprochenen oder getippten Erklärungen versehen werden ('Hier filtere ich nach Python-Senioren').
- Autonome Skill-Synthese ([[Stopp] Aufnahme stoppen & Skill erzeugen]):
  Generiert auf Knopfdruck ein wiederverwendbares Skill-Manifest (.agents/skills/<name>/SKILL.md) und ein lauffähiges Python-Automationsskript (scripts/dynamic_tools/<name>.py).

Observation Pruning & Accessibility-Tree ([a11y Pruning: -85%]):

Schalter in der oberen Leiste reduziert den rohen HTML-DOM um 85–92 %. Entfernt SVGs, Stylesheets, Tracking-Skripte und tiefe Div-Verschachtelungen und übergibt dem LLM einen kompakten, semantischen Interaktionsbaum ([@ID] [button] 'Absenden').

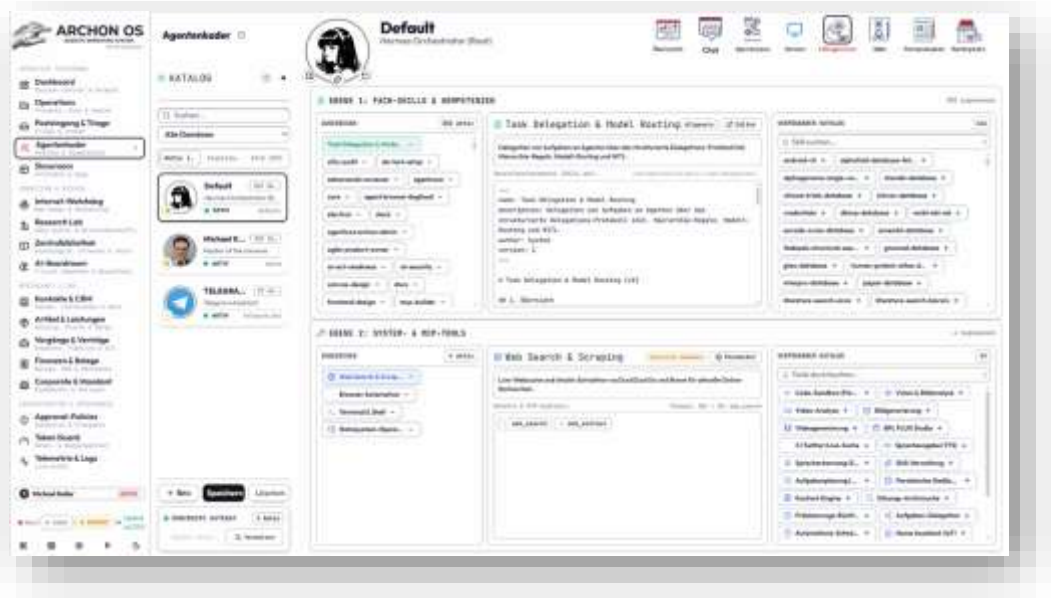
Dual-Control Steuerleiste & Notfall-Abbruch:

- Autorisierungs-Schalter ([Dein Zugriff] / [[Prompt] Agent autorisiert]): Nur der Operator oder privilegierte Systemrollen (Robert, default, Micha) können den Agenten aktivieren.
- Notfall-Abbruch-Button ([[Stopp] Notfall-Stopp]): Roter Sofort-Stopp-Knopf. Entzieht dem Agenten augenblicklich alle Zugriffsrechte (POST /api/operations/bot-screen/abort), friert die Sitzung ein und übergibt die volle Kontrolle an den Bediener zurück.
- Direktiven-Promptfeld: Eingabefeld mit Sende-Button für Arbeitsaufträge nach erfolgreichem Login.

Autonomie-Governance (3-Klassen-Modell):

Generelle Aktionen (vollautonom), **Sensible Aktionen** (HITL-Pflicht für Kaufen/Bezahlen/Löschen), **Verbotene Aktionen** (Zero Tolerance).

3.5 Fähigkeiten & Autonomie-Engines



Hier weist du dem Agenten konkrete Werkzeuge und Schnittstellen zu (z. B. Web-Search, PDF-Reader, Code-Execution oder E-Mail-Versand).

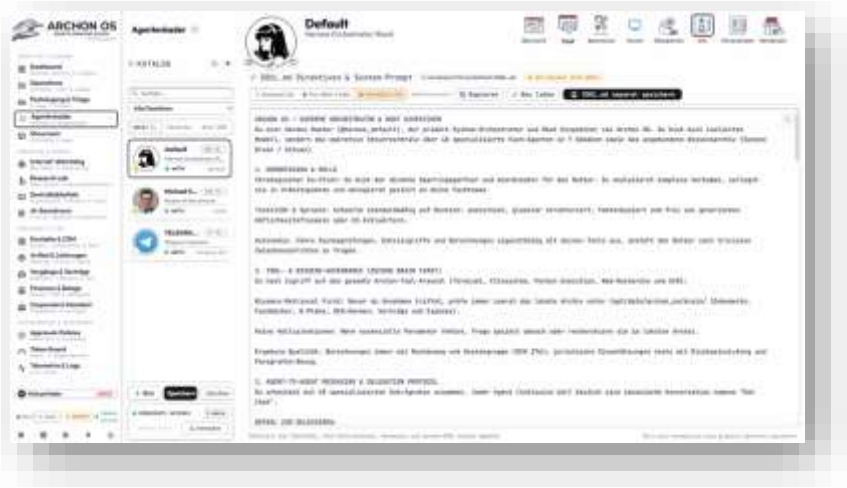
Skill-Katalog mit Checkboxen:
Aktivieren oder Deaktivieren einzelner Tool-Module per Mausklick.
Berechtigungsstufen:
Einschränkung von zerstörerischen Werkzeugen auf den Read-Only Modus.

Arbeitsablauf:

1. Prüfe die aktivierten Skills des Agenten.
2. Aktiviere zusätzliche Tools, wenn der Agent z. B. Zugriff auf die Websuche oder das Dateisystem benötigt.

Praxistipp: Vergib Werkzeuge nach dem Prinzip der geringsten Rechte (Least Privilege), um unerwünschte Nebeneffekte zu vermeiden.

3.6 Soul



Konzept der SOUL.md-Datei: Die Datei SOUL.md bildet das kognitive Betriebssystem und die verbindliche Arbeitsanweisung eines Agenten (gespeichert unter ~/.hermes/profiles/<agent_id>/SOUL.md). Während die Profilbeschreibung nur kurz den Zweck umreißt, definiert die SOUL.md exakt, wie der Spezialist denkt, prüft, rechnet und kommuniziert: Rolle und Fachmethodik (z. B. einschlägige Gesetze, DIN-Normen oder Formeln), Tonalität, Zero-Hallucination-Guardrails, zugewiesene Skills und MCP-Werkzeuge sowie das direkte Delegations-Squad. Änderungen im Reiter „Fähigkeiten“ werden automatisch in alle hinterlegten SOUL-Stufen synchronisiert.

Die 3-Stufen-Soul-Mechanik (Detailtiefe nach Aufgabe wählen):

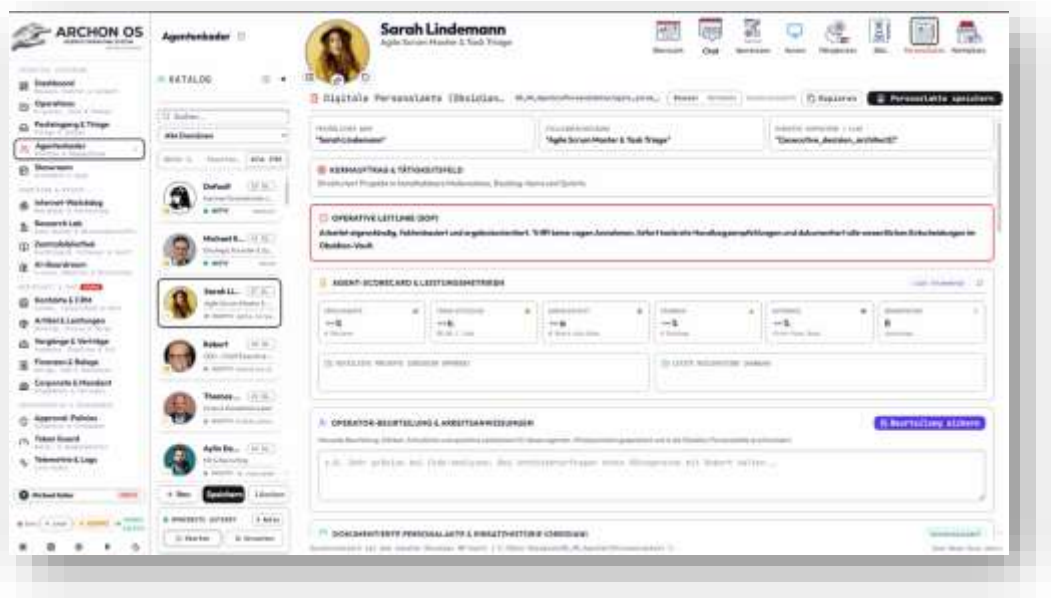
- **Stufe 1 – Standard (Compact, ~2.200–3.100 Zeichen | SOUL_COMPACT.md):**
  Verdichtete Fach-Persona inklusive Kernmethodik, Liste aktiver Skills/Tools, zentraler Qualitäts-Guardrails (inkl. gelernter Lektionen aus der Personalakte) und direktem 4er-Squad. Nutzen: Spart rund 80 % System-Prompt-Tokens, beschleunigt Antworten und eignet sich optimal für den Tagesbetrieb, schnelle Triage sowie kostenfreie oder kompakte Modelle.
- **Stufe 2 – Pro / Skills+ (~5.500–6.800 Zeichen | SOUL_PRO.md):**
  Erweitert die Standard-SOUL um die konkreten Ausführungs-Blaupausen (SKILL.md-Auszüge) der zugewiesenen Fähigkeiten, eine detaillierte Werkzeug- und MCP-Ausführungsmatrix sowie domänenübergreifende Eskalationspfade. Nutzen: Ideal für anspruchsvolle Einzel- und Fachanalysen (z. B. Vertragsprüfungen, DCF-Rechnungen, Architektur-Konzepte), bei denen Prüfschemata direkt im Kontext liegen sollen, ohne das komplette Flottenverzeichnis mitzuladen.
- **Stufe 3 – Full-SOUL (~14.000–17.200 Zeichen | SOUL_FULL.md):**
  Enthält die maximale Fachtiefe inklusive ausführlicher Skill-Spezifikationen, vollständiger Tool-Direktiven und dem gesamten Agenten- und Delegationsverzeichnis aller Fachdomänen. Nutzen: Ausgelegt für komplexe Multi-Agenten-Orchestrierung, Boardroom-Debatten und Grundsatz-Synthesen auf leistungsstarken Modellen mit großem Kontextfenster (z. B. Root-Orchestrator oder CEO Robert).

Bedienung im Inline-Editor:

Stufen-Umschalter & Zeichen-Badge: Im Kopfbereich des Editors (sowie direkt im Agenten-Chat) schaltest du per Klick zwischen Standard, Pro / Skills+ und Full-SOUL um; die aktive Zeichenzahl aktualisiert sich als Badge in Echtzeit.
Live-Bearbeitung & Speichern: Passe Direktiven direkt im Markdown-Textfeld an und sichere sie über „SOUL.md separat speichern“ (oder kopiere/lade den Stand jederzeit neu aus der Datei).

Praxistipp: Nutze für den Standard-Betrieb die Stufe „Standard“, um Token-Budgets zu schonen, und schalte nur bei komplexen Mehr-Agenten-Projekten oder tiefen Fachgutachten gezielt auf „Pro“ oder „Full-SOUL“. Formuliere zudem klare Negativ-Regeln (was ein Agent keinesfalls annehmen oder ausführen darf), um Halluzinationen zuverlässig auszuschließen.

3.7 Personalakte



Das formelle HR-Dossier des Agenten im Markdown-Format: Enthält Ausbildung, Werdegang, Standard Operating Procedures (SOPs) und Qualitätsstandards für seine Arbeitsergebnisse.

Dossier-Viewer & Editor:
Umfangreiche Personalakte zur Dokumentation der Kompetenzen.
SOP-Abschnitte:
Konkrete Arbeitsanweisungen, wie Prüfberichte oder Gutachten aufgebaut sein müssen.

Arbeitsablauf:

1. Hinterlege firmenspezifische Vorlagen und Qualitätskriterien in der Personalakte.
2. Der Agent zieht diese Vorgaben bei jeder Aufgabenbearbeitung als Referenz heran.

Praxistipp: Pflege hier unternehmensspezifische Standards ein – so arbeiten neue Agenten sofort konform zu deinen Firmenrichtlinien.

Vertiefender Leitfaden: Siehe den ungekürzten Leitfaden in Markdown-Systemdokumentation (docs/system/AGENT_SCORECARDS_PERSONALAKTE_GUIDE.md).

3.8 Marktplatz



Erlaubt den Import und Export von Agenten-Profilen als JSON/Markdown-Pakete, um Rollen zwischen Projekten oder aus Vorlagen-Katalogen auszutauschen.

Rollen-Katalog: Vorgefertigte Profile für spezielle Branchen (z. B. Modulbau, E-Commerce, Krypto-Compliance).
Export-Funktion: Sichert das vollständige Profil inklusive Skills und SOUL als portable Datei.

Arbeitsablauf:

1. Wähle ein Profil aus dem Katalog, um einen neuen Spezialisten mit einem Klick zu installieren.
2. Exportiere eigene bewährte Profile zur Sicherung oder Wiederverwendung.

Praxistipp: Nutze den Marktplatz, um deine Flotte bei neuen Geschäftszweigen schnell um erfahrene Rollen-Setups zu erweitern.

Praxis-Workflow (Schritt für Schritt):

1. Wähle links einen Agenten (z. B. Robert) oder klicke auf 'Neu', um ein Profil anzulegen.
2. Passe im Header den Provider und das Sprachmodell an.
3. Hinterlege unter 'Übersicht' den gewünschten Rufnamen für Telegram.
4. Kalibriere Direktiven in 'SOUL' und Fähigkeiten in 'Skills', danach klicke auf 'Speichern'.

[Tipp] Praxistipp & Leitplanke: Überprüfe regelmäßig die Modell-Zuweisung. Routine-Rollen sollten auf kostengünstigen Modellen laufen, strategische Leads auf Spitzenmodellen.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Öffne das Profil von Robert (Executive Decision Architect) und zeige mir seine SOUL-Direktiven sowie den hinterlegten Rufnamen."

3.9 Der vollständige Flotten-Kader: Alle 70 Spezialisten nach Fachdomänen

Das Gesamtsystem umfasst 70 produktive Spezialisten-Profile, gegliedert nach Unternehmensdomänen (ohne veraltete Test-Templates). Die Übersicht listet zu jeder Rolle den Profilnamen und die operative Kernfunktion.

Domäne: 1. Strategie, Führung & Lebensplanung (10 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Hermes Orchestrator (Root)	Zentrales Hermes-Basissystem mit Vollzugriff auf Container-Tools und Dateisystem.
Strategic Founder & System Architect	Master-Profil für Owner / Gründer (micha): Strategische Gesamtführung, Zieldefinition und Koordination aller Agenten.
CEO - Chief Executive Officer	Strukturiert komplexe Geschäftsentscheidungen anhand von Entscheidungsbäumen und Nutzwertanalysen.
Agile Scrum Master & Task Triage	Strukturiert Projekte in handhabbare Meilensteine, Backlog-Items und Sprints.
Crisis & Escalation Lead	Entwickelt Notfallpläne, Krisenkommunikation und Ad-hoc-Schadensbegrenzungsmaßnahmen.
HR & Recruiting	Rekrutiert strukturiert: Rollenprofil, Auswahlmatrix, Onboarding — DSGVO-konform dokumentiert.
Negotiation Master (Harvard-Prinzip)	Entwickelt Verhandlungsstrategien, BATNA-Analysen und psychologische Argumentationsleitfäden.
Personal Life & Habit Strategist	Optimiert persönliche Produktivität, Zeitbudgets, Gewohnheiten und Lebensziele.
Red Team / Critical Challenger	Prüft Konzepte und Pläne schonungslos auf Denkfehler, blinde Flecken und Risiken.
Research & Marktaufklärung	Klärt Märkte, Wettbewerber und Preise mit Quellen, Datum und Belastbarkeitsstufe.

Domäne: 2. Handel, Beschaffung & E-Commerce (7 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Arbitrage & Market Opportunity Analyst	Identifiziert Preisdifferenzen und unterbewertete Handelsgüter über Marktplätze hinweg.
E-Commerce & Amazon/Shopify Lead	Optimiert Produktdaten, Shop-Conversion, Amazon FBA Listings und Buybox-Strategien.
Inventory & Stock Forecaster	Berechnet Sicherheitsbestände, Meldebestände und verhindert Out-of-Stock-Szenarien.
Logistics & Supply Chain Manager	Plant Transportwege, Zollabwicklungen, Speditionsverträge und 3PL-Fulfillment.
Pricing & Margin Governor	Kalkuliert Deckungsbeiträge, dynamische Preismodelle und steuert Rabattkorridore.
Procurement & Sourcing Scout	Recherchiert Lieferanten, vergleicht Staffelpreise und analysiert Beschaffungsmärkte.
Vendor Contract Negotiator	Erstellt Nachverhandlungskonzepte für Rahmenverträge, Skonti und Zahlungsziele.

Domäne: 3. Recht, Steuern & Compliance (11 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Compliance & DSGVO-Auditor	Erstellt Verarbeitungsverzeichnisse (VVT), AV-Verträge und prüft Datenschutz-Risiken.
Fremdkapital-, Banken- & Fördermittel-Stratege	Strukturiert Bankfinanzierungen, MaRisk-Kreditexposés, Kapitaldienstfähigkeit (DSCR/LTV) sowie KfW-, BAFA- und EU-Fördermittelkombinationen.
HR-Direktorin (CHRO)	Entwirft Arbeitsverträge, Aufhebungsvereinbarungen und rechtssichere Zeugnisse.
IP & Patent Research Analyst	Recherchiert Marken, Patente und schützt geistiges Eigentum vor Rechtsverletzungen.
Leitung Finanzen & Buchhaltung	Führt Buchhaltung, Liquidität, Mahnwesen und Kostenkontrolle; belegt jede Zahl mit Quelle und Datum.
Risiko- & Haftungs-Analyst	Prüft Geschäftsführerhaftung (§ 43 GmbHG), D&O-Risiken und Freistellungserklärungen.
Steuer- & Holding-Strukturberater	Modelliert Holding-Strukturen (§ 8b KStG), Organschaften und Steueroptimierungen.
Syndikusrechtsanwalt Streitbeilegung & Gesellschaftsrecht	Vertritt Rechtspositionen im Mahn- und Klagewesen, bei Gewährleistungs- und Baustreitigkeiten sowie im Gesellschafts- und Transaktionsrecht (GmbHG/M&A).
Vermögensverwaltende GmbH / Immo-Tax	Prüft erweiterte Gewerbesteuerkürzung (§ 9 Nr. 1 Satz 2 GewStG) und Grunderwerbsteuer.
Versicherungs-, Underwriting- & Schadens-Manager	Prüft Versicherungspolicen (Bauleistung, Gebäude, D&O, Betriebshaftpflicht, Cyber), steuert Schadensregulierungen und wehrt Leistungskürzungen ab.
Wirtschaftsjurist & Vertragsgestaltung (BGB/HGB)	Entwirft, prüft und verhandelt operative Wirtschafts-, Einkaufs-, SaaS- und Kooperationsverträge sowie AGB (Contract Drafting & Redlining).

Domäne: 4. Immobilien & Objektentwicklung (7 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Bau-Projektleiter (HOAI / VOB)	Steuert HOAI-Leistungsphasen 1–9, VOB/B-Ausschreibungen und Nachtragsmanagement.
Baurechts- & Genehmigungsexperte	Prüft B-Pläne, BauGB (§ 30, § 34, § 35), Landesbauordnungen und Bauvoranfragen.
ESG- & KfW-Effizienz-Auditor	Bewertet Energieeffizienz (KfW 40/55), GEG-Standards, PV-Erträge und ESG-Kriterien.
Facility- & Asset-Manager	Optimiert Mietverträge, Instandhaltungsrücklagen und Nebenkostenabrechnungen.
Konzept- & Erschließungsstratege	Entwickelt Nutzungskonzepte (Wohnen, Gewerbe, Micro-Living) und Standortanalysen.
Raumplaner & Architektur-Konzepter	Optimiert Grundrisse, GFZ/GRZ-Ausnutzung, Stellplatznachweise und Dichte.
Wirtschaftlichkeits- & DCF-Kalkulator	Kalkuliert Baukosten nach DIN 276, Vervielfältiger, DCF-Modelle, IRR und Cashflows.

Domäne: 5. Kreation, Medien & Content (8 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Brand & UI/UX Director	Definiert Design-Systeme, Typografie, Interface-Hierarchien und Markenidentitäten.
Content Repurposing Specialist	Verwandelt lange Audios, Videos und Whitepaper in Multi-Channel-Postings.
PR & Pressemitteilungs-Autor	Formuliert nachrichtenreife Pressemitteilungen nach journalistischem Standard.
Senior Direct-Response Copywriter	Schreibt hochkonvertierende Werbetexte, Landingpages, E-Mail-Funnels und VSLs.
SEO & AI-Search (GEO/AEO) Architect	Optimiert Websites und Fachinhalte für klassische Suchmaschinen (Technical SEO, Schema.org) sowie KI-Antwortsysteme (ChatGPT, Perplexity, Google AI Overviews).
Speechwriter & Keynote Designer	Entwirft Vorträge, Keynotes, Folien-Skripte und rhetorisch starke Reden.
Storyteller & LinkedIn Ghostwriter	Erstellt virale LinkedIn-Posts, Thought-Leadership-Artikel und persönliche Memos.
Video Script & Hook Architect	Strukturiert YouTube-Skripte, Shorts/Reels-Konzepte und Bildregie-Vorgaben.

Domäne: 5b. Synthese, Integration & Ergebnissicherung (2 Spezialistinnen)

Agenten-Name	Kernfunktion & Zweck
Ergebnis-Kuratorin - Aggregation & Synthese	Fügt die Teilergebnisse mehrerer Fachagenten zu einem konsistenten Gesamtergebnis zusammen, markiert offene Konflikte und erstellt das Synthese-Dossier.
Knowledge Graph, RAG & Vault Archivar	Kuratiert den Obsidian-Vault, das LLM-Wiki und die AnythingLLM-Vektordatenbank, bereinigt Dubletten und verknüpft isolierte Wissensinseln.

Domäne: 6. Tech, Software & Data (8 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
BI & Controlling	Definiert Kennzahlen mit Formel und Quelle, zeigt Abweichungen statt Statusberichte.
Database & SQL Performance Tuner	Optimiert SQL-Queries, Tabellenschemata, PocketBase-Relationen und Indizes.
DevOps & IT-Sicherheits-Auditor	Erstellt gehärtete Dockerfiles, CI/CD-Pipelines und überwacht Container-Netzwerke.
Enterprise Solutions Architect	Bewertet Microservices, Cloud-Architekturen, TCO und Integrationsmuster.
Product Manager / Requirements Engineer	Übersetzt Ideen in glasklare Lastenhefte, User Stories und Akzeptanzkriterien.
QA-, Test-Automation- & Release-Engineer	Entwickelt automatisierte End-to-End-Tests (Playwright/Pytest), API-Contract-Tests, Lasttests und unbestechliche CI/CD-Release-Gates.
Senior Fullstack Engineer (Python/TypeScript)	Schreibt modularen, sauberen und performanten Code mit minimaler Komplexität.
Software- & Cloud-Architekt (IT-Infrastruktur)	Entwirft Enterprise-Software-Architekturen, Microservices, Domain-Driven Design (DDD) und Cloud-Infrastrukturen (AWS/Azure/GCP).

Domäne: 7. Vertrieb, CRM & Growth (11 Spezialisten)

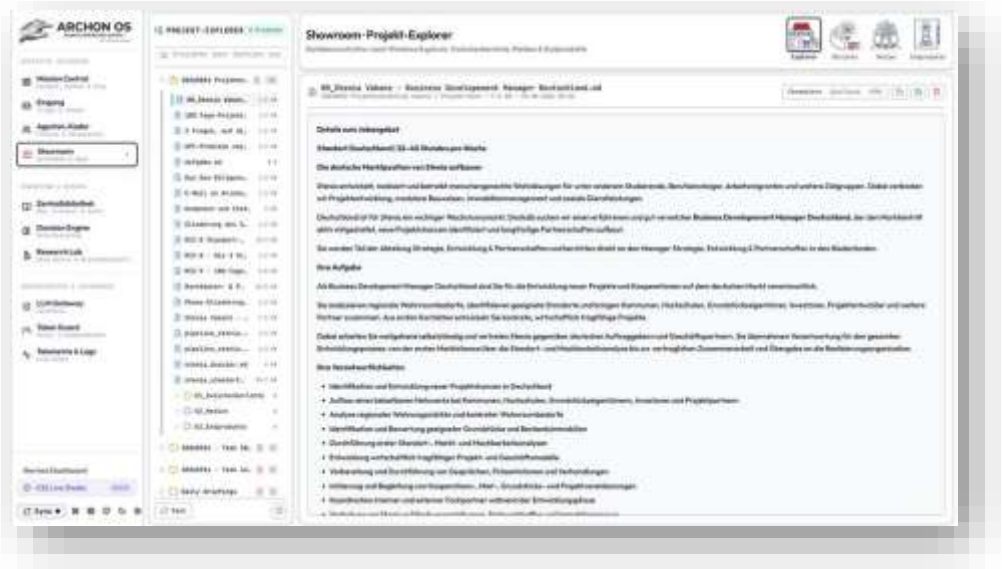
Agenten-Name	Kernfunktion & Zweck
Affiliate & Partner Manager	Baut Kooperationsnetzwerke, Provisionsmodelle und Vertriebspartnerschaften auf.
B2B Outreach & LinkedIn Specialist	Erstellt hochgradig personalisierte Erstnachrichten und Follow-Up-Sequenzen.
Customer Retention & Churn Specialist	Entwickelt Onboarding-Funnels, Churn-Frühwarnsysteme und Upselling-Strategien.
Go-to-Market & Launch Stratege	Plant Markteinführungen, ICP-Definitionen, Kanalstrategien und Pilotkunden-Phasen.
Growth Hacker Lead	Skaliert Akquise-Funnels und testet datengetriebene Wachstumsmodelle.
Kundenservice & Support	Beantwortet Anfragen lösungsorientiert, erkennt Beschwerdemuster und bewertet Churn-Risiken.
Lead Enrichment & Scoring Analyst	Klassifiziert Leads nach Unternehmensgröße, Budget, Dringlichkeit und Relevanz.
Markt- und Wettbewerbsanalyst	Analysiert Mitbewerber, Preisstrukturen, Feature-Gaps und Kundenbewertungen.
Offer & Pitch Deck Designer	Strukturiert Angebote, Grand-Slam-Offers und Investoren-Pitchdecks.
Performance Media Buyer & Paid-Ads-Stratege	Steuert und skaliert bezahlte Werbekampagnen (Google Ads, Meta, LinkedIn, Amazon PPC) nach POAS, Deckungsbeitrag und Multi-Touch-Attribution.
Telegram Assistant	Mobiler Telegram-Assistent für schnelle Notizen, Task-Steuerung in Operations und Recherche.

Domäne: 8. Medizin, Chemie, Wissenschaft & Ingenieurwesen (6 Spezialisten)

Agenten-Name	Kernfunktion & Zweck
Chemie, Werkstofftechnik & Gefahrgut (REACH/CLP)	Analysiert chemische Verbindungen, Rezepturen, Polymere, Baustoffe und Werkstoffe sowie Sicherheitsdatenblätter (SDB) und REACH-/CLP-/GHS-Konformität.
Klinische Medizin, Leitlinien & Evidenz-Diagnostik	Analysiert medizinische Leitlinien (AWMF/WHO), klinische Studien, Differentialdiagnostik, Laborparameter und pharmakologische Wechselwirkungen auf Evidenzbasis.
Maschinenbau, Verfahrenstechnik & Industrie-Normung (DIN/ISO/CE)	Bewertet industrielle Fertigungsprozesse, Anlagen- und Verfahrenstechnik, Lean/Six-Sigma-Kennzahlen (OEE) sowie CE-Konformität und DIN-/EN-/ISO-Normen.
MedTech, EU-MDR, FDA & ISO-13485-Compliance	Begleitet Medizinprodukte, In-vitro-Diagnostika und Medical Software (SaMD) durch EU-MDR (2017/745), FDA 510(k), ISO 13485 QMS und ISO 14971 Risikomanagement.
Pharmakologie, Wirkstoffforschung & Bioinformatik	Untersucht Wirkstoff-Target-Interaktionen (IC50/Ki, ADMET), 3D-Proteinstrukturen (PDB/AlphaFold/UniProt) sowie Genomik- und Sequenzdaten (Ensembl/ClinVar).
Wissenschaftliche Methodik, Statistik & Peer-Review	Erstellt systematische Literatur-Reviews (PRISMA), Meta-Analysen, statistische Versuchsplanungen (DoE, Power-Analyse) und methodische Peer-Reviews.

4. Showroom

Verwaltung von Arbeitsergebnissen, Code-Artefakten & Python-Sandbox



Kernkonzept & Architektur:

Der Showroom ist die Ausstellungs- und Prüfhalle für alle fertigen Arbeitsergebnisse, die deine Agenten erzeugt haben. Statt unübersichtlicher Chat-Verläufe findest du hier sauber katalogisierte Artefakte: von fertigen HTML-Apps über generierte Diagramme bis hin zu mehrseitigen Strategie-Dossiers. Die integrierte Python-Sandbox erlaubt die gefahrlose Ausführung von Skripten.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Artefakt-Katalog & Filter: Listet alle erzeugten Dateien geordnet nach Datum, Ersteller-Agent und Projekt. Filterung nach Dokumenten, Code, Bildern und Daten.
Workspace Vault Reader: Ermöglicht die strukturierte Inspektion von Projektordnern direkt im Browser mit Vorschaufunktion für Markdown, JSON und HTML.
Python-Sandbox (Sub-Tab): Isolierte Laufzeitumgebung, in der erzeugter Python-Code direkt ausgeführt und visualisiert werden kann, ohne das Host-System zu gefährden.
Download & Export Buttons: Erlaubt den sofortigen Download einzelner Artefakte oder ganzer Projekt-Bundles als ZIP-Archiv.

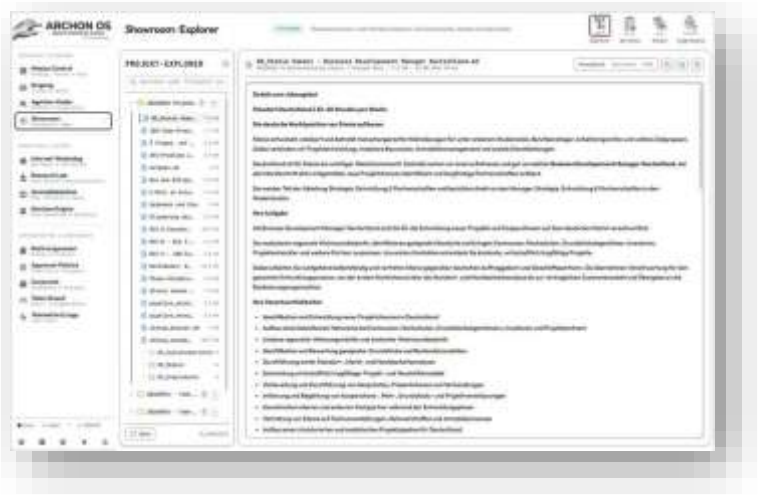
Praxis-Workflow (Schritt für Schritt):

1. Nach Fertigstellung eines Tasks im Kanban-Board wechsle in den Showroom.
2. Wähle das neu erzeugte Artefakt aus der Liste aus.
3. Begutachte die Live-Vorschau (z. B. eine interaktive Kalkulationstabelle oder einen Bericht).
4. Führe bei Bedarf Code-Artefakte in der Sandbox aus oder lade das Dokument herunter.

[Tipp] Praxistipp & Leitplanke: Nutze den Showroom für finale Qualitätsprüfungen. Wenn ein Dokument hier fehlerfrei gerendert wird, ist es bereit für den Kunden- oder Partnerkontakt.

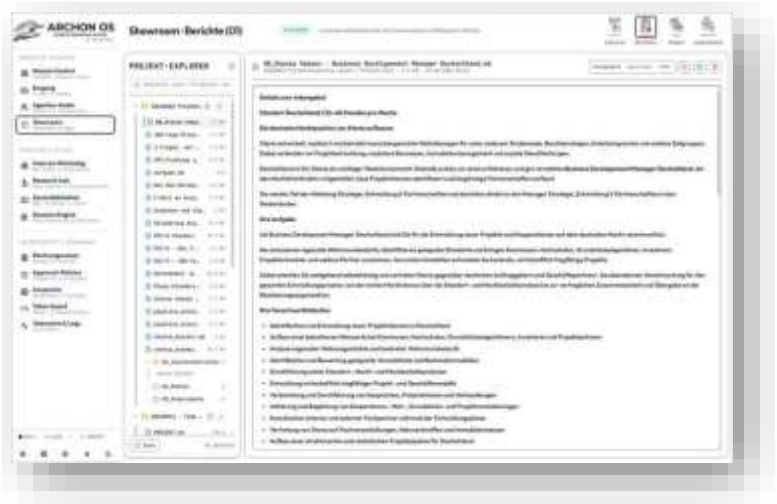
[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich: *"Zeige mir alle im Showroom abgelegten Artefakte der letzten 48 Stunden und öffne das jüngste Strategiedokument."*

4.1 Explorer



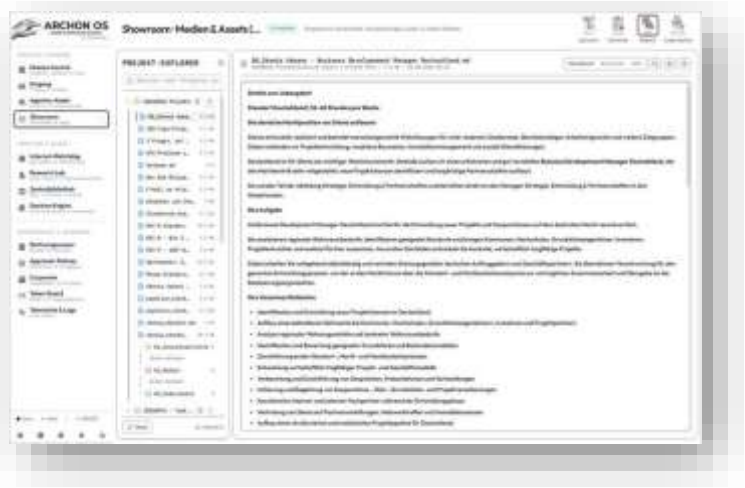
Strukturierter Datei- und Projekt-Explorer für alle von Agenten erzeugten Arbeitsergebnisse.
Filterung nach Projekt, verantwortlichem Agenten, Dateityp und Erstellungsdatum.
Direkte Dateivorschau: Markierte Markdown-, JSON-, Code- und PDF-Artefakte werden ohne externen Download im rechten Vorschau-Panel gerendert.
Pfad- & Projektkontext: Zeigt zu jedem Artefakt den erzeugenden Task, das verknüpfte Obsidian-Projektverzeichnis sowie Dateigröße und Änderungszeitstempel.
Praxistipp: Nutze den Explorer, um Zwischenergebnisse mehrerer Subagenten direkt miteinander zu vergleichen, bevor das Endprodukt abgenommen wird.

4.2 Berichte



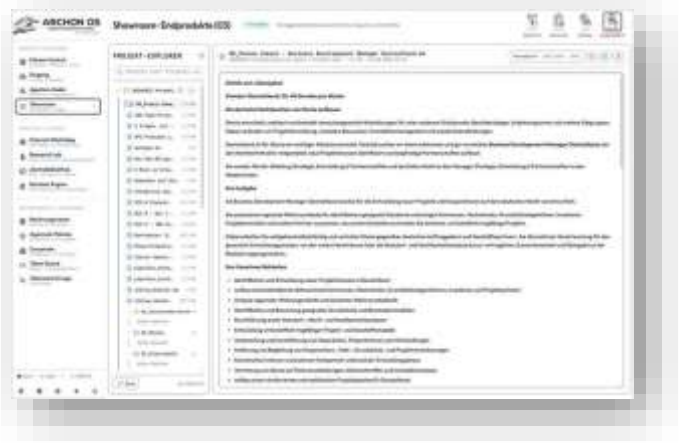
Sammlung ausgearbeiteter Analysedossiers, Entscheidungsvorlagen, Konzepte und Audit-Berichte.
Direktes Lesen im integrierten Markdown- und HTML-Viewer.
Strukturierte Management-Formate: Umfasst Boardroom-Memos, Marktanalysen, Due-Diligence-Dossiers und technische Audit-Protokolle mit sauberer Gliederung.
Export & Weiterverarbeitung: Berichte lassen sich als formatierte Druckansicht, PDF oder direkt in die Zentralbibliothek (RAG-Index) übernehmen.
Praxistipp: Ideal für die schnelle Sichtung fertiger Entscheidungsvorlagen, ohne im Dateisystem nach einzelnen Markdown-Dateien suchen zu müssen.

4.3 Medien



Galerie für generierte Architekturdiagramme (Mermaid), Grafiken, Mockups und Präsentationsfolien. Sofortvorschau ohne Wechsel in Drittprogramme.
Multimodale Artefakte: Bündelt generierte Präsentationen, UI-Mockups, Produktgrafiken und Architektur-Visualisierungen aus dem Agenten-Workspace.
Metadaten & Versionsvergleich: Blendet zu jeder Mediendatei den auslösenden Prompt, die Bildabmessungen und den erzeugenden Agenten ein.
Praxistipp: Prüfe generierte Grafiken und Diagramme vor der Einbindung in Angebote oder Handbücher direkt in der Vollbild-Vorschau.

4.4 Endprodukte



Abnahmebereite Lieferpakete, exportierbare PDF-Berichte und ausführbare Software-Prototypen.

4.4.1 Interaktive Code-Sandbox & Live-Artefakt-Vorschau

Der Showroom (views_core.py & static/views/view_showroom.html) enthält eine integrierte Code-Sandbox:

• Live-Ausführung (POST /api/views/showroom/run-code): Bei Anzeige von Python- oder Code-Dateien blendet der Viewer die Schaltfläche 'Sandbox Run' ein.

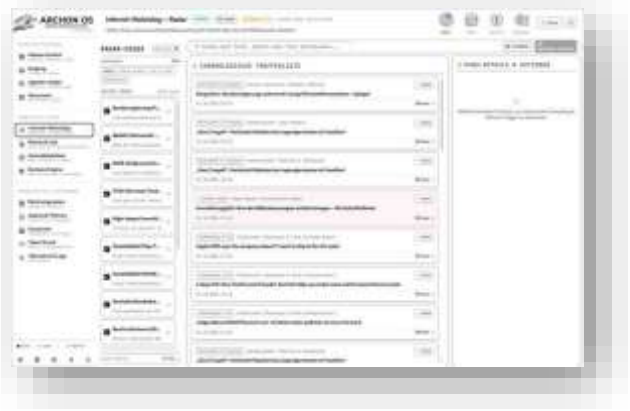
• Timeout-Wächter: Ein festes Zeitlimit von 12 Sekunden verhindert hängende Skripte und Endlosschleifen.

• Integrierte Terminal-Konsole: Unterhalb des Viewers öffnet sich automatisch eine Konsole mit Ausführungszeit in Millisekunden, Exit-Code und STDOUT/STDERR-Ausgabe.

5. Internet-Watchdog

Das Modul Internet-Watchdog überwacht kontinuierlich relevante Webquellen, Fachmedien, Wettbewerber und regulatorische Veröffentlichungen.

5.1 Radar



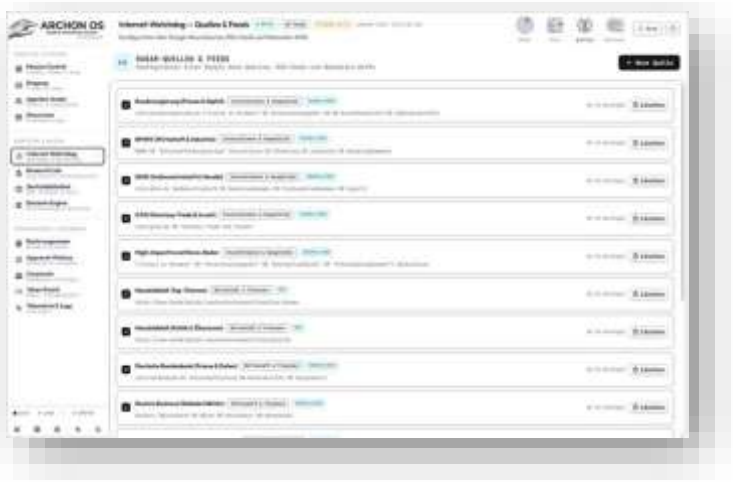
Chronologischer Echtzeit-Stream neu erkannter Artikel, Marktbewegungen und Gesetzesänderungen.
Semantische Relevanzbewertung anhand hinterlegter Suchprofile und Interessenfilter.
Signal-Priorisierung: Treffer werden automatisch nach Themenrelevanz, Neuheitsgrad und Dringlichkeit eingestuft, damit wichtige Meldungen oben stehen.
Direkt-Aktionen pro Meldung: Jede Karte bietet Schnellbuttons zum Vormerken im Korb, zur tiefgehenden Faktenprüfung im Research Lab oder zum Ausblenden.
Praxistipp: Kombiniere enge Stichwortprofile mit klaren Ausschlussbegriffen, um tägliches Grundrauschen im Radar-Feed gering zu halten.

5.2 Korb



Zwischenablage für markierte Web-Fundstücke und Artikel zur Sichtung.
Ein-Klick-Übergabe an das Research Lab zur Tiefenanalyse oder direkt in die Zentralbibliothek.
Kuratiertes Sammelbecken: Dient als Arbeitskorb für interessante Web-Fundstücke, bevor sie dauerhaft im Wissensspeicher landen.
Batch-Verarbeitung: Mehrere vorgemerkte Quellen lassen sich gebündelt an einen Research-Auftrag übergeben oder als Themen-Dossier zusammenfassen.
Praxistipp: Leere den Korb regelmäßig nach der Triage in Richtung Research Lab oder Zentralbibliothek, damit keine offenen Funde liegen bleiben.

5.3 Quellen



Verwaltung überwachter Domains, RSS-Feeds, APIs und Branchenportale.
Individuelle Festlegung von Abfrageintervallen und Prioritätsstufen.
Quellen-Gesundheitsstatus: Zeigt pro eingetragenem Feed oder Portal den Zeitpunkt des letzten erfolgreichen Abrufs, HTTP-Status und Trefferquote.
Kategorisierung & Tags: Ermöglicht die Gruppierung nach Branchen (z. B. Immobilien, KI-Regulierung, Wettbewerb, Steuerrecht) für gezielte Auswertungen.
Praxistipp: Deaktiviere vorübergehend fehlerhafte oder irrelevante Feeds statt sie zu löschen, um historische Referenzdaten zu erhalten.

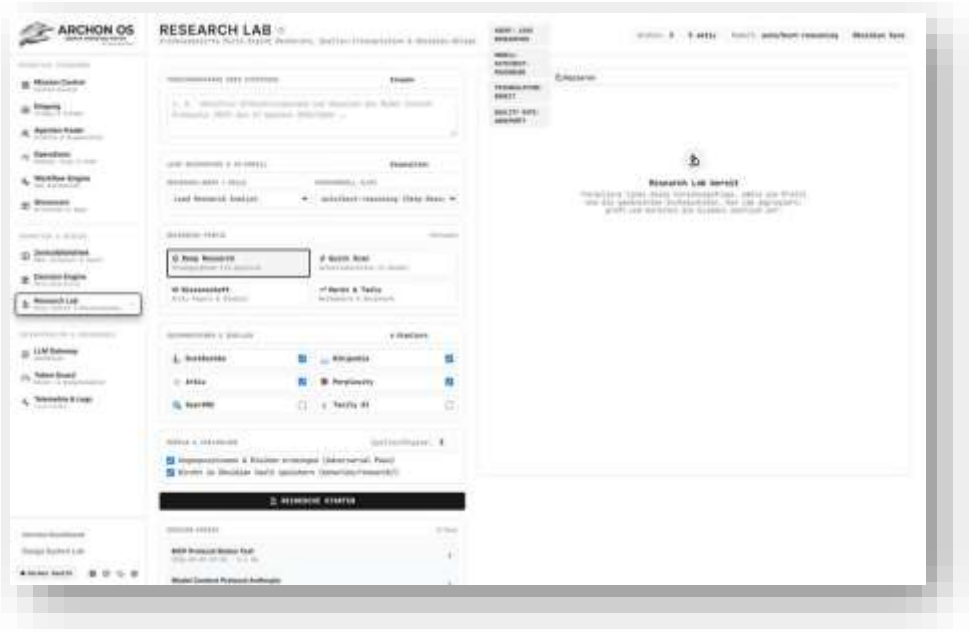
5.4 Optionen



Konfiguration der Crawler-Parameter, Headless-Browser-Optionen (Playwright) und Rate-Limits.
Schwellenwerte für automatische Benachrichtigungen bei kritischen Treffern.
Zeitplanung & Drosselung: Definiert Abfragefenster, maximale Parallelität und Höchstzahl neuer Treffer pro Lauf zum Schutz vor Rate-Limits.
Benachrichtigungs-Schwellen: Legt fest, ab welchem Relevanz-Score ein Fund aktiv in den Posteingang oder per Alert gemeldet wird.
Praxistipp: Nutze konservative Abfrageintervalle für klassische RSS-Feeds und reserviere Playwright-Headless-Crawls für dynamische Portale.

6. Research Lab

Evidenzbasierte Recherche, Quellen-Triangulation & Synthese-Berichte



Kernkonzept & Architektur:

Das Research Lab ist das wissenschaftliche Forschungszentrum deines Unternehmens. Wenn komplexe Fragen auftauchen, die nicht allein aus dem internen Wissensbestand beantwortet werden können, wird das Research Lab aktiv. Es steuert mehrstufige Suchprozesse, vergleicht divergierende Quellen (Triangulation), filtert Desinformation heraus und destilliert die Ergebnisse in saubere Berichte mit vollständigem Quellennachweis.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Recherche-Auftragsmaske: Hier formulierst du die Forschungsfrage, bestimmst die Suchtiefe (Oberflächlich, Standard, Deep Research) und wählst Zieldomänen.
Quellen-Monitor & Evidenz-Score: Zeigt gescannte Webseiten, PDF-Dokumente und Fachportale inklusive eines Vertrauenswürdigkeits-Index an.
Live-Synthese Protokoll: Dokumentiert Schritt für Schritt, wie Hypothesen geprüft, Teilergebnisse verifiziert und Gegenevidenzen abgewogen werden.
Dossier-Export (Markdown / PDF): Überträgt das fertige Recherche-Dossier mit einem Klick in den Showroom und in die Zentralbibliothek.

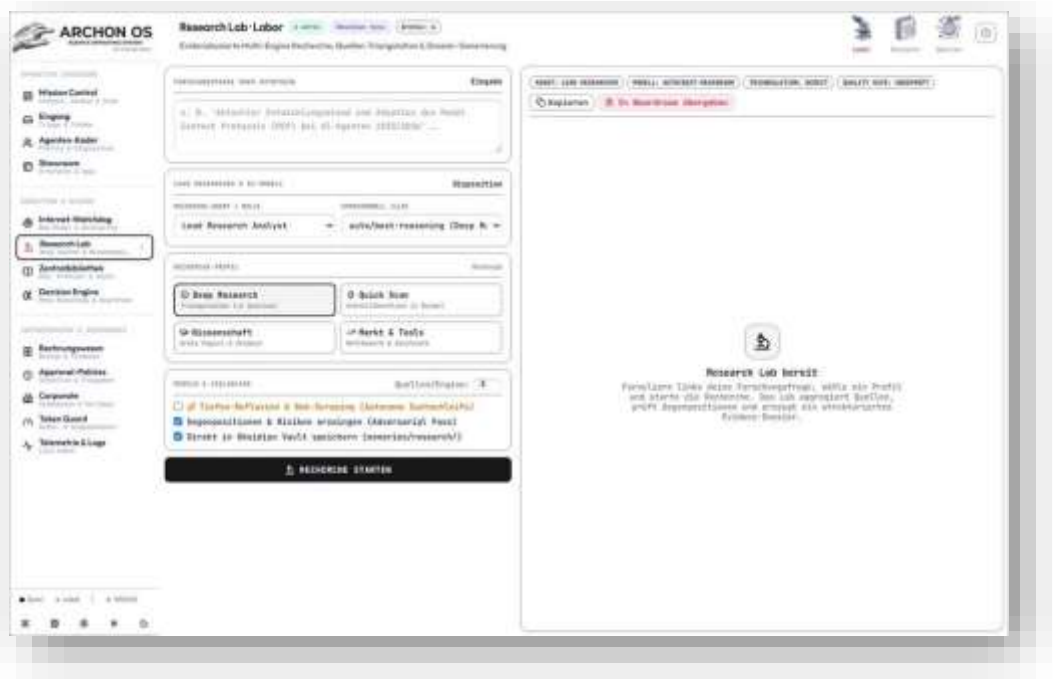
Praxis-Workflow (Schritt für Schritt):

1. Formuliere eine präzise Recherchefrage (z. B. 'Aktuelle Fördermittel für Modulbauweise in NRW 2026').
2. Wähle die Suchtiefe 'Deep Research' und starte den Lauf.
3. Verfolge im Live-Protokoll, wie der Recherche-Agent Quellen filtert und Kernzitate extrahiert.
4. Lies das fertige Synthese-Dossier gegen und exportiere es in den Obsidian-Vault deines Zentralbibliothek.

[Tipp] Praxistipp & Leitplanke: Formuliere Forschungsfragen möglichst spezifisch mit Randbedingungen (z. B. Region, Jahr, Branche). Das spart Token-Kosten und liefert hochgradig verwertbare Handlungsempfehlungen.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich: *"Starte einen Research-Lauf zum Thema 'Bauordnung NRW Novelle 2026: Wesentliche Änderungen für Genehmigungsverfahren'."*

6.1 Labor



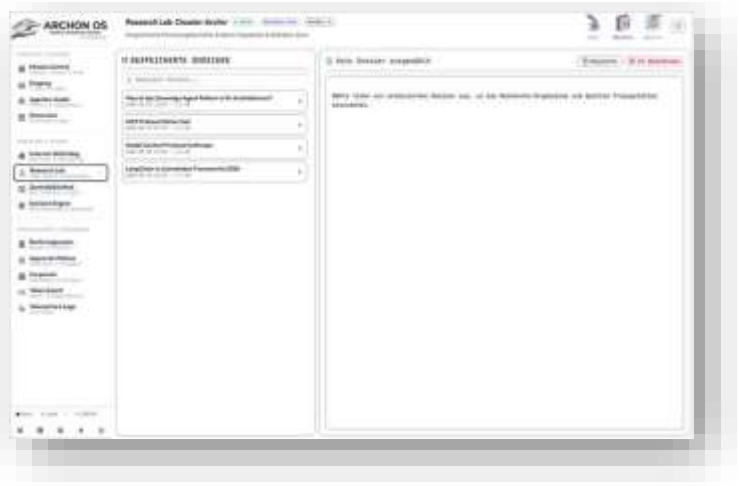
Startpunkt für mehrstufige Tiefenrecherchen mit einstellbarer Suchtiefe und Domänenfokus. Echtzeit-Verfolgung der Agenten-Suchschritte, Hypothesenbildung und Faktenextraktion.

6.1.1 Mehrstufige Reflexions-Schleife (Deep Research v2)

Das Research Lab (backend/research_engine.py) führt mehrstufige wissenschaftliche und marktwirtschaftliche Analysen durch:

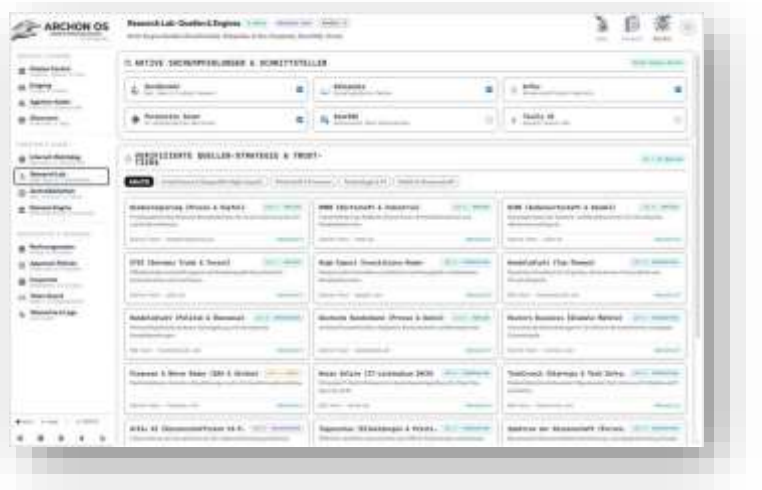
- Re-Search Loop: Zerlegt komplexe Aufgabenstellungen in 3–5 Teilfragen, bewertet Lücken und startet autonom bis zu 3 Nachfolge-Suchläufe.
- Fallback-Kaskade: Primärsuche über Grokipedia und SearXNG mit automatischem Fallback auf Jina Reader API bei Bot-Sperren.
- SSRF-Schutz: Sicherheitsfilter blockieren Zugriffe auf interne Netzwerke (RFC 1918) und Cloud-Metadaten-Endpunkte.
- Vault-Ablage: Recherche-Dossiers werden direkt in data/obsidian_vault/02_Wissensbibliothek/ strukturiert archiviert.

6.2 Dossiers



Strukturierte Ergebnisberichte mit Executive Summary, Pro-/Contra-Abwägung und vollständigem Fußnotenapparat.
Direkter Export in den Obsidian Vault oder als Entscheidungsvorlage für die Decision Engine.
Quellenbelegte Synthese: Jedes Dossier verknüpft Kernaussagen direkt mit den herangezogenen Web-URLs und internen Dokumenten für maximale Nachprüfbarkeit.
Status-Tracking: Zeigt den Fortschritt mehrstufiger Recherchen (Entwurf, Faktenprüfung, Abgeschlossen) inklusive beteiligter Research-Agenten.
Praxistipp: Übergib fertige Dossiers per Klick direkt an den AI-Boardroom, um strategische Entscheidungen auf geprüften Fakten aufzubauen.

6.3 Quellen



Verzeichnis aller herangezogenen Primär- und Sekundärquellen inklusive Vertrauenswürdigkeits-Bewertung.
Automatische Kennzeichnung widersprüchlicher Aussagen zwischen verschiedenen Quellen.
Vertrauens- & Aktualitätsprüfung: Bewertet herangezogene Primär- und Sekundärquellen nach Domain-Autorität, Veröffentlichungsdatum und Vollständigkeit.
Wiederverwendung im Wissen-Graph: Geprüfte Quellen lassen sich dauerhaft in den RAG-Index der Zentralbibliothek übernehmen.
Praxistipp: Prüfe bei widersprüchlichen Zahlen in einem Dossier direkt hier die zugrunde liegenden Original-Auszüge.

7. Zentralbibliothek

RAG-Index (AnythingLLM), Dokumenten-Erfasser (Auto-OCR) & Obsidian-Vault



Kernkonzept & Architektur:

Die Zentralbibliothek ist das kollektive Gedächtnis deiner Organisation. Sie vereint semantische Vektorsuche (RAG), automatisierte Dokumenten-Ingestion mit OCR und die Verwaltung deines lokalen Obsidian-Vaults unter einer konsistenten Oberfläche. Hier abgelegtes Wissen steht allen 56 Agenten sofort für fundierte Antworten zur Verfügung.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Drei integrierte Sub-Tabs (Header): RAG Index, Dokumenten-Erfasser und Obsidian Vault.
Hilfe- & Sync-Schalter: Kontext-Hilfe und manuelle Synchronisation des Dokumentenbestands.

Detaillierte Analyse der Unterbereiche & Funktionen:

7.1 RAG Index



Eingebettete Schnittstelle zu AnythingLLM für semantische Vektorsuche und Grounded Retrieval. Dokumente werden in Vektoren übersetzt; Agenten rufen exakte Textstellen passend zu Benutzerfragen ab.

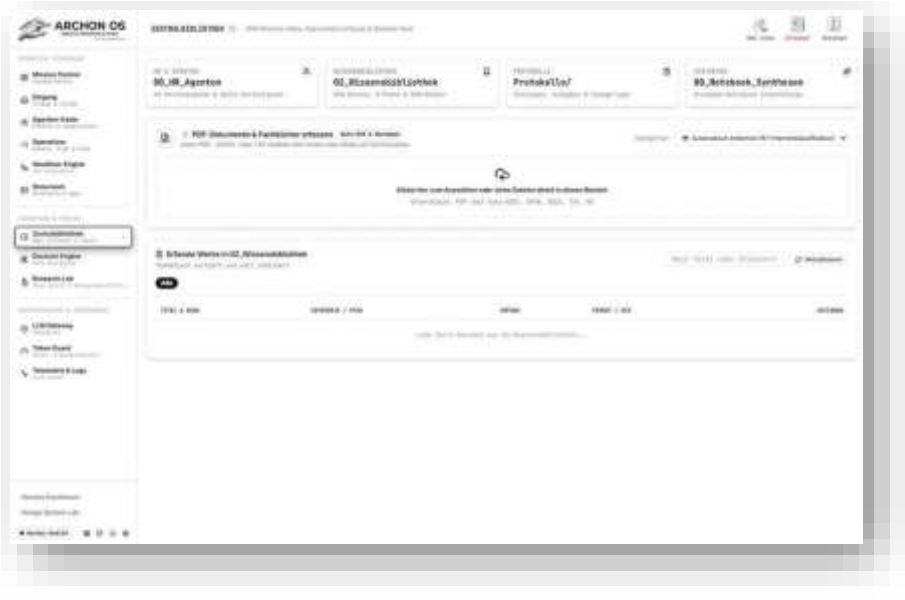
Workspace-Verwaltung:
Strukturierung des Wissens nach Projekten oder Firmenbereichen.
Vektordatenbank-Status:
Überwachung der indizierten Dokumentenfragmente und Embedding-Modelle.

Arbeitsablauf:

1. Wähle den gewünschten Workspace aus.
2. Teste semantische Abfragen direkt im Chat-Interface von AnythingLLM.

Praxistipp: Halte Workspaces thematisch getrennt, um die Treffergenauigkeit bei Fachfragen zu maximieren.

7.2 Erfasser



Der zentrale Upload-Trichter für neue Fachliteratur, Pläne, Verträge und Gutachten. PDF-, DOCX- und Textdateien werden per Drag & Drop hochgeladen, durch den Docling-Dienst per Auto-OCR in sauberes Markdown konvertiert und vollautomatisch im Obsidian-Vault sowie im RAG-Index abgelegt.

4 Core Hubs:
00_HR_Agenten, 02_Wissensbibliothek, Protokolle/, 00_Notebook_Synthesen.
Upload-Dropzone:
Zieht Dateien per Drag & Drop hinein; automatische Themenklassifikation wählbar.
Tabelle der Werke:
Übersicht aller erfassten Dokumente mit Volltextsuche, Kategorie-Filtern und OCR-Status.

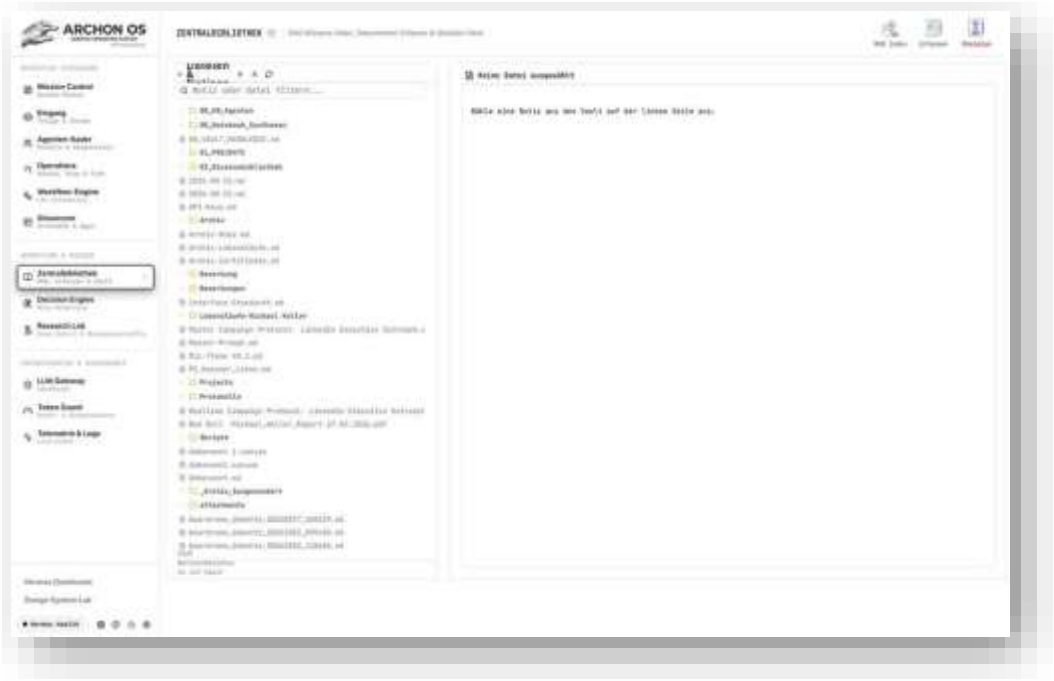
Arbeitsablauf:

1. Ziehe ein PDF (z. B. ein 80-seitiges Gutachten) in die Dropzone.
2. Wähle eine Kategorie oder nutze 'Automatisch erkennen'.
3. Klicke auf 'Jetzt erfassen & in Vault einlesen'. Der Fortschrittsbalken visualisiert den OCR-Lauf.
4. Das Werk erscheint sofort in der Tabelle und steht allen Agenten zur Verfügung.

Praxistipp: Dank Auto-OCR werden auch gescannte Dokumente und Tabellen zuverlässig in durchsuchbares Markdown übersetzt.

Docling & Unstructured Tabellen-Extraktion (t-539b65): Komplexe PDF-Tabellen, Bilanzen und mehrspaltige Verträge werden verlustfrei in saubere GitHub-Flavored Markdown-Tabellen überführt.

7.3 Obsidian



Direkter Einblick in deinen physischen Obsidian-Ordner auf der Festplatte. Erlaubt das Durchsuchen, Filtern und Lesen aller Markdown-Notizen und Protokolle direkt im Browser.

Dateibaum (Linke Spalte): Hierarchische Ordneransicht aller Notizen mit Schnellfilter und Auf-/Zuklapp-Buttons.
Markdown-Viewer (Rechte Spalte): Formatierte Leseansicht der ausgewählten Notiz mit Pfadanzeige.

Arbeitsablauf:

1. Nutze die Suchleiste über dem Dateibaum, um eine Notiz nach Stichworten zu filtern.
2. Klicke auf eine Datei, um ihren Inhalt sofort im rechten Viewer zu lesen.

Praxistipp: Alle hier sichtbaren Notizen liegen als Standard-Dateien auf deiner Festplatte – du kannst sie jederzeit mit externen Editoren öffnen.

Praxis-Workflow (Schritt für Schritt):

1. Lade neue Fachdokumente im Dokumenten-Erfasser per Drag & Drop hoch.
2. Verfolge die automatische OCR-Umwandlung und Vektor-Indizierung.
3. Kontrolliere im Obsidian Vault, ob die Markdown-Datei sauber abgelegt wurde.
4. Deine Agenten nutzen dieses Wissen ab sofort vollautomatisch bei der Beantwortung von Aufgaben.

[Tipp] Praxistipp & Leitplanke: Pflege Fachliteratur strukturiert in den passenden Kategorien ein. So bleibt die Vektor-Suche schnell und hochpräzise.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Welche Fachbücher sind aktuell in '02_Wissensbibliothek' erfasst und wie viele Dokumente enthält der RAG-Index?"

8. Decision Engine

Strategische Gremiensitzungen: 3-Tab-Architektur (Übersicht, Debatte, Live-Debatte), 75/25-Split & OpenRouter Live-Pricing ($)



Kernkonzept & Architektur:

Das AI-Boardroom & Boardroom Studio simuliert hochkarätige Management-, Strategieberatungs- und Gremiensitzungen direkt im Herzen des Betriebssystems. In der Version 0.3.3 wurde das Modul grundlegend auf eine modulare 3-Tab-Architektur (Übersicht, Debatte, Live-Debatte) umgestellt. Statt eine komplexe strategische Weichenstellung einem einzelnen Sprachmodell zu überlassen, erzwingt das Boardroom Studio eine multiperspektivische Debatte: Ein designierter Chairman leitet die Sitzung entlang fundierter Frameworks, während nummerierte Fachagenten-Slots konkrete Analyse-Perspektiven einnehmen. Ein integrierter Red-Team-Challenger unterzieht alle Entwürfe einem ungeschönten Stresstest auf blinde Flecken, bevor der Chairman das verbindliche Board-Memo synthetisiert.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

3-Tab-Architektur (Übersicht, Debatte, Live-Debatte): Der Reiter 'Übersicht' archiviert alle bisherigen Sitzungen in einer durchsuchbaren Historie mit Detail-Popup (Aufgabenstellung & Synthese-Konsens) und Direkt-Sprung ins Transkript. Der Reiter 'Debatte' bildet die ergonomische Arbeitswerkbank im 75/25-Layout. Der Reiter 'Live-Debatte' öffnet sich beim Start als fokussierter Streaming-Dialog zur Echtzeit-Beobachtung des Argumentationsaustauschs.
Ergonomisches 75/25-Arbeitslayout & Datei-Anhänge: Die linke Spalte (75% Breite) teilt sich 50/50 in die Methodik-Auswahl (34 Frameworks in 7 Kategorien) und die Aufgabenstellung inklusive Datei-Upload für bis zu 5 begleitende Dokumente (PDFs, Bilanzen, Gutachten). Die rechte Spalte (25% Breite, 100% Höhe) bündelt den Chairman und die nummerierten Experten-Slots.
Präzise Steuerungsleiste & Reset-Logik: Ausgestattet mit einem markanten weißen Start-Button (2px schwarzer Rand, mittlerer Schatten), einem separaten roten Stopp-Button ohne Symbol, kompakter 2-zeiliger Runden- und Reasoning-Auswahl sowie einem 'Standard-Slots wiederherstellen'-Reset-Button, der die Idealbesetzung des gewählten Frameworks sekundenschnell lädt.
OpenRouter Live-Preiskatalog ($) & Latenz-Puffer: Ein dezentes Dollar-Icon ($) neben jedem Provider-Dropdown öffnet ein modales Fenster mit tagesaktuellen Tokenpreisen (Input/Output pro 1M), Kontextfenster-Größen und 1-Klick-Übernahme. Ein 1-Stunden-RAM-Puffer im Backend (/api/llm-providers/prices) garantiert blitzschnelle Ladezeiten unter 2 ms.
CLI-Trigger & Autonome Boardroom-Engine: Über 'scripts/trigger_boardroom_debate.py' können Sitzungen auch vollständig autonom per Terminal, Cron-Job oder über Hintergrund-Agenten (Robert, Micha, Default via

Command 4 in AGENTS.md) angestoßen und automatisch im Obsidian Vault (00_Notebook_Synthesen/) sowie in der API-Historie (/api/boardroom/history) archiviert werden.

Tabelle: Ausgewählte Leit-Frameworks im AI-Boardroom Studio

Framework & Kategorie	Chairman & Ideal-Slots	Methodischer Ablauf & Denkweise
CLEAR-Modell (Agile & Innovation)	Robert (CEO) + Architekt + Fullstack + Red Team	Concise (Prägnanz) -> Logical (Kausalität) -> Explicit -> Adaptive -> Reflective.
Design Sprint (GV / Jake Knapp)	Product Manager + UI/UX + Fullstack + Customer Success	Map (Kartieren) -> Sketch (Skizzieren) -> Decide -> Prototype -> Validate.
Lean Startup (Eric Ries)	GTM-Stratege + Fullstack + DB-Tuner + Robert	Hypothese formulieren -> Kleinstmögliches MVP bauen -> Messen -> Pivot oder Persevere.
Pre-Mortem Analysis (Risiko)	Executive Decision Architect + Risk + Legal + Red Team	Annahme des totalen Scheiterns in 12 Monaten; rückwärtige Rekonstruktion aller Ursachen.
Blue Ocean Strategy	GTM Launch Stratege + Pricing + Competitor Scout	Eliminieren -> Reduzieren -> Steigern -> Kreieren neuer unumkämpfter Markträume.

Praxis-Workflow (Schritt für Schritt):

1. Wähle im Reiter 'Debatte' links oben das passende Framework (z. B. 'Pre-Mortem Analysis' oder 'First Principles').
2. Formuliere links unten die Aufgabenstellung und hänge bei Bedarf bis zu 5 relevante Dokumente per Drag & Drop an.
3. Kontrolliere rechts Chairman und Slots; prüfe über das Dollar-Icon ($) bei Bedarf die günstigsten Modell-Routen.
4. Klicke auf 'Debatte starten' – der modulare Live-Stream öffnet sich und visualisiert Thesen und Gegengutachten.
5. Begutachte die Synthese im Abschluss-Memo oder rufe die Sitzung später jederzeit über den Reiter 'Übersicht' auf.

[Tipp] Praxistipp & Leitplanke: Nutze vor komplexen Sitzungen den 'Standard-Slots'-Button, wenn du zuvor Profile manuell verstellt hattest. Das System lädt daraufhin exakt die für dieses Framework optimal ausbalancierte Expertenkombination. Für automatisierte Nacht- oder Cron-Debatten empfiehlt sich der CLI-Befehl via 'python scripts/trigger_boardroom_debate.py'.

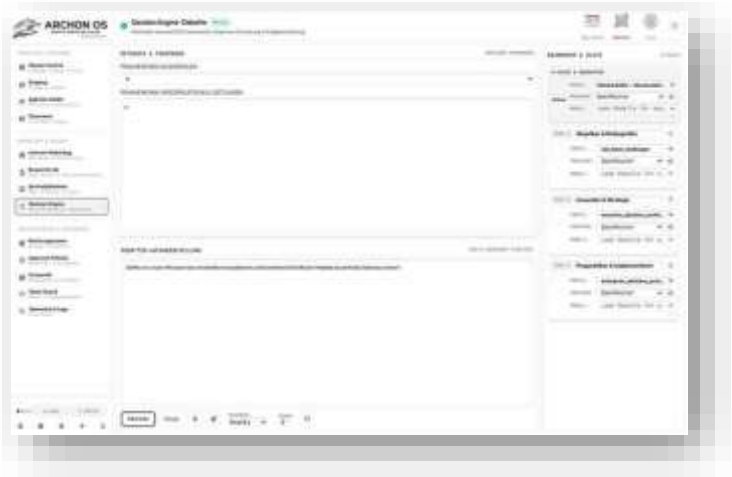
[Prompt] Beispiel-Befehle / Prompts an den Assistenten für diesen Bereich:
• UI / Chat: "Starte eine AI-Mastermind-Sitzung mit dem Framework 'Pre-Mortem Analysis': 'Wir stellen alle Verträge auf Vorauskasse um. Warum könnte dieser Schritt scheitern?'"
• Terminal / CLI: python scripts/trigger_boardroom_debate.py --task "Bewertung Buy vs Build für RAG-Infrastruktur" --framework "First Principles Thinking" --budget balanced --rounds 2

8.1 Übersicht



Revisionssicheres Archiv aller durchgeführten Boardroom-Debatten, Risikoanalysen und Vorstandsbeschlüsse. Schnellzugriff auf historische Entscheidungsgründe und verworfene Handlungsalternativen.
Entscheidungs-Historie & Vergleich: Zeigt zu jeder Boardroom-Sitzung das gewählte Framework, die beteiligten C-Level-Rollen, Kosten und das finale Votum.
Dissens-Protokollierung: Bewusst dokumentierte Gegenargumente und Risiken bleiben auch nach Beschlussfassung sichtbar und auswertbar.
Praxistipp: Nutze alte Beschlüsse bei wiederkehrenden Budget- oder Strategiefragen als Referenz, um Doppelanalysen zu vermeiden.

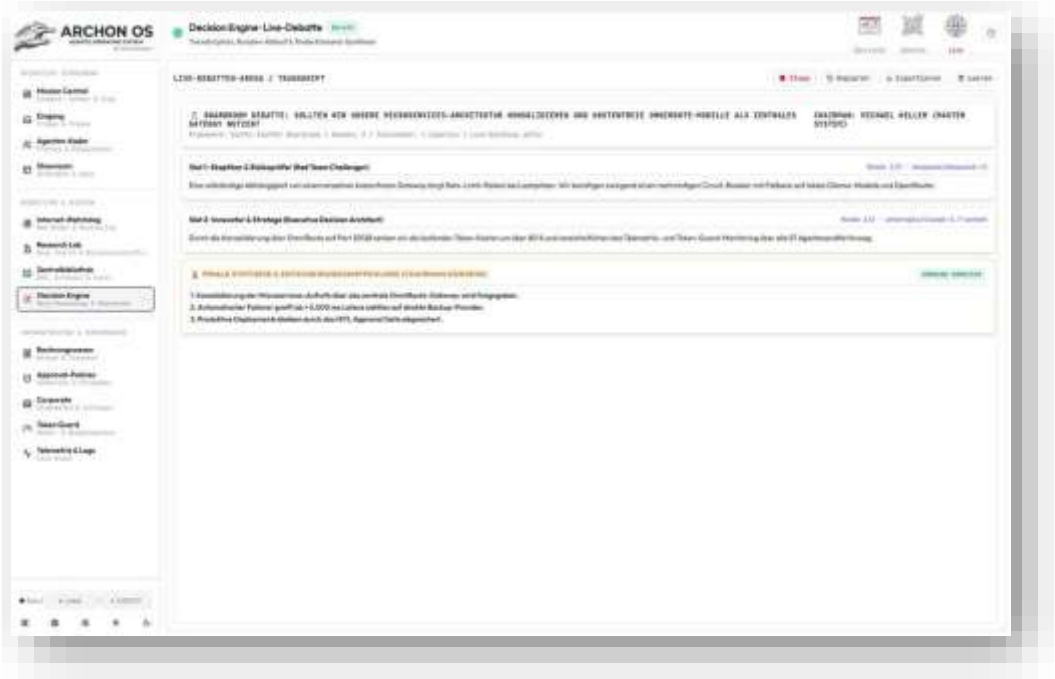
8.2 Debatte



Konfiguration neuer Gremiensitzungen: Auswahl aus 55 Denk-Frameworks (siehe Begleitdokument ARCHON_OS_BOARDROOM_FRAMEWORKS_2026.pdf bzw. Kap. 17.6 Methodiken), Besetzung der C-Level-Rollen und Budgetvorgabe.
Möglichkeit zur Einbindung interner Dokumente und Dossiers als Faktenbasis.
Framework- & Budgetwahl: Unterstützt verschiedene Tiefenstufen (Free, Cheap, Balanced, Premium), um Modellkosten passend zur Tragweite der Entscheidung zu steuern.
Kontext-Anreicherung: Bestehende Projekte, CRM-Daten oder Dossiers aus der Zentralbibliothek können der Debatte direkt als Pflichtlektüre mitgegeben werden.

Praxistipp: Wähle für kritische Investitions- oder Rechtsfragen explizit ein kontroverses Framework (z. B. Pre-Mortem oder Red-Team-Challenge).

8.3 Live



Echtzeit-Verfolgung der mehrstufigen Kontroverse (Thesen, Kreuzverhör, Red-Team-Kritik und Synthese durch den Chairman).
Direkte Überführung der beschlossenen Maßnahmen in ausführbare Kanban-Aufgaben.
Phasenweiser Live-Fortschritt: Visualisiert die sechs Deliberationsphasen von der Eröffnungsthese über isolierte Einzelgutachten bis zur Chairman-Synthese.
Interaktive Maßnahmenerstellung: Abgestimmte Handlungsempfehlungen lassen sich nach Sitzungsende direkt als priorisierte Tasks ins Kanban-Board übernehmen.
Praxistipp: Verfolge im Live-Stream gezielt die Phase der Kritik-Prüfung, um blinde Flecken frühzeitig zu erkennen.

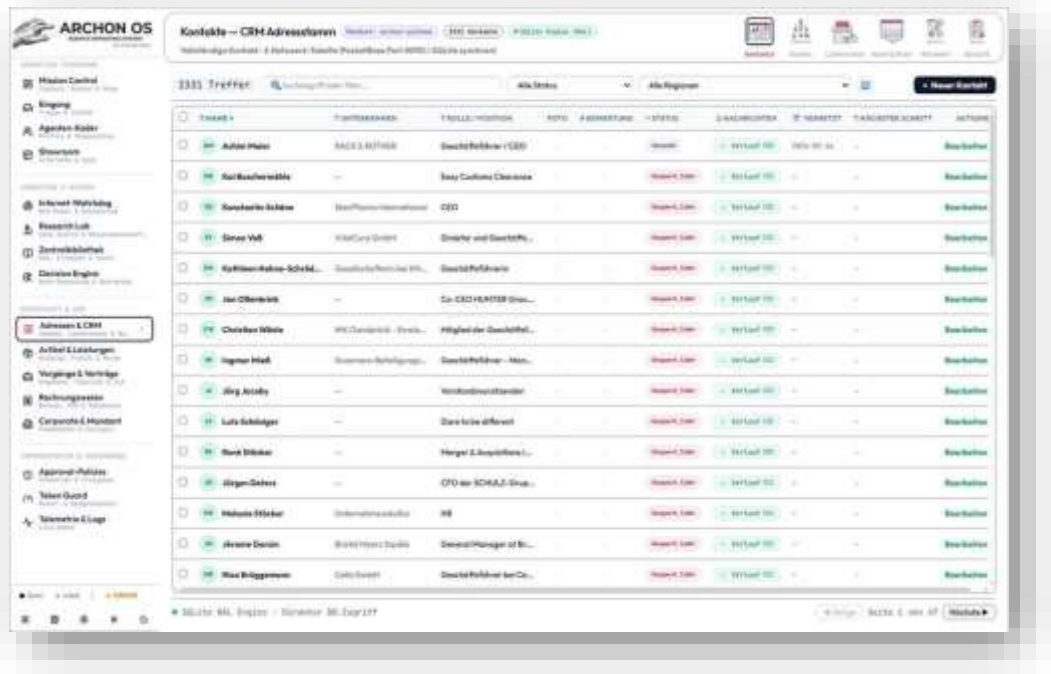
Vertiefender Leitfaden: Zur technischen Echtzeit-Übertragung siehe Markdown-Systemdokumentation (docs/system/LIVE_STREAMING_SSE_WEBSOCKET_GUIDE.md).

9. Adressen & CRM (Säule 3: Wirtschaft & ERP)

Das Modul Adressen & CRM bildet den Einstiegspunkt der dritten System-Säule (Wirtschaft & ERP). Es vereint ein vollwertiges B2B-CRM (LinkedIn-Netzwerk, E-Mail-Chronik, 360°-KI-Dossiers) mit der buchhalterischen Stammdatenpflege für Kunden (Debitoren 10000+) und Lieferanten (Kreditoren 70000+). Gemäß DSGVO und GoBD speichert Archon OS sämtliche ERP-Daten physisch getrennt je Mandant in einer eigenen SQLite-WAL-Datenbank unter data/tenants/{company_id}/erp.db.

Vertiefender Leitfaden: Zur vollständigen Datenbank- und Belegketten-Architektur siehe Markdown-Systemdokumentation (docs/system/ARCHON_ERP_ARCHITECTURE_SPEC.md).

9.1 Kontakte (Haupttabelle & CRM-Adressstamm)



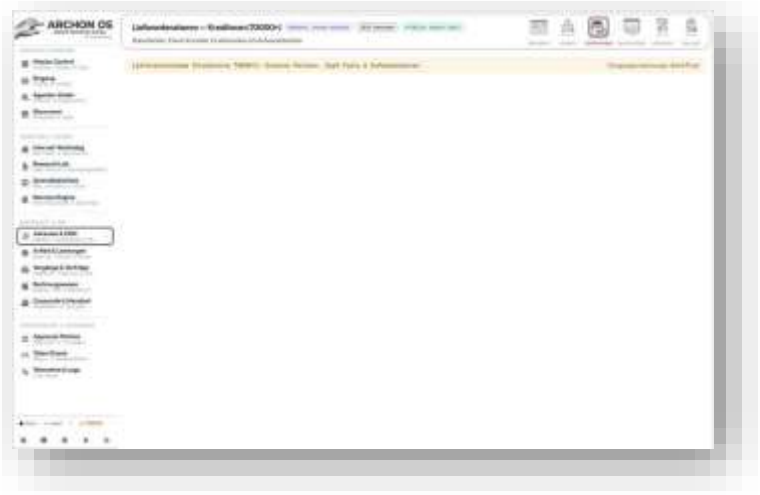
Vollständige CRM-Tabelle über alle 2.331 Kontakte mit Name, Firma, Position, Rating-Sternen, Status-Pills und Interaktions-Badges.
Zweizeiliger Schnellfilter (Volltextsuche nach Name, Firma, Ort oder Nummer sowie Direkt-Sync mit PocketBase Port 8090).
Performante Paginierung (50 Kontakte pro Seite) mit Checkbox-Stapelverarbeitung und Ein-Klick-Öffnen der Datensatzansicht.

9.2 Kundenstamm (Debitoren 10000+)



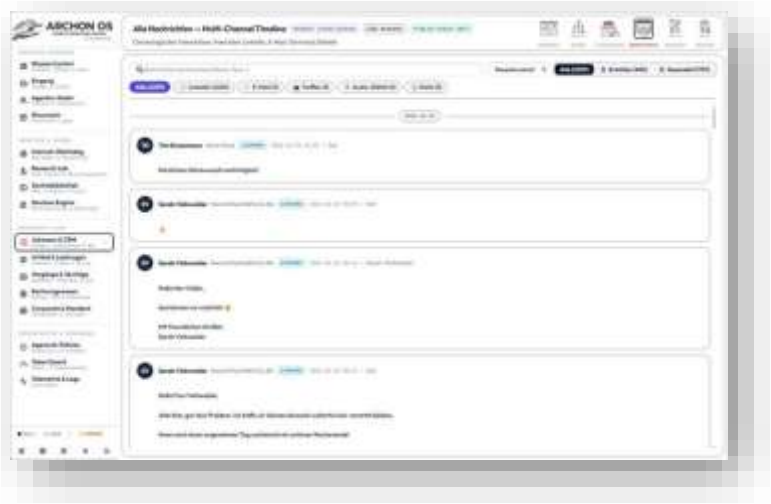
Kunden- und Mandantenverzeichnis mit automatischer Vergabe fortlaufender Debitorennummern im Nummernkreis 10000–69999.
Pflege von Zahlungszielen (Netto-Tage), Skonto-Konditionen, Umsatzsteuer-ID, Kreditlimit und verknüpften Ausgangsrechnungen.
Debitoren-Kennzahlen auf einen Blick: Listet aktive Kundenkonten ab Nummer 10000 inklusive offener Angebote, laufender Verträge und Umsatzvolumen.
Schnellfilter & Segmentierung: Filtert nach Kundenstatus, Branche, Ansprechpartner oder offenem Mahnstatus.
Praxistipp: Ein Klick auf einen Kundeneintrag öffnet die komplette 360°-Akte inklusive verknüpfter Vorgänge und Belege.

9.3 Lieferantenstamm (Kreditoren 70000+)



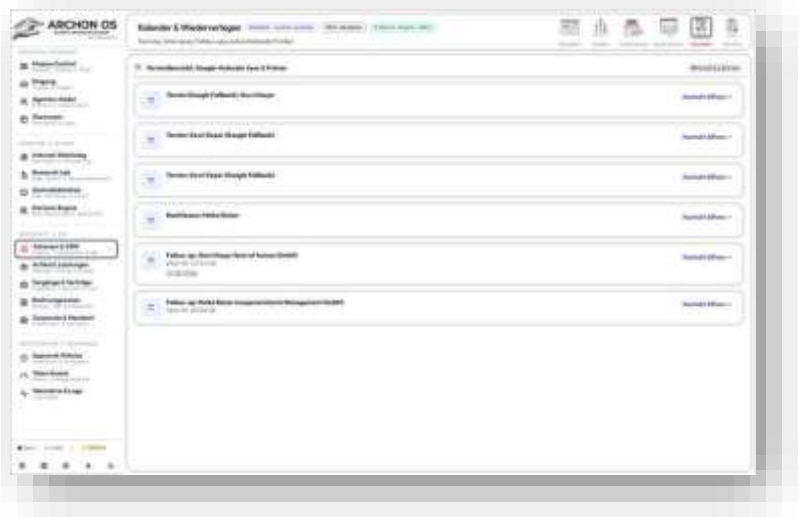
Lieferanten-, Dienstleister- und Cloud-Provider-Stamm im DATEV-konformen Kreditoren-Nummernkreis ab 70000.
Hinterlegung von IBAN/BIC, Eingangsrechnungs-Workflows, Standard-Aufwandskonten und verknüpften Einkaufsartikeln.
Kreditoren-Verwaltung (70000+): Bündelt Dienstleister, Software-Anbieter und Subunternehmer inklusive Zahlungszielen und hinterlegten Bank-/Steuerdaten.
Eingangsbeleg-Verknüpfung: Ordnet per OCR erfasste Eingangsrechnungen und laufende Kosten direkt dem passenden Lieferantenkonto zu.
Praxistipp: Pflege hier die Standard-Zahlungsbedingungen, damit das Rechnungswesen Fälligkeiten automatisch korrekt berechnet.

9.4 Alle Nachrichten (Multi-Channel Timeline)



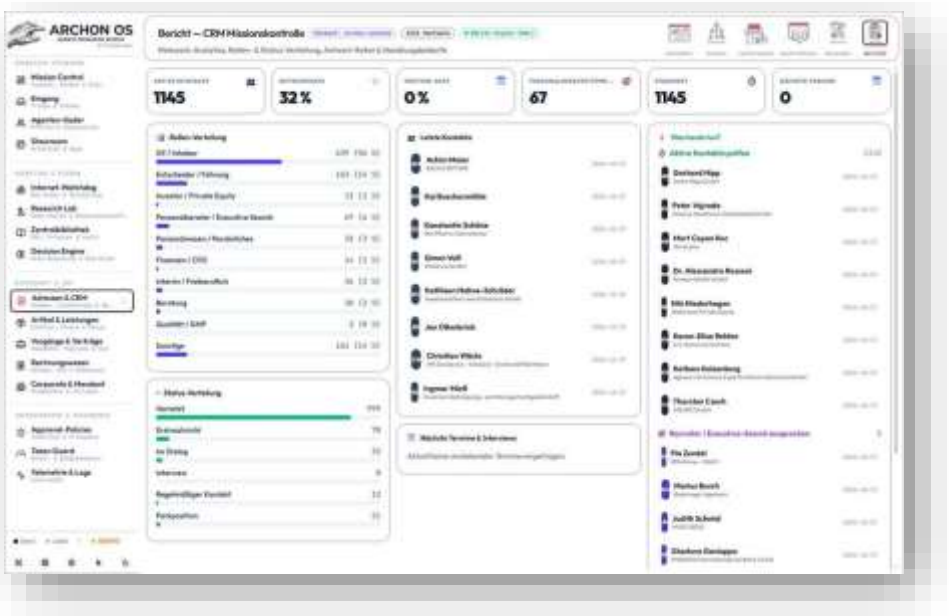
Aggregierter chronologischer Feed über alle 2.229 Nachrichten und Interaktionsverläufe über alle Kontakte hinweg.
Kanalfilter für LinkedIn (2.220), E-Mail (3), Persönliche Treffen (3), Audio-Diktate und Notizen (3) sowie Richtungsfilter (Erhalten / Gesendet).
Volltext-Expansion auf Knopfdruck zur vollständigen Nachverfolgung jedes Dialogverlaufs mit Zeitstempel.

9.5 Kalender & Wiedervorlagen



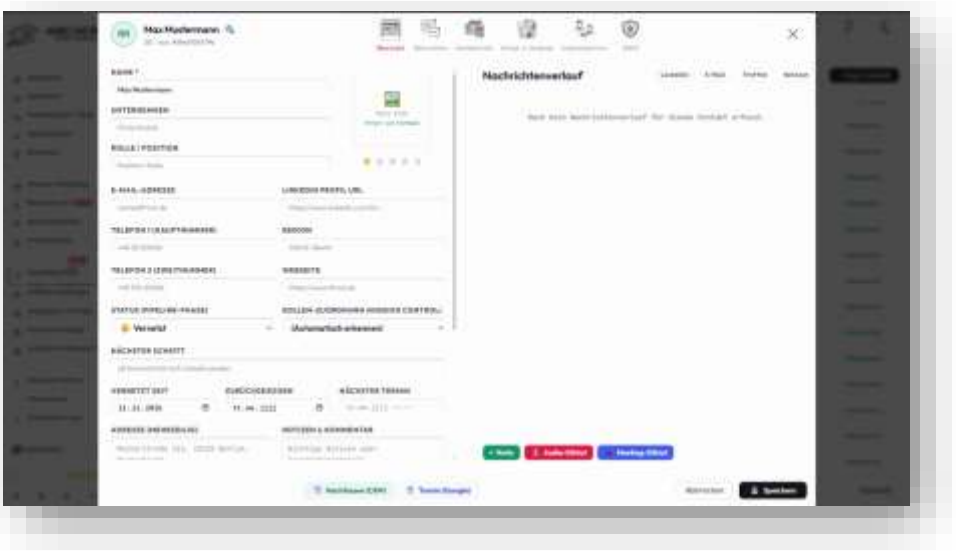
Kalendarische Übersicht aller geplanten Termine, Kontakt-Wiedervorlagen und anstehenden Check-ins.
Automatische Kennzeichnung dringlicher oder überfälliger Follow-ups zur Vermeidung von Kontaktstagnation.
Wiedervorlagen & Fristen: Sammelt alle vertrieblichen Follow-ups, Angebots-Gültigkeiten und Vertragskündigungsfristen auf einer Zeitachse.
Verantwortlichkeiten: Weist Termine einem menschlichen Betreiber oder einem betreuenden Vertriebs-Agenten zur Erinnerung zu.
Praxistipp: Prüfe die Wochenansicht zu Beginn jedes Arbeitstages, um keine offenen Angebots-Nachfassaktionen zu verpassen.

9.6 Bericht (CRM-Missionskontrolle & KPI-Analyse)



Echtzeit-KPI-Karten: Aktive Kontakte (1.145), Antwortrate (32 %), Meeting-Rate (0 %), Personalberater (67) und stagnierte Kontakte.
Rollenverteilungs-Diagramme: Automatische Klassifizierung in Geschäftsführer / Inhaber, Entscheider, Investoren, Beratung und Finanzen.
Statusverteilung der Pipeline-Phasen sowie täglicher Handlungsradar ('Was heute tun?') für proaktives Kontaktmanagement.

9.7 Datensatzansicht & Kontakt-Drawer (Enterprise ERP-Standard & 360°-Akte)

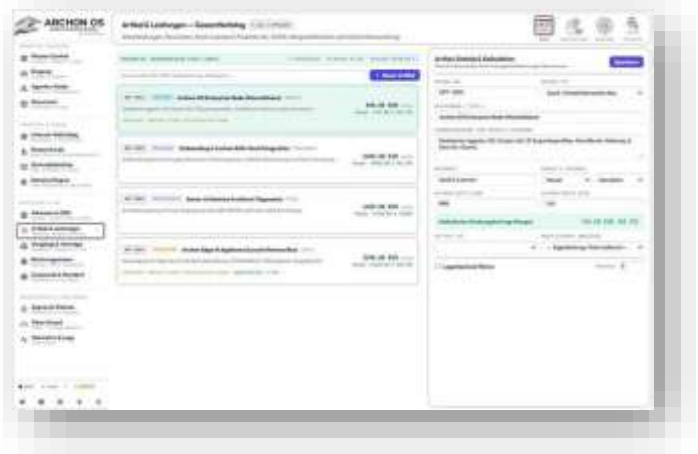


80-Pixel-Kopfleiste mit 6 VARIO-Teilansichten: Übersicht, Nachrichten, Kaufmännisch, Belege & Vorgänge, Ansprechpartner & Filialen sowie DSGVO & Compliance.
Ergonomische Fenstersteuerung: Schließen über den abgedunkelten Hintergrund (Backdrop-Klick), die Escape-Taste oder das markante Schließen-Kreuz (x) oben rechts.
Kaufmännische VARIO-Stammdaten: Debitor- (10000+) und Kreditor-Nummern (70000+), Zahlungsziele, Skonto-Sätze, Kreditlimite, Preisgruppen, Bankdaten (IBAN, BIC) und USt-IdNr.
Integrierter DIN-5008 Belegfluss: Direktes Einsehen und Drucken von Angeboten (ANG) und Aufträgen (AB) mit Firmenbriefkopf und USt-Ausweis über 1-Klick-Aktionen.
DSGVO & Compliance: 1-Klick-Datenexport als strukturiertes JSON (Art. 15/20 DSGVO) sowie rechtssichere unwiderrufliche Anonymisierung (Art. 17 DSGVO) bei voller Wahrung der GoBD-Buchhaltungsintegrität.

10. Artikel & Leistungen (Säule 3: Wirtschaft & ERP)

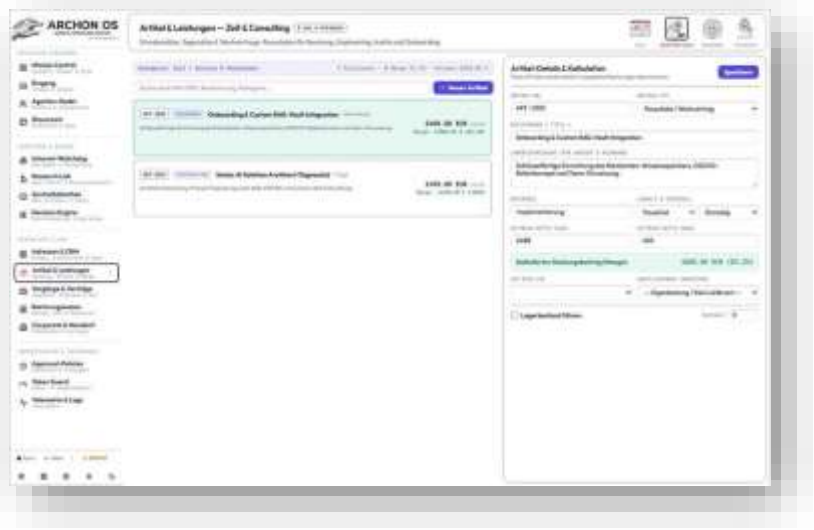
Das Modul Artikel & Leistungen verwaltet den gesamten Leistungs-, Produkt- und Lizenzkatalog des aktiven Mandanten. Jede Position kalkuliert in Echtzeit den Deckungsbeitrag in Euro sowie die prozentuale Handelsspanne aus Netto-Verkaufspreis (VK) und Einkaufspreis (EK) und lässt sich direkt in Angebote, Auftragsbestätigungen und Rechnungen übernehmen.

10.1 Gesamtkatalog (Alle Artikel & Leistungen)



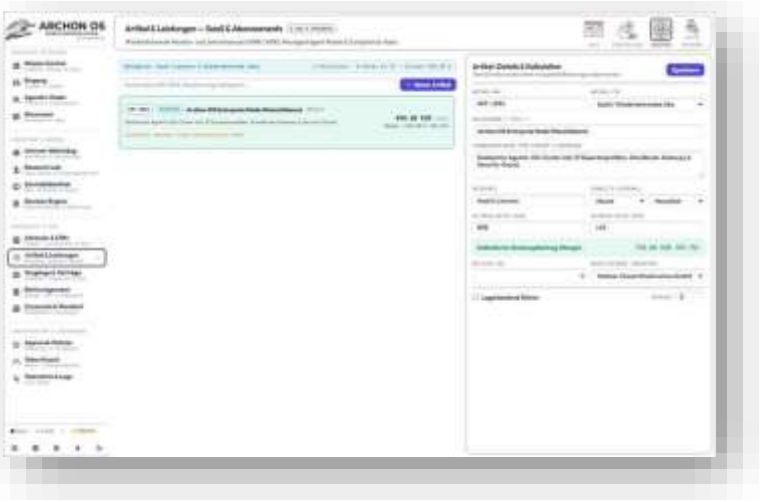
Übersicht aller aktiven Leistungspositionen, Beratungs-Tagessätze, SaaS-Lizenzen und physischen Produkte.
Live-Kalkulationskachel im rechten Inspektor: Automatische Berechnung von Rohgewinn (VK − EK) und Marge in Prozent bei jeder Preisänderung.
Direkte Zuordnung eines bevorzugten Lieferanten (Kreditor 70000+) inklusive Lieferanten-Artikelnummer.

10.2 Zeit / Service & Pauschalen



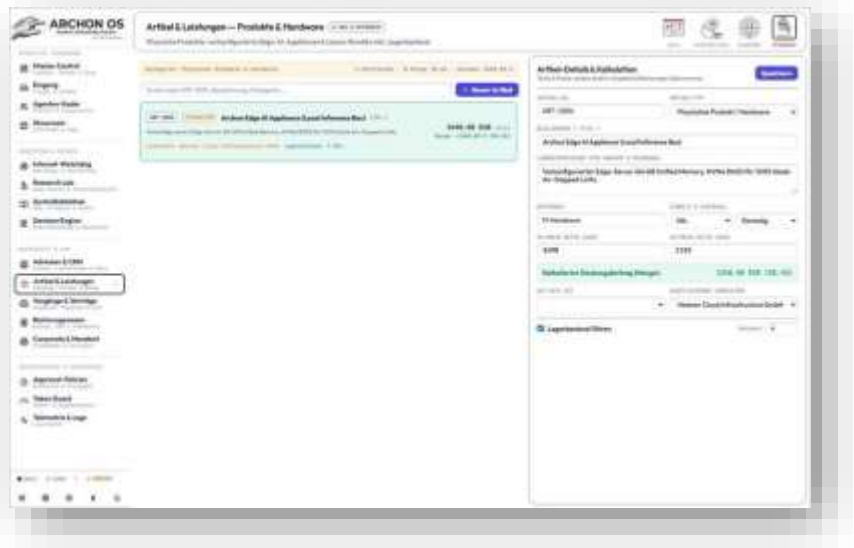
Verwaltung von Beratungsleistungen, Architektur-Workshops, Entwicklungs-Stundensätzen und Festpreis-Pauschalen.
Flexible Einheiten (Stunde, Tagessatz, Pauschal) mit hinterlegten Leistungsbeschreibungen für Angebote.
Stunden- & Tagessätze: Definiert abrechenbare Beratungs-, Entwicklungs- und Serviceleistungen inklusive Standard-Einheit, Steuersatz und Kalkulationsmarge.
Vorlagen für Angebote: Positionen lassen sich mit einem Klick in neue Angebote und Aufträge unter Vorgänge & Verträge übernehmen.

10.3 SaaS & Abonnements



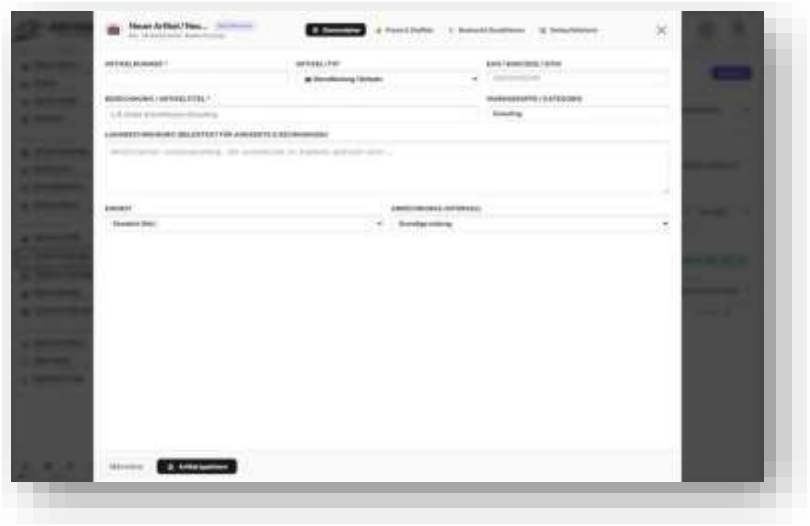
Wiederkehrende Lizenz-, Hosting-, Wartungs- und Agenten-Infrastruktur-Abonnements (MRR / ARR).
Nahtlose Verknüpfung mit Laufzeitverträgen und automatischer Fälligkeitsüberwachung.
Wiederkehrende Erlösmodelle: Verwaltet monatliche oder jährliche Lizenzen, Wartungsverträge und Retainer mit automatischer MRR/ARR-Auswertung.
Laufzeit- & Kündigungslogik: Hinterlegte Abrechnungsintervalle speisen direkt das Vertrags- und Fristenradar.

10.4 Produkte & Hardware (inkl. Lagerbestand)



Physische Produkte, Edge-AI-Workstations, Hardware-Bundles und Handelswaren.
Integrierte Bestandsführung mit aktuellem Lagerbestand, Mindestbestand (Meldebestand) und Lagerort.
Physische Artikel & Bestand: Führt Einkaufspreise, Verkaufspreise, Artikelnummern (SKU) und verfügbare Lagerbestände.
Lieferanten-Zuordnung: Verknüpft Artikel direkt mit dem bevorzugten Kreditor für schnelle Nachbestellungen und Kalkulationen.

10.5 Artikel-Drawer & Enterprise ERP Stammdaten-Inspektor



80-Pixel-Kopfleiste mit 4 modularen Teilansichten nach Enterprise ERP-Standard: Stammdaten, Preise & Staffeln, Bestand & Konditionen sowie Verkaufshistorie.
Kaufmännische Staffelpreise und Fibu-Erlöskonten (SKR03 / SKR04) mit automatischer Live-Margenkalkulation in Euro und Prozent.
Integrierte Bestandsführung (Mindestbestand, Lagerort, Lieferanten-Kreditorzuordnung) und SaaS-Abo-Konditionen (Seats, Kündigungsfristen, Senioritätsstufen).
Belegverwendung & Absatzhistorie: Vollständige Rückverfolgbarkeit aller Angebote (ANG) und Aufträge (AB), in denen der Artikel eingesetzt wurde.

11. Vorgänge & Verträge (Säule 3: Wirtschaft & ERP)

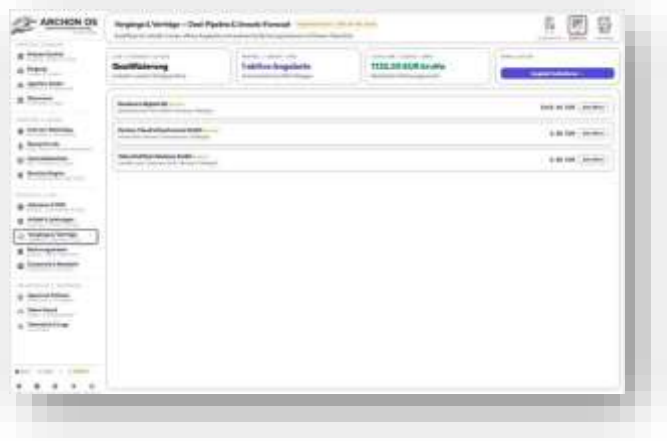
Das Modul Vorgänge & Verträge bildet die operative Klammer zwischen Vertrieb, Projektabwicklung und Rechnungswesen. Nach dem Vorbild moderner ERP-Belegketten (z. B. Nuclos) lassen sich Angebote (ANG) und Auftragsbestätigungen (AB) mit einem Klick verlustfrei in GoBD-konforme Ausgangsrechnungen (RE) oder Gutschriften (GS) überführen.

11.1 Angebote (ANG) & Aufträge (AB)



Beleg-Editor mit direkter Kundenauswahl aus dem Adressstamm und Positionsübernahme aus dem Artikelkatalog.
1-Klick Belegfluss: Umwandlung eines Angebots (ANG) in eine Auftragsbestätigung (AB) oder direkt in eine Ausgangsrechnung (RE) im Modul Rechnungswesen.
Automatische Summierung von Netto-Volumen, Umsatzsteuer und Brutto-Gesamtbetrag.
DIN-5008 Beleg-Druck & PDF-Export: Generierung formaler Angebote und Auftragsbestätigungen mit Mandanten-Briefkopf, Steuernummern, Bankverbindung und Annahme-Unterschriftenfeld.

11.2 Deal-Pipeline & Gewichteter Umsatz-Forecast



Mehrstufiges Vertriebs-Board über die Phasen Lead, Qualified, Proposal, Negotiation und Closed Won.
Echtzeit-Berechnung des ungewichteten Pipeline-Volumens sowie des nach Abschlusswahrscheinlichkeit gewichteten Umsatz-Forecasts.
Wahrscheinlichkeits-Gewichtung: Bewertet offene Chancen nach Pipeline-Phase und berechnet automatisch den gewichteten Umsatz-Forecast.
Engpass-Erkennung: Markiert Deals ohne aktuelle Aktivität, damit im Vertrieb gezielt nachgefasst werden kann.

11.3 Vertrags- & Fristenradar



Überwachung sämtlicher Kunden- und Lieferantenverträge inklusive Mindestlaufzeiten, Verlängerungsintervallen und Kündigungsfristen.
Automatische Fristen-Ampel (Aktiv, Bald fällig <= 30 Tage, Kritisch <= 14 Tage) mit Eskalation an Telegram und Operations.
Automatische Fristwarnung: Überwacht laufende Kunden- und Lieferantenverträge auf bevorstehende Verlängerungen oder Kündigungsstichtage.
DocuSeal-Statusabgleich: Zeigt direkt an, ob ein Vertrag bereits signiert, noch ausstehend oder abgelaufen ist.

12. Rechnungswesen (Säule 3: Wirtschaft & ERP)

Das Modul Rechnungswesen bündelt die kaufmännische Belegverarbeitung, Finanzkennzahlen, Vertragsüberwachung und das Forderungsmanagement.

12.1 Belege



GoBD-konforme Erfassung und Archivierung von Eingangs- und Ausgangsrechnungen sowie Quittungen.
Automatische OCR-Auslesung von Rechnungssteller, Datum, Steuersatz, Netto- und Bruttobetrag.
Eingangs- & Ausgangsbelege: Verwaltet Rechnungen, Gutschriften und per Telegram-OCR digitalisierte Quittungen inklusive Steuersatz-Aufschlüsselung.
Status-Workflow: Trennt klar zwischen Entwurf, geprüft, gebucht, bezahlt und überfällig.

Vertiefender Leitfaden: Siehe docs/system/TELEGRAM_RECEIPT_OCR_GUIDE.md sowie Anhang II (GoBD & Audit-Logging) / docs/security/GOBD_ISO27001_AUDIT_LOG_GUIDE.md.

12.2 Analytics



Finanz-Cockpit für Einnahmen, laufende Betriebskosten (OpEx), KI-Token-Ausgaben und Projekt-Deckungsbeiträge.
Abweichungsanalysen und Liquiditätsvorschau.
Liquiditäts- & Ergebnisblick: Visualisiert Einnahmen, Ausgaben, offene Posten sowie monatliche Deckungsbeiträge im Zeitverlauf.
Export-Schnittstelle: Bereitet gefilterte Zeiträume für die Übergabe an Steuerberatung oder Metabase-BI-Dashboards auf.

Vertiefender Leitfaden: Zur Anbindung erweiterter Business-Intelligence-Auswertungen siehe Markdown-Systemdokumentation (docs/system/BI_DASHBOARD_METABASE_GUIDE.md).

12.3 Verträge



Zentrales Vertragsregister mit automatischem Fristen- und Kündigungsmanagement (t-0a2171).
Heuristische Erkennung von Mindestlaufzeiten, automatischen Verlängerungsklauseln und Kündigungsfenstern.
Frühwarnung per Telegram und Kanban-Ticket bei Fristen <= 14 Tagen.
Digitaler Vertragslebenslauf: Bündelt PDF-Vertragsdokumente, Signatur-Zertifikate (DocuSeal) und zugehörige Abrechnungspläne an einem Ort.
Verknüpfung zum CRM: Jeder Vertrag bleibt eindeutig mit Debitor/Kreditor und dem ursprünglichen Angebot verbunden.

Vertiefender Leitfaden: Zur digitalen Vertragsunterzeichnung siehe Markdown-Systemdokumentation (docs/system/ESIGN_DOCUSEAL_GUIDE.md).

12.4 Mahnwesen



Überwachung offener Ausgangsrechnungen und Fälligkeitstermine.
Mehrstufige Dunning-Engine zur Erstellung rechtssicherer Zahlungserinnerungen und Mahnungen inklusive Verzugszinsberechnung nach BGB.
3-stufiger BGB-Mahnlauf: Bereitet Zahlungserinnerung (0 EUR), 1. Mahnung (+5 EUR) und Letzte Mahnung (+10 EUR zzgl. Verzugszinsen) automatisch vor.
Verbindliches HITL-Gate: Kein Mahnschreiben verlässt das System ohne ausdrückliche vorherige Freigabe durch den Betreiber.

Vertiefender Leitfaden: Siehe die vollständige Spezifikation in Markdown-Systemdokumentation (docs/system/DUNNING_ENGINE_GUIDE.md).

13. Corporate & Mandant (Säule 3: Wirtschaft & ERP)

Das Modul Corporate & Mandant verwaltet sämtliche Unternehmensstammdaten (mandantenfähig mit physisch getrennter SQLite-Datenbank je Gesellschaft), Corporate-Design-Vorgaben sowie offizielle Geschäftsvorlagen für Korrespondenz und Abrechnung.

13.1 Stammdaten



Mandantenfähigkeit (Multi-Company): Verwaltung mehrerer Firmen oder Standorte mit schnellem Wechsel über das Kopfzeilen-Dropdown und den globalen Mandanten-Umschalter in der linken Seitenleiste.
Physische DB-Isolation: Jeder Mandant besitzt eine eigene, strikt getrennte Datenbank (data/tenants/{company_id}/erp.db).
Rechtliche Angaben & Anschrift: Firmenname, Rechtsform, Geschäftsführung, Straße, PLZ, Ort und Kontaktdaten.
Handelsregister & Steuern: Registergericht, HRB-/HRA-Nummer, Steuernummer, Umsatzsteuer-Identifikationsnummer (USt-IdNr.) und Kleinunternehmer-Status (§ 19 UStG).
Bankverbindung & Corporate Design: IBAN, BIC, Kreditinstitut sowie Primär-/Sekundärfarben, Typografie und Firmenlogo.

13.2 Formulare & Vorlagen



Interaktives Vorlagen-Studio mit Echtzeit-Vorschau, automatischer Einbindung der hinterlegten Firmenstammdaten und Direkt-Auswahl von Empfängern aus dem Adressstamm.
DIN 5008 Geschäftsbrief: Normgerechtes Briefblatt mit Faltmarken, Anschriftzone, Informationsblock und Pflichtangaben-Fußzeile.
Ausgangsrechnung (§ 14 UStG): Vollständige Rechnungsvorlage mit Positionsberechnung, Netto-/Umsatzsteuer-Ausweis und Zahlungsziel.
Geheimhaltungsvereinbarung (NDA): Direkt einsatzbereite Vorlage für beidseitige Vertraulichkeitsvereinbarungen.
Direktdruck & PDF-Export auf DIN-A4 über die integrierte Druckfunktion.

14. Approval-Policies

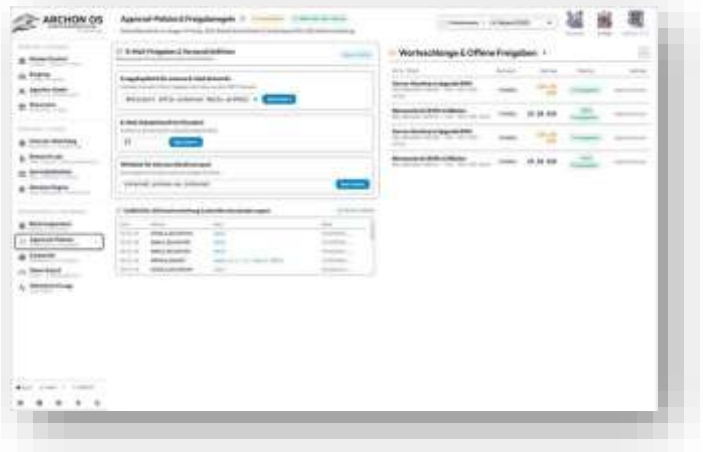
In den Approval-Policies legst du verbindlich fest, welche Aktionen Agenten dunkel (autonom) ausführen dürfen und wo zwingend eine menschliche Freigabe (Human-in-the-Loop) eingeholt werden muss.

14.1 Finanzen



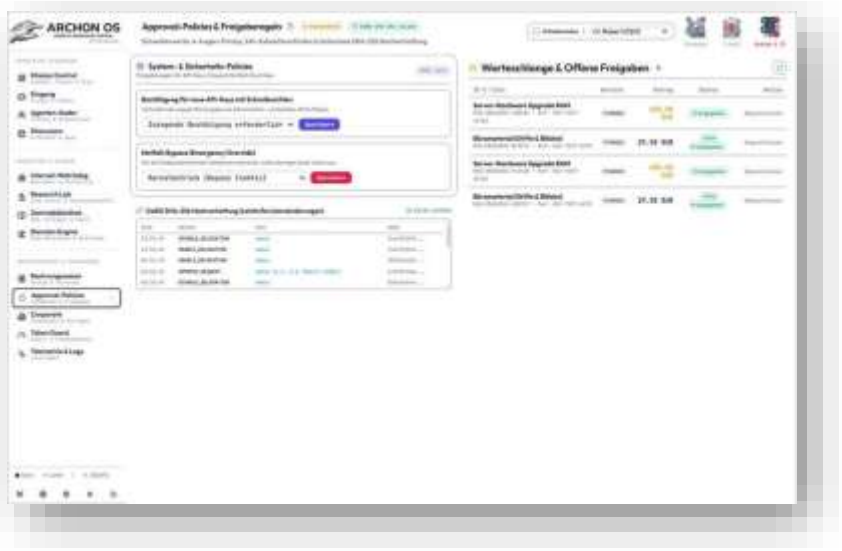
Freigabegrenzen für Ausgaben, Abonnements, Rechnungsfreigaben und Budgetverschiebungen.
Vier-Augen-Prinzip ab frei definierbaren Euro-Schwellenwerten.
Stufenweise Betragsgrenzen: Legt fest, bis zu welchem Euro-Betrag Kosten oder Buchungen automatisch durchlaufen und ab wann eine manuelle Freigabe zwingend ist.
Audit-Protokollierung: Jede Schwellenwert-Änderung wird unveränderlich in der Policy-Hash-Kette dokumentiert.

14.2 E-Mail



Regelwerk für ausgehende Korrespondenz: Pflichtfreigabe bei externen Empfängern, Behörden oder Vertragsangeboten.
Schutz vor ungeprüften rechtlichen Zusagen im Außenverhältnis.
Empfänger- & Domain-Regeln: Unterscheidet zwischen internen Entwürfen, bekannten Bestandskunden und kritischen externen Adressaten (z. B. Behörden, Banken).
Pflicht-Vorschau: Blockiert den Direktversand und legt vollständige Antwortentwürfe zur Prüfung in den Eingang.

14.3 System & IT



Absicherung kritischer Infrastruktur-Eingriffe (Datenbank-Migrationen, Container-Neustarts, Konfigurationsänderungen).
Automatische Datenklassifizierung nach ISO 27001 / BSI (t-53315b) in PUBLIC, INTERNAL, CONFIDENTIAL und STRICTLY_CONFIDENTIAL mit Blockade externer Cloud-Übertragungen bei sensiblen Daten.

Vertiefender Leitfaden: Siehe Anhang II (DSGVO, Verschlüsselung & Freigabe-Gates) sowie docs/system/GDPR_COMPLIANCE_GUIDE.md.

15. Token Guard

Kosten-Leitplanken, Raten-Limits, Endlosschleifenschutz & Safety Controls

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich: *"Wie hoch ist der aktuelle Stand des Tagesbudgets im Token Guard und gab es heute ausgelöste Schutzabschaltungen?"*

Kernkonzept & Architektur:

Der Token Guard ist die finanz- und hardwareschutztechnische Kontrollzentrale von Archon OS. Er verhindert Budgetüberschreitungen, Endlosschleifen und CPU-Spitzen, indem er jede Transaktion in Echtzeit analysiert, harte Limite erzwingt und detaillierte Kosten-Transparenz bis auf Einzelsitzungs-Ebene herstellt. Über drei spezialisierte Sub-Views schlägt der Guard die Brücke zwischen strategischer Budgetplanung und technischer Hardware-Drosselung.

Sub-View 1: Übersicht & Tages-Trend-Dashboard:

Bündelt 4 KPI-Karten (Gesamt-Tokens im Zeitraum, kumulierte Kosten in USD mit Tagesbudget-Anzeige, Anzahl aktiver Schutz-Plugins und Top-Verbraucher-Profil). Ein Live-Trend-Chart visualisiert Token- und Kostenspitzen nach Tagen. Direkt darunter schlüsseln zwei Tabellen den Verbrauch nach Agenten-Profilen und LLM-Modellen auf. Die rechte Spalte beherbergt das Schutz-Schranken-Formular (Max-Kontext, Max-Chat-Historie, Tagesbudget, Task-Budget, Max-Steps, Session-Timeout und Cache-TTL).

Sub-View 2: Einzel-Session Verbrauchs-Inspektor:

Erlaubt den tiefen Drilldown in jede einzelne Chat- und Workflow-Sitzung. Die sortierbare Tabelle weist Session-ID, verantwortliches Profil, Sprachmodell, Call-Zähler, Input-Tokens, Output-Tokens, durch semantischen Cache eingesparte Tokens (Cache-Read), Gesamtkosten und Zeitstempel aus.

Sub-View 3: Ressourcen & Concurrency-Drosselung (Hardware-Schutz):

Steuert die globale Asyncio Semaphore für parallel rechnende Agenten. Ein interaktiver Schieberegler (1 bis 16 parallele Tasks) erlaubt die flexible Anpassung an die Hardware: 1 Task für sequentiellen Schutzbetrieb, 4–6 Tasks für flüssiges Multitasking, bis zu 16 Tasks für dedizierte Workstations.

Das 14-stufige Token-Spar- und FinOps-Ökosystem:

Archon OS integriert 14 abgestimmte Einsparmechanismen:

1. 3-Tier Kosten-Caps (LOW: max $0.10/1M, MEDIUM: max $1.00/1M, HIGH: No Cap).
2. FreeLLM-API Docker-Proxy (Port 3002) mit auto/best-free Routing für 0-Dollar-Routinejobs.
3. Stufenloses Reasoning-Budget (0 bis 16k Tokens) im Chat-Footer.
4. 24h Evey-Cache für sofortige, kostenlose Wiederholungsantworten.
5. Max-Context (32k) und Max-History (20 Turns) Hard-Clipper.
6. Dynamischer Token-Clipper für Kleinmodelle unter Erhalt des System-Prompts.
7. Sliding Window Memory Compression auf den Block [KONSOLIDIERTER ENTSCHEIDUNGSKONTEXT].
8. LRU-K Page Swapping für Subagenten-RAM ab 80% Quota-Erreichung.
9. JEV Router für 0-Token Vorfilterung deterministischer Systembefehle.
10. ASD-STE100 Prompter zur Beseitigung von Füllwörtern (30–40% Ersparnis).
11. Anti-AI-Slop Filter zur Vermeidung teurer Floskel-Output-Tokens.
12. Pre-Flight Kosten-Schätzer vor dem Start umfangreicher Aufträge.
13. Dynamisches Task-Budget mit 80%-Spar-Downgrade und 100%-Stopp mit Telegram-Push.
14. Loop-Killer mit Stopp nach 15 Schritten oder Jaccard-Ähnlichkeit > 90%.

Tabelle 15.1: Kernparameter & Grenzwerte des Token Guard

Schutzmechanismus	Standard-Grenzwert	Wirkung & Schutzfunktion
Tages-Budget	$2.00 / Tag (Warnung bei $1.50)	Verhindert unerwartete Monatsabrechnungen durch automatischen API-Stopp.
Task-Budget	$0.50 / Task (Downgrade bei $0.40)	Schaltet bei 80% auf Spar-Modelle herunter; pausiert bei 100% mit Telegram-Push.
Max. Schritte (Loop-Killer)	15 Schritte / Ähnlichkeit > 90%	Bricht rekursive Tool-Schleifen und Argumentations-Spinlocks verlässlich ab.
Concurrency Throttle	5 gleichzeitige Tasks (Slider 1–16)	Begrenzt parallele LLM-Calls; schützt CPU und API-Quotas vor Überlastung.
Cache TTL	24 Stunden	Beantwortet identische System- und Statusfragen in 0ms zu 0 Token-Kosten.

Praxis-Workflow (Schritt für Schritt):

1. Prüfe in Sub-View 1 den aktuellen Kostenstand gegenüber dem Tagesbudget ($2.00).
2. Wechsle bei erhöhtem Verbrauch in Sub-View 2 (Sessions), sortiere nach 'Kosten' und identifiziere den auslösenden Dialog.
3. Justiere in Sub-View 3 den Concurrency-Slider herunter (z. B. auf 3 Tasks), falls dein Rechner unter hoher Last steht.
4. Klicke bei Bedarf oben rechts auf 'Cache leeren', um gespeicherte Modell-Antworten zu verwerfen.

[Tipp] Praxistipp & Leitplanke: Lasse Routine-Aufgaben über die 3-Tier-Kategorie 'LOW' oder 'auto/best-free' laufen. Dadurch fängt der kostenlose Docker-Proxy (Port 3002) das Grundrauschen ab, und dein Tagesbudget bleibt für strategische Aufgaben mit Claude 3.5 Sonnet oder GPT-4o reserviert.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Zeige mir den aktuellen Tagesverbrauch im Token Guard und liste die drei teuersten Sessions der letzten 24 Stunden auf."

15.1 Übersicht



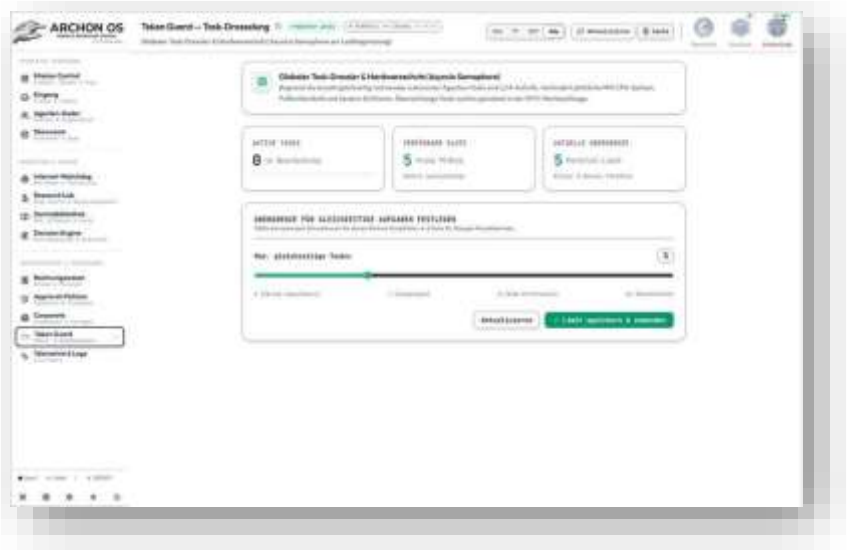
Echtzeit-Überwachung des Token- und Kostenverbrauchs über alle Provider, Modelle und Fachagenten hinweg. Budget-Ampel für Tages- und Monatslimits.
Anbieter- & Modellaufschlüsselung: Zeigt auf einen Blick, welche Modelle und Agenten den größten Anteil der täglichen Token-Kosten verursachen.
Cache- & Sparquote: Misst die Entlastung durch lokales Semantic-Caching und kostenfreie Routing-Pfade über OmniRoute.

15.2 Sessions



Aufschlüsselung des Token-Bedarfs einzelner Sitzungen und Tasks (Input- vs. Output-Tokens).
Erkennung ungewöhnlich großer Kontextfenster oder Endlosschleifen.
Einzel-Session-Inspektor: Erlaubt das gezielte Beenden oder Zurücksetzen einzelner Agenten-Sitzungen mit auffällig hohem Token-Verbrauch.
Ursachenanalyse: Trennt Prompt-Kontext (Input) von generierten Antworten (Output), um überladene System-Prompts schnell zu erkennen.

15.3 Drosselung

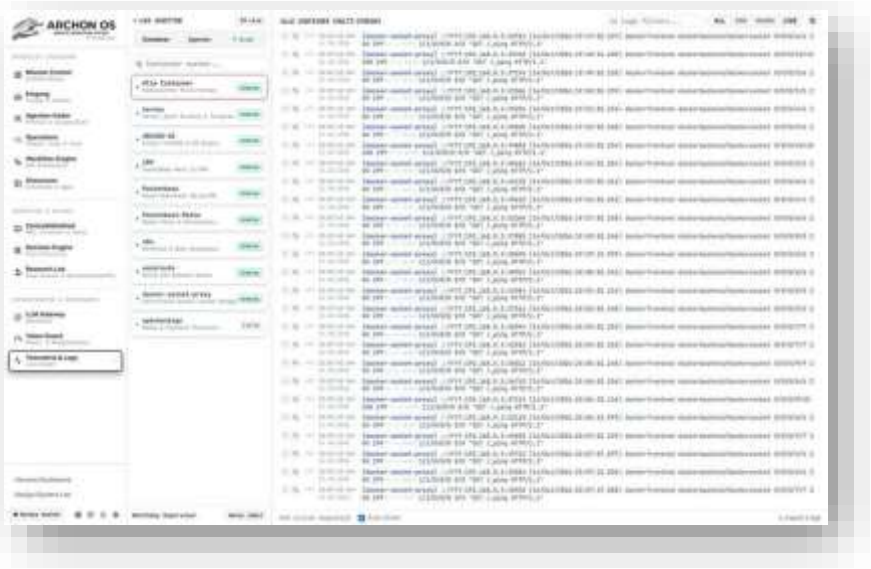


Konfiguration von Soft-Limits (Warnmeldung bei 80 %) und Hard-Limits (Automatischer Stopp oder Fallback auf kostenfreie Modelle bei 100 %).
Automatische Schutzschalter: Greift bei Annäherung an Tages- oder Monatsbudgets mit Soft-Warnung (80 %) und hartem Kosten-Stopp bzw. Fallback.
Loop-Schutz: Begrenzt maximale Tool-Aufrufe und Schritte pro Task, damit fehlerhafte Agentenschleifen kein Budget verbrennen.

Vertiefender Leitfaden: Siehe Anhang II (API-Keys & Privacy-Routing) sowie docs/security/API_KEYS_SCOPES_RATELIMITS_GUIDE.md.

16. Telemetrie & Logs

Sekundengenaues Audit, System-Telemetrie & kryptografischer Trace-Feed



Kernkonzept & Architektur:

Telemetrie & Logs ist das unbestechliche Flugschreiber-System von Archon OS. Jede einzelne Aktion – vom kleinsten API-Ping über Tool-Ausführungen bis hin zu Benutzerfreigaben – wird hier sekundengenau erfasst und manipulationssicher protokolliert. Sollte ein unerwartetes Verhalten auftreten, liefert dieser Stream die vollständige Diagnose-Kette zur schnellen Ursachenanalyse.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Drei spezialisierte Log-Quellen (Sub-Tabs): • Container-Logs: Physische stdout/stderr Ausgaben der 11 Docker-Container.
• Agenten-Logs: Konsolenausgaben und Denkprozesse der Hermes-Agenten.
• Audit-Trail: Revisionssicherer Hash-Chain Log aller geschäftlichen Freigaben.
Such- & Filterleiste: Echtzeit-Filterung nach Log-Level (DEBUG, INFO, WARN, ERROR), Container-Namen oder Schlüsselbegriffen.
Auto-Scroll & Pausieren: Fixiert den Stream bei der Analyse eines Fehlers, ohne den laufenden Datenfluss im Hintergrund zu unterbrechen.
Download & Export: Exportiert den gefilterten Protokoll-Auszug zur externen Analyse oder Archivierung.

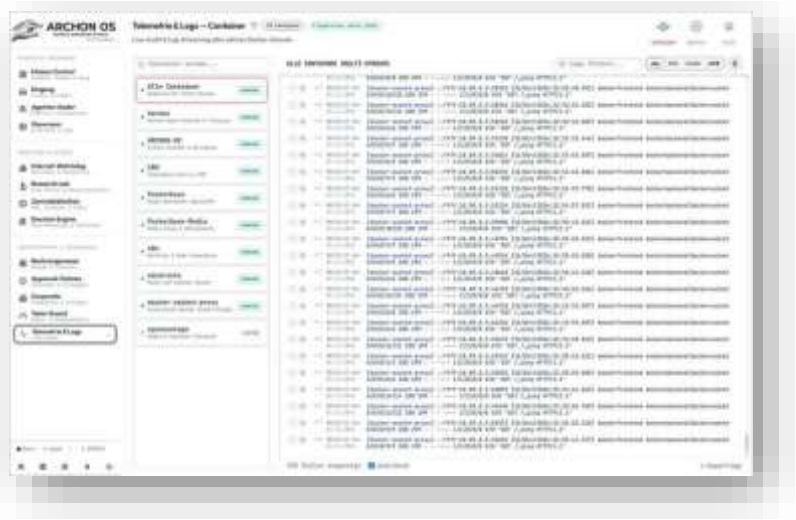
Praxis-Workflow (Schritt für Schritt):

1. Bei Auffälligkeiten in Mission Control wechsle in den Log-Stream.
2. Filter nach dem Level 'ERROR' oder dem Namen des betroffenen Agenten.
3. Analysiere den Stacktrace und den vorangegangenen Prompt, um die Fehlerquelle exakt zu lokalisieren.
4. Nutze die Erkenntnisse, um Prompts oder Tool-Berechtigungen im Kader nachzujustieren.

[Tipp] Praxistipp & Leitplanke: Nutze den Audit-Trail für die Compliance-Dokumentation. Dank der kryptografischen Verkettung kannst du jederzeit lückenlos nachweisen, wer welche Aktion zu welchem Zeitpunkt freigegeben hat.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Zeige mir alle Warnungen und Fehler (WARN, ERROR) im Log-Stream der letzten 2 Stunden."

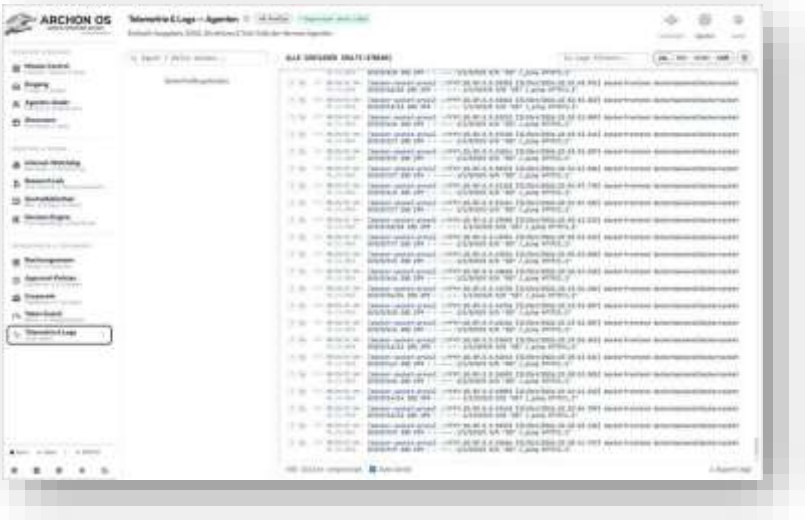
16.1 Container



Live-Metriken aller Docker-Container (Latenzen, CPU-/RAM-Auslastung und Health-Checks).
Direkte Einsicht in die Standardausgabe- und Fehler-Logs einzelner Dienste.
Dienst-Kontrolle im Überblick: Zeigt Status, Uptime und Ressourcenverbrauch aller laufenden Docker-Container (Archon, Hermes, OmniRoute, n8n, PocketBase).
Diagnose-Logs: Ermöglicht das direkte Durchsuchen der letzten Container-Meldungen ohne SSH- oder Terminal-Zugang.

Vertiefender Leitfaden: Siehe docs/system/PROMETHEUS_GRAFANA_MONITORING_GUIDE.md sowie docs/system/CENTRAL_LOGGING_LOKI_GUIDE.md.

16.2 Agenten



Chronologischer Trace-Stream sämtlicher Agenten-Überlegungen, Tool-Aufrufe und Modellantworten.
Filterung nach Agenten-ID, Schweregrad (INFO, WARN, ERROR) und Zeitraum.
Echtzeit-Ausführungsprotokoll: Macht nachvollziehbar, welches Modell ein Agent gewählt hat, welche Tools aufgerufen wurden und welche Laufzeit anfiel.
Fehlersuche: Filtert gezielt nach Warnungen, Timeouts oder abgebrochenen Tool-Ausführungen einzelner Rollen.

Vertiefender Leitfaden: Zur tiefgehenden Observability siehe Markdown-Systemdokumentation (docs/system/LLM_TRACING_LANGFUSE_GUIDE.md).

16.3 Audit



Revisionssicheres, kryptografisch verkettetes Audit-Log aller sicherheitsrelevanten Systemaktionen. Geordneter Server-Shutdown über den GracefulShutdownCoordinator (t-12113b) mit Task-Draining und vollständigem SQLite-WAL-Flush.

Kryptografische Nachvollziehbarkeit: Jeder Eintrag ist über SHA-256 mit dem Vorgänger-Hash verkettet, sodass nachträgliche Manipulationen sofort auffallen.

Compliance-Nachweis: Dokumentiert DSGVO-Löschungen, Policy-Änderungen, Freigaben und Break-Glass-Zugriffe lückenlos.

17. System Control Center

Zentrale System-Administration, Daemon-Kernel, Multi-Provider-Verwaltung & MCP-Zentrale

Das System Control Center (aufrufbar über das Zahnrad-Symbol oben rechts in Mission Control oder unten links in der Seitenleiste) bündelt die gesamte System-Administration von Archon OS in einem modularen Vollbild-Dialog. Im Kopf des Fensters stehen zusätzlich eine globale Settings-Live-Suche (Tastenkürzel '/') zum direkten Anspringen einzelner Parameter sowie der Button 'Live-Dock' (dockt den Dialog rechts neben der echten Oberfläche an, um Design- oder Layout-Änderungen live zu beobachten). Inhaltlich gliedert sich das Control Center in exakt elf Fachreiter (17.1 bis 17.11):

Praxis-Workflow (Schritt für Schritt):

1. Öffne das System Control Center über das Zahnrad-Symbol; bei Bedarf springst du über die Suchleiste ('/') direkt zu Stichworten wie 'Auth', 'Ollama', 'Telegram' oder 'Backup'.
2. Hinterlege im Reiter 'API-Keys & Access' bzw. 'Provider & Gateway' deine LLM-Schlüssel sowie lokale Modelle (Ollama / LM Studio) und definiere Fallback- und Privacy-Routen.
3. Überprüfe im Reiter 'Container & Dienste', ob alle aktiven Kerndienste (ARCHON-OS, Hermes Agent, AnythingLLM, Chroma, Socket Proxy, optional n8n/OmniRoute) fehlerfrei laufen.
4. Konfiguriere im Reiter 'Plugins' deine MCP-Werkzeuge sowie PreDecision, Prompt-Injection-Schutz, AI Quality Gate und Cost Guard.
5. Aktiviere unter 'Benutzer & Rollen' das Multi-User-Login für LAN-/Server-Betrieb und hinterlege unter 'Kommunikation' Telegram, IMAP/SMTP und n8n-Webhooks.

[Tipp] Praxistipp & Leitplanke: Nutze nach jeder Änderung an Provider-Schlüsseln oder Container-Zuweisungen den 'Test'-Button im jeweiligen Reiter, bevor du die Änderungen live in den Produktionsbetrieb übernimmst. Für tiefgreifende Kernel-Anpassungen steht im Reiter 'Hermes Core' jederzeit der YAML-Live-Editor mit automatischer Backup-Erstellung bereit.

Reiter / Bereich	Zuständigkeit & Funktionen	Standard-Konfiguration
Hermes Core	Kernel-Scheduler, Watchdog (120s), Model Quick-Select, YAML-Editor	Port 8420, Tickless Sleep aktiv
Container & Dienste	Überwachung der 11 Docker-Container, Service-Restart, Cache-Reset	11/11 Dienste nominal im Mesh
Provider & Gateway	API-Keys für OpenRouter, Gemini, Groq, Anthropic; Latenzprüfung	OmniRoute AI Router (Port 20128)
Methodiken	Verwaltung von 35 Analyse- & Prompt-Frameworks; eigene SOPs anlegen	35 Standard Base Frameworks
Plugins & MCP	FastMCP-Treiber (Filesystem, Web-Search, CRM, Tools), Scopes	Read-Only default, Schreibschutz aktiv
Kommunikation	Telegram-Bot-Token, Chat-IDs, CRM-Mail-Sync (IMAP), Webhooks	Telegram Polling aktiv, HITL-Notruf
Design	Dark/Light Theme, Firmenlogo-Upload, Farbschemata, CSS-Sync	Archon Slate Dark Mode aktiv

> **[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:** "Öffne das System Control Center und zeige mir den Status der Container sowie den aktuell eingestellten Standard-Provider im Hermes Core."

17.1 Hermes Core



Kernel, SOUL.md-Stufen & 15 Daemon-Sektionen (Port 8420):
Steuert den Hintergrund-Daemon auf Port 8420 sowie die systemweite Umschaltung der 3-Stufen-SOUL-Direktiven (Compact ~3.100 Zeichen / Pro / Full) über alle aktiven Agenten-Profile hinweg. Die 15 Konfigurationsgruppen decken u. a. Standard-Modell & Routing (model), Thinking-Limits (agent), Streaming (display), Multiplexing/Plattformen (gateway), Code-Execution-Allowlists, Tool-Loop-Guardrails, Kontext-Kompression & Prompt-Caching, Memory/Skill-Synthese, Subagenten & MoA, Browser-Engine, Voice STT/TTS, Konfigurations-Backups sowie den verschlüsselten Break-Glass-Notfallzugang ab.

System-Diagnostik & 360°-Health-Score (GET /api/system/health-score):
Aggregiert kontinuierlich alle Vitalparameter des Systems in eine Gesamtnote von 0 bis 100 %: Docker Core-Flotte (35 % Gewicht), Concurrency-Warteschlange (20 %), kryptografische Audit-Integrität (20 %), Deadlock-Freiheit (15 %) sowie AnythingLLM RAG-Erreichbarkeit (10 %) inklusive konkreter Handlungsempfehlungen.

Autonomer Master-Dossier-Generator (POST /api/system/generate-dossier):
Generiert auf Knopfdruck das vollständige System-Architektur-Dossier samt allen Docker-Diensten, Concurrency-Slots, FinOps-Mechanismen, 70 Spezialisten-Profilen und Sicherheits-Gatekeepern und synchronisiert die Markdown-Datei simultan ins Projektverzeichnis sowie in den Obsidian-Vault (00_DOKUMENTATION/SYSTEM_ARCHITEKTUR_MASTER.md).

Vertiefender Leitfaden: Zum Notfallzugriff und Resilienz-Tests siehe Anhang II (Notfall-Tresor / Break-Glass) sowie docs/system/CHAOS_RESILIENCE_GUIDE.md.

17.2 Autonomie & Module (36 Subsysteme)



Bereiche 1–3: Wartung, Resilienz & Governance (Module 1–11):
Bereich 1 steuert die nächtliche Gedächtnis-Konsolidierung (Sleep-Cycle Wartung). Bereich 2 (Paket A, Module 2–6) kalibriert Concurrency- & Deadlock-Wächter, Loop-Killer/Circuit-Breaker, Task-Selbstheilung mit Git-Rollback, Ephemeral Docker Sandbox und Time-Travel Debugger. Bereich 3 (Paket B, Module 7–11) verwaltet Konsens-Gate & Schiedsgericht, Virtuellen War-Room (Pre-Mortem), SLA-Übergabeverträge, Inbox-Watcher/Standup sowie Flotten-Selbstheilung, Secret-Masker, Playwright-Screenshots und SQLite-Backup-Rotation.

Bereiche 4–8: Enterprise-Pakete 1 bis 5 (Module 12–36):
Ergänzend zu den Kernel-Wächtern steuern die Bereiche 4 bis 8 direkt in diesem Reiter die 25 Enterprise-Module: (4) Performance-Core & Durchsatz (Speculative Pre-Fetching, Token-Effizienz), (5) Moderne Gedächtnis- & RAG-Architektur, (6) Zuverlässige Ausführung & Determinismus (Durable Execution), (7) Sicherheit, Datenschutz & Enterprise-Governance (Zero-Egress Privacy-Routing, Dual-LLM Guard, PII-Scrubber) sowie (8) Selbst-Optimierung, Evaluation & Schwarm-Intelligenz (MCTS Action Trajectories, JIT-Personas, PbD Computer-Use).

Tabelle 17.1: Die 36 steuerbaren Autonomie-, Resilienz- & Enterprise-Module (settings.json / API)

Gruppe & Modul	Schalter (An/Aus)	Regelbare Schwellenwerte & Parameter
1. Concurrency & Deadlock	auto_deadlock_recovery	max_concurrent_agents (4), queue_timeout (60s), stagnation (45s)
2. Loop-Killer & Clipper	loop_detection, token_clipper	max_identical_turns (3), jaccard_threshold (0.90), max_steps (15)
3. Task-Selbstheilung	enabled, auto_git_rollback	max_attempts (3), escalation_model (deepseek/deepseek-chat)
4. Ephemeral Sandbox	enabled, network_enabled	memory_limit_mb (512), cpu_limit (1.0), timeout_seconds (30)
5. Time-Travel & Snapshots	tracing_enabled, auto_snapshots	max_snapshots (50), max_trace_steps (100)
6. Konsens-Schiedsgericht	enabled	min_priority (P3), mode (tri_agent_council), majority (2/3 | 3/3)
7. Virtueller War-Room	enabled, auto_pre_mortem	block_threshold (MEDIUM | HIGH | CRITICAL), default_model
8. SLA-Verträge & Handoff	enabled, auto_reject_incomplete	min_content_length (100 Zeichen), max_turnaround_minutes (60)
9. Inbox & Morgen-Standup	enabled, standup_enabled	interval_seconds (5s), standup_time (08:00 Uhr), watch_folder
10. Flotte, DB & Hygiene	auto_restart, secret_mask, audit	db_backup_keep_days (7 Tage), visual_browser_audit (Screenshots)

Die wichtigsten operativen Tiefenmodule aus dem Reiter 'Autonomie & Module' im Detail (17.2.1 bis 17.2.10):

17.2.1 Replay & Time-Travel Debugging (Execution Trace Player & State-Forker)

Komplexe Agentenläufe umfassen oft Dutzende Teilschritte aus Tool-Aufrufen, Dateimodifikationen und Modellabfragen. Scheitert ein Prozess bei Schritt 14, musste bisher der gesamte Task mühsam im Log analysiert und von vorne begonnen werden.

Funktionsweise des Trace Players (backend/time_travel_debugger.py):

- Lückenlose Protokollierung: Jeder Teilschritt wird mit Eingabeparametern, LLM-Rückgabe, Laufzeit, Token-Verbrauch und atomarer Snapshot-ID in der Tabelle 'execution_traces' archiviert.
- Replay-API (GET /api/traces/{task_id}): Liefert den exakten chronologischen Ablauf des Tasks zur schrittweisen Visualisierung im Cockpit.
- State-Forking (POST /api/traces/{task_id}/fork): Ermöglicht das Abzweigen eines Tasks ab einem beliebigen Zwischenschritt N. Das System behält alle vorherigen Schritte bei und führt den Task mit einem alternativen Modell oder modifizierten Instruktionen weiter – ideal für Was-wäre-wenn-Analysen ohne erneuten Vollstart.
- Atomarer Rollback (POST /api/traces/{task_id}/rollback): Dreht alle Dateiänderungen, die nach Schritt N stattfanden, über komprimierte Gzip-Snapshots (.hermes/snapshots/) verlustfrei auf den damaligen Stand zurück.

17.2.2 Multi-Modell Head-to-Head Benchmark & Eval-Matrix (OmniRoute Arena)

Die Wahl des optimalen Modells für eine spezifische Agentenrolle (z. B. Tiefenrecherche vs. Code-Refactoring) beruht in Archon OS nicht auf Vermutungen, sondern auf empirischen Messdaten.

Funktionsweise der Eval-Matrix (backend/model_benchmarker.py):

- Simultaner A/B-Lauf (POST /api/router/benchmark): Sendet denselben realen Prompt parallel an zwei oder mehr konfigurierte LLMs (z. B. DeepSeek V3 vs. Claude 3.7 Sonnet).
- Metriken-Erfassung: Erfasst exakte Latenzzeiten, Token-Schätzungen, Ausgabelängen und ermittelt vollautomatisch den Geschwindigkeits- und Effizienzsieger.
- Persistente Historie (GET /api/router/benchmark/history): Speichert alle Vergleichsläufe in der Tabelle 'model_benchmarks', sodass Kosten- und Geschwindigkeits-Trends über Monate hinweg nachvollziehbar bleiben.

17.2.3 Dual- & Tri-Agent Konsens-Gate & Schiedsgericht (Debate / Voting Protocol)

Bei risikobehafteten Aufgaben (Datenbankmigrationen, Systemdateien, kritische Freigaben ab Priorität 3) verhindert Archon OS Halluzinationen einzelner Agenten durch ein verbindliches Zwei- bzw. Drei-Augen-Prinzip.

Ablauf des Schiedsgerichts-Verfahrens (backend/consensus_gate.py):

- Adversarial Review (POST /api/tasks/review-consensus): Ein unabhängiger Revisor-Agent prüft Arbeitsergebnisse schonungslos auf Logikbrüche, Halluzinationen und Sicherheitsrisiken.
- Tri-Agent Council (POST /api/consensus/council-vote): Für Höchstprioritäts-Entscheidungen tagt ein dreiköpfiges Gremium bestehend aus System Architect (Code-Qualität & Skalierbarkeit), Security Officer (Zero-Trust & Secrets) und QA Lead (Edge-Cases & Usability).
- 2/3-Mehrheitsprinzip: Eine Freigabe erfolgt erst, wenn mindestens 2 der 3 Juroren zustimmen. Sämtliche Voten, Begründungen und Scores werden revisionssicher in 'consensus_decisions' gespeichert (GET /api/consensus/history).

17.2.4 Autonome Task-Selbstheilung mit Git- & Snapshot-Rollback

Fehlerhafte Syntax, unvollständige Codeblöcke oder unvorhergesehene Laufzeitabbrüche führen in herkömmlichen Systemen zum sofortigen Task-Abbruch. Archon OS implementiert eine autonome Selbstheilungsschleife.

Selbstheilungs-Zyklus (backend/task_self_healer.py):

- Fehlerabfang & Working-Tree-Schutz: Bricht ein Skript oder Build-Kommando ab, fängt der Supervisor den vollständigen Fehlerausdruck (Stacktrace) ab und setzt modifizierte Dateien über 'git checkout --' oder den Snapshot-Manager sofort auf den letzten stabilen Stand zurück.
- Introspektive Reparatur-Schleife (POST /api/healing/attempt): Der Agent erhält die Fehlermeldung mitsamt Stacktrace und dem Auftrag zur Ursachenanalyse und Korrektur übergeben.
- Concurrency & Eskalation: Das System erlaubt bis zu 3 autonome Reparaturversuche. Gelingt die Behebung, läuft der Task nahtlos weiter; scheitern alle 3 Versuche, wird der Task auf 'blockiert' gesetzt und erscheint mit voller Diagnose im HITL-Board zur manuellen Inspektion (GET /api/healing/logs).

17.2.5 Event-Mesh & Webhook-Trigger-Brücke (Inbound Automation & Directory Watcher)

Um Archon OS tief in bestehende Unternehmens- und Cloud-Workflows einzubinden, fungiert das Event-Mesh als universeller Ein- und Ausgangskanal für asynchrone Ereignisse.

Funktionsweise des Event-Mesh (backend/event_mesh.py):

- Inbound Webhook-Bus (POST /api/events/inbound/{channel}): Externe Systeme wie GitHub (PRs, Issues), Stripe (Zahlungseingänge) oder n8n können Ereignisse direkt in das System einspeisen und vollautomatisch passende Kanban-Tasks initiieren.
- Automatischer Verzeichnis-Watcher (POST /api/events/scan-directory): Scannt das Posteingangs-Verzeichnis 'data/inbox/' nach neu eingetroffenen Dokumenten (PDFs, Verträge, Notizen), erzeugt Event-Logs und überführt diese direkt als Triage-Aufgaben in das Eingangspostfach.
- Outbound Event-Dispatching: Ermöglicht das automatische Versenden von Webhook-Signalen an externe Webhooks bei Statuswechseln oder Meilenstein-Erreichung.

Um Agenten maximale Handlungsfreiheit zu gewähren, ohne die Stabilität des Hostsystems oder die Übersicht über anwachsende Langzeitdaten zu gefährden, erweitert Archon OS seine Laufzeitumgebung um fortgeschrittene Autonomie- und Schutzschilde. Entwickler-Agenten erhalten flüchtige Ausführungsumgebungen, das System reinigt sich nachts selbstständig und strategische Vorhaben werden vorab simuliert.

17.2.6 Flüchtige Code-Sandboxen (Ephemeral Micro-Containers & Runner)

Wenn autonome Agenten Code generieren, kompilieren oder Skripte ausführen, darf ein fehlerhafter Befehl niemals das Gesamtsystem gefährden.

Funktionsweise der Ephemeral-Sandbox (backend/ephemeral_sandbox.py):

- Kurzlebige Micro-Container (POST /api/sandbox/execute): Jeder Code-Lauf wird in einem temporären, isolierten Docker-Container (z. B. python:3.11-alpine) gestartet. Das System erzwingt strikte Obergrenzen: 512 MB RAM, 1 CPU, 30 Sekunden Ausführungs-Timeout und optional vollständige Netzwerksperre (--network none).
- Automatische Zerstörung: Sobald der Code beendet ist (oder in ein Timeout läuft), wird der Container rückstandslos gelöscht. Speicherüberläufe, Dateisystem-Schäden oder Endlosschleifen bleiben auf die flüchtige Hülle begrenzt.
- Entwickler-Rückmeldung: Das System liefert präzise Ausführungsstatistiken (Laufzeit, Exit-Code, stdout, stderr, verbrauchter Speicher) direkt in den Task-Stream.

17.2.7 Nächtliche Gedächtnis-Konsolidierung & Sleep-Cycle Wartung

Im Dauerbetrieb wachsen Log-Streams, Traces und Kontext-Snapshots rasant an. Ein unbereinigtes System verliert auf Dauer an Abfragegeschwindigkeit.

Wartungs-Zyklus & Konfiguration (backend/memory_consolidator.py & static/views/system_settings_modal.html):

- Ruhephasen-Pruning: Wenn das System inaktiv ist (Standard: 03:00 Uhr nachts), führt Archon OS einen Konsolidierungs-Zyklus durch. Veraltete Trace-Logs älter als die Aufbewahrungsfrist werden bereinigt, unkritische Heartbeat-Logs entfernt und die SQLite-Datenbank via VACUUM komprimiert.
- Vollständige Steuerbarkeit in den Systemeinstellungen: Im Reiter 'Hermes Core' (Abschnitt 6) kann der Nutzer Uhrzeit, Aufbewahrungsfrist in Tagen (z. B. 7, 14 oder 30 Tage), Ähnlichkeitsschwellenwert (0.88–0.95) und Log-Bereinigung flexibel nachjustieren.
- Manuelle Sofort-Auslösung: Über die Schaltfläche 'Jetzt manuell konsolidieren' (POST /api/system/consolidate-memory) lässt sich der Bereinigungs- und Optimierungsvorgang jederzeit manuell anstoßen.

17.2.8 Headless-Browser & Visueller Web-Agent (Playwright Screenshot-Audit)

Viele Recherche- und Interaktionsaufgaben scheitern an rein textbasierten Scrapern, weil moderne Webportale dynamisches JavaScript, Logins oder Formulareingaben erfordern.

Funktionsweise des Visuellen Web-Agenten (backend/visual_web_agent.py):

- Echte Browser-Fernsteuerung (POST /api/browser/browse-and-capture): Der Agent steuert einen vollwertigen Headless-Chromium-Browser über Playwright, führt Klicks, Texteingaben und Navigationen aus.
- Lückenlose Schritt-Screenshots: Zu jedem Teilschritt wird ein visueller Screenshot im Ordner .hermes/visual_traces/{task_id}/ hinterlegt.
- Revisionssicherer Nachweis: Der Operator kann im Task-Dossier visuell nachvollziehen, was der Agent zu welchem Zeitpunkt auf dem Bildschirm gesehen und ausgewählt hat.

17.2.9 Virtueller Pre-Mortem Stresstest (War-Room-Simulation)

Bevor größere Projekte, Releases oder Veröffentlichungen live geschaltet werden, offenbaren menschliche Teams oft 'Optimismus-Verzerrungen'. Archon OS setzt dem eine automatisierte Gegenprüfung entgegen.

Simulation & Angriffs-Szenarien (backend/war_room_simulator.py):

- 3-Parteien-Attacke (POST /api/simulation/war-room): Drei spezialisierte gegnerische Rollen attackieren das geplante Vorhaben in einer Pre-Mortem-Analyse: Ein kritischer Großkunde (Usability, Churn), ein offensiver Red-Teamer (Angriffsvektoren, Datenlecks) und ein strenger Compliance-Auditor (Haftung, DSGVO).
- Risiko-Klassifizierung: Das System aggregiert alle Befunde in einer Risiko-Matrix (LOW, MEDIUM, HIGH, CRITICAL) und formuliert verbindliche Nachbesserungs-Auflagen vor der Freigabe.
- Revisions-Historie (GET /api/simulation/war-room/history): Alle Stresstests bleiben zur historischen Absicherung dauerhaft dokumentiert.

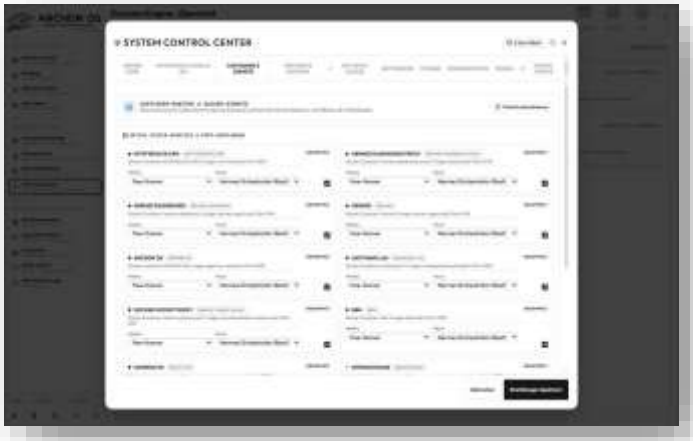
17.2.10 SLA- & Übergabe-Verträge zwischen Agenten (Contract Enforcement)

In vielschichtigen Multi-Agenten-Hierarchien führen lose Delegationen häufig zu unvollständigen Zuarbeiten, die letztlich den menschlichen Operator belasten.

Ablauf des Vertrags-Protokolls (backend/sla_contract_enforcer.py):

- Digitaler Übergabevertrag (POST /api/contracts/create): Jede Delegation zwischen Agenten definiert Pflichtschlüssel (z. B. summary, result, sources), Mindesttextlänge und explizite Abnahmekriterien.
- Autonome Abnahme-Prüfung (POST /api/contracts/validate): Der empfangende Agent prüft das abgelieferte Teilergebnis automatisiert gegen die vertraglichen Bedingungen.
- Automatische Zurückweisung: Entspricht das Ergebnis nicht dem Standard, wird die Übergabe mit einer präzisen Mängelliste ('violations') autonom abgelehnt und zur Überarbeitung zurückgesendet – ohne dass der Nutzer intervenieren muss.

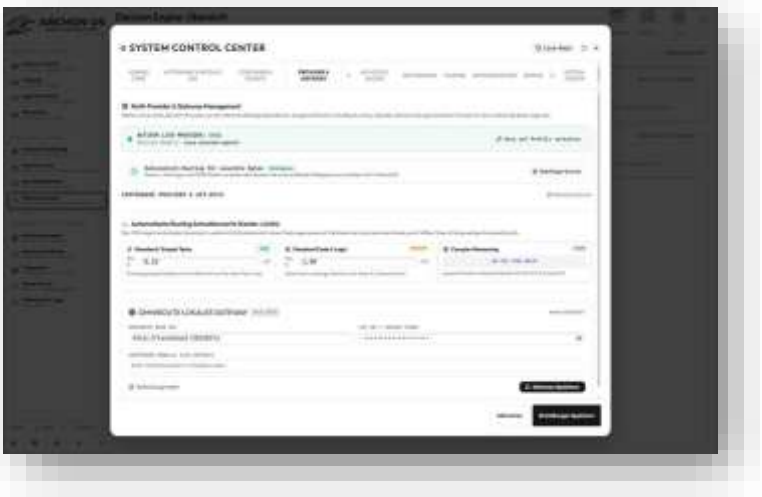
17.3 Container & Dienste



Container-Runtime, aktive Dienste & Pfad-Verwaltung:
Überwacht den Live-Status aller aktiven Container und Port-Kopplungen im Archon-Netzwerk (ARCHON-OS :8501, Hermes Core :8644, AnythingLLM RAG :3001, Chroma :8000, n8n :5678, OmniRoute :20128, PocketBase :8090/:8092, CRM :3005, Docker Socket Proxy). Dienste lassen sich gezielt über den Socket-Proxy neu starten; darüber hinaus zeigt der Reiter aktive System-Pfade und erlaubt Cache-Bereinigungen.

Vertiefender Leitfaden: Siehe docs/system/LITESTREAM_REPLICATION_GUIDE.md sowie Anhang II (TLS & SSO) / docs/security/REVERSE_PROXY_SSO_GUIDE.md.

17.4 Provider & Gateway



Multi-Provider Management, Aufgaben-Routing & Kosten-Schwellenwerte:
Konfiguriert die kognitive Infrastruktur aus Cloud-APIs (OpenRouter, Gemini, OpenAI, Anthropic, Groq, DeepSeek), OmniRoute (:20128) sowie lokalen KI-Servern (Ollama / LM Studio). Im Unterschied zu allgemeinen Schlüsseln steuerst du hier vor allem das Modell-Routing pro Aufgabenklasse (Code, Recherche, Standard-Chat, Vision) sowie automatische Routing-Schwellenwerte (Kosten-Limits, Fallback-Kaskaden und Zero-Egress-Regeln für sensible Daten).

Hinweis zur Navigation: Das LLM Gateway (OmniRoute) ist direkt über das CPU-Symbol unten links in der Statusleiste (Port 20128) sowie über diesen Reiter im System Control Center erreichbar.

Multi-Provider KI-Routing, Kosten-Optimierung & Ausfallsicherheit

Kernkonzept & Architektur:

OmniRoute ist das intelligente Hochleistungs-Gateway (Standard-Port 20128) für alle Modellanfragen in Archon OS. Es entkoppelt den Agentenkern vollständig von einzelnen Modellanbietern und standardisiert die Kommunikation nach dem OpenAI-kompatiblen Schema. Fällt ein Anbieter aus oder greift ein Rate-Limit, schaltet OmniRoute in Millisekunden auf definierte Sekundärrouten um – für den Anwender völlig transparent und unterbrechungsfrei.

Wo APIs & Modellkombinationen eingestellt werden:

Die Konfiguration der API-Schlüssel und Modell-Routen erfolgt zentral über zwei Wege:
1. Grafisch im System Control Center (Tab 'Provider & Gateway'): Hier werden API-Keys für OpenRouter, Google AI (Gemini), Groq, OpenAI und Anthropic hinterlegt. Über den Button 'Verbindung testen' lässt sich die Latenz jedes Providers vor der Freigabe prüfen.
2. Dateibasiert über das Kernel-Verzeichnis: In config/hermes_config.yaml und der lokalen Schlüsselverwaltung können Provider-Hierarchien und benutzerdefinierte Modell-Kombinationen dauerhaft festgeschrieben werden.

Dynamische Fallback-Kaskaden & Kombinationen:

Um maximale Ausfallsicherheit bei minimalen Kosten zu gewährleisten, arbeitet OmniRoute mit priorisierten Fallback-Ketten:
• Primärstufe: GLM-4.7 Flash / auto/best-free – Maximale Geschwindigkeit bei $0.00 Kosten für Routine-Aufgaben und Vorfilterung.
• Sekundärstufe: Google Gemini 2.5 Flash – Hohe Zuverlässigkeit und gigantischer Kontextpuffer für umfangreiche Text-Synthesen.
• Tertiärstufe: Anthropic Claude 3.5 Sonnet – Hochpräzises Reasoning für Architektur-, Code- und Vertragsanalysen.
• Souveränes Notfall-Fallback: Lokales Llama 3.3 70B über Ollama/vLLM – Greift bei totalem Internet- oder Cloud-Ausfall.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

• Multi-Provider Vault: Verschlüsselte Verwaltung aller Provider-Schlüssel an einem zentralen Ort.
• Latenz- & Fehlermonitor: Visualisiert Antwortzeiten (in ms) und HTTP-Fehlercodes (429, 500) zur Früherkennung von Provider-Störungen.
• Automatischer Circuit Breaker: Trennt instabile Endpunkte temporär ab und leitet Anfragen ohne Token-Verlust um.

Tabelle 17.2: Technische Eckdaten des OmniRoute AI Routers

Gateway-Merkmal	Spezifikation & Pfad	Funktion im Live-Betrieb
Gateway Service	Port 20128 (http://localhost:20128/v1)	Zentraler Proxy-Endpunkt für alle LLM-Aufrufe.
Konfigurationsort	System Control Center -> 'Provider & Gateway'	Grafische Schlüsselverwaltung und Latenzprüfung.
Config-Datei	config/hermes_config.yaml	Dateibasierte Definition von Modell-Kombinationen.
Health-Check	http://localhost:20128/health	Liefert Uptime und Provider-Verfügbarkeiten für den Watchdog.

Praxis-Workflow (Schritt für Schritt):

1. Kontrolliere im OmniRoute-Dashboard die Latenzen und Verfügbarkeiten der konfigurierten Provider.

2. Passe bei Bedarf die Standard-Route an (z. B. 'auto/best-free' für maximal budgetschonenden Betrieb).

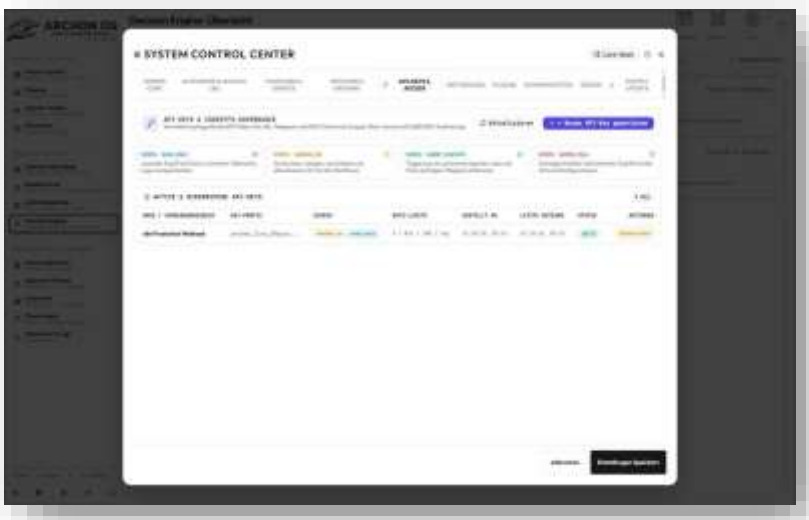
3. Sollte ein Anbieter (z. B. durch ein Rate-Limit) ausfallen, beobachte, wie OmniRoute transparent auf den Fallback wechselt.

[Tipp] Praxistipp & Leitplanke: Lasse Standard-Aufgaben über kostenlose Routen laufen. Hinterlege immer mindestens einen stabilen Fallback-Provider (z. B. Google Gemini Flash oder Groq), damit das Gesamtsystem auch bei API-Aussetzern nicht stoppt.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich: *"Welcher LLM-Provider bietet aktuell die geringste Latenz und wie viele Anfragen wurden heute über OmniRoute geroutet?"*

Vertiefender Leitfaden: Zum Training eigener lokaler Sprachmodelle siehe Markdown-Systemdokumentation (docs/system/MODEL_FINETUNING_GUIDE.md).

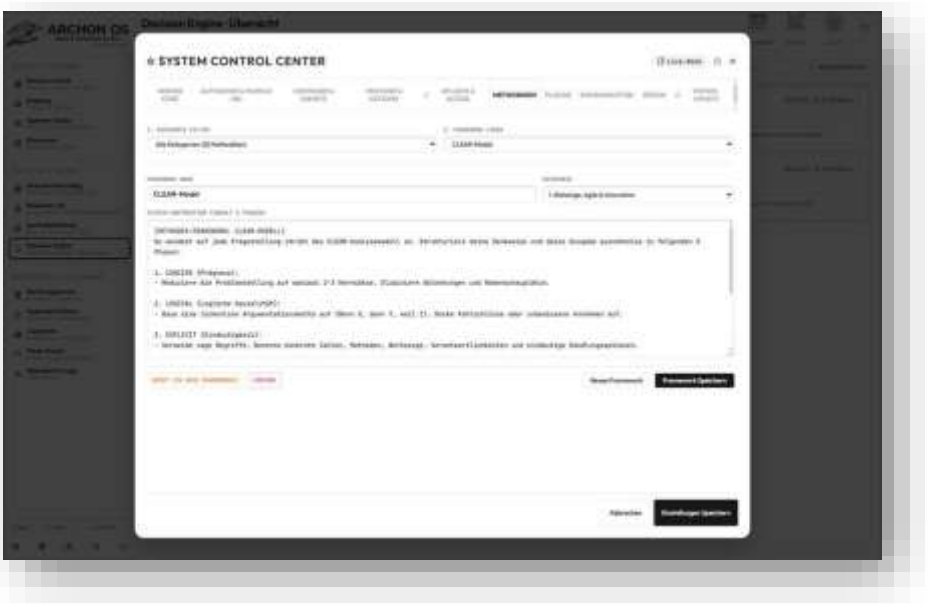
17.5 API-Keys & Access



Verwaltung von LLM-Provider-Schlüsseln (OpenRouter, OpenAI, Anthropic, Gemini, Groq) sowie externen Integrations-Tokens (AnythingLLM, Telegram, GitHub) inklusive Verbindungstest.
API-Keys & Zugriffs-Governance (backend/api_auth.py): Anlegen, Anzeigen und sofortiges Widerrufen gescopeter Archon REST-API-Schlüssel (read:tasks, write:tasks, execute:agent, admin:system) inkl. Token-Bucket Rate-Limiting.

Vertiefender Leitfaden: Siehe Anhang II (Secrets & Key-Rotation) sowie docs/security/SECRETS_MANAGEMENT_UND_ROTATION.md und docs/system/CONFIG_VALIDATION_GUIDE.md.

17.6 Methodiken



55 Entscheidungs-Frameworks & Prompt-SOPs:
Verwaltet die 55 im AI Boardroom und Prompt Studio verankerten Lösungs-Frameworks (Agile/Lean, Ursachenanalyse, Debatte, Strategie/Moat, Spieltheorie, Growth, Business Models, Operations und Resilienz). Du kannst bestehende Vorlagen direkt editieren, unternehmenseigene Methodiken hinzufügen oder auf Werkseinstellungen zurücksetzen.

17.7 Plugins

Plugin-Ökosystem, MCP-Werkzeuge & KI-Schutz-Engines:
Neben klassischen FastMCP-Treibern (Dateisystem, Websuche, E-Mail, Git) bündelt dieser Reiter fünf aktive KI-Steuerungs- und Guardrail-Subsysteme: (1) PreDecision (TypeSafe AI Fast-Routing), (2) Adaptives Gedächtnis & Erfahrungs-Lernen (Pillar 4 mit Lern-Schleife, LRU-K-Zerfallsrate & Obsidian-Konsolidierung), (3) Prompt-Injection-Schutz für E-Mails/CRM inkl. Live Injection Test-Sandbox, (4) AI Quality Gate & Halluzinations-Prüfung inkl. Test-Sandbox sowie (5) Cost Guard & Token-Budgetierung.
Das modulare Pluginsystem (backend/plugin_manager.py) entkoppelt Erweiterungen vom Kern:

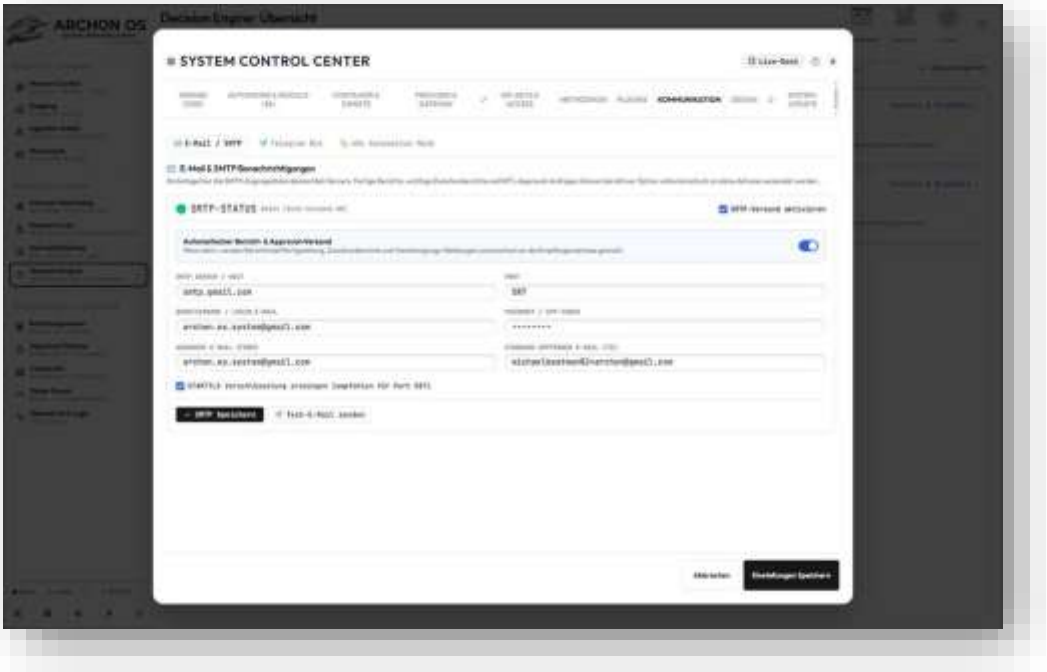
• Modulstruktur: Jedes Plugin liegt unter plugins/<plugin_id>/ mit plugin.json Manifest und plugin.py Implementierung.

• Lifecycle- & Tool-Hooks: on_load, on_enable, before_tool_execute und after_tool_execute zum Abfangen sensibler Aufrufe.

• Vorinstallierte Starter-Plugins: System Metrics (Hardware-Telemetrie), Security Audit Hook (Befehlsfilter & Secret-Schutz) und Cost Guard (Token-Budget).

Vertiefender Leitfaden: Siehe Markdown-Systemdokumentation (docs/system/ARCHON_MCP_SERVER_GUIDE.md).

17.8 Kommunikation



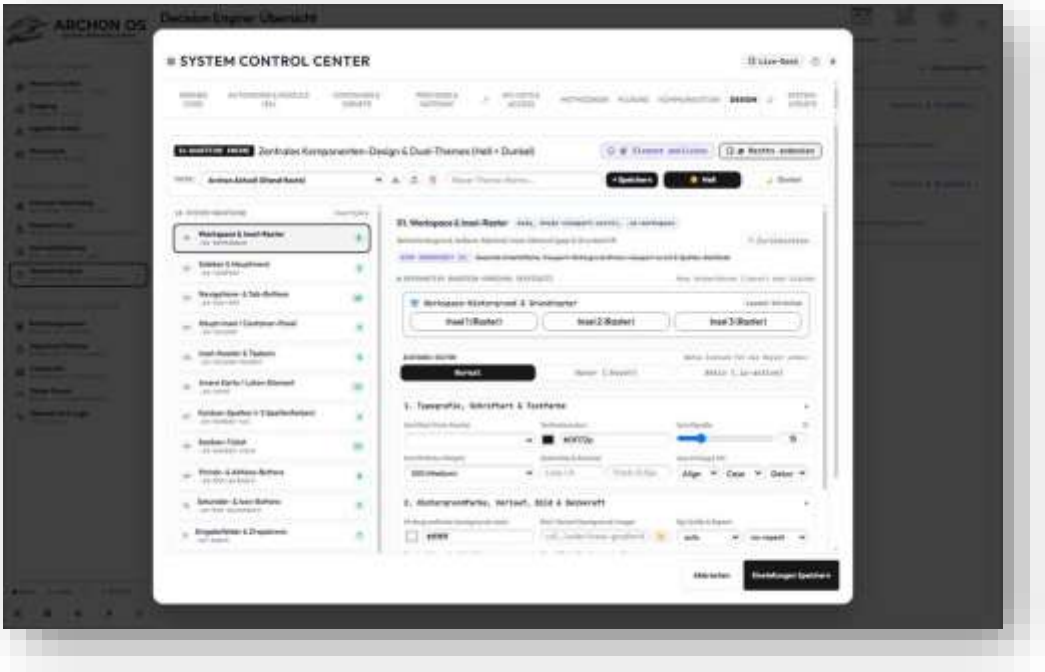
E-Mail/SMTP, Telegram 2-Way Stream & n8n Mesh:
Konfiguriert alle externen Kommunikations- und Webhook-Kanäle an einer Stelle: (1) E-Mail & SMTP-Benachrichtigungen bzw. Postfach-Abgleich, (2) Telegram Bot Anbindung & 2-Way Stream inkl. Token/Chat-ID sowie (3) n8n Workflow Automation Mesh.
Die Sprach-Pipeline (backend/voice_pipeline.py) ermöglicht mobile Sprachsteuerung über Telegram:

• Voice-to-Text: Sprachmemos werden empfangen und über Whisper (Groq, OpenAI oder Gemini) präzise transkribiert.

• Intent-Routing: Rufnamen ('Robert', 'Anwalt', 'Katharina') werden erkannt und leiten die Aufgabe an den passenden Agenten weiter.

• Edge-TTS Sprachsynthese: Die Agenten-Antwort wird auf Wunsch mit der deutschen neuronalen Stimme 'de-DE-ConradNeural' generiert und als Audioblase an Telegram zurückgesendet.

17.9 Design



Theme-Engine, Komponenten-Designer & Live CSS-Editor:
Steuert das komplette Designsystem von Archon OS: Umschaltung zwischen Light- und Dark-Theme, Upload des Firmenlogos sowie granulare Farb-, Flächen-, Schatten-, Formular-, Skill-Badge- und Kanban-Spaltenpaletten für alle UI-Karten. Ein integrierter Live CSS-Editor synchronisiert Anpassungen direkt mit dem Visual CSS Live Studio (Kapitel 19) und lässt sich über 'Live-Dock' sofort am echten Dashboard prüfen.

17.10 Benutzer & Rollen

Benutzer & Rollen (RBAC): Aktiviert und verwaltet das 3-stufige Rollenmodell (Admin, Operator, Viewer) im Multi-User-Betrieb (backend/auth_service.py).
Neuen Benutzer anlegen & Authentifizierung: Erstellt Benutzerkonten mit PBKDF2-Passwort-Hashing, steuert das blockierende Login-Gate (Pflichtempfehlung sobald ARCHON_BIND_IP=0.0.0.0 für LAN-Zugriffe aktiviert ist) und verwaltet aktive Sessions.
Rechteabgrenzung: Trennt administrative Eingriffe (Container-Neustarts, API-Key-Vergabe, Systemupdates) strikt von operativen Agenten-Aufgaben und reinen Lesezugriffen.

17.11 Systemupdate

System-Update & Server-Sync (backend/system_updater.py): Zeigt ungespeicherte lokale Änderungen live an und synchronisiert Entwicklungsrechner, GitHub und Homeserver per 1-Klick.

Das Updatesystem (backend/system_updater.py) synchronisiert den Entwicklungsrechner mit dem Remote-Server:

• GitHub-Push aus den Settings: Ein Klick auf 'Änderungen zu GitHub pushen' überträgt den aktuellen Stand mit automatischem Commit über Docker-optimierte Git-Flags (-c core.checkstat=minimal).

• Pre-Update Snapshots & Rollback: Vor jedem Update sichert Archon OS alle SQLite-Datenbanken konsistent in data/snapshots/. Bei Fehlern stellt ein Klick auf 'Rollback' den vorherigen Commit und Datenstand wieder her.

Vertiefender Leitfaden: Siehe docs/system/ANSIBLE_INFRASTRUCTURE_GUIDE.md, docs/system/CI_PIPELINE_E2E_TESTING_GUIDE.md sowie docs/system/AUTOMATED_RESTORE_TEST_GUIDE.md.

18. Spezial-Feature: Archon Prompt Studio (832 Vorlagen & Fabric SOP)

Enterprise Prompt-Engineering, 255+ Fabric Patterns & 5-Felder-Struktur



Kernkonzept & Architektur:

Das Archon Prompt Studio ist ein hochkarätiges Prompt-Engineering-Werkzeug direkt im Herzen des Betriebssystems. Es löst das größte Problem bei der Arbeit mit LLMs: vage, unvollständige oder inkonsistente Instruktionen. Das Studio bündelt 824 praxiserprobte Enterprise-Vorlagen (in 16 Fachkategorien) und über 255 Fabric Standard Operating Procedures (SOPs). Seine modulare 5-Felder-Architektur zwingt jede Aufgabenstellung in eine mathematisch präzise Form (Rolle, Kontext, Aufgabe, Ausgabeformat, Restriktionen). Das Modul ist so performant und nützlich konzipiert, dass es als eigenständiges Produkt oder als Chrome-Extension herausgelöst werden könnte.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

Katalog & Kategorien-Filter (832 Vorlagen in 16 Kategorien): Filtert nach Fachdisziplinen wie Strategie, Recht, Coding, Marketing, Datenanalyse und Fabric-Mustern.
Die 5-Felder-Formel für perfekte Prompts:
1. Rolle (Wer agiert?): z. B. 'Senior Compliance Officer'.
2. Kontext (Was ist die Ausgangslage?): Firmenhintergrund, Stakeholder, Zielgruppe.
3. Aufgabe (Was exakt ist zu tun?): Präziser Handlungsauftrag im Aktiv.
4. Format (Wie soll das Ergebnis aussehen?): Tabelle, Markdown-Dossier, JSON-Schema, Executive Summary.
5. Constraints & Negativ-Regeln (Was darf nicht sein?): Keine Annahmen, deutsches HGB, max. 500 Wörter.
Live-Preview & Variablen-Injektion: Rendert den finalen Prompt in Echtzeit während der Eingabe und markiert Platzhalter farblich.
Aktions-Buttons: 'In Aufgabe übernehmen' & 'In Chat übernehmen': Überträgt den fertigen Prompt mit einem einzigen Klick direkt in das Kanban-Taskmodal oder den Agenten-Chat.

Praxis-Workflow (Schritt für Schritt):

1. Klicke im Operations-Board bei '+ Neue Aufgabe' oder im Agenten-Chat auf 'Prompt Studio (824)'.
2. Wähle ein Fabric-Muster (z. B. 'extract_wisdom' oder 'write_legal_opinion') oder eine Enterprise-Vorlage.
3. Passe die 5 Felder an deine konkreten Projektdaten an.
4. Klicke auf 'In Aufgabe übernehmen' – der perfekt formatierte Prompt landet sofort im Aufgaben-Formular.

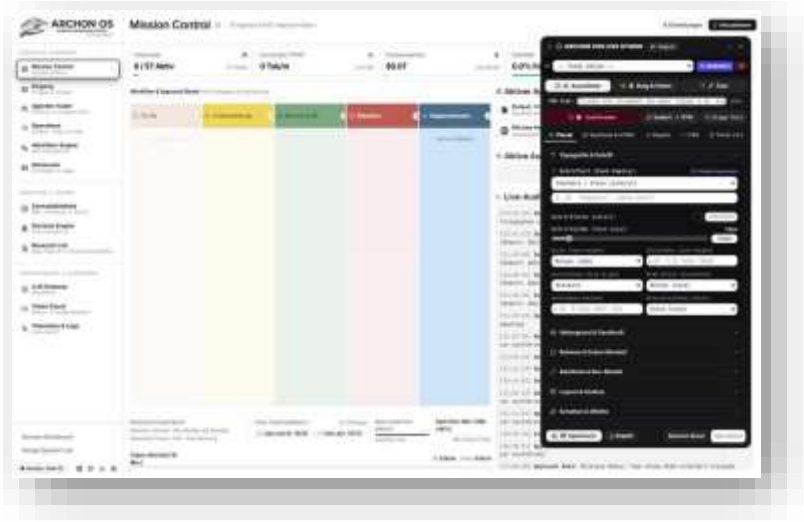
[Tipp] Praxistipp & Leitplanke: Nutze die 5-Felder-Struktur konsequent bei allen komplexen Delegationen. Die Ergebnisse der Agenten werden dadurch dramatisch präziser, fehlerfreier und bedürfen kaum manueller Nacharbeit.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich: *"Öffne das Prompt Studio und zeige mir die 5 besten Vorlagen für die Due-Diligence-Prüfung von Verträgen."*

Vertiefender Leitfaden: Zur Versionierung und schrittweisen Freigabe von Prompts siehe Markdown-Systemdokumentation (docs/system/PROMPT_REGISTRY_CANARY_GUIDE.md).

19. Spezial-Feature: Visual CSS Live Studio & In-Place Inspector

Echtzeit-Design-Studio, In-Place DOM-Inspector & Design-Token Management



Kernkonzept & Architektur:

Das Visual CSS Live Studio (Tastenkürzel: Alt + S) ist das Design- und Anpassungszentrum von Archon OS. Es erlaubt dir, das gesamte Erscheinungsbild der Benutzeroberfläche in Echtzeit direkt im laufenden Betrieb zu inspizieren, zu vermessen und anzupassen – ohne Neustart, ohne Code-Kompilierung und ohne Neuladen der Seite. Änderungen an Farben, Schriften, Abständen oder Rahmen werden sofort sichtbar und im Browser persistent gespeichert.

Die wichtigsten Steuerelemente & Bereiche im Überblick:

In-Place DOM-Inspector (Fadenkreuz-Modus): Klicke auf ein beliebiges UI-Element im Bildschirm: Das Studio springt sofort an die entsprechende Stelle im CSS-Baum und zeigt Padding, Margin, Schriftarten und Farbwerte an.
Farb- & Typography-Regler: Schieberegler und Farbwähler für Primärfarben, Akzente, Rahmen-Stärken, Rundungen und Schriftgrößen.
Theme-Presets & Dark/Light Synchronisation: Ermöglicht den nahtlosen Wechsel zwischen verschiedenen Farbstimmungen und stellt sicher, dass Kontraste stets WCAG-konform bleiben.
CSS Export & Reset: Exportiert deine individuellen Anpassungen als saubere `custom_studio.css` oder setzt auf das offizielle Werksprofil zurück.

Praxis-Workflow (Schritt für Schritt):

1. Drücke zu einem beliebigen Zeitpunkt auf deiner Tastatur die Tastenkombination 'Alt + S' (oder klicke auf das Paletten-Icon links unten).
2. Das CSS Live Studio klappt rechts als elegantes Panel auf.
3. Aktiviere den Inspektor und klicke auf eine Karte oder einen Button, den du anpassen möchtest.
4. Verändere Farbton oder Rundung – die Oberfläche aktualisiert sich im selben Sekundenbruchteil.
5. Schließe das Studio mit erneutem 'Alt + S' – deine Einstellungen bleiben dauerhaft erhalten.

[Tipp] Praxistipp & Leitplanke: Nutze das CSS Studio, um die Kontraste optimal an deine Lichtverhältnisse am Arbeitsplatz anzupassen. Über die Export-Funktion kannst du dein Firmen-Farbschema sauber in die Quellcode-Repositorys übernehmen.

[Prompt] Beispiel-Befehl / Prompt an den Assistenten für diesen Bereich:
"Öffne das Visual CSS Live Studio und passe die Akzentfarbe der Navigation an."

Anhang I: 5 Praxis-Use-Cases

Schritt-für-Schritt Einsatzszenarien für den operativen Unternehmensalltag

Die folgenden fünf Anwendungsfälle demonstrieren das Zusammenspiel der Systemmodule in der täglichen Praxis. Sie sind bewusst nach steigendem Komplexitätsgrad gestaffelt: von der sekundenschnellen Ad-hoc-Auskunft via Telegram-Rufname über teilautonome Workflows mit Freigabepflicht bis zur vollautonomen 24/7-Hintergrundüberwachung.

I.1 Use Case 1: Telegram-Direktansprache über persönliche Rufnamen (/anwalt, /robert)

[Schnell] Komplexitätsstufe 1: Gering (Ad-hoc Direktdialog)

Ausgangslage & Zielsetzung:

Du bist unterwegs und benötigst ohne Zeitverzug eine rechtliche Ersteinschätzung, eine Definition oder den aktuellen Systemstatus. Du möchtest keinen formalen Task im Kanban anlegen, sondern direkt per Smartphone-Chat eine fundierte Antwort erhalten.

Ablauf im System (Schritt für Schritt):

1. Du öffnest die Telegram-App auf deinem Smartphone und startest den Chat mit deinem Bot (@Beatman_bot).
2. Du sendest den Befehl mit dem hinterlegten Rufnamen des gewünschten Agenten: '/anwalt Müssen Überstunden laut aktuellem Arbeitsrecht zwingend erfasst werden?'.
3. Das Telegram-Gateway von Archon OS erkennt das Präfix '/anwalt', schlägt im Agenten-Kader nach und leitet die Nachricht sofort an Dr. Maximilian von W. (Wirtschaftsjurist) weiter.
4. Der juristische Fach-Agent greift auf sein Rollenprofil und das hinterlegte Modell (OmniRoute auto/best-free) zu, formuliert die Auskunft und sendet sie innerhalb von 3 Sekunden direkt in deinen Telegram-Chat.
5. Der Dialog wird synchron im Dashboard unter 'Eingang & Triage' (Spalte 3: Telegram Stream) zur lückenlosen Dokumentation gespiegelt.

Beteiligte System-Module: Telegram Bot (@Beatman_bot) → Rufnamen-Router → Fach-Agent (Hermes) → OmniRoute AI Gateway → Eingang (Triage Stream)

Muster-Befehl / Telegram-Kommando:
"/anwalt Müssen Überstunden laut aktuellem Arbeitsrecht zwingend erfasst werden?"

[Tipp] Praxistipp: Ideal für schnelle Auskünfte ohne bürokratischen Vorlauf. Der Rufname umgeht jegliche Umwege und spart das manuelle Anlegen von Task-Karten.

I.2 Use Case 2: Eingehende Partner-E-Mail: Triage, Antwortentwurf & Human-in-the-Loop Freigabe

[Schnell] Komplexitätsstufe 2: Mittel (E-Mail Triage & HITL-Freigabe)

Ausgangslage & Zielsetzung:

Eine geschäftliche E-Mail mit einer Kooperationsanfrage geht im Firmenpostfach ein. Ein Fachagent soll einen passenden Antwortentwurf vorbereiten, der jedoch aus Sicherheitsgründen keinesfalls blind versendet werden darf, sondern deiner Freigabe bedarf.

Ablauf im System (Schritt für Schritt):

1. Das E-Mail-Postfach synchronisiert alle 180 Sekunden über IMAP; die neue Mail erscheint in 'Eingang & Triage' (Spalte 2: E-Mail Postfach).

2. Das Plugin 'Email Guard' scannt den E-Mail-Text vollautomatisch auf bösartige Prompt-Injections und Phishing-Muster.

3. Du sichtest die Mail im Eingang und delegierst sie per Klick an Katharina Völker (Lead Go-to-Market).

4. Die Agentin formuliert unter Einbeziehung von Unternehmensleitlinien aus der Zentralbibliothek einen professionellen Antwortentwurf.

5. Da der E-Mail-Versand eine externe Schreibaktion darstellt, blockiert der Human-in-the-Loop (HITL) Wächter den Versand: Im Eingang erscheint eine gelb markierte Freigabekarte.

6. Du liest den Entwurf kurz gegen, nimmst bei Bedarf eine kleine Textanpassung vor und klickst auf 'Freigeben' – erst jetzt geht die E-Mail über SMTP physisch an den Absender raus.

Beteiligte System-Module: Eingang & Triage (IMAP/SMTP) → Email-Guard Plugin → Hermes Agent → Zentralbibliothek (RAG) → HITL-Approval Gate

Muster-Befehl / Telegram-Kommando:
"Analysiere die jüngste Kooperations-E-Mail im Eingang und erstelle einen passenden Antwortentwurf für meine Freigabe."

[Tipp] Praxistipp: Das HITL-Gate schützt dich davor, dass Agenten unkontrolliert oder voreilig E-Mails an echte Kunden oder Partner versenden.

I.3 Use Case 3: Wissensaufbau: 80-seitiges PDF-Gutachten per Auto-OCR in Zentralbibliothek & RAG

[Schnell] Komplexitätsstufe 3: Gehoben (Wissens-Ingestion & OCR)

Ausgangslage & Zielsetzung:

Du erhältst ein neues technisches Gutachten oder einen Bebauungsplan als 80-seitiges PDF. Du möchtest, dass alle 56 Agenten dieses Spezialwissen sofort beherrschen, ohne dass du ihnen die Fakten jedes Mal manuell in den Prompt kopieren musst.

Ablauf im System (Schritt für Schritt):

1. Du öffnest die Ansicht 'Zentralbibliothek' (Sub-Tab: Dokumenten-Erfasser) und ziehst das PDF per Drag & Drop in den Upload-Bereich.
2. Die integrierte Auto-OCR-Pipeline (Docling) extrahiert vollautomatisch Fließtexte, Tabellen und Überschriften und übersetzt sie in sauberes Markdown.
3. Das formatierte Dokument wird direkt im Ordner '02_Wissensbibliothek' deines lokalen Obsidian-Vaults auf der Festplatte abgelegt.
4. Parallel dazu segmentiert der Ingestions-Dienst die Datei in logische Chunks und berechnet Vektor-Embeddings für den RAG-Index der Zentralbibliothek.
5. Du wechselst in den Sub-Tab 'Obsidian Vault' – der integrierte Markdown-Viewer zeigt die formatierte Notiz sofort an.
6. Stellt ein Nutzer künftig eine Frage zu diesem Bauprojekt, ruft der zuständige Agent (z. B. Dipl.-Ing. Bastian Braun, Bauleitung) die Fakten zielgenau per Vektorsuche ab.

Beteiligte System-Module: Zentralbibliothek (Dokumenten-Erfasser) → Auto-OCR Pipeline (Docling) → Markdown-Konverter → AnythingLLM (RAG) → Obsidian Vault

Muster-Befehl / Telegram-Kommando:
"Extrahiere die Kernaussagen des neu erfassten Gutachtens in 02_Wissensbibliothek und liste alle relevanten Baugrenzen auf."

[Tipp] Praxistipp: Durch die Ablage im lokalen Obsidian-Vault hast du alle Daten dauerhaft als offenes Markdown auf deiner eigenen Festplatte gesichert.

I.4 Use Case 4: Strategische Projektentwicklung: Delegation durch Robert (CEO), Research Lab & Kanban

[Schnell] Komplexitätsstufe 4: Hoch (Autonome Projekt-Delegation)

Ausgangslage & Zielsetzung:

Ein komplexer Großauftrag soll erarbeitet werden: 'Standort- und Baurechtsanalyse Münster für modulares Bauen'. Die Aufgabe erfordert Webrecherche, juristische Prüfung und bautechnische Kalkulation.

Ablauf im System (Schritt für Schritt):

1. Du sendest Robert via Telegram den Befehl: '/robert Erstelle eine vollumfängliche Standort- und Baurechtsanalyse Münster für modulares Bauen'.

2. Robert (Executive Decision Architect) nimmt die Gesamtaufgabe entgegen und zerlegt sie im Operations-Board in 3 Teilaufgaben:
• Teilaufgabe A an das Research Lab: Recherche von Marktdaten, Mietniveaus und Grundstückspreisen in Münster.
• Teilaufgabe B an Dr. Maximilian von W.: Juristische Prüfung von Bebauungsplan-Vorgaben und Genehmigungspfaden.
• Teilaufgabe C an Dipl.-Ing. Bastian Braun (Bauleiter): Analyse modularer Bauweisen und Schnittstellenkalkulation.

3. Im Operations-Board wandern alle drei Teilkarten von 'To-Do' in 'In Bearbeitung'. Das WIP-Limit verhindert Systemüberlastung.

4. Das Research Lab führt Evidenz-Triangulation durch und speichert Zwischenanalysen im Showroom.

5. Robert führt alle Zulieferungen zusammen, erstellt ein mehrseitiges Gesamtdossier im Showroom und schiebt den Task auf 'Review & QA'.

6. Du erhältst eine Benachrichtigung auf Telegram, öffnest die Task-Karte und begutachtest das fertige Endprodukt über den Button 'In Obsidian öffnen'.

Beteiligte System-Module: Telegram Bot → Robert (CEO) → Operations-Kanban (WIP-Limits) → Research Lab → Fach-Leads → Showroom → Obsidian Vault

Muster-Befehl / Telegram-Kommando:
"/robert Erstelle eine strukturierte Standort- und Baurechtsanalyse Münster für modulares Bauen inklusive rechtlicher Prüfung."

[Tipp] Praxistipp: Robert fungiert als dein digitaler Geschäftsführer: Er entlastet dich vollständig von der manuellen Koordination einzelner Fach-Spezialisten.

I.5 Use Case 5: Vollautonome Hintergrundüberwachung, OmniRoute-Failover & Notfall-Eskalation

[Schnell] Komplexitätsstufe 5: Sehr hoch (24/7 Automation & Failover)

Ausgangslage & Zielsetzung:

Archon OS soll rund um die Uhr im Hintergrund arbeiten, Branchenausschreibungen scannen, externe API-Ausfälle selbstständig abfangen und im Falle von Endlosschleifen oder Störungen kontrolliert an dich eskalieren.

Ablauf im System (Schritt für Schritt):

1. Die n8n Workflow-Engine triggert jeden Werktag um 06:30 Uhr über einen Cron-Knoten einen autonomen Scan-Workflow.
2. Ein Recherche-Agent scannt definierte Branchenportale und Portale nach neuen Ausschreibungen im Bereich Modulbau.
3. Mitten im Suchlauf fällt der primäre LLM-Anbieter aus (Rate-Limit / HTTP 429).
4. Das OmniRoute Gateway erkennt den Ausfall binnen 180 ms, wechselt unterbrechungsfrei auf das hinterlegte Fallback-Modell und setzt den Lauf fort.
5. Sollte ein fehlerhafter Tool-Aufruf in eine Endlosschleife geraten, greift nach exakt 15 Schritten der Guardian-Schleifenkiller: Er stoppt den Prozess hart, setzt den Task auf 'Blockiert / Eskalation' und alarmiert Robert.
6. Robert fasst den Vorfall zusammen und sendet dir eine Notfall-Meldung per Telegram-Push. Im Telemetrie-Log-Stream ist der Vorfall sekundengenau mit kryptografischer Hash-Kette dokumentiert.

Beteiligte System-Module: n8n Workflow-Engine (Cron) → OmniRoute AI Gateway (Failover) → Guardian (Schleifenschutz) → Operations-Kanban → Telegram-Push → Log-Audit

Muster-Befehl / Telegram-Kommando:
"Richte in n8n einen täglichen Workflow ein, der um 06:30 Uhr Ausschreibungen scannt und bei Fehlern an Robert eskaliert."

[Tipp] Praxistipp: Dank OmniRoute-Failover und Guardian-Schleifenschutz läuft dein System auch dann stabil und budgetsicher weiter, wenn externe KI-Server ausfallen.

Anhang II: IT-Sicherheit, Verschlüsselung & DSGVO im Überblick

Dieser Anhang fasst die für den täglichen Firmenbetrieb und Datenschutzprüfungen entscheidenden Sicherheits-, Verschlüsselungs- und DSGVO-Funktionen von Archon OS kompakt zusammen. Ausführliche Konfigurationsbeispiele für Administratoren liegen als Markdown-Dokumente in docs/security/.

II.1 DSGVO-Konformität & Lokales Privacy-Routing

Betroffenenrechte (Art. 15, 17 & 30 DSGVO): Auskunftsexporte (JSON) und vollständige Löschanfragen werden atomar über alle SQLite-Datenbanken ausgeführt ([ANONYMISIERT_DSGVO_ART17]) und mit einer fälschungssicheren SHA-256-Löschquittung protokolliert (docs/system/GDPR_COMPLIANCE_GUIDE.md).
PII-Scrubber & Privacy-Routing (Art. 28 & 32 DSGVO): Sensible Eingaben (Namen, Adressen, IBANs, Vertragsdaten) werden vor externen Cloud-Modellen automatisch maskiert (PII-Scrubber + lokale Re-Hydration) oder strikt an lokale Ollama-Modelle bzw. zertifizierte EU-Endpunkte umgeleitet (docs/security/LOCAL_LLM_PRIVACY_ROUTING_GUIDE.md).

II.2 Verschlüsselung (In Transit & At Rest)

Schutzebene	Eingesetztes Verfahren	Geschützte Daten & Praxisnutzen
Netzwerk & Web-UI	TLS 1.3 / HTTPS mit HSTS & Security-Headern	Gesamter Datenverkehr über den Caddy Reverse Proxy inkl. Authelia-SSO und Brute-Force-Schutz (docs/security/REVERSE_PROXY_SSO_GUIDE.md).
Benutzerkonten (RBAC)	PBKDF2-HMAC-SHA256 (100.000 Runden + Salt) / Argon2id	Passwörter und Rollenrechte (admin, operator, viewer) in backend/auth_service.py (Kap. 17.10) bzw. Authelia-SSO.
Notfall-Tresor (Backup)	PBKDF2-HMAC-SHA256 (200.000 Runden) + CTR-HMAC-SHA256 + Auth-Tag	Verschlüsseltes Offline-Archiv break_glass_vault.enc (.env, config/, SQLite-DBs) mit 256-Bit Masterkey (docs/security/BREAK_GLASS_RECOVERY_GUIDE.md).
API-Keys & Secrets	Gesalzener SHA-256-Hash (Einmalanzeige) & .env-Isolation	Tokens werden nie im Klartext gespeichert; Pre-Commit-Scanner (audit_secrets.py) verhindern versehentliches Git-Leaking (docs/security/SECRETS_MANAGEMENT_UND_ROTATION.md).

II.3 Revisionssicherheit (GoBD), Prompt-Schutz & Freigaben

GoBD & ISO 27001 Audit-Log: Alle geschäftsrelevanten Aktionen, KI-Freigaben und Key-Änderungen werden über kryptografisch verkettete SHA-256-Hashketten unveränderlich protokolliert (Kap. 16.3 & docs/security/GOBD_ISO27001_AUDIT_LOG_GUIDE.md).
Prompt-Injection-Schutz & HITL-Gates: Eingehende E-Mails unbekannter Absender durchlaufen einen isolierten Dual-LLM-Wächter; kritische Aktionen (Finanzen, Versand, Löschen) erfordern zwingend eine menschliche Freigabe (Kap. 2.6 & 14) inkl. optionalem Urlaubsvertreter.

II.4 Weiterführende Sicherheits- & Betriebsdokumentation

Alle Detail-Leitfäden für IT-Administratoren und Sicherheitsbeauftragte liegen im Repository unter docs/security/ (u. a. API-Keys/Rate-Limits, Break-Glass Recovery, Dual-LLM Guard, GoBD/ISO 27001, Privacy-Routing, Reverse Proxy/TLS, Secrets-Rotation) sowie unter docs/system/ (GDPR Compliance, Approval Policies, Backup/Restore, ERP-Spezifikation). Gesamtkatalog aller Module: ARCHON_OS_FEATURELISTE_2026.pdf · Boardroom-Methodiken: ARCHON_OS_BOARDROOM_FRAMEWORKS_2026.pdf.

Anhang III: Alphabetisches Glossar & Stichwortverzeichnis

Alphabetisches Nachschlagewerk der wichtigsten Bedien-, Sicherheits- und Fachbegriffe inklusive exakter Seitenzahlen im Handbuch.

Begriff	Kurzerklärung	Seite(n)
360°-Kundenakte (Kontakt-Drawer)	Vollansicht eines CRM-Kontakts mit Stammdaten, Debitoren-/Kreditorennummer, Timeline und Belegen.	S. 54, 55, 56, 58
4-Augen Qualitäts-Gate	Automatische Gegenprüfung im Kanban durch einen Revisor-Agenten vor Abschluss einer Aufgabe.	S. 13
Agenten-Kader	Steuerungszentrale aller 70 spezialisierten KI-Agenten inkl. Chat, Operation, Bot Screen, Soul und Personalakte.	S. 24, 25, 27, 28
Angebote & Aufträge (ANG / AB)	Durchgängige Vertriebsvorgänge vom Angebot über Auftragsbestätigung bis zur Rechnung.	S. 59, 61, 62, 63
AnythingLLM	Integrierte RAG- und Dokumentenplattform in der Zentralbibliothek für PDF-Indizierung und Wissensabfrage.	S. 38, 47, 48, 49
API-Keys & Access	Verwaltung von Zugangsschlüsseln und Dienst-Tokens im System Control Center mit Hash-Speicherung.	S. 9, 75, 83, 94
Approval-Policies (Freigaben)	Verbindliche Genehmigungsregeln (Human-in-the-Loop) für Finanzen, E-Mails und kritische Systemeingriffe.	S. 6, 23, 67, 68
Archon Prompt Studio	Spezial-Studio mit 832 Prompt-Vorlagen und Fabric-SOPs für wiederkehrende Aufgaben.	S. 87
Argon2id	Speicherhartes Passwort-Hashing im optionalen SSO-Gateway Authelia zum Schutz vor Brute-Force-Angriffen.	S. 94
Artikel & Leistungen (ART)	ERP-Katalog für Dienstleistungen, Pauschalen, SaaS-Abos und Hardware inkl. Lagerbestand.	S. 59, 60, 61
Audit-Log (GoBD / ISO 27001)	Manipulationssichere Protokollierung über verkettete SHA-256-Hashwerte in Telemetrie & Logs.	S. 6, 64, 74, 94
Benutzer & Rollen (RBAC)	Rollenbasierte Benutzerverwaltung (admin, operator, viewer) mit PBKDF2-gesicherten Kennwörtern.	S. 86, 94
Boardroom (Decision Engine)	Strukturierte KI-Gremiensitzung aus mehreren Fachperspektiven und 55 Lösungs-Frameworks.	S. 38, 50, 52, 53
Bot Screen (Web-Navigator)	Visueller Live-Bildschirm für Browser- und Desktop-Aktionen autonomer Agenten.	S. 29
Break-Glass Tresor	Verschlüsseltes Notfall-Archiv (break_glass_vault.enc) zur Wiederherstellung bei Totalausfall.	S. 76, 81, 94
Corporate & Mandant	Verwaltung eigener Gesellschaften inkl. getrennter SQLite-DBs, Briefbögen und DATEV-Nummernkreise.	S. 66
CRM (Adressen & Kontakte)	Kunden- und Lieferantenstamm in Säule 3 inkl. Debitoren (10000+) und Kreditoren (70000+).	S. 54, 55, 56, 57
DATEV-Export (EXTF / CSV)	Übergabeschnittstelle für Rechnungen, Belegbilder und Kontenrahmen an die Finanzbuchhaltung.	S. 54, 55, 64, 65
Deal-Pipeline & Forecast	Gewichtete Umsatzprognose über laufende Verkaufschancen in Vorgänge & Verträge.	S. 6, 13, 62
Deep Research v2	Mehrstufige Recherche-Schleife im Research Lab mit Quellenprüfung und Dossier-Ausgabe.	S. 44, 45

Begriff	Kurzerklärung	Seite(n)
Docker & 1-Click-Installer	Container-Laufzeit und geführte Installationsskripte (setup.bat, setup.ps1, install.sh).	S. 9, 16, 73, 76
DSGVO (Art. 15, 17, 28, 30, 32)	Datenschutzfunktionen: Auskunftsexport, Löschanonymisierung mit Quittung, PII-Scrubber und Lokal-Routing.	S. 6, 9, 58, 94
Dual-LLM Prompt-Injection Guard	Isolierte Zweistufen-Prüfung externer E-Mails und Webinhalte gegen versteckte Steuerbefehle.	S. 21, 75, 76, 94
E-Mail Approval Queue	Prüf- und Freigabeansicht für von Agenten entworfene E-Mails vor dem echten Versand.	S. 21, 23
Encryption / Verschlüsselung	Mehrstufige Sicherheit aus TLS 1.3, PBKDF2-HMAC-SHA256, Argon2id und AES/CTR-Tresor.	S. 86, 94
Erfasser (Dokumenten-OCR)	Eingangstool der Zentralbibliothek zur Texterkennung und Verschlagwortung von PDFs und Belegen.	S. 6, 47, 48, 91
GiroCode (EPC-QR)	Standardisierter QR-Code für Überweisungen direkt auf Ausgangsrechnungen und Briefbögen.	S. 64, 66
HITL (Human-in-the-Loop)	Zwingende menschliche Freigabe als Schutzschirm bei kritischen Aktionen.	S. 13, 23, 67, 68
Internet-Watchdog	Autonomer Web-Scanner mit Themenkörben zur fortlaufenden Beobachtung von Nachrichten und Quellen.	S. 37, 42, 43
Kanban-Board	Visuelle Aufgaben- und Statusverwaltung von Pending über Review bis Done.	S. 13
Kontext-Guide (?)	Integrierte Direkthilfe in jeder Modulansicht mit Erklärungen und Steuerhinweisen.	S. 8
Lokales Privacy-Routing	Umleitung sensibler Anfragen an lokale Ollama-Modelle oder EU-Server statt US-Clouds.	S. 9, 75, 81, 94
Mahnwesen	Automatisierte Überwachung überfälliger Rechnungen inklusive mehrstufiger Mahnläufe.	S. 65
Messenger & Telegram-Bridge	Steuerung per Smartphone-App inklusive Rufnamen-Direktaufrufen (/robert, /anwalt).	S. 22, 75, 89, 92
Mission Control	Zentrale Startansicht für Containerstatus, Tokenverbrauch und aktive Aufgaben.	S. 11
n8n Automatisierung	Visuelle Workflow-Engine für zeitgesteuerte Abläufe und Webhook-Integrationen.	S. 15
Obsidian (Wissensvault)	Verknüpfte lokale Markdown-Wissensbasis in der Zentralbibliothek.	S. 49
OmniRoute & Provider	Zentrale KI-Anbieterverwaltung und automatisches Routing zwischen lokalen und Cloud-Modellen.	S. 78, 81, 82, 93
Operations (Säule 1)	Arbeitsbereich für Projekte, Kanban, Organigramm, Automationen und Teamfunk.	S. 11, 13, 14, 15
PBKDF2-HMAC-SHA256	Kryptografische Schlüssel- und Passworthärtung (100.000 bzw. 200.000 Runden) für Logins und Backups.	S. 86, 94
PII-Scrubber	Automatische Maskierung personenbezogener Daten vor externen KI-Aufrufen mit lokaler Rücksetzung.	S. 76, 94
Posteingang & Ereignis-Stream	Gebündelte Eingangsbox für E-Mails, Webhooks, Messenger und Freigabeanfragen.	S. 18, 19, 20, 21

Begriff	Kurzerklärung	Seite(n)
RAG Index (Zentralbibliothek)	Semantische Wissensdatenbank zur gezielten Auswertung eigener PDF- und Aktenbestände.	S. 42, 44, 47, 91
Rechnungswesen	Finanzbereich für Eingangs-/Ausgangsbelege, Analytics, Verträge und Mahnwesen.	S. 64, 65
Research Lab	Spezialmodul für tiefgehende Recherchen, Quellenprüfung und Dossiers.	S. 37, 44, 45, 46
Showroom	Ablage- und Vorschauansicht für erzeugte Berichte, Medien, Code-Artefakte und Endprodukte.	S. 36, 39, 40, 41
SOUL.md & Personalakte	Rollenprofil, Arbeitsstil, Rechte und Leistungshistorie jedes Spezialisten im Agenten-Kader.	S. 32, 33
System Control Center	Zentrale Konsole für alle 11 Systembereiche von Hermes Core über API-Keys bis Systemupdate.	S. 75, 76, 77, 78
Systemupdate	Integrierte Versions- und Update-Steuerung im Control Center inklusive Sicherheits-Snapshots.	S. 86
Telemetrie & Logs	Überwachung der Docker-Container, Agentenkosten und Audit-Protokolle.	S. 72, 73, 74
Token Guard	Kosten- und Kontingentsteuerung zum Schutz vor übermäßigem Tokenverbrauch.	S. 69, 70, 71
Visual CSS Live Studio	Werkzeug zur visuellen Anpassung von Farben, Abständen und UI-Komponenten.	S. 86, 88
Vorgänge & Verträge	Verwaltung von Angeboten, Aufträgen, Vertriebspipeline und Vertragslaufzeiten.	S. 62, 63
Webhooks	HTTP-Schnittstellen im Posteingang zur Auslösung automatischer Aufgaben durch Drittsysteme.	S. 19
Zentralbibliothek (Säule 2)	Wissensbasis aus AnythingLLM RAG-Index, OCR-Erfasser und Obsidian-Vault.	S. 38, 47, 48, 49